# Tópicos de Estudo em Filogenômica e Bioinformática de Metazoários (Rascunho em Desenvolvimento)

Denis Jacob Machado

Laboratório de Filoinformática (https://phyloinformatics.com), e
Departamento de Bioinformática e Genômica · Colégio de Computação e Informática, e
Centro de Computação Inteligente para Prevenção de Ricos para Saúde e Meio Ambiente (CIPHER).
**Universidade da Carolina do Norte em Charlotte, Charlotte, Carolina do Norte, E.U.A.**
ORCiD: 0000-0001-9858-4515.

2026

© 2026 Denis Jacob Machado.

Este trabalho está licenciado sob a licença Creative Commons Atribuição-NãoComercial 4.0 Internacional (CC-BY-NC 4.0).

https://creativecommons.org/licenses/by-nc/4.0/deed.pt_BR

# Sumário

**Prefácio** **xiii**

**1 Fundamentos Teórico-Filosóficos da Filogenética** **1**

1.1 Introdução . . . 1
1.2 A Estrutura das Árvores Filogenéticas . . . 2
1.2.1 Árvores, Cladogramas e Topologias . . . 2
1.2.2 Componentes Elementares: Nós, Ramos, Terminais e Raiz . . . 2
1.2.3 Grupos-Irmãos, Splits e Consenso Estrito . . . 2
1.2.4 Formatos de Arquivo para Árvores Filogenéticas . . . 3
1.3 Táxons, Clados e Classificação Filogenética . . . 3
1.3.1 Grupos Monofiléticos, Parafiléticos e Poliféticos . . . 3
1.4 O Conceito de Caráter . . . 3
1.4.1 A Natureza Histórica do Caráter . . . 3
1.4.2 Tipos de Caráter . . . 4
1.4.3 Caracteres Fenotípicos e Genotípicos . . . 4
1.5 Homologia: Definição, Epistemologia e Debate . . . 5
1.5.1 A Definição Operacional e a Homologia como Hipótese Nula . . . 5
1.5.2 O Debate Homologia–Sinapomorfia . . . 5
1.5.3 O Debate Homologia Primária–Secundária . . . 5
1.5.4 Homologia Estática e Dinâmica . . . 5
1.5.5 Tipos de Transformações . . . 6
1.6 Homoplasia: Definição, Medição e Interpretação . . . 6
1.6.1 Definição e Estatuto Epistemológico . . . 6
1.6.2 Medição da Homoplasia . . . 7
1.6.3 InDels e Homoplasia . . . 7
1.7 Comparação com Grupo Externo, Polaridade e Enraizamento . . . 7
1.7.1 Grupo Externo, Grupo Interno e a Identidade dos Três Problemas . . . 7
1.7.2 Enraizamento de Lundberg . . . 7
1.7.3 Expansão Sucessiva do Grupo Externo . . . 8
1.7.4 Análise Simultânea e Evidência Total . . . 8
1.8 Homologia Dinâmica, InDels e Sequenciamento de Alto Rendimento . . . 8
1.8.1 O Problema dos InDels em Alinhamento Estático . . . 8
1.8.2 Algoritmos de Otimização de Sequências sob Homologia Dinâmica . . . 9
1.8.3 Verossimilhança sob Homologia Dinâmica . . . 9
1.8.4 Computação Paralela . . . 9

1.9 Redes Filogenéticas . . . 10
1.10 Critérios de Otimalidade . . . 10
1.10.1 Visão Geral e Incomensurabilidade . . . 10
1.10.2 Parcimônia . . . 10
1.10.3 Máxima Verossimilhança . . . 11
1.10.4 Inferência Bayesiana . . . 11
1.10.5 Comprimento Mínimo de Descrição Filogenética (PMDL) . . . 11
1.11 Ponderação de Caracteres . . . 11
1.11.1 Ponderação Implicada . . . 11
1.11.2 Ponderação por Aproximações Sucessivas . . . 12
1.12 Suporte de Clados . . . 12
1.12.1 Suporte de Bremer . . . 12
1.12.2 Jackknife . . . 12
1.12.3 Bootstrap . . . 12
1.13 Análise de Sensibilidade e Métricas de Comparação Topológica . . . 12
1.13.1 Análise de Sensibilidade . . . 12
1.13.2 Distância de Robinson-Foulds . . . 13
1.13.3 Distância de *Match Split* . . . 13
1.14 Perspectivas e Debates em Aberto . . . 13
1.14.1 Homologia Estática versus Dinâmica . . . 13
1.14.2 Tratamento de InDels . . . 13
1.14.3 Incomensurabilidade entre Critérios de Otimalidade . . . 14
1.14.4 Árvores de Genes, Árvore de Espécies e Transferência Horizontal . . . 14
1.14.5 Sistemática Ponto-e-Clique . . . 14
1.15 Conclusão . . . 14

**2 Métodos de Inferência Probabilística para Reconstrução Filogenômica 21**
2.1 Introdução . . . 21
2.2 Fundamentos Teóricos da Probabilidade em Filogenética . . . 21
2.2.1 A Função de Verossimilhança . . . 21
2.2.2 O Modelo Markov Geral . . . 22
2.3 Classificação de Métodos de Verossimilhança Máxima . . . 22
2.3.1 O Conceito de Parâmetros de Incômodo . . . 22
2.3.2 Máxima Verossimilhança Integrada (MVI) . . . 23
2.3.3 Máxima A Posteriori (MAP) . . . 23
2.3.4 Máxima Verossimilhança Relativa (MVR) e Suas Três Variantes . . . 24
2.3.5 O Paradoxo: Felsenstein vs. Farris . . . 24
2.3.6 Conexões Adicionais: Goldman (1990) e Tuffley & Steel (1997) . . . 25
2.4 A Perspectiva Bayesiana . . . 25
2.4.1 Teorema de Bayes e Inferência Posterior . . . 25
2.4.2 Convergência Bayesiana e o Teorema de Bernstein-von Mises . . . 27
2.4.3 Topologias Discretas e Espaço BHV . . . 27
2.5 Especificação Incorreta de Modelo . . . 28
2.5.1 Convergência para a Melhor Resposta Errada . . . 28

2.5.2 Consequência Topológica . . . 29
2.6 Dados Finitos e *a priori* Inescapável . . . 30
2.6.1 Influência Persistente da Priori . . . 31
2.7 Práticas Responsáveis para Trabalhar com Prioris e Modelos . . . 32
2.7.1 Análise de Sensibilidade . . . 32
2.7.2 Teste de Adequação de Modelo . . . 32
2.7.3 Relatório Honesto de Incerteza . . . 33
2.8 Parcimônia Reconsiderada: Premissas para um Critério Alternativo . . . 33
2.8.1 Premissas . . . 34
2.8.2 Vantagens Práticas da Parcimônia . . . 34
2.9 Conclusão . . . 34

**3 Modelos de Substituição na Reconstrução Filogenética 39**
3.1 Introdução . . . 39
3.2 Princípios Teóricos . . . 39
3.2.1 A Função de Verossimilhança em Sistemática . . . 39
3.2.2 O Modelo Markov Geral Reversível . . . 40
3.2.3 Modelos Nomeados como Casos Especiais . . . 40
3.3 Variação de Taxa Entre Sítios . . . 41
3.3.1 Sítios Invariáveis . . . 41
3.3.2 Heterogeneidade de Taxas e a Distribuição Gamma Discreta . . . 41
3.4 Expansão para Cinco Estados: Modelos com Indels . . . 42
3.4.1 Modelo de Jukes-Cantor de Cinco Estados . . . 42
3.4.2 Modelos de Nascimento-Morte . . . 42
3.5 Formas de Verossimilhança e Suas Relações . . . 42
3.6 Modelagem Proteica e Restrições Estruturais . . . 43
3.6.1 Matrizes de Substituição de Aminoácidos . . . 43
3.6.2 Modelos de Mistura e Evolução Dependente de Sítio . . . 43
3.6.3 Modelos Avançados Estruturalmente Restritos . . . 44
3.7 Seleção de Modelo . . . 44
3.7.1 Critérios Clássicos de Seleção de Modelo . . . 44
3.7.2 Impacto da Seleção de Modelo . . . 45
3.8 Implementação Computacional . . . 45
3.8.1 Computando Verossimilhança de Árvore: O Algoritmo de Poda de Felsenstein 45
3.8.2 Cadeia de Markov Monte Carlo para Inferência Bayesiana . . . 45
3.9 Limites de Interpretação de Resultados . . . 46
3.9.1 Inconsistência Estatística de Parcimônia: A Zona de Felsenstein . . . 46
3.9.2 Viés Anterior de Clado e Probabilidades Posteriores de Clado . . . 46
3.10 Avanços Recentes . . . 47
3.10.1 Modelos Ocultos de Markov para Análise de Sequência . . . 47
3.10.2 Alinhamento de Sequência Baseado em Verossimilhança . . . 47
3.10.3 Modelos de Indel de Nascimento-Morte . . . 48
3.11 Aprendizado de Máquina em Seleção de Modelo de Substituição . . . 48
3.11.1 Motivação para Abordagens de AM . . . 48

3.11.2 Florestas Aleatórias e Redes Neurais Profundas . . . 48
3.11.3 Codificação Direta de Alinhamento . . . 48
3.11.4 Inferência Livre de Verossimilhança para Modelos Intratáveis . . . 49
3.11.5 Design de Dados de Treinamento e Generalização . . . 49
3.11.6 Limitações da Seleção de Modelo Baseada em AM . . . 49
3.12 Redes Neurais de Proteína e Modelos de Linguagem . . . 50
3.12.1 Modelos de Linguagem de Proteína . . . 50
3.12.2 Phyloformer e Arquiteturas de Atenção . . . 50
3.13 Conclusão . . . 50

**4 Diversidade de Tipos de Dados e Estratégias de Sequenciamento para Reconstrução Filogenômica 55**
4.1 Sequenciamento de Genoma Completo (Leitura Curta) . . . 55
4.1.1 Características Gerais . . . 55
4.1.2 Forças e Limitações . . . 56
4.2 Sequenciamento de Genoma Completo (Leitura Longa: PacBio HiFi / ONT) . . . 56
4.2.1 Características Gerais . . . 56
4.2.2 Forças e Limitações . . . 57
4.3 Transcriptômica (RNA-seq) . . . 57
4.3.1 Características Gerais . . . 57
4.3.2 Forças e Limitações . . . 58
4.4 Elementos Ultraconservados (UCEs) . . . 58
4.4.1 Características Gerais . . . 58
4.4.2 Forças e Limitações . . . 59
4.5 Enriquecimento Híbrido Ancorado (AHE) . . . 59
4.5.1 Características Gerais . . . 59
4.5.2 Forças e Limitações . . . 60
4.6 Angiosperms353 / Conjuntos de Sondas Universais . . . 60
4.6.1 Características Gerais . . . 60
4.6.2 Forças e Limitações . . . 61
4.7 Captura de Exons Customizada / Específica de Linhagem . . . 61
4.7.1 Características Gerais . . . 61
4.7.2 Forças e Limitações . . . 62
4.8 RADseq / ddRADseq / GBS . . . 62
4.8.1 Características Gerais . . . 62
4.8.2 Forças e Limitações . . . 63
4.9 Genome Skimming (WGS Raso) . . . 63
4.9.1 Características Gerais . . . 63
4.9.2 Forças e Limitações . . . 64
4.10 Filogenômica de Genoma Organellar (Plastômica / Mitogenômica) . . . 64
4.10.1 Características Gerais . . . 64
4.10.2 Forças e Limitações . . . 65
4.11 Filogenômica Baseada em Gene BUSCO . . . 65
4.11.1 Características Gerais . . . 65

4.11.2 Forças e Limitações . . . 66
4.12 Métodos Assembly-Free / k-mer (AAF, CASTER, Read2Tree) . . . 66
4.12.1 Características Gerais . . . 66
4.12.2 Forças e Limitações . . . 67
4.13 Considerações Comparativas . . . 67

**5 RNA-seq em Estudos Filogenômicos 73**
5.1 Introdução e Motivações . . . 73
5.2 Motivações para RNA-seq em Filogenômica . . . 73
5.2.1 Acesso a Loci Codificantes Múltiplos . . . 73
5.2.2 Economia de Custos em Organismos Não-Modelo . . . 73
5.2.3 Dados de Expressão Integrados . . . 74
5.2.4 Acesso a Repositórios Públicos . . . 74
5.3 Desafios Técnicos: Preservação de Tecido e Qualidade de RNA . . . 74
5.3.1 Degradação Rápida de RNA . . . 74
5.3.2 Métodos de Preservação de Tecido . . . 74
5.3.3 Variação Tecido-Específica . . . 75
5.4 Desafios Analíticos: Determinação de Ortologia e Contaminhação Paráloga . . . 75
5.4.1 Complexidade Aumentada de Ortologia . . . 75
5.4.2 Pipelines de Ortologia . . . 76
5.4.3 Contaminação Paráloga e Captura de Contaminação . . . 76
5.5 Desafios Analíticos: Discordância de Árvore Gênica e Alinhamento . . . 76
5.5.1 Incompletude de Linhagem Ordenação (ILS) . . . 76
5.5.2 Introgressão . . . 76
5.5.3 Duplicação Gênica e Perda . . . 77
5.5.4 Qualidade de Alinhamento e Mascaramento . . . 77
5.6 Estratégias para Superar Desafios . . . 77
5.6.1 Pipelines de Processamento Automatizado . . . 77
5.6.2 Análise Multi-Método de Discordância . . . 77
5.6.3 Enriquecimento de Captura Alvo Derivado de RNA-seq . . . 78
5.7 Aplicações Empíricas e Casos de Estudo . . . 78
5.7.1 Invertebrados . . . 78
5.7.2 Plantas . . . 78
5.7.3 Considerações de Qualidade em Dados Retrospectivos . . . 79
5.8 Direções Futuras e Perspectivas . . . 79
5.8.1 Sequenciamento de RNA de Leitura Longa . . . 79
5.8.2 Transcriptômica em Nível de Célula Única . . . 79
5.8.3 Integração com Outros Tipos de Dados . . . 79

**6 Elementos Repetitivos, Elementos Transponíveis e Viés de Conteúdo GC 83**
6.1 Introdução . . . 83
6.2 Definições de Conceitos Genômicos Chave . . . 83
6.2.1 Elementos Repetitivos . . . 83
6.2.2 Elementos Transponíveis . . . 84
6.2.3 Regiões Não-Codificantes e DNA “Lixo” . . . 84

6.2.4 Viés de Conteúdo GC . . . 85
6.3 Origens Evolutivas de DNA Repetitivo . . . 86
6.3.1 Origens de Elementos Transponíveis . . . 86
6.3.2 Retrotransposons Não-LTR: LINEs e SINEs . . . 86
6.3.3 DNA Transposons . . . 86
6.3.4 Repetições em Tandem: Satélites, Minissatélites, e Microssatélites . . . 87
6.3.5 Interação Entre Classes de Repetições . . . 87
6.4 Obstáculos que Repetições Genômicas Colocam para Estudos Genômicos . . . 88
6.4.1 Ambiguidade e Multi-Mapeamento . . . 88
6.4.2 Complexidade de Gráfico e Emaranhados . . . 88
6.4.3 Variações Estruturais e Montagem Incorreta . . . 88
6.5 Desafios Específicos de Montagem e Anotação . . . 88
6.6 Soluções de Sequenciamento e Bioinformática . . . 89
6.6.1 Tecnologias de Sequenciamento de Leitura Longa . . . 89
6.6.2 Ferramentas Bioinformáticas para Identificação e Mascaramento de Repetição 89
6.6.3 Estratégias de Montagem para Genomas Ricos em Repetição . . . 90
6.6.4 Abordagens de Pangenoma para Variação de Repetição . . . 90
6.6.5 Combinação de Estratégias . . . 91
6.7 Desafios Emergentes e Direções Futuras . . . 91
6.8 Implicações para Filogenômica . . . 91

**7 Tecnologia da Informação Aplicada a Problemas Filogenéticos 99**
7.1 Introdução . . . 99
7.2 Panorama Histórico do Software Filogenético . . . 100
7.2.1 A Era Inicial: Mainframes e o Nascimento de PHYLIP (1973–1985) . . . 100
7.2.2 Proliferação de Software Especializado (1985–2000) . . . 100
7.2.3 A Revolução Bayesiana e MCMC (2000–2015) . . . 101
7.2.4 Software Moderno: Paradigmas Eficientes (2015–Presente) . . . 102
7.3 Debates Centrais Moldados pela Computação . . . 103
7.3.1 Parcimônia Versus Verossimilhança . . . 103
7.3.2 Redes Versus Árvores . . . 103
7.3.3 Critério de Optimalidade Unificado . . . 104
7.4 Obstáculos Computacionais Não Resolvidos . . . 104
7.4.1 NP-Dureza da Busca em Árvores . . . 104
7.4.2 Incomputabilidade de Complexidade Algorítmica . . . 104
7.4.3 Quadro Conceitual: Cladística Versus Métodos Baseados em Modelos . . . 105
7.4.4 Papel Emergente de Aprendizado de Máquina . . . 105
7.5 Caso de Estudo: Contribuições Recentes de Wheeler e Colaboradores . . . 105
7.5.1 PhyG: Análise de Grafo Filogenético . . . 106
7.5.2 Thompson Sampling para Otimização Adaptativa . . . 106
7.5.3 Comprimento Mínimo de Descrição Filogenética (PMDL) . . . 106
7.6 Discussão: Futuro de Software Filogenético . . . 106
7.7 Conclusão . . . 107

**8 Projeto de Sistemas Computacionais de Alto Desempenho para Filogenômica 111**
8.1 Introdução . . . 111
8.2 Perfil Computacional de Workflows Filogenômicos . . . 112
8.2.1 Fase 1: Controle de Qualidade e Pré-processamento de Leituras . . . 112
8.2.2 Fase 2: Montagem, Mapeamento e Extração de Locus . . . 112
8.2.3 Fase 3: Inferência de Ortologia . . . 112
8.2.4 Fase 4: Alinhamento Múltiplo de Sequências . . . 112
8.2.5 Fase 5: Aparagem e Filtragem de Alinhamento . . . 113
8.2.6 Fase 6: Estimação de Árvore de Gene (Máxima Verossimilhança) . . . 113
8.2.7 Fase 7: Estimação de Árvore de Gene (Bayesiana) . . . 113
8.2.8 Fase 8: Inferência de Árvore de Espécies e Análise de Concordância . . . 113
8.3 Arquitetura de Hardware Proposta . . . 114
8.3.1 Filosofia de Design . . . 114
8.3.2 Componentes Recomendados . . . 114
8.3.3 Rationale de Seleção de CPU . . . 114
8.3.4 Rationale de Seleção de GPU . . . 114
8.3.5 Arquitetura de Armazenamento . . . 114
8.3.6 Fabric de Rede . . . 115
8.3.7 Otimização Financeira: Custo Total de Propriedade . . . 115
8.4 Software Stack e Gerenciamento de Ambiente . . . 116
8.4.1 Sistema Operacional e Agendamento de Job . . . 116
8.4.2 Containerização e Reproducibilidade . . . 116
8.4.3 Orquestração de Pipeline . . . 116
8.5 Estratégia de Alocação de Recursos . . . 117
8.5.1 Design de Partição SLURM . . . 117
8.5.2 Agendamento Fair-Share . . . 117
8.5.3 Limites de Recurso e Accountability . . . 117
8.6 Requisitos de Recurso Recomendados por Tipo de Análise . . . 117
8.7 Gerenciamento Multi-Usuário . . . 117
8.7.1 Estrutura de Conta . . . 117
8.7.2 Quotas de Armazenamento . . . 118
8.7.3 Segurança e Controle de Acesso . . . 118
8.7.4 Treinamento e Documentação . . . 118
8.8 Monitoramento e Alertas . . . 118
8.9 Roadmap de Escalabilidade: Pense em Fases . . . 119
8.10 Conclusão . . . 119

**9 Gestão de Dados Ômicos 123**
9.1 Introdução: O Problema de Reproducibilidade em Biologia Computacional . . . 123
9.1.1 Opacidade e Fragilidade de Software . . . 123
9.1.2 Sensibilidade de Parâmetro e Configuração . . . 123
9.1.3 Negligência em Gestão de Dados . . . 124
9.1.4 Escala do Problema . . . 124
9.2 Os Princípios FAIR: Um Framework para Intendência de Dados . . . 124

9.2.1 Origem e Escopo . . . 124
9.2.2 Os Quinze Sub-Princípios . . . 124
9.2.3 FAIR Aplica-se a Três Entidades . . . 125
9.3 FAIR Além de Dados: Princípios para Software de Pesquisa . . . 125
9.4 Implementando FAIR em Gestão de Dados Ômicos . . . 126
9.4.1 Repositórios de Dados e Identificadores . . . 126
9.4.2 Metadados: O Ponto Fraco Perene . . . 126
9.4.3 Gerenciadores de Workflow como Habilitadores FAIR . . . 127
9.4.4 Containers como Infraestrutura de Reprodutibilidade . . . 127
9.5 Limitações Técnicas de Computação e Seu Impacto em Reprodutibilidade . . . 128
9.5.1 Comportamento Dependente de Hardware . . . 128
9.5.2 Restrições de Memória e Armazenamento . . . 128
9.5.3 Paradoxo de Reprodutibilidade em Nuvem . . . 128
9.6 Checklist Prático: Fazendo Projeto Filogenômico FAIR . . . 129
9.6.1 Antes de Análise . . . 129
9.6.2 Durante Análise . . . 129
9.6.3 Após Análise . . . 129
9.7 Conceitos Chave para Estudo Adicional . . . 130
9.7.1 Ontologias e Vocabulários Controlados em Ômicas . . . 130
9.7.2 Planos de Gestão de Dados (DMPs) . . . 130
9.7.3 Distinção Entre Aberto e FAIR . . . 130
9.7.4 Padrões de Proveniência Computacional . . . 130
9.8 Conexões para Design de Sistema HPC . . . 130
9.9 Conclusão . . . 131

**10 Inteligência Artificial na Ciência Biomédica Contemporânea 135**
10.1 Introdução . . . 135
10.2 Aprendizado de Máquina Supervisionado e Não Supervisionado na Biomedicina . . . 136
10.2.1 Aprendizado Supervisionado: Aplicações e Escopo . . . 136
10.2.2 Aprendizado Não Supervisionado e Descoberta de Estrutura Latente . . . 136
10.2.3 Debates: Generalizabilidade, Viés e Incerteza . . . 137
10.3 Aprendizado Profundo e Aprendizado de Representação . . . 137
10.3.1 Arquiteturas e Aplicações Biomédicas . . . 137
10.3.2 Interpretabilidade e o Problema da Caixa Preta . . . 138
10.4 Modelos Generativos e Dados Sintéticos . . . 139
10.4.1 Redes Adversariais Generativas e Autoencodificadores Variacionais . . . 139
10.4.2 Design de Proteína e Ácido Nucleico . . . 139
10.4.3 Dados Sintéticos: Promessas e Riscos . . . 140
10.5 Redes Bayesianas e Inferência Probabilística Guiada por IA . . . 140
10.5.1 Modelagem Principiada de Incerteza . . . 140
10.5.2 Aprendizado de Estrutura e Inferência Causal . . . 140
10.5.3 Modelos Híbridos Probabilísticos-Aprendizado Profundo . . . 141
10.6 Modelos de Linguagem em Larga Escala em Fluxos de Trabalho Científicos . . . 141
10.6.1 Aplicações em Pesquisa Biomédica . . . 141

10.6.2 Limitações Epistêmicas e Riscos . . . 142
10.7 Sistemas Híbridos e AutoML . . . 142
10.7.1 IA Híbrida: Combinando Paradigmas . . . 142
10.7.2 AutoML: Democratização e Seus Inconvenientes . . . 143
10.7.3 Aprendizado Federado e IA Preservadora de Privacidade . . . 143
10.8 Desafios Persistentes . . . 143
10.9 Conclusão . . . 144

**11 Aspectos Legais e Éticos no Uso de Dados Genômicos 151**
11.1 Introdução . . . 151
11.2 Marcos Internacionais: Convenção sobre Diversidade Biológica e Protocolo de Nagoia 151
11.2.1 A Convenção sobre Diversidade Biológica (1992) . . . 151
11.2.2 Protocolo de Nagoia sobre Acesso e Repartição de Benefícios (2014) . . . 152
11.3 Legislação Brasileira: Biodiversidade e Proteção de Dados . . . 152
11.3.1 Lei da Biodiversidade (Lei nº 13.123/2015) e SisGen . . . 152
11.3.2 Lei Geral de Proteção de Dados (LGPD - Lei nº 13.709/2018) . . . 153
11.3.3 Legislação Brasileira em Pesquisa com Animais . . . 153
11.4 Marcos Internacionais para Compartilhamento de Dados Genômicos . . . 154
11.4.1 Infraestrutura Internacional de Sequências: GenBank, ENA e DDBJ . . . 154
11.4.2 Políticas de Mandatos de Dados Abertos de Agências de Financiamento . . . 154
11.5 Considerações Éticas em Pesquisa Genômica com Comunidades Indígenas e Tradicionais 155
11.5.1 Direitos de Comunidades Indígenas e Biopirataria . . . 155
11.5.2 Princípios de Pesquisa Respeitosa com Comunidades Indígenas . . . 155
11.6 GDPR Europeu e Proteção de Dados Genômicos Internacionais . . . 156
11.6.1 Regulação Geral de Proteção de Dados (GDPR) e Sequências Genômicas . . . 156
11.6.2 Implicações para Pesquisa Internacional em Genômica . . . 156
11.7 Acesso Aberto e Ciência Aberta em Genômica . . . 157
11.7.1 Movimento de Dados Abertos e Ciência Aberta . . . 157
11.7.2 Repositórios de Acesso Controlado e Modelos de Governança . . . 157
11.8 Conformidade Prática: Guia para Pesquisadores . . . 158
11.8.1 Planejamento de Pesquisa com Considerações Legais e Éticas . . . 158
11.8.2 Documentação de Métodos para Transparência . . . 158
11.9 Perspectivas Futuras: Harmonização Internacional e Dados Genômicos como Bem Comum . . . 159
11.9.1 Esforços de Harmonização de Regulações Internacionais . . . 159
11.10Conclusão . . . 159

**Agradecimentos 163**

# Prefácio

Este livro reúne material de estudo sobre filogenômica e bioinformática de metazoários, abrangendo desde os fundamentos teórico-filosóficos da sistemática filogenética até questões contemporâneas de inteligência artificial, legislação brasileira e infraestrutura computacional. A obra é organizada em onze capítulos que cobrem os principais tópicos necessários para a compreensão e a prática da reconstrução filogenômica em larga escala.

O texto enfatiza tanto os princípios teóricos quanto os aspectos práticos de implementação, incluindo a formulação matemática dos métodos probabilísticos, a diversidade de dados moleculares disponíveis, as estratégias de sequenciamento, os desafios impostos por elementos repetitivos e os requisitos de infraestrutura computacional. Os capítulos finais abordam o papel emergente da inteligência artificial na ciência biomédica e os aspectos legais e éticos do uso de dados genômicos, com ênfase na legislação brasileira e nos marcos internacionais.

Cada capítulo contém suas próprias referências bibliográficas, o que permite consultas independentes. A ordem dos capítulos segue uma progressão lógica dos fundamentos para as aplicações, mas cada capítulo foi escrito de forma razoavelmente autocontida. Um guia de estudo é apresentado ao final de cada capítulo.

Denis Jacob Machado
Charlotte, Carolina do Norte, E.U.A., 2026

# Capítulo 1

# Fundamentos Teórico-Filosóficos da Filogenética

## 1.1 Introdução

Inferir a história evolutiva dos organismos exige observações organizadas e hereditárias capazes de discriminar entre hipóteses filogenéticas concorrentes. A transformação de observações biológicas brutas em tal evidência não é uma operação trivial: ela demanda uma compreensão principiada do que constitui um caráter, de como os caracteres sustentam a hipótese de ancestralidade comum, e de como conflitos aparentes entre caracteres são interpretados e resolvidos (Wheeler et al. 2006).

Esses problemas têm uma longa e contestada história. Lankester (1870) introduziu o termo *homoplasia* para distinguir feições que se assemelham superficialmente mas não compartilham uma origem comum. Hennig (1966) formalizou a distinção entre estados de caráter ancestrais e derivados compartilhados, fornecendo o fundamento lógico da metodologia cladística. Pinna (1991) e Patterson (1982) abordaram subsequentemente o estatuto epistemológico da homologia como hipótese. Wheeler et al. (2006) e Wheeler (2012) sintetizaram essas contribuições em um arcabouço computacional integrado, capaz de lidar com a escala e a complexidade dos dados genômicos modernos.

Os caracteres são, nesse arcabouço, objetos carregados de teoria (*theory-laden objects*) no sentido de Popper (1959): a compreensão prévia que o investigador tem da biologia dos organismos informa a decisão de reconhecer uma feição como um caráter. A sistemática filogenética é, portanto, uma ciência ideográfica — não nomotética — que busca descobrir as séries de eventos históricos de transformação que explicam a variação hereditária entre linhagens (Grant e Kluge 2004b).

O advento do sequenciamento de alto rendimento (HTS, do inglês *high-throughput sequencing*) alterou fundamentalmente a escala em que dados filogenéticos são coletados: centenas ou milhares de loci podem agora ser sequenciados para dezenas a centenas de táxons em um único experimento. Essa abundância de dados não simplifica os problemas conceituais de delimitação de caracteres, avaliação de homologia e gestão de homoplasia; pelo contrário, os amplifica. A urgência prática dessas questões é ilustrada por análises de larga escala como a de Jacob Machado et al. (2021c), que analisou 2.006 genomas completos da subfamília *Orthocoronavirinae* usando parcimônia de evidência total, produzindo a hipótese filogenética mais abrangente para esse grupo à época e elucidando a origem e a história de hospedeiros do SARS-CoV-2. Jacob Machado et al. (2021d) revisaram a trajetória da epidemiologia genômica desde suas origens na epidemiologia molecular até a pandemia de COVID-19, demonstrando como a redução dramática nos custos de sequenciamento possibilitou

a vigilância filogenômica em escala global.

Desenvolvimentos recentes no software estenderam ainda mais o escopo da inferência filogenética. PhyG (Wheeler et al. 2024), sucessor do POY5, estende a busca filogenética a grafos gerais, incluindo redes *softwired* e *hardwired*, e oferece melhorias substanciais em qualidade de otimização e velocidade de execução. Wheeler e Varón (2025) propuseram o comprimento mínimo de descrição filogenética (PMDL, do inglês *phylogenetic minimum description length*) como um critério de otimalidade unificado fundamentado na teoria algorítmica da informação. O presente capítulo examina esses fundamentos conceituais e sua implementação prática em fluxos de trabalho contemporâneos de análise filogenética.

## 1.2 A Estrutura das Árvores Filogenéticas

### 1.2.1 Árvores, Cladogramas e Topologias

Na sistemática filogenética, os termos **árvore filogenética**, **cladograma** e **topologia** são frequentemente utilizados de forma intercambiável (Wheeler 2012). A árvore filogenética é a ferramenta primária para descrever relações evolutivas entre organismos. Formalmente, árvores são grafos conexos e acíclicos que representam relações hierárquicas aninhadas entre grupos. Em YBYRÁ e em outros programas de análise filogenética, árvores são tipicamente representadas em notação parentética, seguindo o formato Newick ou o formato Hennig86 (também denominado TREAD) (Machado 2015).

### 1.2.2 Componentes Elementares: Nós, Ramos, Terminais e Raiz

Os elementos estruturais de uma árvore filogenética são os seguintes:

**Terminais** Os terminais — também denominados *unidades taxonômicas operacionais* (OTUs, do inglês *operational taxonomic units*) ou folhas (*leaves*) — são os objetos que ocorrem nas extremidades da árvore. Terminais frequentemente representam táxons, mas podem representar qualquer entidade comparável (e.g., sequências, populações, espécies fósseis).

**Nós** Os nós são os pontos de interseção em uma árvore, identificando cada componente. Nós internos representam ancestrais hipotéticos e são denominados *unidades taxonômicas hipotéticas* (HTUs, do inglês *hypothetical taxonomic units*); nós terminais correspondem às OTUs. Em uma árvore enraizada, a raiz é o único nó com grau dois.

**Ramos** Os ramos são as arestas que conectam dois nós adjacentes. Cada ramo pode ser associado a um comprimento representando o número de transformações ou a duração evolutiva do intervalo.

**Raiz** A raiz determina a polaridade das transformações de caráter no cladograma (Schuh e Brower 2009). O enraizamento converte uma árvore não enraizada em uma árvore enraizada, estabelecendo a direção das transformações evolutivas.

### 1.2.3 Grupos-Irmãos, Splits e Consenso Estrito

Em uma árvore binária, **grupos-irmãos** (*sister-groups*) são dois grupos que compartilham um único ancestral comum exclusivo (Schuh e Brower 2009). Um **split** é a bipartição de um conjunto de

terminais induzida pela remoção de uma aresta da árvore. Por exemplo, a árvore `(A,(C,(D,(E,F))))` pode ser dividida nas subárvores `(E,F)` e `(A,(C,D))` pela remoção do ramo que as une. Uma **árvore de consenso estrito** contém exclusivamente os nós presentes em *todas* as árvores de um conjunto de resultados igualmente ótimos; qualquer inconsistência resulta no colapso do nó correspondente (Schuh e Brower 2009).

### 1.2.4 Formatos de Arquivo para Árvores Filogenéticas

Dois formatos de arquivo são amplamente utilizados para representar árvores em notação parentética:

**Newick** Adotado por programas como GARLI, MrBayes, PAUP*, PHYLIP, PROTML e TREE--PUZZLE. Terminais são separados por vírgulas e as relações de grupo-irmão por parênteses aninhados. Suporta comprimentos de ramo e rótulos de nós internos:

```
((A:5,B:7)Ancestral:10,C:3);
```

**TREAD (Hennig86)** Representa árvores precedidas pelo cabeçalho `tread`. Múltiplas árvores são separadas por asteriscos, e a última termina com ponto e vírgula. É comum incluir `proc-;` ao final do arquivo para uso em TNT (Goloboff et al. 2008).

## 1.3 Táxons, Clados e Classificação Filogenética

### 1.3.1 Grupos Monofiléticos, Parafiléticos e Poliféticos

Um **táxon** é qualquer grupo de organismos reconhecido em qualquer nível da hierarquia sistemática (Schuh e Brower 2009). A sistemática filogenética distingue três tipos de agrupamento (Hennig 1966; Schuh e Brower 2009):

**Grupo monofilético (clado)** Composto por um ancestral comum único e *todos* os seus descendentes. Somente grupos monofiléticos são reconhecidos como unidades naturais e válidas de classificação cladística (Hennig 1966).

**Grupo parafilético** Ao qual falta exatamente um grupo monofilético para se tornar monofilético (e.g., “Reptilia” no sentido clássico, que exclui Aves).

**Grupo polifilético** Ao qual faltam dois ou mais grupos monofiléticos para se tornar monofilético; tipicamente reflete convergência evolutiva (Schuh e Brower 2009).

A monofilia de qualquer agrupamento é uma proposição a ser avaliada pela congruência de caracteres, não uma assunção metodológica (Nixon e Carpenter 1993).

## 1.4 O Conceito de Caráter

### 1.4.1 A Natureza Histórica do Caráter

Um caráter, no sentido filogenético, é “uma série de transformação historicamente independente” (Wheeler et al. 2006, p. 333). Caracteres não são simples observações, mas declarações teoricamente

organizadas sobre variação hereditária entre táxons, carregando noções de relevância, comparabilidade e correspondência (Wheeler 2012). São objetos carregados de teoria no sentido de Popper (1959): a compreensão prévia do investigador informa a decisão de reconhecer uma feição como caráter.

Grant e Kluge (2004b) argumentam que esse é o único conceito de caráter consistente com as exigências epistemológicas da sistemática filogenética. Como séries de transformação, caracteres são indivíduos históricos, análogos em estatuto ontológico às espécies e clados. A independência relevante para a inferência filogenética é **independência histórica ou transformacional**, não correlação funcional ou desenvolvimental (Grant e Kluge 2004b).

Os **estados de caráter** são as formas alternativas que uma série de transformação pode assumir. Para caracteres binários, estados designam tipicamente presença ou ausência de uma estrutura; para dados de sequência, os estados são os resíduos nucleotídicos ou aminoacídicos em uma dada posição.

### 1.4.2 Tipos de Caráter

Wheeler et al. (2006) reconhecem cinco tipos fundamentais de caráter:

**Aditivos** Assumem ordenação linear dos estados; o custo de transformação é a distância aditiva entre os estados (Farris 1970).

**Não-aditivos** Atribuem custos iguais a todas as transformações, sem homologia aninhada entre estados (Fitch 1971).

**Matriz (Sankoff)** Permitem custos de transformação arbitrários especificados por uma matriz de custos (Sankoff 1975; Sankoff e Rousseau 1975).

**Sequência** Tratam cadeias contíguas de nucleotídeos ou aminoácidos como unidade de comparação, com transformações envolvendo substituição, inserção ou deleção.

**Cromossômicos** Otimizam simultaneamente a variação em nível nucleotídico e em nível de loco; aplicáveis a genomas mitocondriais, bacterianos e virais (Wheeler et al. 2006).

PhyG (Wheeler et al. 2024) estende ainda mais essa representação para alfabetos efetivamente ilimitados, permitindo a análise de dados linguísticos, desenvolvimental e outros tipos de dados comparativos não-padrão.

### 1.4.3 Caracteres Fenotípicos e Genotípicos

Caracteres fenotípicos são características estruturais ou funcionais que expressam o genótipo em conjunto com influências ambientais, incluindo dados morfológicos, comportamentais e de sequências de aminoácidos. Caracteres genotípicos derivam diretamente de sequências de DNA ou RNA, eliminando preocupações com heritabilidade; seu desafio principal é que a homologia de nucleotídeos não pode ser testada isoladamente, mas requer um teste de congruência com outros caracteres (Wheeler et al. 2006). O princípio da **evidência total** (Kluge 1989) sustenta que toda a evidência disponível — fenotípica e genotípica — possui igual valor inicial para discriminar entre hipóteses filogenéticas e deve ser analisada simultaneamente.

## 1.5 Homologia: Definição, Epistemologia e Debate

### 1.5.1 A Definição Operacional e a Homologia como Hipótese Nula

Na formulação de Wheeler et al. (2006, p. 10), "feições são homólogas quando suas origens podem ser rastreadas a uma única transformação em um ramo do cladograma que leva ao ancestral comum mais recente." Três consequências decorrem dessa definição: (1) a homologia é **dependente do cladograma** — não há noção de homologia sem referência a um cladograma, nem escolha entre cladogramas sem declarações de homologia; (2) a homologia é a **hipótese nula** na construção de grupos monofiléticos durante a busca em árvores; (3) toda afirmação de homologia é simultaneamente uma hipótese filogenética, sujeita à falsificação pela incongruência de caracteres.

Grant e Kluge (2004b) argumentam, de forma independente, que a homologia refere-se a uma **relação histórica de identidade** — a identidade de ser derivado do mesmo evento único de transformação — e como tal é conceitualmente anterior e distinta do teste cladístico de congruência de caracteres.

### 1.5.2 O Debate Homologia–Sinapomorfia

Nixon e Carpenter (2012) argumentam que a equação de homologia com sinapomorfia, proposta por Patterson (1982), é histórica e conceitualmente incorreta. Hennig (1966) claramente pretendia que a homologia abrangesse tanto a plesiomorfia quanto a sinapomorfia, uma vez que ambas representam feições compartilhadas por táxons em decorrência de ancestralidade comum. Uma simplesiomorfia é homóloga no nível mais inclusivo em que constitui uma sinapomorfia; no nível do grupo interno, ela é homóloga mas filogeneticamente não-informativa (Nixon e Carpenter 2012).

### 1.5.3 O Debate Homologia Primária–Secundária

Pinna (1991) propôs um modelo de dois estágios: a **homologia primária** refere-se a proposições iniciais baseadas em similaridade, geradas antes da análise; a **homologia secundária** refere-se às proposições que sobrevivem ao teste de congruência de caracteres. Wheeler et al. (2006) rejeitam essa separação como "nem uma necessidade metodológica nem epistemológica" (Wheeler et al. 2006, p. 10). Grant e Kluge (2004b) argumentam que a distinção confunde o *conceito* de homologia com as *operações de descoberta* usadas para detectar instâncias desse conceito; como ambos são distintos, nenhuma categoria epistemológica intermediária é necessária. O teste de congruência pode ser aplicado diretamente ao conjunto irrestrito de hipóteses de homologia — que é o núcleo da reivindicação do arcabouço de **homologia dinâmica** (Wheeler 2001a,b).

### 1.5.4 Homologia Estática e Dinâmica

A **homologia estática** codifica hipóteses de homologia em uma matriz fixa antes da análise filogenética. Em sistemática molecular, o alinhamento múltiplo de sequências é o método canônico: cada coluna é tratada como um caráter e cada resíduo dentro da coluna como um estado homólogo (homologia posicional). A limitação crítica é que o alinhamento ótimo é dependente da topologia; um alinhamento produzido sob uma árvore-guia pode diferir do alinhamento ótimo para o cladograma ótimo (Wheeler et al. 2006).

A **homologia dinâmica** trata a homologia como um problema de otimização resolvido simultaneamente com a busca em árvores, empregando o mesmo critério de otimalidade para ambas as

etapas; a solução globalmente ótima é a combinação de custo mínimo de cladograma mais esquema de homologia (Wheeler et al. 2006).

Um desenvolvimento prático importante são os **alinhamentos implícitos** (*implied alignments*), introduzidos por Wheeler (2003a) como representações visuais das sinapomorfias em um determinado cladograma. Cada alinhamento implícito é único para uma topologia e um conjunto de parâmetros de transformação específicos; usá-lo como base para uma análise independente subsequente reintroduziria os problemas da homologia estática (Wheeler et al. 2006).

### 1.5.5 Tipos de Transformações

Os estados de caráter classificam-se de acordo com polaridade e distribuição na árvore (Hennig 1966; Schuh e Brower 2009):

**Apomorfia** Estado de caráter derivado, originado a partir de um estado ancestral em um evento de transformação.

**Plesiomorfia** Estado de caráter ancestral. Plesiomorfias são homologias legítimas, mas não são informativas para discriminar hipóteses de relacionamento (Nixon e Carpenter 2012).

**Sinapomorfia** Ocorrência compartilhada de um estado apomórfico em um grupo monofilético (Grant e Kluge 2004a); evidência fundamental de monofiletismo.

**Simplesiomorfia** Estado ancestral compartilhado por um grupo não-monofilético de terminais; não sustenta agrupamentos naturais.

**Autapomorfia** Apomorfia exclusiva de um único terminal ou táxon; diagnóstica para terminais individuais, mas não informativa para relacionamentos entre eles.

## 1.6 Homoplasia: Definição, Medição e Interpretação

### 1.6.1 Definição e Estatuto Epistemológico

Homoplasia ocorre "quando um estado de caráter é compartilhado por dois ou mais táxons sem ser resultado de ancestralidade comum, mas sim de paralelismo ou convergência" (Wheeler et al. 2006, p. 336). O termo foi introduzido por Lankester (1870). Em termos operacionais, a homoplasia é qualquer transformação não-mínima de um caráter em um cladograma — definição explicitamente específica da árvore: uma feição homoplástica em um cladograma pode ser otimizada sem passos extras em outro (Wheeler 2012).

Farris (1983) e Kluge (2009) argumentam que a homoplasia funciona como um **falsificador** da hipótese de árvore na qual ocorre. O cladograma preferido é aquele menos falsificado pela homoplasia, i.e., aquele que minimiza hipóteses *ad hoc* de convergência e paralelismo. Este é o critério de parcimônia enunciado em termos epistemológicos. Uma **hipótese *ad hoc*** é uma suposição invocada para eliminar observações inconvenientes; em cladística, o recurso *a priori* à homoplasia — explicar similaridade como não-homóloga sem justificativa topológica — é o exemplo paradigmático (Grant e Kluge 2004a).

### 1.6.2 Medição da Homoplasia

O **índice de consistência** (CI) para um caráter é a razão entre o número mínimo possível de passos e o número observado em uma dada árvore (Kluge e Farris 1969). Um CI de 1,0 indica ausência de homoplasia. O **índice de retenção** (RI; Farris 1989) mede a fração da aparente sinapomorfia efetivamente retida como sinapomorfia na árvore; é menos sensível ao número de táxons do que o CI.

Goloboff (1991) introduziu a distinção entre homoplasia e **decisividade** (*decisiveness*) — o conteúdo informativo de uma matriz em relação à escolha de árvores, proporcional à variância no comprimento das árvores sobre todos os cladogramas possíveis. Valores menores de CI ou RI não implicam necessariamente menor decisividade: um conjunto de dados pode ter alta homoplasia no cladograma mais parcimonioso e ainda ser altamente decisivo se as árvores alternativas forem substancialmente menos parcimoniosas. Esse resultado adverte contra confundir o nível de homoplasia com a força da evidência para um cladograma (Goloboff 1991).

### 1.6.3 InDels e Homoplasia

Inserções e deleções (InDels) exibem padrões de homoplasia distintos das substituições nucleotídicas. Redelings et al. (2024) observam que as taxas de InDels variam substancialmente entre grupos taxonômicos e regiões genômicas, e que um viés de deleção é observado na maioria das linhagens estudadas. Como InDels são eventos relativamente raros comparados às mutações pontuais, e como a probabilidade de um InDel idêntico ocorrer independentemente em duas linhagens não aparentadas na mesma posição é muito baixa, InDels compartilhados constituem evidência sinapomórfica particularmente forte (Redelings et al. 2024).

## 1.7 Comparação com Grupo Externo, Polaridade e Enraizamento

### 1.7.1 Grupo Externo, Grupo Interno e a Identidade dos Três Problemas

O **grupo interno** (*ingroup*) é o grupo monofilético putativo cujas relações internas constituem o foco primário do estudo; a monofilia do grupo interno é uma hipótese a ser testada, não uma suposição a ser imposta (Nixon e Carpenter 1993). O **grupo externo** (*outgroup*) é qualquer táxon externo ao grupo interno incluído para enraizar a rede resultante e estabelecer a polaridade dos caracteres (Grant 2019; Nixon e Carpenter 1993).

Nixon e Carpenter (1993) esclareceram que a comparação com grupo externo, a determinação da polaridade de caráter e o enraizamento reduzem-se todos a uma única operação: a polaridade não precisa — e não deve — ser decidida antes da análise filogenética; ela é uma consequência do enraizamento, não um pré-requisito. O "algoritmo de grupo externo" de Maddison et al. (1984, discutido em Nixon e Carpenter 1993), que aplica parcimônia independentemente ao grupo interno e ao externo, constitui uma forma relaxada de parcimônia teoricamente indefensável (Nixon e Carpenter 1993). A solução é a análise simultânea irrestrita de todos os terminais em um único network não-enraizado, que é então enraizado entre o grupo interno e o externo.

### 1.7.2 Enraizamento de Lundberg

O enraizamento de Lundberg consiste na construção de um ancestral hipotético para enraizar a rede. Nixon e Carpenter (1993) concluíram que esse procedimento é consistente com a parcimônia cladística

apenas quando o ancestral hipotético é derivado de evidências ontogenéticas ou paleontológicas independentes, não da comparação com o grupo externo; usá-lo de outra forma é circular.

### 1.7.3 Expansão Sucessiva do Grupo Externo

Grant (2019) propôs o procedimento de **expansão sucessiva do grupo externo**: a amostra do grupo externo é expandida iterativamente, com prioridade para terminais mais estreitamente relacionados ao grupo interno e para terminais de regiões da topologia externa fracamente suportadas, até que a topologia e as hipóteses de homologia do grupo interno permaneçam estáveis ao longo de pelo menos duas rodadas consecutivas de expansão. Esse procedimento fornece uma regra de parada defensável sem implicar que os resultados estão além da refutação (Grant 2019).

### 1.7.4 Análise Simultânea e Evidência Total

A **análise simultânea** refere-se à análise conjunta de múltiplos conjuntos de dados em oposição à análise separada seguida de consenso (Nixon e Carpenter 1996). O termo **evidência total** é frequentemente sinônimo (Kluge 1989), embora alguns autores reservem "evidência total" para análises que incorporam *todos* os dados disponíveis (Kluge 1989; Nixon e Carpenter 1996). Ambas as abordagens se opõem à análise particionada seguida de consenso, que pode ocultar conflito informativo entre as partições (Grant e Kluge 2003).

## 1.8 Homologia Dinâmica, InDels e Sequenciamento de Alto Rendimento

### 1.8.1 O Problema dos InDels em Alinhamento Estático

Inserções e deleções (InDels) constituem a segunda fonte mais importante de variação genômica, após as mutações pontuais (Redelings et al. 2024). A maioria dos algoritmos de alinhamento não é ciente da filogenia (*phylogeny-aware*) e tende a inferir alinhamentos nos quais caracteres são independentemente deletados muitas vezes quando considerados em uma árvore, resultando em superestimativa de eventos de perda convergente e perda do sinal filogenético genuíno carregado por InDels compartilhados (Redelings et al. 2024).

As consequências empíricas de codificar gaps como dados ausentes em análise de máxima verossimilhança (ML) foram estudadas sistematicamente por Jacob Machado et al. (2021a). Esse estudo demonstrou que os escores de ML correlacionam negativamente com os custos de abertura de gap, e que variações no número e na distribuição de gaps produzem efeitos substanciais e amplamente imprevisíveis na topologia das árvores. Usando simulações de Monte Carlo que substituíram nucleotídeos por gaps mantendo fixa a homologia nucleotídica, Jacob Machado et al. (2021a) confirmaram que, sob a convenção padrão de gaps como nucleotídeos desconhecidos, o critério de ML recompensa o alinhamento com mais gaps, convergindo para o **alinhamento de identidade trivial** (TIA, do inglês *trivial identity alignment*) como ótimo quando o espaço de alinhamento é completamente explorado. Esta é uma inconsistência fundamental: alinhar sequências com MAFFT e então avaliar a qualidade do alinhamento com o escore de ML aplica critérios de otimalidade distintos em diferentes estágios da mesma análise.

Para quantificar o número e a distribuição de gaps em qualquer alinhamento, Jacob Machado et al. (2021a) introduziram quatro índices: o **Índice de Contiguidade de Gaps** (GCI), o **Índice**

**de Contiguidade de Nucleotídeos** (NCI), o **Índice de Gaps Compartilhados** (SGI) e o **Índice Topológico de Gaps** (TGI), que fornecem uma base quantitativa para caracterizar decisões de alinhamento independentemente de qualquer árvore particular.

### 1.8.2 Algoritmos de Otimização de Sequências sob Homologia Dinâmica

A homologia dinâmica, tal como implementada em análise direta (Wheeler 1996), trata a homologia como um problema de otimização resolvido simultaneamente com a busca em árvores, empregando o mesmo critério de otimalidade para ambas as etapas. Wheeler et al. (2006) descrevem quatro procedimentos heurísticos para resolver o problema de determinação de sequências de HTU:

**Otimização Direta (*Direct Optimization*)** (Wheeler 1996) Avalia simultaneamente as homologias de sequências nucleicas e o custo do cladograma sem exigir alinhamento pré-análise. InDels são tratados como eventos informativos via uma matriz de custo de edição.

**Otimização por Passagens Iterativas (*Iterative Pass Optimization*)** (Wheeler 2003b) Combina a otimização direta de três sequências com melhoria iterativa. As sequências de HTU são otimizadas com base em sequências descendentes e ancestrais simultaneamente, até a estabilização do custo total.

**Otimização de Estados Fixos (*Fixed-States Optimization*)** (Wheeler 1999) Trata cada sequência como um único caráter multiestado cujo estado é uma das sequências terminais observadas. As sequências de HTU são retiradas desse pool predeterminado via programação dinâmica.

**Otimização Baseada em Busca (*Search-Based Optimization*)** (Wheeler 2003c) Estende a otimização de estados fixos permitindo que o usuário forneça um conjunto maior de soluções candidatas para os estados ancestrais.

PhyG (Wheeler et al. 2024) aprimora todos esses procedimentos por meio de percursos de grafo específicos para cada caráter (Varón e Wheeler 2012), gerando tipicamente árvores mais curtas do que o POY5, com melhorias de escore atingindo 7% em conjuntos de dados empíricos.

### 1.8.3 Verossimilhança sob Homologia Dinâmica

A análise de ML pode ser realizada sob o arcabouço de homologia dinâmica sem exigir alinhamento pré-análise (Wheeler et al. 2006). Nessa implementação, um modelo GTR (*general time reversible*) de cinco estados é utilizado, com os estados A, C, G, T e gap — tratando o gap como um quinto estado de caráter no processo de Markov, diferentemente das implementações padrão.

PhyG (Wheeler et al. 2024) implementa adicionalmente a verossimilhança Sem Mecanismo Comum (NCM, do inglês *No-Common-Mechanism*; Tuffley e Steel 1997), que não assume um modelo compartilhado entre os sítios e é equivalente à parcimônia para árvores sem penalidades de rede.

### 1.8.4 Computação Paralela

A escala dos dados de HTS demanda recursos computacionais distribuídos. O problema de busca em cladogramas é amenável à paralelização porque muitas réplicas heurísticas independentes podem ser executadas concorrentemente em processadores separados (Wheeler et al. 2006). PhyG (Wheeler et al. 2024) adota um modelo diferente: usa *threads* leves do sistema operacional em vez de MPI,

eliminando a necessidade de bibliotecas externas e permitindo implantação em hardware comum e em clusters de alto desempenho sem configuração adicional.

## 1.9 Redes Filogenéticas

A análise filogenética tradicional está restrita a árvores — grafos acíclicos dirigidos em que cada nó não-raiz tem exatamente um pai. Essa estrutura representa apenas herança vertical e estritamente bifurcante. Processos como transferência horizontal de genes, hibridização e introgressão produzem histórias evolutivas reticuladas que árvores não podem representar sem invocar hipóteses *ad hoc* de homoplasia (Wheeler et al. 2024).

PhyG (Wheeler et al. 2024) estende a busca filogenética a redes *softwired* e *hardwired*:

**Rede *softwired*** Cada caráter ou bloco de dados segue uma única árvore de display; blocos diferentes podem seguir caminhos distintos pela rede, capturando histórias heterogêneas produzidas por transferência horizontal.

**Rede *hardwired*** Cada vértice de reticulação herda de dois pais simultaneamente, e o custo é determinado pelos custos de transformação em ambos os ramos parentais. Os custos de redes *hardwired* são sempre pelo menos tão altos quanto os de qualquer árvore de display derivável do grafo (Wheeler et al. 2024).

Blocos de dados individuais podem ser atribuídos a caminhos reticulados separados via o comando `reblock`, permitindo ao usuário especificar quais loci compartilham uma história comum (Wheeler et al. 2024).

## 1.10 Critérios de Otimalidade

### 1.10.1 Visão Geral e Incomensurabilidade

A sistemática filogenética requer um critério de otimalidade: uma métrica pela qual comparamos árvores candidatas e selecionamos aquela ou aquelas que melhor explicam os dados. Os três critérios dominantes — parcimônia, máxima verossimilhança e probabilidade posterior Bayesiana — são **incomensuráveis**: uma pontuação de parcimônia, um log-verossimilhança e uma probabilidade posterior não podem ser diretamente comparados entre métodos (Wheeler e Varón 2025). Isso impede a seleção principiada de modelos ou a comparação de tipos alternativos de grafos sob os arcabouços existentes.

### 1.10.2 Parcimônia

A **parcimônia** seleciona o cladograma que minimiza o custo total — o número total de eventos de transformação postulados (Farris 1983; Wheeler et al. 2006). Minimizar a homoplasia não é meramente conveniência computacional, mas um princípio epistemológico fundamentado na navalha de Ockham: cada instância de homoplasia representa um evento evolutivo independente que deve ser explicado sem referência à ancestralidade compartilhada.

### 1.10.3 Máxima Verossimilhança

A **máxima verossimilhança** seleciona a árvore que maximiza $\Pr(D \mid T, \theta)$, a probabilidade dos dados $D$ dada a árvore $T$ e um conjunto de parâmetros do modelo $\theta$. Requer a especificação explícita de um modelo de substituição.

### 1.10.4 Inferência Bayesiana

A **inferência Bayesiana** calcula a distribuição de probabilidade posterior $P(T \mid D)$ sobre o espaço de topologias, sob uma distribuição *a priori* especificada, combinando informação dos dados com crenças prévias expressas formalmente.

### 1.10.5 Comprimento Mínimo de Descrição Filogenética (PMDL)

Wheeler e Varón (2025) propuseram o PMDL como um critério de otimalidade unificado fundamentado na teoria da informação algorítmica (Kolmogorov 1968; Li e Vitányi 1997). O PMDL define a complexidade de uma hipótese filogenética $H$ como:

$$K(H) = K(M) + K(D \mid M) \tag{1.1}$$

onde $K(M)$ é a complexidade algorítmica do modelo $M$ (abrangendo tanto a estrutura do grafo quanto o modelo de transformação de caracteres) e $K(D \mid M)$ é a complexidade dos dados $D$ dado o modelo — equivalente à verossimilhança dos dados sob o modelo (Wheeler e Varón 2025). A hipótese preferida é aquela que minimiza $K(H)$.

Essa formulação tem várias propriedades desejáveis. Primeiro, o PMDL gera esquemas naturais de ponderação de caracteres sem especificação externa: cada tipo de dado contribui com suas próprias complexidades via o mesmo arcabouço. Segundo, inclui a complexidade do grafo, permitindo a competição entre árvores, redes e florestas em uma escala numérica comum. Terceiro, converge sobre a parcimônia para modelos de baixa complexidade, sobre a verossimilhança para conjuntos de dados grandes, e sobre a probabilidade posterior Bayesiana quando prioris são especificadas, unificando os três arcabouços dominantes (Wheeler e Varón 2025). O PMDL está implementado no PhyG (Wheeler et al. 2024).

## 1.11 Ponderação de Caracteres

### 1.11.1 Ponderação Implicada

Goloboff (1993) propôs a ponderação implicada (*implied weighting*) como método de estimar simultaneamente os pesos dos caracteres e buscar o cladograma ótimo. A adequação de um caráter é definida como $F = K/(K + S)$, onde $K$ é uma constante de concavidade definida pelo usuário e $S$ é o número de passos extras (homoplasia) para aquele caráter em uma dada árvore (Wheeler et al. 2006). A análise maximiza a adequação total durante a busca em árvores. A constante $K$ controla a taxa com que a função diminui à medida que a homoplasia aumenta: valores baixos penalizam pesadamente caracteres altamente homoplásticos. A sensibilidade a essa escolha deve ser examinada como parte de qualquer análise que empregue ponderação implicada (Goloboff 1993, 2013).

O PMDL (Wheeler e Varón 2025) fornece uma alternativa: por gerar pesos intrinsecamente a partir da complexidade algorítmica do modelo e dos dados, não requer que o usuário especifique

uma constante de concavidade.

### 1.11.2 Ponderação por Aproximações Sucessivas

Farris (1969) propôs a ponderação por aproximações sucessivas (*successive approximation weighting*) como um procedimento iterativo: os caracteres são primeiro analisados com pesos iguais; a árvore resultante é usada para calcular estatísticas de ajuste dos caracteres (e.g., CI); os caracteres são reponderados e a análise é repetida até a estabilização. Esse método difere da ponderação implicada em que realiza a ponderação entre ciclos analíticos, não continuamente durante a busca.

## 1.12 Suporte de Clados

Identificar o cladograma ótimo é apenas um componente de uma análise filogenética. Avaliar a confiança nos grupos recuperados é igualmente importante. Grant e Kluge (2008) argumentam que os valores de suporte devem refletir a força da evidência para um grupo, não meramente a frequência com que ele é recuperado sob perturbação dos dados.

### 1.12.1 Suporte de Bremer

O **índice de suporte de Bremer** (Bremer 1988) mede a diferença em custo entre o cladograma ótimo que contém um dado clado e o cladograma ótimo que não o contém. Um valor mais alto indica que mais evidência suporta o clado. Sob verossimilhança, é expresso como diferença nos escores de log-verossimilhança.

### 1.12.2 Jackknife

O **jackknife** (Farris et al. 1996) é um método de reamostragem sem reposição: um subconjunto de caracteres é deletado aleatoriamente em cada réplica, e a frequência com que cada clado aparece é reportada. O jackknife é considerado mais defensável teoricamente do que o bootstrap sob parcimônia porque não reamostra caracteres com reposição, o que distorce a independência dos caracteres (Farris et al. 1996).

### 1.12.3 Bootstrap

O **bootstrap** (Felsenstein 1985) reamostra caracteres com reposição; cada réplica é uma nova matriz do mesmo tamanho em que alguns caracteres estão ausentes e outros duplicados. As frequências de bootstrap são amplamente reportadas mas criticadas em bases teóricas (Farris et al. 1996). Jacob Machado et al. (2021b) investigaram a relação empírica entre valores de suporte de bootstrap e testes de razão de verossimilhança, encontrando uma relação positiva consistente, embora a correspondência precisa dependa das premissas do modelo e das propriedades dos dados.

## 1.13 Análise de Sensibilidade e Métricas de Comparação Topológica

### 1.13.1 Análise de Sensibilidade

Em sistemática filogenética, a **análise de sensibilidade** avalia em que medida as hipóteses obtidas são afetadas por variáveis analíticas como estratégias de busca, critérios de otimalidade, métodos de

alinhamento e esquemas de custos de transformação (Machado 2015; Wheeler 1995). Morrison e Ellis (1997) demonstraram que os resultados filogenéticos podem ser mais sensíveis a esses valores de parâmetros do que à escolha do método analítico.

Os resultados de uma análise de sensibilidade podem ser sumarizados de várias formas (Wheeler et al. 2006): (1) percentagem de conjuntos de parâmetros sob os quais cada nó é recuperado (Giribet et al. 2001); (2) gráficos "tapetes Navajo" (*Navajo rugs*), em que o espaço de parâmetros é uma grade bidimensional com monofilia de cada clado indicada por codificação de cores; (3) consenso dos clados recuperados sob todos os conjuntos de parâmetros. Conjuntos de parâmetros ótimos podem ser identificados minimizando a incongruência de partição entre subconjuntos de dados (Wheeler et al. 2006). O **Meta-Índice de Retenção** (MRI), calculado como o RI sobre todos os caracteres, foi proposto como métrica livre de partição para essa finalidade (Wheeler et al. 2006).

### 1.13.2 Distância de Robinson-Foulds

Originalmente proposta por Robinson e Foulds (1981), a **distância de Robinson-Foulds** (RF) é calculada pelo número de operações elementares necessárias para transformar uma árvore na outra, equivalente ao número de splits exclusivos a cada árvore. Uma limitação conhecida é que o deslocamento de um único OTU pode alterar múltiplos nós, fazendo com que a métrica superestime as diferenças entre duas topologias.

### 1.13.3 Distância de *Match Split*

A **distância de *match split*** (MS) para árvores filogenéticas binárias não-enraizadas é definida por Bogdanowicz e Giaro (2012) como o custo da melhor atribuição global entre as arestas internas das duas árvores comparadas. A distância MS é mais sensível do que a RF e, ao mesmo tempo, mais resistente ao deslocamento de um número pequeno de terminais (Bogdanowicz e Giaro 2012), tornando-a especialmente adequada para a identificação de táxons rogue.

## 1.14 Perspectivas e Debates em Aberto

### 1.14.1 Homologia Estática versus Dinâmica

O debate mais fundamental em filogenética molecular concerne ao papel do alinhamento múltiplo de sequências. Proponentes de homologia estática argumentam que o alinhamento é uma etapa necessária em que hipóteses de homologia posicional são explicitamente declaradas e avaliadas independentemente da árvore. Proponentes da homologia dinâmica argumentam que fixar alinhamentos antes da busca introduz viés dependente da topologia e impede a identificação do cladograma-mais-esquema-de-homologia globalmente ótimo (Wheeler et al. 2006). Redelings et al. (2024) fornecem evidência adicional sob a perspectiva dos InDels: a maioria dos algoritmos de alinhamento não é ciente da filogenia, introduz viés da árvore-guia e leva a uma superestimativa de eventos de perda independentes.

### 1.14.2 Tratamento de InDels

Redelings et al. (2024) identificam três abordagens dominantes para o tratamento de InDels: (1) exclusão de colunas contendo gaps; (2) tratamento de gaps como dados ausentes; e (3) codificação de InDels — que codifica cada evento de InDel como um caráter binário de presença/ausência

(Simmons et al. 2007). Modelos probabilísticos de InDels, como os baseados no arcabouço TKF (Thorne et al. 1991), oferecem um tratamento mais principiado, mas têm sido implementados em contextos relativamente limitados (Redelings et al. 2024). A ausência de um padrão ouro amplamente aceito para o tratamento de InDels permanece uma limitação significativa da prática filogenética contemporânea.

### 1.14.3 Incomensurabilidade entre Critérios de Otimalidade

Uma pontuação de parcimônia, um log-verossimilhança e uma probabilidade posterior Bayesiana não podem ser diretamente comparados entre métodos (Wheeler e Varón 2025). O PMDL aborda essa limitação expressando todos os componentes da hipótese filogenética em uma unidade comum de bits. Se o PMDL alcançará adoção empírica ampla dependerá de melhorias contínuas nas aproximações de limite superior usadas para estimar a complexidade de Kolmogorov e da disponibilidade de implementações amigáveis ao usuário (Wheeler e Varón 2025).

### 1.14.4 Árvores de Genes, Árvore de Espécies e Transferência Horizontal

Análises filogenômicas frequentemente recuperam incongruências entre árvores de genes, que podem surgir de coalescência profunda, hibridização, separação de linhagens incompleta ou transferência horizontal de genes (HGT). Wheeler (2012) adverte contra a tendência de atribuir toda a incongruência a HGT sem evidência independente, argumentando que isso é *ad hoc*. A modelagem explícita de eventos reticulados no PhyG (Wheeler et al. 2024) oferece uma alternativa rigorosa: se uma rede com nós de reticulação especificados fornece um escore PMDL significativamente menor do que a melhor árvore, a hipótese de rede é suportada pelos dados, não meramente assumida.

### 1.14.5 Sistemática Ponto-e-Clique

A democratização do software bioinformático tornou a análise filogenética acessível a investigadores com treinamento limitado nos fundamentos teóricos da disciplina. Grant et al. (2003) documentaram os riscos desse desenvolvimento, mostrando como a aplicação acrítica de parâmetros padrão, o tratamento inadequado de InDels e o uso de escolhas analíticas teoricamente injustificadas produzem resultados que superficialmente se assemelham à análise filogenética rigorosa enquanto carecem de seu fundamento lógico. A coerência epistemológica exigida pelo arcabouço cladístico demanda que os procedimentos analíticos sejam transparentes, repetíveis e teoricamente justificados (Wheeler et al. 2006).

## 1.15 Conclusão

Os conceitos de caráter, homologia e homoplasia formam uma tríade teórica interconectada que fundamenta toda a sistemática filogenética. Caracteres são séries de transformação carregadas de teoria. Homologia é uma hipótese dependente da árvore de ancestralidade compartilhada, que serve como hipótese nula na construção do cladograma. Homoplasia é uma transformação não-mínima específica da árvore que atua como falsificador do cladograma no qual é observada.

A comparação com grupo externo, a polaridade de caráter e o enraizamento são o mesmo problema, resolvido pela análise simultânea irrestrita de todos os terminais (Nixon e Carpenter 1993). A monofilia do grupo interno é uma hipótese sujeita a teste empírico, não uma suposição

prévia, e o procedimento de expansão sucessiva do grupo externo (Grant 2019) fornece um critério objetivo e repetível para limitar a amostra do grupo externo.

O sequenciamento de alto rendimento não alterou os fundamentos conceituais da filogenética; amplificou as consequências de como esses fundamentos são implementados. O tratamento de InDels como dados ausentes é uma fonte empiricamente demonstrada de erro topológico imprevisível e inflação de escore (Jacob Machado et al. 2021a). O arcabouço de homologia dinâmica, ao integrar o alinhamento de sequências e a busca em árvores em um único problema de otimização, fornece a abordagem mais coerente teoricamente. O PMDL (Wheeler e Varón 2025) fornece um critério unificado que pode dissolver a tripartição parcimônia-verossimilhança-Bayesiana expressando todas as formas de inferência filogenética em uma linguagem comum da teoria da informação.

**Roteiro de Revisão do Capítulo**

1. Caracteres são **indivíduos históricos** carregados de teoria (séries de transformação; Hennig 1966); filogenética = ciência **ideográfica**, não nomotética (Grant e Kluge 2004b; Popper 1959).
2. Cinco tipos de caráter: aditivo (Farris 1970), não-aditivo (Fitch 1971), Sankoff (Sankoff 1975), sequência e cromossômico (Wheeler et al. 2006); fenotípicos *vs.* genotípicos; evidência total (Kluge 1989).
3. Homologia ≠ sinapomorfia (Nixon e Carpenter 2012); homologia = hipótese nula na construção de grupos; relação histórica de identidade (Grant e Kluge 2004b).
4. Debate primária/secundária (de Pinna 1991): rejeitado (Grant e Kluge 2004b; Wheeler et al. 2006); nenhuma categoria intermediária necessária sob homologia dinâmica (Wheeler 2001a,b).
5. Homologia estática (alinhamento fixo) vs. dinâmica (otimização simultânea); alinhamentos implícitos: específicos de topologia e parâmetro (Wheeler 2003a).
6. InDels: 2ª maior fonte de variação genômica; gaps como missing data → TIA e topologias imprevisíveis (Jacob Machado et al. 2021a); índices GCI, NCI, SGI, TGI (Jacob Machado et al. 2021a).
7. Homoplasia como **falsificador** da árvore (Farris 1983; Kluge 2009); CI (Kluge e Farris 1969), RI (Farris 1989), decisividade ≠ homoplasia (Goloboff 1991).
8. Polaridade + grupo externo + enraizamento = **mesmo problema**; análise simultânea irrestrita (Nixon e Carpenter 1993). Lundberg rooting válido apenas com evidência independente (Nixon e Carpenter 1993).
9. Expansão sucessiva do grupo externo (Grant 2019); ingroup monophyly = hipótese a testar.
10. Análise simultânea / evidência total (Kluge 1989; Nixon e Carpenter 1996) vs. particionada (Grant e Kluge 2003).
11. 4 algoritmos de otimização: DO (Wheeler 1996), passagens iterativas (Wheeler 2003b), estados fixos (Wheeler 1999), baseado em busca (Wheeler 2003c); PhyG supera POY5 (Varón e Wheeler 2012; Wheeler et al. 2024).
12. Verossimilhança sob DH: GTR + gap como 5º estado; NCM ≡ parcimônia para árvores (Tuffley e Steel 1997).
13. Ponderação implicada: $F = K/(K + S)$ (Goloboff 1993, 2013); aproximações sucessivas (Farris 1969).
14. Suporte: Bremer (Bremer 1988), jackknife (Farris et al. 1996), bootstrap (Felsenstein 1985); relação bootstrap/LRT (Jacob Machado et al. 2021b).
15. 4 critérios: parcimônia (Farris 1983); ML; IB; PMDL: $K(H) = K(M) + K(D \mid M)$ (Wheeler e Varón 2025). Os três primeiros são **incomensuráveis**.
16. Redes *softwired* e *hardwired* no PhyG (Wheeler et al. 2024); custo *hardwired* ≥ melhor árvore de display.
17. Sensibilidade: Navajo rugs, MRI, incongruência de partição (Morrison e Ellis 1997; Wheeler 1995; Wheeler et al. 2006).
18. Sistemática ponto-e-clique: riscos de defaults acríticos (Grant et al. 2003). HGT ≠ explicação padrão para incongruência (Wheeler 2012).
19. Aplicações empíricas: Orthocoronavirinae (Jacob Machado et al. 2021c); epidemiologia genômica (Jacob Machado et al. 2021d).

## Referências


Bogdanowicz, D. e K. Giaro (2012). "Matching split distance for unrooted binary phylogenetic trees". Em: *IEEE/ACM Transactions on Computational Biology and Bioinformatics* 9, pp. 150–160. doi: 10.1109/TCBB.2011.48.

Bremer, K. (1988). "The limits of amino acid sequence data in angiosperm phylogenetic reconstruction". Em: *Evolution* 42, pp. 795–803. doi: 10.1111/j.1558-5646.1988.tb02497.x.

Farris, J. S. (1969). "A successive approximations approach to character weighting". Em: *Systematic Zoology* 18, pp. 374–385. doi: 10.2307/2412182.

Farris, J. S. (1970). "Methods for computing Wagner trees". Em: *Systematic Zoology* 19, pp. 83–92. doi: 10.2307/2412028.

Farris, J. S. (1983). "The logical basis of phylogenetic analysis". Em: *Advances in Cladistics*. Ed. por N. I. Platnick e V. A. Funk. New York: Columbia University Press, pp. 277–302.

Farris, J. S. (1989). "The retention index and the homoplasy excess". Em: *Systematic Zoology* 38, pp. 406–407. doi: 10.2307/2992406.

Farris, J. S., V. A. Albert, M. Källerjö, D. Lipscomb e A. G. Kluge (1996). "Parsimony jackknifing outperforms neighbor-joining". Em: *Cladistics* 12, pp. 99–124. doi: 10.1111/j.1096-0031.1996.tb00196.x.

Felsenstein, J. (1985). "Confidence limits on phylogenies: an approach using the bootstrap". Em: *Evolution* 39, pp. 783–791. doi: 10.1111/j.1558-5646.1985.tb00420.x.

Fitch, W. M. (1971). "Toward defining the course of evolution: minimum change for a specified tree topology". Em: *Systematic Zoology* 20, pp. 406–416. doi: 10.2307/2412116.

Giribet, G., G. D. Edgecombe e W. C. Wheeler (2001). "Arthropod phylogeny based on eight molecular loci and morphology". Em: *Nature* 413, pp. 157–161. doi: 10.1038/35093097.

Goloboff, P. A. (1991). "Homoplasy and the choice among cladograms". Em: *Cladistics* 7, pp. 215–232. doi: 10.1111/j.1096-0031.1991.tb00035.x.

Goloboff, P. A. (1993). "Estimating character weights during tree search". Em: *Cladistics* 9, pp. 83–91. doi: 10.1111/j.1096-0031.1993.tb00209.x.

Goloboff, P. A. (2013). "Extended implied weighting". Em: *Cladistics* 30, pp. 260–272. doi: 10.1111/cla.12047.

Goloboff, P. A., J. S. Farris e K. C. Nixon (2008). "TNT, a free program for phylogenetic analysis". Em: *Cladistics* 24, pp. 774–786. doi: 10.1111/j.1096-0031.2008.00217.x.

Grant, T. (2019). "Outgroup sampling in phylogenetics: severity of test and successive outgroup expansion". Em: *Journal of Zoological Systematics and Evolutionary Research* 57, pp. 748–763. doi: 10.1111/jzs.12303.

Grant, T., J. Faivovich e D. Pol (2003). "The perils of point-and-click systematics". Em: *Cladistics* 19, pp. 276–285. doi: 10.1111/j.1096-0031.2003.tb00371.x.

Grant, T. e A. G. Kluge (2003). "Data exploration in phylogenetic inference: scientific, heuristic, or neither". Em: *Cladistics* 19, pp. 379–418. doi: 10.1111/j.1096-0031.2003.tb00324.x.

Grant, T. e A. G. Kluge (2004a). "Perspectives: Explicit phylogenetic inference and character weighting". Em: *Cladistics* 20, pp. 1–6. doi: 10.1111/j.1096-0031.2004.00002.x.

Grant, T. e A. G. Kluge (2004b). "Transformation series as an ideographic character concept". Em: *Cladistics* 20, pp. 23–31. doi: 10.1111/j.1096-0031.2004.00003.x.

Grant, T. e A. G. Kluge (2008). "Clade support measures and their adequacy". Em: *Cladistics* 24, pp. 1051–1064. doi: 10.1111/j.1096-0031.2008.00231.x.

Hennig, W. (1966). *Phylogenetic Systematics*. Urbana, Illinois: University of Illinois Press.

Jacob Machado, D., S. Castroviejo-Fisher e T. Grant (2021a). "Evidence of absence treated as absence of evidence: the effects of variation in the number and distribution of gaps treated as missing data on the results of standard maximum likelihood analysis". Em: *Molecular Phylogenetics and Evolution* 154, p. 106966. doi: 10.1016/j.ympev.2020.106966.

Jacob Machado, D., R. Lyra e R. Hanner (2021b). "An empirical test of the relationship between the bootstrap and likelihood ratio test statistics in phylogenetics". Em: *Cladistics* 37, pp. 149–158. doi: 10.1111/cla.12422.

Jacob Machado, D., R. Lyra, S. Scott, S. Guirales e D. A. Janies (2021c). "Fundamental evolution of all *Orthocoronavirinae* including three deadly lineages descendent from Chiroptera-hosted coronaviruses: SARS-CoV, MERS-CoV and SARS-CoV-2". Em: *Cladistics* 37, pp. 461–488. doi: 10.1111/cla.12454.

Jacob Machado, D., R. A. White, J. Kofsky e D. A. Janies (2021d). "Fundamentals of genomic epidemiology, lessons learned from the coronavirus disease 2019 (COVID-19) pandemic, and new directions". Em: *Antimicrobial Stewardship & Healthcare Epidemiology* 1, e60. doi: 10.1017/ash.2021.222.

Kluge, A. G. (1989). "A concern for evidence and a phylogenetic hypothesis of relationships among *Epicrates* (Boidae, Serpentes)". Em: *Systematic Zoology* 38, pp. 7–25. doi: 10.2307/2992432.

Kluge, A. G. (2009). "Corroboration in cladistics". Em: *Evolutionary Biology* 36, pp. 186–190. doi: 10.1007/s11692-009-9064-4.

Kluge, A. G. e J. S. Farris (1969). "Quantitative phyletics and the evolution of anurans". Em: *Systematic Zoology* 18, pp. 1–32. doi: 10.2307/2412603.

Kolmogorov, A. N. (1968). "Some theorems on algorithmic entropy and the algorithmic quantity of information". Em: *Uspekhi Matematicheskikh Nauk* 23, p. 201.

Lankester, E. R. (1870). "On the use of the term homology in modern zoology, and the distinction between homogenetic and homoplastic agreements". Em: *Annals and Magazine of Natural History* 6, pp. 34–43.

Li, M. e P. Vitányi (1997). *An Introduction to Kolmogorov Complexity and Its Applications*. 2ª ed. New York: Springer.

Machado, D. J. (2015). "YBYRÁ facilitates comparison of large phylogenetic trees". Em: *BMC Bioinformatics* 16, p. 204. doi: 10.1186/s12859-015-0642-9.

Morrison, D. A. e J. T. Ellis (1997). "Effects of nucleotide sequence alignment on phylogeny estimation: a case study of 18S rDNAs of Apicomplexa". Em: *Molecular Biology and Evolution* 14, pp. 428–441. doi: 10.1093/oxfordjournals.molbev.a025784.

Nixon, K. C. e J. M. Carpenter (1993). "On outgroups". Em: *Cladistics* 9, pp. 413–426. doi: 10.1111/j.1096-0031.1993.tb00234.x.

Nixon, K. C. e J. M. Carpenter (1996). "On simultaneous analysis". Em: *Cladistics* 12, pp. 221–241. doi: 10.1111/j.1096-0031.1996.tb00010.x.

Nixon, K. C. e J. M. Carpenter (2012). "On homology". Em: *Cladistics* 28, pp. 160–169. doi: 10.1111/j.1096-0031.2011.00371.x.

Patterson, C. (1982). "Morphological characters and homology". Em: *Problems of Phylogenetic Reconstruction*. Ed. por K. A. Joysey e A. E. Friday. London: Academic Press, pp. 21–74.

Pinna, M. C. C. de (1991). "Concepts and tests of homology in the cladistic paradigm". Em: *Cladistics* 7, pp. 367–394. doi: 10.1111/j.1096-0031.1991.tb00045.x.

Popper, K. R. (1959). *The Logic of Scientific Discovery*. Originally published 1934 as *Logik der Forschung*. New York: Basic Books.

Redelings, B. D., I. Holmes, G. Lunter, T. Pupko e M. Anisimova (2024). "Insertions and deletions: computational methods, evolutionary dynamics, and biological applications". Em: *Molecular Biology and Evolution* 41, msae177. doi: 10.1093/molbev/msae177.

Robinson, D. F. e L. R. Foulds (1981). "Comparison of phylogenetic trees". Em: *Mathematical Biosciences* 53, pp. 131–147. doi: 10.1016/0025-5564(81)90043-2.

Sankoff, D. (1975). "Minimal mutation trees of sequences". Em: *SIAM Journal on Applied Mathematics* 28, pp. 35–42. doi: 10.1137/0128004.

Sankoff, D. e P. Rousseau (1975). "Locating the vertices of a Steiner tree in arbitrary space". Em: *Mathematical Programming* 9, pp. 240–246. doi: 10.1007/BF01681346.

Schuh, R. T. e A. V. Z. Brower (2009). *Biological Systematics: Principles and Applications*. 2ª ed. Ithaca, New York: Cornell University Press. 311 pp.

Simmons, M. P., K. Müller e A. P. Norton (2007). "The relative performance of InDel-coding methods in simulations". Em: *Molecular Phylogenetics and Evolution* 44, pp. 724–740. doi: 10.1016/j.ympev.2007.04.001.

Thorne, J. L., H. Kishino e J. Felsenstein (1991). "An evolutionary model for maximum likelihood alignment of DNA sequences". Em: *Journal of Molecular Evolution* 33, pp. 114–124. doi: 10.1007/BF02193625.

Tuffley, C. e M. Steel (1997). "Links between maximum likelihood and maximum parsimony under a simple model of site substitution". Em: *Bulletin of Mathematical Biology* 59, pp. 581–607. doi: 10.1007/BF02459467.

Varón, A. e W. C. Wheeler (2012). "The tree-alignment problem". Em: *BMC Bioinformatics* 13, p. 293. doi: 10.1186/1471-2105-13-293.

Wheeler, W. C. (1995). "Sequence alignment, parameter sensitivity, and the phylogenetic analysis of molecular data". Em: *Systematic Biology* 44, pp. 321–331. doi: 10.2307/2413570.

Wheeler, W. C. (1996). "Optimization alignment: the end of multiple sequence alignment in phylogenetics?" Em: *Cladistics* 12, pp. 1–9. doi: 10.1111/j.1096-0031.1996.tb00086.x.

Wheeler, W. C. (1999). "Fixed character states and the optimization of molecular sequence data". Em: *Cladistics* 15, pp. 379–385. doi: 10.1111/j.1096-0031.1999.tb00272.x.

Wheeler, W. C. (2001a). "Homology and DNA sequence data". Em: *The Character Concept in Evolutionary Biology*. Ed. por G. P. Wagner. San Diego: Academic Press, pp. 303–317.

Wheeler, W. C. (2001b). "Homology and the optimization of DNA sequence data". Em: *Cladistics* 17, S3–S11. doi: 10.1111/j.1096-0031.2001.tb00105.x.

Wheeler, W. C. (2003a). "Implied alignment: a synapomorphy-based multiple-sequence alignment method and its use in cladogram search". Em: *Cladistics* 19, pp. 261–268. doi: 10.1111/j.1096-0031.2003.tb00368.x.

Wheeler, W. C. (2003b). "Iterative pass optimization of sequence data". Em: *Cladistics* 19, pp. 254–260. doi: 10.1111/j.1096-0031.2003.tb00367.x.

Wheeler, W. C. (2003c). "Search-based optimization". Em: *Cladistics* 19, pp. 348–355. doi: 10.1111/j.1096-0031.2003.tb00380.x.

Wheeler, W. C. (2012). *Systematics: A Course of Lectures*. Hoboken, New Jersey: Wiley-Blackwell. 426 pp.

Wheeler, W. C., R. DeSalle e G. Giribet (2006). *Dynamic Homology and Phylogenetic Systematics: A Unified Approach Using POY*. New York: American Museum of Natural History Press. 365 pp.

Wheeler, W. C. e A. Varón (2025). "Phylogenetic minimum description length: an optimality criterion based on algorithmic complexity". Em: *Cladistics* 41, pp. 193–211. doi: 10.1111/cla.12589.

Wheeler, W. C., A. Washburn e L. M. Crowley (2024). "PhylogeneticGraph (PhyG): a new phylogenetic graph search and optimization program". Em: *Cladistics* 40, pp. 97–105. doi: 10.1111/cla.12563.

# Capítulo 2

# Métodos de Inferência Probabilística para Reconstrução Filogenômica

## 2.1 Introdução

A reconstrução de relações filogenéticas a partir de dados genômicos situa-se na intersecção da biologia evolutiva, estatística e ciência computacional. Nos últimos três decênios, o paradigma analítico dominante em filogenética deslocou-se de métodos baseados em parcimônia para abordagens probabilísticas — máxima verossimilhança (MV) e inferência Bayesiana (IB). Este deslocamento foi impulsionado pela explosão de dados de sequências moleculares, pelo desenvolvimento de modelos cada vez mais sofisticados de evolução de sequências e pela disponibilidade de poder computacional que teria parecido fantástico aos sistematas dos anos 1990.

Como Wheeler (2012) nos lembra, "não existe uma única resposta para 'qual é o melhor método?' da mesma forma que não existe uma única resposta para 'qual é a melhor árvore?' Um critério deve ser especificado em ambos os casos" (Wheeler 2012). A escolha de um marco probabilístico é ela própria uma hipótese sobre como a inferência deve proceder — e é uma que tem sido vigorosamente contestada em fundamentos teóricos, filosóficos e práticos.

## 2.2 Fundamentos Teóricos da Probabilidade em Filogenética

### 2.2.1 A Função de Verossimilhança

A verossimilhança de uma árvore $T$ dado dados $D$ é proporcional à probabilidade dos dados dada a árvore (Edwards 1972):

$$l(T|D) \propto \Pr(D|T)$$

Um método sistemático de MV seleciona a árvore $T$ que maximiza $\Pr(D|T)$. Esta maximização requer especificar um conjunto de *parâmetros de incômodo* (*nuisance parameters*) $\theta$, definidos como todas as quantidades necessárias para calcular $\Pr(D|T)$ além dos dados e da topologia da árvore (Wheeler 2012). Os três parâmetros de incômodo mais consequentes são: (1) o modelo de transformação de caracteres; (2) parâmetros de ramo (comprimentos de ramo); e (3) a distribuição de taxas de mudança entre caracteres.

### 2.2.2 O Modelo Markov Geral

A descrição reversível mais geral de mudança de caráter para $n$ estados é especificada por uma matriz de taxa instantânea $R$ e um vetor de frequência estacionária $\boldsymbol{\pi}$. As condições de simetria impostas em $R$ são:

$$\forall i,\ R_{ii} = 0; \quad \forall i, j,\ R_{ij} = R_{ji}; \quad \sum_{i=1}^{n}\sum_{j=1}^{n} \pi_i \cdot \pi_j \cdot R_{ij} = 1$$

**É assim que leríamos essa equação, passo-a-passo:**

- **Parte 1:** "Para todo $i$, erre-sub-ii é igual a zero;"
- **Parte 2:** "Para todo $i$ e $j$, erre-sub-ij é igual a erre-sub-ji;"
- **Parte 3:** "O somatório duplo, com $i$ e $j$ de 1 até $n$, de pi-sub-i vezes pi-sub-j vezes erre-sub-ij é igual a 1."

**Veja algumas observações de pronúncia e contexto:**

| Símbolo | Descrição e Pronúncia |
|---|---|
| $\forall$ | Lido como "Para todo" ou "Qualquer que seja". |
| $R_{ii}, R_{ij}$ | Pronuncia-se a letra e os índices ("erre-ii" ou "erre-ij"). |
| $\pi_i$ | O som de $\pi$ em português é sempre "pí", nunca "pái". |
| $\sum\sum$ | Chamado de "Somatório duplo". |
| $n$ | Lido simplesmente como a letra "ene". |

Estas matrizes são combinadas na matriz de taxa $Q$:

$$Q_{ij} = \begin{cases} R_{i,j} \cdot \pi_j & \text{se } i \neq j \\ -\sum_{m=1}^{n} R_{i,m} \cdot \pi_m & \text{se } i = j \end{cases}$$

A probabilidade de mudança entre estados $i$ e $j$ em tempo $t$ é:

$$P_{i,j}(t) = \sum_{m=1}^{n} e^{\lambda_m t} \cdot U_{m,i} \cdot U^{-1}_{j,m}$$

onde $\lambda_m$ (lâmbda-sub-$m$) são os autovalores de $Q$, $U$ é a matriz de autovetores e $U^{-1}$ sua inversa.

## 2.3 Classificação de Métodos de Verossimilhança Máxima

### 2.3.1 O Conceito de Parâmetros de Incômodo

Wheeler (2012) apresenta uma classificação hierárquica dos métodos de verossimilhança usados em sistemática. A ideia-chave é que cada método difere em *como trata os parâmetros de incômodo e as atribuições de estados ancestrais.* Este é um ponto fundamental frequentemente negligenciado: diferentes formulações do que exatamente está sendo maximizado — médias sobre estados (MVM),

melhores estados em nós (MVP), ou melhores caminhos evolutivos completos (VPC) — levam a métodos genuinamente diferentes com propriedades distintas.

### 2.3.2 Máxima Verossimilhança Integrada (MVI)

Se conhecêssemos a distribuição de parâmetros de incômodo, $\Phi(\theta|T)$, poderíamos integrá-los fora do espaço de parâmetros $\Theta$:

$$p(D|T) = \int p(D|T,\theta)d\Phi(\theta|T)$$

**Assim leríamos esta equação, passo-a-passo:**

- **Lado Esquerdo:** "A probabilidade pê ($p$) de dê ($D$) dado tê ($T$) é igual a..."
- **Lado Direito:** "A integral da probabilidade pê ($p$) de dê ($D$) dado tê ($T$) e teta ($\theta$), em relação à medida fi ($\Phi$) de teta ($\theta$) dado tê ($T$)."
- **Leitura Fluida:** "A probabilidade de D dado T é a integral da verossimilhança de D dado T e teta ($\theta$), integrada sobre a distribuição *a priori* (ou medida) de teta ($\theta$) dado T."

**Algumas observações de pronúncia e contexto:**

| Símbolo | Descrição e Pronúncia |
|---|---|
| $p(A\|B)$ | O traço vertical "\|" é sempre lido como **"dado"**. |
| $\int$ | Lido como **"Integral"**. |
| $\theta$ | Letra grega **"teta"**. |
| $\Phi$ | Letra grega **"fi"** (maiúsculo). |
| $d\Phi$ | O "$d$" indica o diferencial, lido como **"em relação a"** ou **"na medida de"**. |

A árvore que maximiza esta probabilidade integrada é a árvore de **Máxima Verossimilhança Integrada** (MVI). Esta é a abordagem teoricamente mais satisfatória porque conta para nossa incerteza nos parâmetros de incômodo ao invés de escolher um único conjunto "melhor".

### 2.3.3 Máxima A Posteriori (MAP)

Se também temos uma **distribuição priori sobre árvores**, $p(T)$, podemos perguntar: qual árvore tem a maior probabilidade posterior? Székelyi e Steel (1999) mostraram que o método com a maior expectativa de retornar a árvore verdadeira seleciona a árvore maximizando $p(T) \times \Pr(D|T)$. Esta é a árvore de **Máxima A Posteriori** (MAP) — a estimativa Bayesiana.

Aqui está a conexão importante: quando todas as prioris de árvore são **iguais** (uma priori flat, não-informativa), a árvore MAP é idêntica à árvore MVI. Como Wheeler nota, "o uso de prioris de árvore não-uniformes (tais como empíricas ou Yule) quebra esta identidade" (Wheeler 2012).

### 2.3.4 Máxima Verossimilhança Relativa (MVR) e Suas Três Variantes

Na prática, raramente conhecemos a distribuição de parâmetros de incômodo. Ao invés de integrá-los, **otimizamos**: escolhemos $\theta$ para maximizar $p(D|T, \theta)$. Isto é chamado **Máxima Verossimilhança Relativa** (MVR), e é "em geral, a metodologia usada em análises empíricas" (Wheeler 2012).

#### Máxima Verossimilhança Média (MVM)

Este é o abordagem mais comumente usada. Ela **soma sobre todas as atribuições de estados possíveis de vértice**, ponderadas por suas probabilidades. Quando as pessoas referem-se a "MV" em análises filogenéticas típicas, geralmente significam MVM — e Wheeler nota que "para o restante desta discussão, quando falarmos de métodos de MV, estaremos referindo-nos a MVM" (Wheeler 2012).

Em MVM, os estados ancestrais são parâmetros de incômodo. Não nos importamos realmente qual estado um ancestral tinha; nos importamos com a verossimilhança da *árvore e dos dados*. A forma estatisticamente correta de remover quantidades desconhecidas de um cálculo de probabilidade é **marginalizar** (isto é, somar ou integrar) sobre elas, não otimizá-las.

#### Máxima Verossimilhança Mais Parcimoniosa (MVP)

Também sugerida por Barry e Hartigan (1987), MVP **atribui estados de vértice específicos** (junto com outros parâmetros) tais que a verossimilhança geral da árvore é maximizada. O nome insinua uma conexão com parcimônia, e de fato a ideia de selecionar estados ancestrais "melhores" soa similar. Porém, há um detalhe: em MVP, as **probabilidades de ramo são as mesmas sobre todos os caracteres**, então "MVP não escolherá (em geral) a mesma árvore que parcimônia" (Wheeler 2012).

MVP difere de MVM em que otimiza sobre estados ancestrais. Ela escolhe a atribuição única melhor. Em estatística, substituir uma integral por uma otimização é conhecido como tomar um estimador "plug-in" ou de ponto, e tende a **superestimar a evidência** para uma árvore particular.

#### Verossimilhança de Caminho Evolutivo (VCE)

Originalmente proposta por Farris (1973), VCE vai além de MVP. Ao invés de apenas especificar estados de vértice ancestrais, VCE especifica **a sequência inteira de estados de caráter intermediários entre vértices** tais que a verossimilhança geral da árvore é maximizada. Pense nela como maximizar a verossimilhança ao longo de cada único "caminho" evolutivo na árvore.

Um resultado notável: a árvore que maximiza VCE **é precisamente a árvore mais parcimoniosa**. Wheeler afirma isto diretamente:

> "A árvore que maximiza esta forma de verossimilhança é precisamente a árvore mais parcimoniosa. Este resultado se sustenta para um conjunto amplo e robusto de assunções (não há exigência de taxas baixas ou homogêneas de mudança de caráter, por exemplo)" (Wheeler 2012)

### 2.3.5 O Paradoxo: Felsenstein vs. Farris

A relação entre parcimônia e verossimilhança cria o que parece ser uma contradição. Felsenstein (1973, 1978) argumentou que métodos de MV são estatisticamente consistentes e mostrou que

a parcimônia pode ser inconsistente sob certas condições (a "Zona de Felsenstein," onde ramos longos se atraem mutuamente). Mas Farris (1973a) mostrou que parcimônia *é* um método de MV sob a formulação VCE. Se MV é consistente e parcimônia é MV, então parcimônia deveria ser consistente também—mas Felsenstein mostrou que nem sempre é. Wheeler (2012, p. 218) resolve este aparente paradoxo reconhecendo que Farris e Felsenstein estavam discutindo **formas diferentes de verossimilhança**: a MV de Felsenstein refere-se a MVM (média sobre estados ancestrais com um modelo comum entre caracteres), enquanto a MV de Farris refere-se a VCE (maximização sobre o caminho inteiro de mudanças evolutivas). São problemas de otimização genuinamente diferentes que podem produzir árvores ótimas diferentes. Os resultados de consistência de Felsenstein aplicam-se a MVM, não a VCE, e assim a contradição se dissolve.

### 2.3.6 Conexões Adicionais: Goldman (1990) e Tuffley & Steel (1997)

A ligação entre parcimônia e verossimilhança foi explorada por Goldman (1990), que mostrou que quando os pesos de aresta são constantes sobre a árvore, verossimilhança e parcimônia convergem (Goldman 1990). Tuffley e Steel (1997) introduziram o **modelo Sem-Mecanismo-Comum** (*No-Common-Mechanism*, NCM), onde cada caráter tem uma taxa potencialmente única que pode variar entre arestas (Tuffley e Steel 1997). Sob este modelo e uma estrutura tipo Neyman, a verossimilhança global torna-se uma função direta do comprimento de parcimônia. Porém, como Wheeler (2012, p. 224) alerta, esta equivalência se sustenta estritamente apenas "quando o número de estados de cada caráter ($r_i$) é uma constante sobre o conjunto de dados." Quando $r_i$ varia entre caracteres, a verossimilhança NCM introduz um fator de ponderação específico por caráter, de modo que "NCM pode ser visto como um esquema de ponderação de caracteres baseado em verossimilhança em análises de parcimônia" (Wheeler 2012).

É importante distinguir VCE do modelo NCM: VCE é uma variante em *como estados ancestrais são tratados*, situando-se dentro da classificação de Wheeler como um sabor de Máxima Verossimilhança Relativa. O modelo NCM, em contraste, é uma variante no *modelo evolutivo em si*. VCE produz uma equivalência exata com parcimônia sob condições muito gerais (sem exigência de taxas baixas ou homogêneas). NCM produz equivalência com parcimônia apenas condicionalmente—quando $r_i$ é constante entre caracteres. Apesar dessas diferenças, ambos os resultados convergem na mesma conclusão: que a parcimônia tem uma fundação principiada dentro da estrutura de verossimilhança.

## 2.4 A Perspectiva Bayesiana

### 2.4.1 Teorema de Bayes e Inferência Posterior

A inferência Bayesiana em filogenética reformula inferência de árvore usando o Teorema de Bayes. A probabilidade posterior de uma topologia $T$ dado dados $D$, parâmetros de substituição $\theta$, e pesos de ramo $t_T$ é:

$$p(T|D,\theta,t_T) = \frac{p(T)\cdot p(D|T,\theta,t_T)}{\sum_{T_j\in\tau} p(T_j)\cdot p(D|T_j,\theta,t_T)}$$

**Assim leríamos esta equação, passo-a-passo:**

- **Lado Esquerdo:** "A probabilidade pê ($p$) de tê ($T$) dado dê ($D$), teta ($\theta$) e tê sub-tê ($t_T$) é

igual a...”

- **Numerador:** “A probabilidade *a priori* de tê ($T$) vezes a verossimilhança de dê ($D$) dado tê ($T$), teta ($\theta$) e tê sub-tê ($t_T$)...”
- **Denominador:** “...dividido pelo somatório, para toda topologia tê-j ($T_j$) pertencente ao conjunto tau ($\tau$), da probabilidade de tê-sub-j ($T_j$) vezes a verossimilhança de dê ($D$) dado tê-sub-j ($T_j$), teta ($\theta$) e tê sub-tê ($t_T$).”
- **Leitura Fluida:** “A posterior da árvore $T$ é o produto da sua priori pela sua verossimilhança, normalizado pelo somatório das probabilidades de todas as topologias possíveis no espaço das árvores $\tau$.”

**Algumas observações de pronúncia e contexto:**

| Símbolo | Descrição e Pronúncia |
|---|---|
| $p(T)$ | Frequentemente chamada de **“priori”** da topologia. |
| $t_T$ | Lido como **“tê sub-tê”**, representa os comprimentos dos ramos da árvore $T$. |
| $\sum_{T_j \in \tau}$ | Lido como **“somatório para cada tê-j pertencente a tau”**. |
| $\tau$ | Letra grega **“tau”**, aqui representando o conjunto de todas as topologias possíveis. |
| $\frac{A}{B}$ | Em voz alta, dizemos o numerador e usamos a expressão **“sobre”** ou **“dividido por”** para o denominador (neste caso, $A$ sobre $B$ ou $A$ dividido por $B$). |

Integração sobre parâmetros de incômodo remove a condicionalidade sobre eles:

$$p(T|D) = \frac{\iint p(\theta), p(T|\theta), p(t_T|\theta, T), p(D|\theta, T, t_T)\ dt_T, d\theta}{\sum_{T_j \in \tau} \iint p(\theta), p(T_j|\theta), p(t_{T_j}|\theta, T_j), p(D|\theta, T_j, t_{T_j})\ dt_{T_j}, d\theta}$$

**Assim leríamos esta equação, passo-a-passo:**

- **Lado Esquerdo:** “A probabilidade posterior da árvore ($T$) dados apenas os dados ($D$).”
- **Numerador:** “A integral dupla sobre os parâmetros teta ($\theta$) e pesos de ramo ($t_T$) da probabilidade conjunta de todos os componentes do modelo.”
- **Denominador:** “O somatório, para todas as árvores possíveis ($T_j$), da mesma integral dupla realizada no numerador.”
- **Leitura Fluida:** “A probabilidade da topologia $T$ é a sua verossimilhança marginalizada sobre todos os possíveis valores de parâmetros e comprimentos de ramo, normalizada pela soma das verossimilhanças marginais de todas as outras topologias.”

**Algumas observações de pronúncia e contexto:**

| Símbolo | Descrição e Pronúncia |
|---|---|
| $\iint$ | Lido como **"Integral dupla"**. Representa a integração sobre múltiplos parâmetros simultaneamente. |
| $dt_T, d\theta$ | Indicam as variáveis de integração. Lemos como **"em relação a tê-sub-tê e teta"**. |
| Marginalização | O processo de usar integrais para "remover" parâmetros de incômodo $(\theta, t_T)$ e focar apenas no que interessa $(T)$. |
| $p(T\|D)$ | Note que $\theta$ e $t_T$ sumiram do lado esquerdo; isso ocorre porque foram **"integrados"** para fora da equação. |

### 2.4.2 Convergência Bayesiana e o Teorema de Bernstein-von Mises

Uma garantia teórica fundamental frequentemente citada em análise Bayesiana é que, dados dados suficientes, a distribuição posterior convergerá à "verdade". Isto é formalizado pelo **Teorema de Bernstein-von Mises** (BvM). O Teorema BvM afirma que sob condições de regularidade específicas, conforme a quantidade de dados (em filogenética, o comprimento de sequência $n$) aproxima-se do infinito, a distribuição posterior converge para uma distribuição normal multivariada centrada nos valores de parâmetros verdadeiros (ou no estimador de máxima verossimilhança), com variância encolhendo a zero (Vaart 1998).

Porém, é crítico reconhecer que esta garantia de convergência é tanto **assintótica** quanto **condicional**:

- **Assintótica.** Aplica-se estritamente apenas no limite conforme $n \to \infty$. Para qualquer alinhamento finito (que é tudo que temos), a garantia é uma aproximação cuja qualidade depende de quão grande $n$ é relativo à complexidade do problema.
- **Condicional.** A formulação padrão do Teorema BvM requer que o mecanismo gerador de dados verdadeiro (i.e., o processo biológico real que produziu as sequências) situe-se perfeitamente dentro do espaço de modelos predefinidos sendo explorado. Se o modelo verdadeiro $M_{\text{verdadeiro}}$ não é um elemento do espaço de modelos $\mathcal{M}$, as garantias fundamentais do Teorema BvM padrão não se aplicam diretamente.

### 2.4.3 Topologias Discretas e Espaço BHV

Uma sutileza adicional frequentemente negligenciada: o Teorema BvM clássico aplica-se a parâmetros contínuos em espaço euclidiano. Topologias de árvore, porém, são **objetos combinatórios discretos**. O espaço de parâmetros filogenético não é uma variedade suave. É, ao invés, uma coleção de ortantes (um por topologia) colados ao longo de suas fronteiras, formando o espaço de árvore Billera-Holmes-Vogtmann (BHV) (Billera et al. 2001).

O Teorema BvM pode ser aplicado aos parâmetros contínuos (comprimentos de ramo, parâmetros do modelo de substituição) *condicional em uma topologia fixada*, mas a convergência de probabilidade posterior sobre topologias é um problema separado e mais difícil. Para a topologia discreta em si, o

comportamento de convergência depende de condições adicionais, incluindo se a topologia verdadeira é identificável sob o modelo assumido, e se os dados fornecem sinal suficiente para distinguir entre topologias concorrentes.

**Explicando de forma simples: O Problema das Árvores**

Imagine que você está tentando mapear o caminho de uma estrada. Em uma geometria comum, você pode se mover suavemente para qualquer lado. Mas, na filogenética, mudar a estrutura de uma árvore (a "topologia") é como pular de um universo para outro.
Cada árvore possível é como uma sala separada. Você pode caminhar livremente dentro da sala (ajustando o tamanho dos ramos), mas para mudar quem é "parente" de quem, você precisa atravessar uma porta estreita que conecta essas salas. O **Espaço BHV** é o nome matemático para esse "labirinto de salas" coladas umas às outras. O desafio é que as regras normais de probabilidade funcionam bem dentro de cada sala, mas ficam muito mais complicadas quando tentamos decidir em qual sala os dados realmente deveriam estar.

**Consequências Práticas para a Pesquisa**

- **O Problema da Convergência (MCMC):** Como o espaço das árvores é um "labirinto de salas", os algoritmos (como os do MrBayes ou BEAST) muitas vezes ficam "presos" em uma sala (uma topologia) que parece boa, mas não conseguem encontrar a porta para uma sala ainda melhor. É por isso que exigimos milhões de gerações e o uso de múltiplas cadeias frias e quentes (MCMCMC).
- **Incerteza não-Euclidiana:** Você não pode simplesmente tirar a "média" de duas árvores diferentes para obter uma árvore média. Na prática, usamos o *Consenso de Maioria* ou *Árvores de Máxima Credibilidade de Clado* porque a média aritmética não faz sentido em espaços discretos.
- **Sinal Filogenético vs. Ruído:** Se a "verdade" estiver exatamente na fronteira entre duas salas (ex: uma radiação muito rápida onde o ramo interno é quase zero), o modelo pode oscilar infinitamente entre topologias, gerando suporte baixo (valores de posterior baixos) não por erro, mas pela própria geometria do espaço.

## 2.5 Especificação Incorreta de Modelo

### 2.5.1 Convergência para a Melhor Resposta Errada

Em filogenética, podemos afirmar com confiança que o modelo é *sempre* especificado incorretamente em algum grau. Evolução de sequência biológica é um processo profundamente complexo impulsionado por taxas de mutação heterogêneas, seleção natural operando em múltiplos níveis, assortimento incompleto de linhagens, transferência horizontal de genes, dinâmica populacional mutável, e processos de substituição dependentes de contexto. Modelos Markov padrão de evolução de sequência (*e.g.*, GTR+$\Gamma$) são abstrações matematicamente tratáveis.

Quando o modelo é especificado incorretamente ($M_{\text{verdadeiro}} \notin \mathcal{M}$), devemos perguntar: a que a distribuição posterior Bayesiana converge conforme o comprimento de sequência aumenta?

Sob especificação incorreta de modelo, a distribuição posterior não converge para a verdade

absoluta. Ao invés, conforme $n \to \infty$, a probabilidade posterior concentra-se nos valores de parâmetros dentro do espaço de modelos explorado que minimizam a divergência de Kullback-Leibler (KL) da distribuição verdadeira geradora de dados. Formalmente, convergência é para:

$$M^* = \arg\min_{M \in \mathcal{M}} D_{KL}(P_{\text{verdadeiro}} | P_M)$$

**Assim leríamos esta equação, passo-a-passo:**

- **Lado Esquerdo:** "M-estrela ($M^*$) é igual ao argumento do mínimo..."
- **Lado Direito:** "...sobre o conjunto de modelos M ($\mathcal{M}$), da Divergência de Kullback-Leibler ($D_{KL}$) entre a distribuição verdadeira ($P_{\text{verdadeiro}}$) e a distribuição do modelo ($P_M$)."
- **Leitura Fluida:** "O modelo ideal $M^*$ é aquele, dentro do nosso conjunto de modelos possíveis, que minimiza a perda de informação (Divergência KL) em relação à realidade dos dados."

**Algumas observações de pronúncia e contexto:**

| Símbolo | Descrição e Pronúncia |
|---|---|
| $M^*$ | O asterisco indica o valor **ótimo** ou a solução do problema. |
| $\arg\min$ | Não queremos o valor mínimo da distância, mas sim **qual modelo** gera esse mínimo. |
| $\mathcal{M}$ | Letra caligráfica representando o **espaço de busca** (todos os modelos que você está testando). |
| $D_{KL}(P\|Q)$ | A **Divergência de Kullback-Leibler**. Mede a "distância" (ou surpresa extra) entre duas distribuições. |

Este $M^*$ é às vezes chamado o valor de parâmetro "pseudo-verdadeiro": a melhor aproximação à verdade disponível dentro da família de modelo errada.

### 2.5.2 Consequência Topológica

Para parâmetros **contínuos** (comprimentos de ramo, taxas de substituição), convergência para o minimizador KL pode produzir valores que são "próximos o suficiente" para ser biologicamente úteis, mesmo que não exatamente corretos. Mas para topologia de árvore (um parâmetro **discreto**), as consequências de especificação incorreta são mais proeminentes.

Um modelo especificado incorretamente pode fazer a posterior concentrar-se em uma topologia que **não é a árvore verdadeira**, e esta concentração pode ocorrer com probabilidade posterior arbitrariamente alta conforme $n \to \infty$. Isto é o mecanismo subjacente ao fenômeno bem-documentado de inflação de probabilidade posterior: posteriores Bayesianas podem atribuir probabilidade aproximando-se a 1.0 a clados incorretos quando o modelo está errado (Cummings et al. 2003; Suzuki et al. 2002; Yang 2007).

Em filogenômica, onde conjuntos de dados massivos produzem superfícies de verossimilhança íngremes, este modo de falha torna-se especialmente perigoso: mais dados não corrige o erro mas ao invés aumenta a certeza com qual a resposta errada é entregue (Kumar et al. 2012).

## 2.6 Dados Finitos e *a priori* Inescapável

Embora teoremas assintóticos sejam valiosos para compreender propriedades teóricas de estimadores, **sistemática empírica lida exclusivamente com dados finitos**. O comprimento de sequência $n$ de qualquer alinhamento físico é sempre um inteiro finito.

Porque **operamos permanentemente em um regime de dados finitos**, o estado assintótico onde a verossimilhança perfeita domina *a priori* nunca é estritamente atingido.

Esta equação explica este estado assintótido do qual falamos acima:

$$\lim_{t\to\infty} P_t = \pi$$

**Assim leríamos esta definição, passo-a-passo:**

- **Expressão:** "O limite de pê-sub-tê ($P_t$), quando o tempo tê ($t$) tende ao infinito, é igual a pi ($\pi$)."
- **Significado Técnico:** "A distribuição do sistema converge para o seu estado estacionário (ou assintótico) $\pi$, independentemente de onde o sistema começou."
- **Leitura Fluida:** "Conforme o tempo passa indefinidamente, a configuração do sistema se estabiliza em uma distribuição de equilíbrio estável."

**Algumas observações de pronúncia e contexto:**

| Símbolo | Descrição e Pronúncia |
|---|---|
| $\lim_{t\to\infty}$ | Lido como **"Limite com tê tendendo ao infinito"**. Representa o comportamento de longo prazo. |
| $P_t$ | A distribuição de probabilidade no instante $t$. |
| $\pi$ | Em filogenética, representa as **frequências de equilíbrio** das bases (A, C, G, T) ou aminoácidos. |
| $\to$ | A seta é lida como **"tende a"** ou **"vai para"**. |

Agora, explicado o estado assintórico ao que nos referimos anteriornemte, podemos retornar à proporcionalidade do Teorema de Bayes:

$$P(\tau, \theta|X) \propto P(X|\tau, \theta)\, P(\tau, \theta)$$

**Assim leríamos esta equação, passo-a-passo:**

- **Lado Esquerdo:** "A probabilidade posterior de tau ($\tau$) e teta ($\theta$) dado xis ($X$) é proporcional a..."
- **Lado Direito:** "...a verossimilhança de xis ($X$) dado tau ($\tau$) e teta ($\theta$), vezes a probabilidade a priori de tau ($\tau$) e teta ($\theta$)."
- **Leitura Fluida:** "A posterior é proporcional ao produto da verossimilhança pela priori."

**Algumas observações de pronúncia e contexto:**

| Símbolo | Descrição e Pronúncia |
|---|---|
| $\propto$ | Lido como **"proporcional a"**. Substitui o sinal de igual quando omitimos o denominador. |
| $\tau$ | Letra grega **"tau"**. Em filogenética, quase sempre representa a **topologia da árvore**. |
| $\theta$ | Letra grega **"teta"**. Representa os **parâmetros do modelo** (como taxas de substituição). |
| $X$ | Representa os **dados observados** (as sequências de DNA ou aminoácidos). |

O posterior é sempre um compromisso matemático entre a informação contida nos dados (a verossimilhança) e a informação especificada antes dos dados serem observados (a priori). Conforme $n$ cresce, a superfície de verossimilhança torna-se mais acentuada e exerce muito mais alavancagem, aplanando o impacto relativo da priori. Porém, porque $n$ é finito, a verossimilhança nunca atinge precisão infinita.

Consequentemente, **a distribuição priori é estritamente *sempre* parte da resposta final**.

### 2.6.1 Influência Persistente da Priori

A influência da priori (ou "*prior*") não é uniforme através de todos os parâmetros. Para parâmetros do modelo de substituição (*e.g.*, entradas da matriz de taxa e frequências de base), quantidades moderadas de dados típicamente dominam prioris razoáveis, e o efeito prático da priori torna-se negligenciável. Estes são parâmetros para os quais os dados são altamente informativos, o espaço de parâmetros é baixo-dimensional, e diferentes prioris razoáveis convergem em posteriores similares.

Porém, para outros parâmetros listados abaixo, *a priori* pode persistir tenazmente:

- **Topologia de árvore.** *a priori* sobre topologias é uma distribuição de probabilidade sobre um espaço discreto combinatoriamente vasto. Para $n = 50$ táxons, há aproximadamente $2.8 \times 10^{76}$ árvores bifurcadas não-enraizadas. Uma priori uniforme atribui probabilidade infinitesimal a cada topologia, e diferentes prioris estruturais (uniforme vs. Yule vs. nascimento-morte) atribuem diferentes probabilidades a formas de árvore diferentes. Em regiões da árvore onde os dados carecem de sinal forte — radiações rápidas, internós curtos, substituições saturadas — a posterior sobre topologias concorrentes dependerá fortemente de qualquer priori que foi especificada.

- **Comprimentos de ramo próximos a zero.** Internós curtos, que caracterizam radiações rápidas e a "zona de anomalia" filogenômica, são precisamente os ramos onde os dados fornecem o mínimo de sinal e prioris tem a máxima influência. Brown *et al.* (2010) demonstraram que a priori exponencial de comprimento de ramo padrão em MrBayes pode produzir probabilidades posteriores inflacionadas e estimativas de comprimento de ramo não-confiáveis, não por um bug de software, mas porque a priori era inadvertidamente informativa de formas que interagiam mal com os dados. Rannala *et al.* (2012) confirmaram que prioris de comprimento de ramo

podem ter efeitos substanciais em probabilidades posteriores de árvore mesmo com conjuntos de dados moderadamente grandes.

- **Tempos de divergência.** Em análises de relógio molecular, *a priori* em taxas de ramo (*e.g.*, log-normal, exponencial, ou uniforme) pode deslocar datas de divergência estimadas por dezenas de milhões de anos. Wheeler (2012) sugere que "dada nossa falta de conhecimento, amostragem, linhagem, ambiental, e locus específicos (entre uma miríade de outros conhecidos e desconhecidos) efeitos, a distribuição uniforme pareceria tão apropriada quanto log-normal ou exponencial". Porém, uma priori uniforme em taxas é ela própria uma afirmação forte, atribuindo probabilidade priori igual a taxas biologicamente absurdas quanto a plausíveis. Toda priori diz *algo*, e "não sei" não é uma distribuição de probabilidade.

## 2.7 Práticas Responsáveis para Trabalhar com Prioris e Modelos

Se prioris sempre importam e modelos são sempre errados, a questão não é se estas limitações podem ser eliminadas (não podem). Ao invés, a questão torna-se como trabalhar responsavelmente dentro delas.

### 2.7.1 Análise de Sensibilidade

A resposta prática mais importante é variar ambas as prioris e modelos e examinar como os resultados mudam. Se um clado é apoiado sob uma priori mas não sob outra, ou sob um modelo mas não outro, os dados não são fortes o suficiente para apoiar aquele clado independentemente do método. Esta lógica paralela a recomendação de Wheeler (2012, Seção 10.11) para análise de sensibilidade sob regimes de custo diferente em parcimônia. Conclusões robustas a assunções analíticas são mais confiáveis que aquelas que não são.

### 2.7.2 Teste de Adequação de Modelo

Ao invés de assumir que o modelo escolhido é "próximo o suficiente", pesquisadores devem explicitamente testar se o modelo ajusta-se aos dados, usando ferramentas tais como simulações preditivas posteriores e avaliações de adequação de modelo. Se o modelo falha seu próprio teste de qualidade de ajuste, o posterior que produz é condicional em uma assunção inadequada, e nenhuma quantidade de dados a resgatará.

**O Problema da Adequação do Modelo (*Model Adequacy*)**

- **Seleção vs. Adequação:** Selecionar um modelo é como escolher o sapato que melhor serve entre três opções pequenas. Adequação é medir se o seu pé realmente cabe em algum deles. Se todos forem pequenos, o "melhor" ainda machucará seu pé.
- **Simulações Preditivas Posteriores (PPS):** É um teste de "sanidade". O software usa os resultados da sua análise para gerar dados sintéticos (fictícios). Se os dados simulados pelo modelo forem completamente diferentes dos seus dados reais de DNA, o modelo não "entendeu" o processo biológico.
- **O Perigo da Quantidade de Dados:** Existe um mito de que ter muitos dados (filogenômica) corrige modelos ruins. Muito pelo contrário! Se o modelo está errado, mais dados apenas darão a ele mais confiança para chegar na **resposta errada** com alta probabilidade posterior.

### 2.7.3 Relatório Honesto de Incerteza

Uma probabilidade posterior de 1.0 para um clado significa "este clado é esmagadoramente apoiado **dado** o modelo e as prioris." Não significa que "este clado é certamente correto." Relatando suporte de clado juntamente com fatores de concordância que quantificam quanta proporção do genoma realmente apoia um clado dado fornecerá uma figura mais honesta da evidência que probabilidades posteriores sozinhas.

**Posterior 1.0 vs. Realidade Biológica**

- **A Ilusão do 1.0:** Em grandes conjuntos de dados (filogenômica), a probabilidade posterior frequentemente "infla" para 1.0. Isso ocorre porque o modelo Bayesiano acumula tanta evidência matemática que ele se torna "matematicamente certo", mesmo que o modelo em si esteja simplificando demais a biologia.
- **Sinal Conflitante:** O genoma não é uma unidade única. Diferentes genes podem ter histórias diferentes (devido a triagem incompleta de linhagens ou hibridização). Um posterior de 1.0 pode esconder o fato de que, por exemplo, 40% dos dados dos seus genes apoiam uma árvore diferente.
- **Fatores de Concordância (CF):** Ao contrário do posterior, os CFs (como o *Gene Concordance Factor*) dizem: "De todos os genes que olhamos, quantos realmente mostram esse clado?". Se o posterior é 1.0 mas o CF é 0.2, você sabe que o suporte é forte matematicamente, mas há um conflito biológico massivo subjacente.

## 2.8 Parcimônia Reconsiderada: Premissas para um Critério Alternativo

As seções precedentes demonstraram que métodos probabilísticos repousam sobre assunções—especificação correta de modelo, dados infinitos, prioris bem-comportadas—que nunca são plenamente satisfeitas na prática. Isto levanta uma questão natural: pode o caso para parcimônia ser construído

em seus próprios termos, não meramente como um caso especial de verossimilhança, mas como um critério mais adequado às realidades da inferência filogenética?

### 2.8.1 Premissas

Várias premissas sustentam este argumento. Primeiro, todos os modelos são incorretos, e incorreção do modelo não é meramente imprecisa—pode ser ativamente enganosa. Como Wheeler (2012, p. 279) afirma, a consistência de MV requer "que o modelo usado para reconstrução seja o mesmo que gerou a árvore em primeiro lugar. Em geral, verossimilhança será inconsistente caso contrário." Chang (1996) mostrou que mesmo um caso tão simples quanto usar um modelo quando o cenário verdadeiro foi gerado por dois destrói a consistência (Chang 1996). Segundo, consistência estatística é uma garantia assintótica que é rotineiramente violada na prática: dados empíricos de sequência não são independentes, não são identicamente distribuídos, e são finitos (Wheeler 2012). Terceiro, a própria MV sofre de falhas sistemáticas: Pol e Siddall (2001) demonstraram que verossimilhança é propensa a atração de ramos longos independentemente da correção do modelo, e a "Zona de Farris" (Siddall, 1998)—um modo de falha não encontrado em análises de parcimônia—mostra que parcimônia pode superar verossimilhança sob condições específicas (Pol e Siddall 2001; Siddall 1998). Quarto, a história evolutiva de cada caráter é única, moldada por pressões seletivas únicas, dinâmicas populacionais e contextos mutacionais; tratar caracteres como tendo taxas evolutivas não correlacionadas (como no modelo NCM) é biologicamente mais realista do que impor uma única distribuição paramétrica compartilhada entre todos os sítios e linhagens (Tuffley e Steel 1997).

### 2.8.2 Vantagens Práticas da Parcimônia

A partir destas premissas, várias vantagens práticas se seguem. A parcimônia é **não-paramétrica e robusta**: não assume um modelo específico de evolução de caracteres, e portanto não pode ser enganada por especificação incorreta de modelo da forma que métodos de MV e Bayesianos podem. A parcimônia **evita o problema de parâmetros de incômodo**: não requer especificar comprimentos de ramo, distribuições de taxas, ou frequências de base, todos os quais introduzem dimensões adicionais de incerteza e erro potencial. A parcimônia é **computacionalmente eficiente**: porque não requer exponenciação de matrizes ou otimização numérica de parâmetros contínuos, pontuar árvores sob parcimônia é substancialmente mais rápido, permitindo buscas mais completas do espaço de árvores. Finalmente, a parcimônia tem **poder explicativo máximo** no sentido cladístico: minimiza o número de hipóteses *ad hoc* de homoplasia requeridas para explicar os dados, preferindo assim a árvore que explica mais distribuições de caracteres como eventos históricos ao invés de convergências (Farris 1983).

## 2.9 Conclusão

Inferência filogenética probabilística é uma ferramenta matematicamente rigorosa e praticamente poderosa, mas seus resultados devem ser interpretados com uma compreensão clara de seus limites matemáticos. A convergência de posteriores à "verdade" é uma garantia assintótica aplicável a parâmetros contínuos condicional na assunção não-realista de especificação de modelo perfeita. Esta garantia não se estende diretamente a topologias de árvore discretas. Em realidade biológica, modelos são sempre aproximações, significando que sob especificação incorreta, inferência converge

para a melhor aproximação disponível dentro da família de modelo errada. No caso da topologia de árvore, isto pode significar convergência a uma árvore incorreta com alta confiança.

Além disso, a natureza finita de quaisquer dados genômicos garante que assunções prioris continuem permanentemente um ingrediente ativo nas distribuições posteriores que calculamos, com sua influência persistindo mais fortemente precisamente onde precisamos de confiabilidade: em ramos curtos, em radiações rápidas, e em estimativas de tempo de divergência. Como nossa compreensão coletiva de métodos Bayesianos evolui com o tempo, eles podem ou não permanecer populares e considerados uma ferramenta flexível e informativa. Porém, devem ser usados com a honestidade intelectual que exigem: testando adequação de modelo, conduzindo análises de sensibilidade, e relatando incerteza de forma que distinga o que os dados dizem do que as assunções contribuem.

**Roteiro de Revisão do Capítulo**

1. Verossimilhança: $l(T|D) \propto \Pr(D|T)$; parâmetros de incômodo $\theta$: modelo de substituição, comprimentos de ramo, distribuição de taxas (Edwards 1972; Wheeler 2012).
2. Quatro formas de verossimilhança (Wheeler, 2012): **MVM** (soma sobre estados ancestrais — o "MV" padrão), **MVP** (otimiza estados nos nós), **VCE** (Farris, 1973 — especifica caminho evolutivo completo; $\text{VCE}_{\max} \equiv$ parcimônia) e **MVI** (integra sobre $\theta$; = MAP com priori plana).
3. Paradoxo Felsenstein–Farris: resolvido reconhecendo que a "MV" de Felsenstein = MVM (média sobre estados ancestrais), a "MV" de Farris = VCE (maximização de caminhos evolutivos completos); são critérios de otimização diferentes.
4. Modelo Sem-Mecanismo-Comum (NCM) (Tuffley & Steel, 1997): cada caráter tem taxa única por aresta; sob $r_i$ constante, verossimilhança NCM $\equiv$ parcimônia; difere de VCE (que é variante no tratamento de estados ancestrais, não no modelo em si).
5. Premissas para parcimônia: especificação incorreta de modelo destrói consistência de MV (Chang, 1996); MV também inconsistente na "Zona de Farris" (Siddall, 1998); parcimônia é não-paramétrica, evita parâmetros de incômodo, é computacionalmente eficiente e maximiza poder explicativo.
6. Teorema de Bernstein–von Mises (BvM): posterior $\to$ normal centrada na verdade quando $n \to \infty$ — mas **assintótico** e **condicional** ao modelo verdadeiro $\in \mathcal{M}$.
7. Topologias são objetos discretos; espaço BHV (Billera–Holmes–Vogtmann, 2001) não é variedade suave; BvM para topologias é problema separado.
8. Especificação incorreta ($M_{\text{verdadeiro}} \notin \mathcal{M}$): posterior converge ao minimizador KL $M^* = \arg\min D_{KL}(P_{\text{verdadeiro}} \| P_M)$, não à verdade.
9. Consequência: mais dados $\Rightarrow$ maior certeza na resposta **errada** (inflação de probabilidade posterior) (Kumar et al. 2012; Suzuki et al. 2002).
10. Priori é **sempre** ingrediente ativo com dados finitos; influência persiste em: topologias (espaço combinatório $\sim 2{,}8 \times 10^{76}$ para 50 táxons), ramos curtos (radiações rápidas) e tempos de divergência.
11. Priori exponencial padrão de comprimento de ramo em MrBayes pode inflacionar posteriores (Brown et al., 2010; Rannala et al., 2012).
12. Práticas responsáveis: análise de sensibilidade (variar prioris e modelos), teste de adequação de modelo (simulações preditivas posteriores), relatório honesto de incerteza (fatores de concordância).

## Referências


Billera, L. J., S. P. Holmes e K. Vogtmann (2001). "Geometry of the space of phylogenetic trees". Em: *Advances in Applied Mathematics* 27, pp. 733–767.

Chang, J. T. (1996). "Full reconstruction of Markov models on evolutionary trees: identifiability and consistency". Em: *Mathematical Biosciences* 137.1, pp. 51–73. doi: 10.1016/S0025-5564(96)00075-2.

Cummings, M. P., S. A. Handley, D. S. Myers, D. L. Reed, A. Rokas e K. Winka (2003). "Comparing bootstrap and posterior probability values in the four-taxon case". Em: *Systematic Biology* 52, pp. 477–487.

Edwards, A. W. F. (1972). *Likelihood*. Cambridge, UK: Cambridge University Press.

Farris, J. S. (1983). "The logical basis of phylogenetic analysis". Em: *Advances in Cladistics*. Ed. por N. I. Platnick e V. A. Funk. New York: Columbia University Press, pp. 277–302.

Goldman, N. (1990). "Maximum likelihood inference of phylogenetic trees, with special reference to a Poisson process model of DNA substitution and to parsimony analyses". Em: *Systematic Zoology* 39, pp. 345–361.

Kumar, S., A. J. Filipski, F. U. Battistuzzi, S. L. Kosakovsky Pond e K. Tamura (2012). "Statistics and truth in phylogenomics". Em: *Molecular Biology and Evolution* 29, pp. 457–472.

Pol, D. e M. E. Siddall (2001). "Biases in maximum likelihood and parsimony: a simulation approach to a 10-taxon case". Em: *Cladistics* 17.3, pp. 266–281. doi: 10.1111/j.1096-0031.2001.tb00126.x.

Siddall, M. E. (1998). "Success of parsimony in the four-taxon case: long-branch repulsion by likelihood in the Farris zone". Em: *Cladistics* 14.3, pp. 209–220. doi: 10.1111/j.1096-0031.1998.tb00334.x.

Suzuki, Y., G. V. Glazko e M. Nei (2002). "Overcredibility of molecular phylogenies obtained by Bayesian phylogenetics". Em: *Proceedings of the National Academy of Sciences* 99, pp. 16138–16143.

Tuffley, C. e M. Steel (1997). "Links between maximum likelihood and maximum parsimony under a simple model of site substitution". Em: *Bulletin of Mathematical Biology* 59, pp. 581–607.

Vaart, A. W. van der (1998). *Asymptotic Statistics*. Cambridge, UK: Cambridge University Press.

Wheeler, W. C. (2012). *Systematics: A Course of Lectures*. Hoboken, New Jersey: Wiley-Blackwell. 426 pp.

Yang, Z. (2007). "Fair-balance paradox, star-tree paradox, and Bayesian phylogenetics". Em: *Molecular Biology and Evolution* 24, pp. 1639–1655.

# Capítulo 3

# Modelos de Substituição na Reconstrução Filogenética

## 3.1 Introdução

A reconstrução filogenética a partir de dados de sequências moleculares requer um marco probabilístico explícito para modelar como caracteres mudam ao longo de uma árvore. Este marco é incorporado em modelos de substituição, que especificam as taxas instantâneas de mudança entre estados de caracteres e as frequências estacionárias desses estados. Modelos de substituição fundamentam dois critérios de otimalidade principais na sistemática moderna: máxima verossimilhança (MV) e probabilidade posterior Bayesiana. Ambos os critérios compartilham um núcleo probabilístico comum mas diferem em como tratam parâmetros desconhecidos e como resumem inferência.

Este capítulo sintetiza os princípios teóricos, estratégias de implementação, limites interpretativos e desenvolvimentos recentes associados com modelos de substituição em análise filogenética. As fontes primárias são capítulos 11 e 12 de Wheeler (2012), que tratam critérios de otimalidade de verossimilhança e Bayesiana respectivamente.

## 3.2 Princípios Teóricos

### 3.2.1 A Função de Verossimilhança em Sistemática

Note que esta seção já foi explicada no capítulo anterior, ande detalhes adicionais são fornecidos para auxiliar a compreender as equações. Aqui, algumas informações são repetidas para auxiliar o estudo do material em detrimento do número de páginas.

A fundação da filogenética baseada em modelos é a função de verossimilhança. Para uma árvore $T$ e dados $D$, a verossimilhança é proporcional à probabilidade dos dados dada a árvore e um conjunto de parâmetros (Edwards 1972):

$$l(T|D) \propto \Pr(D|T)$$

Um método sistemático de MV seleciona a árvore $T$ que maximiza $\Pr(D|T)$. Esta maximização requer especificar um conjunto de *parâmetros de incômodo* $\theta$, definidos como todas as quantidades necessárias para calcular $\Pr(D|T)$ além dos dados e da topologia de árvore (Wheeler 2012). Os

três parâmetros de incômodo mais consequentes são: (1) o modelo de transformação de caracteres; (2) parâmetros de ramo (comprimentos de ramo); e (3) a distribuição de taxas de mudança entre caracteres.

### 3.2.2 O Modelo Markov Geral Reversível

Note que esta seção já foi explicada no capítulo anterior, ande detalhes adicionais são fornecidos para auxiliar a compreender as equações. Aqui, algumas informações são repetidas para auxiliar o estudo do material em detrimento do número de páginas.

A descrição reversível mais geral de mudança de caráter para $n$ estados é especificada por uma matriz de taxa instantânea $R$ e um vetor de frequência estacionária $\boldsymbol{\pi}$ (Tavbré 1986; Yang 1994). As condições de simetria impostas em $R$ são:

$$\forall i,\ R_{ii} = 0; \quad \forall i, j,\ R_{ij} = R_{ji}; \quad \sum_{i=1}^{n}\sum_{j=1}^{n} \pi_i \cdot \pi_j \cdot R_{ij} = 1$$

Estas matrizes são combinadas na matriz de taxa $Q$ de Tavaré (1986):

$$Q_{ij} = \begin{cases} R_{i,j} \cdot \pi_j & \text{se } i \neq j \\ -\sum_{m=1}^{n} R_{i,m} \cdot \pi_m & \text{se } i = j \end{cases}$$

A probabilidade de mudança entre estados $i$ e $j$ ao longo do tempo $t$ é então:

$$P_{i,j}(t) = \sum_{m=1}^{n} e^{\lambda_m t} \cdot U_{m,i} \cdot U^{-1}_{j,m}$$

onde $\lambda_m$ são os autovalores de $Q$, $U$ é a matriz de autovetores, e $U^{-1}$ sua inversa (Strang 2006). A restrição de reversibilidade no tempo permite computação eficiente de verossimilhanças de árvore (Wheeler 2012).

Esta formulação acomoda no máximo $n-1$ parâmetros de frequência independentes e $\binom{n}{2} - 1$ parâmetros de taxa independentes.

### 3.2.3 Modelos Nomeados como Casos Especiais

Todos os modelos de substituição em uso atual são restrições do processo reversível geral através de requisitos de simetria adicionais (Wheeler 2012). A hierarquia de menos a mais parametrizado para dados de nucleotídeos é documentada em Swofford et al. (1996) e inclui, entre outros:

- **JC69** (Jukes e Cantor, 1969): um tipo único de substituição com frequências de base iguais. Este é o modelo mais restringido e o único com zero parâmetros livres (além de comprimentos de ramo).
- **K2P** (Kimura, 1980): distingue transições de transversões com frequências de base iguais.
- **HKY85** (Hasegawa et al., 1985): transições versus transversões com frequências de base desiguais.
- **GTR** (Lanave et al., 1984; Tavaré, 1986): o modelo reversível no tempo mais geral com seis categorias de taxa e quatro frequências de base desiguais.

Modelos outros que GTR têm soluções analíticas para $P_{i,j}(t)$, enquanto GTR requer decomposição numérica de autovalores (Wheeler 2012).

## 3.3 Variação de Taxa Entre Sítios

### 3.3.1 Sítios Invariáveis

Dados de sequências moleculares comumente mostram heterogeneidade acentuada em taxas de substituição entre posições. Dois modelos distribucionais são regularmente aplicados para acomodar esta variação.

O parâmetro *proporção de sítios invariáveis* $I$ representa a classe frequentemente observada de posições que nunca mudam (Hasegawa et al. 1985). Um parâmetro separado é adicionado para representar a fração de sítios disponíveis para substituição.

### 3.3.2 Heterogeneidade de Taxas e a Distribuição Gamma Discreta

Para lidar com o fato de que diferentes posições em uma sequência evoluem a velocidades distintas, utiliza-se a *distribuição gamma discreta* (Yang 1994). Este modelo adiciona classes de taxa governadas por um único parâmetro de forma, $\alpha$, que define o grau de variação entre os sítios.

A função densidade de probabilidade (PDF) da distribuição gamma é definida como:

$$g(x;\alpha,\beta) = \frac{\beta^{\alpha} x^{\alpha-1} e^{-\beta x}}{\Gamma(\alpha)} \tag{3.1}$$

Onde:

- $x$: representa a taxa de substituição.
- $\alpha$ (alpha): o parâmetro de forma (*shape parameter*). Quanto menor o valor de $\alpha$, maior é a heterogeneidade (muitos sítios lentos e poucos "hotspots" rápidos).
- $\beta$ (beta): o parâmetro de escala. Na prática filogenética, define-se $\beta = \alpha$ para garantir que a média da distribuição seja 1 ($\alpha/\beta = 1$), mantendo a interpretação das unidades de comprimento de ramo como o número esperado de substituições por sítio.
- $\Gamma(\alpha)$ (Gamma de alpha): a função Gamma, que atua como uma constante de normalização para que a área sob a curva seja igual a 1.

**Implementação via discretização:**

Como integrar sobre uma distribuição contínua é computacionalmente proibitivo, a curva é dividida em $k$ classes (geralmente 4 a 8) de áreas iguais. A taxa média de cada partição é usada como um multiplicador para os comprimentos de ramo da árvore.

É fundamental notar que este é um modelo de **mistura de taxas**: não sabemos *a priori* qual classe de taxa pertence a qual sítio. Portanto, a verossimilhança de um sítio $i$ é calculada como a média ponderada das verossimilhanças sob todas as $k$ classes de taxa:

$$L_i = \sum_{j=1}^{k} \frac{1}{k} L_i(r_j) \tag{3.2}$$

Onde $r_j$ é a taxa representativa da $j$-ésima classe. Este método permite capturar a sinalização filogenética de sítios conservados e variáveis simultaneamente sem aumentar drasticamente o número de parâmetros do modelo.

## 3.4 Expansão para Cinco Estados: Modelos com Indels

### 3.4.1 Modelo de Jukes-Cantor de Cinco Estados

Para análises de homologia dinâmica, o modelo de nucleotídeos de quatro estados pode ser expandido para incluir um quinto estado representando eventos de inserção-deleção (indel) (McGuire et al. 2001; Wheeler et al. 2006). Sob o modelo de Jukes-Cantor de cinco estados (JC69+Gaps), a probabilidade de transição é:

$$P_{ij}(t) = \begin{cases} \frac{1}{5} + \frac{4}{5}e^{-\mu t} & \text{se } i = j \\ \frac{1}{5} - \frac{1}{5}e^{-\mu t} & \text{se } i \neq j \end{cases}$$

Esta abordagem trata indels como eventos atômicos e enfatiza tratabilidade computacional sobre realismo mecanístico.

### 3.4.2 Modelos de Nascimento-Morte

Uma alternativa mais mecanisticamente fundamentada é o modelo de nascimento-morte de Thorne et al. (1991) (TKF91, TKF92), que acopla um processo de Poisson de nascimento-morte com modelos padrão de substituição de quatro nucleotídeos para computar a probabilidade de transformar uma sequência em outra. TKF91 e TKF92 representam o tratamento mais mecanisticamente explícito de indels, onde a probabilidade de $n$ inserções ao longo do tempo $t$ é:

$$p_n(t) = e^{-\mu t}\left[1 - \lambda\beta(t)\right]\left[\lambda\beta(t)\right]^{n-1}$$

onde $\beta(t) = (1 - e^{(\lambda-\mu)t})/(\mu - \lambda e^{(\lambda-\mu)t})$, com $\lambda$ sendo a taxa de inserção e $\mu$ a taxa de deleção.

## 3.5 Formas de Verossimilhança e Suas Relações

Wheeler (2012) e Barry e Hartigan (1987) distinguem várias formas de verossimilhança relevantes para inferência filogenética:

1. **Máxima Verossimilhança Média (MVM)**: soma sobre todas as atribuições possíveis de estados de vértice ponderadas por suas probabilidades. Este é o método "MV" padrão usado em análises empíricas.

2. **Máxima Verossimilhança Mais Parcimoniosa (MVP)**: atribui estados específicos de vértice para maximizar a verossimilhança geral. Probabilidades de ramo são constantes sobre caracteres, então MVP geralmente não seleciona a mesma árvore que parcimônia (Wheeler 2012).

3. **Verossimilhança de Caminho Evolutivo (VCE)**: proposta por Farris (1973), esta forma especifica a sequência inteira de estados intermediários entre vértices. A árvore maximizando

VCE é precisamente a árvore mais parcimoniosa (Wheeler 2012), um resultado também derivado por Goldman (1990) e Tuffley e Steel (1997).

4. **Máxima Verossimilhança Integrada (MVI)**: integra sobre parâmetros de incômodo $\theta$ dada sua distribuição $\Phi(\theta|T)$. Isto corresponde à estimativa MAP Bayesiana quando prioris de árvore são planas (Steel e Penny 2000; Wheeler 2012).

A relação entre estas formas é resumida em Wheeler (2012). O aparente paradoxo entre a reivindicação de consistência de MV de Felsenstein e o resultado de MP-como-MV de Farris dissolve-se uma vez que reconhecemos que os dois autores discutiam diferentes formas de verossimilhança.

## 3.6 Modelagem Proteica e Restrições Estruturais

### 3.6.1 Matrizes de Substituição de Aminoácidos

A evolução proteica é mais complexa que evolução de nucleotídeos. Matrizes empíricas de substituição de aminoácidos, tais como PAM e WAG, foram estimadas de grandes bancos de dados de sequências protéicas alinhadas. Estas matrizes capturam tendências evolutivas médias mas assumem estacionaridade e homogeneidade do processo de substituição, que são biologicamente irrealistas.

Mais realistas são modelos de substituição estruturalmente restritos (SCS, do inglês *structurally constrained substitution*), que contabilizam as restrições físicas impostas pelo enovelamento de proteínas nas taxas de substituições de aminoácidos. Modelos SCS frequentemente incorporam evolução dependente de sítio, significando que a matriz de taxa em um sítio depende dos estados de sítios vizinhos ou contatos estruturais. Esta característica dramaticamente aumenta o realismo biológico mas torna a função de verossimilhança padrão intratável porque métodos filogenéticos baseados em MV calculam verossimilhanças sob a assunção de independência de sítios.

### 3.6.2 Modelos de Mistura e Evolução Dependente de Sítio

Modelos de mistura como CAT e variantes relacionadas incorporam processos de substituição variáveis entre regiões de proteínas combinando modelos mais simples (Lartillot e Philippe 2004). Estas abordagens permitem que diferentes sítios usem diferentes matrizes de substituição, contabilizando parcialmente a heterogeneidade estrutural e funcional de proteínas reais. PhyloBayes implementa modelos dependentes de sítio através de uma mistura de processos de Dirichlet, em que o número de classes de substituição é inferido a partir dos dados ao invés de especificado *a priori*.

Quanto à seleção de modelo, a abordagem depende criticamente de se os modelos assumem evolução independente ou dependente de sítio. Modelos empíricos independentes de sítio (e.g., WAG, LG, JTT) podem ser comparados usando critérios baseados em verossimilhança padrão: testes de razão de verossimilhança, AIC e BIC. Estes critérios são implementados em software como ModelTest-NG, ProtTest3, ModelFinder (dentro de IQ-TREE2) e PartitionFinder. Modelos dependentes de sítio, porém, não podem ser avaliados usando estes critérios tradicionais porque a dependência evolutiva entre sítios é incompatível com funções de verossimilhança filogenética padrão, que calculam verossimilhanças de sítio independentemente. Del Amparo e Arenas (2022) desenvolveram ProteinModelerABC, uma abordagem baseada em computação Bayesiana aproximada (ABC) que realiza seleção de modelo entre modelos SCS usando estatísticas sumárias relacionadas a propriedades estruturais e termodinâmicas de proteínas (Del Amparo e Arenas 2022).

### 3.6.3 Modelos Avançados Estruturalmente Restritos

Modelos SCS avançados adaptam física estatística à evolução molecular. Eles avaliam mutações de aminoácidos usando a probabilidade de fixação de um processo nascimento-morte de Moran e aptidão via distribuição de Boltzmann baseada em energia livre de enovelamento de proteínas (Ferreiro et al. 2026). Estes modelos aumentam dramaticamente o realismo biológico: mutações são aceitas ou rejeitadas com base em seu efeito na estabilidade termodinâmica da proteína ao invés de em uma matriz de intercambiabilidade empírica fixa. Porém, modelos SCS dependentes de sítio não podem fornecer matrizes de intercambiabilidade independentes de sítio e são portanto incompatíveis com inferência filogenética padrão baseada em verossimilhança. São atualmente mais úteis para simulação e para compreender restrições evolutivas do que para uso direto em reconstrução de árvores.

Uma limitação prática crítica é que a maioria das implementações de modelos SCS existentes não está disponível em marcos filogenéticos padrão e livremente acessíveis como IQ-TREE2, RAxML-NG ou BEAST2. Implementar estes modelos em software acessível facilitaria comparações empíricas e promoveria sua adoção em análises filogenômicas.

## 3.7 Seleção de Modelo

### 3.7.1 Critérios Clássicos de Seleção de Modelo

Seleção de modelo tem sido reconhecida como pré-requisito para inferência filogenética precisa. Modelos especificados incorretamente produzem estimativas enviesadas de topologia de árvore e comprimentos de ramo (Abadi et al. 2019; Buckley 2002; Sanderson 2002). Os critérios padrão para seleção de modelo incluem:

- **Teste de Razão de Verossimilhança (TRV).** Quando dois modelos são aninhados, duas vezes a diferença em log-verossimilhança é aproximadamente distribuída como $\chi^2$:

$$2(l_{T,T'}) = 2\log(l_T/l_{T'}) = 2(\log l_T - \log l_{T'})$$

  O limiar de confiança para um grau de liberdade é 1.9207 unidades de log-verossimilhança, correspondendo a uma razão de verossimilhança de 6.826.

- **Critério de Informação de Akaike (AIC).** O AIC (Akaike 1974) penaliza parâmetros com um custo fixo:

$$\mathrm{AIC} = -2\log l_T + 2p$$

  Um parâmetro adicional é favorecido apenas se melhora a verossimilhança por ao menos uma unidade de log.

- **Critério de Informação Bayesiano (BIC).** O BIC (Schwarz 1978) penaliza parâmetros extras mais fortemente, com a penalidade dependendo do tamanho de dados $n$:

$$\mathrm{BIC} = -2\log l_T + p\log n$$

Estes critérios são implementados em software tal como ModelTest e são revistos compreensivamente em Posada e Buckley (2004).

### 3.7.2 Impacto da Seleção de Modelo

Abadi et al. (2019) mostrou que a seleção de modelo afeta estimativas de comprimento de ramo mais fortemente que inferência de topologia. Além disso, nenhum critério padrão foi designado para selecionar o modelo melhor adequado especificamente para inferência precisa de comprimento de ramo.

## 3.8 Implementação Computacional

### 3.8.1 Computando Verossimilhança de Árvore: O Algoritmo de Poda de Felsenstein

Para um único caráter $x$, a verossimilhança de um vértice interno $i$ com vértices descendentes $j$ e $k$ é (Wheeler 2012):

$$L_i(x) = \left( \sum_{x_j} p_{x_i,x_j}(t_j) L_j(x_j) \right) \times \left( \sum_{x_k} p_{x_i,x_k}(t_k) L_k(x_k) \right)$$

Verossimilhanças de caracteres são multiplicadas ao longo de todo conjunto de dados para obter a verossimilhança de árvore. Pesos de ramo são estimados numericamente otimizando a verossimilhança marginal para cada ramo enquanto mantendo todos outros parâmetros constantes, comumente usando o método de Brent (1973) ou Newton-Raphson (Ypma 1995). Porque dados de caracteres são assumidos serem independentes e identicamente distribuídos (i.i.d.), a verossimilhança conjunta de múltiplos caracteres é o produto de seus valores individuais.

### 3.8.2 Cadeia de Markov Monte Carlo para Inferência Bayesiana

Integração numérica direta do posterior é computacionalmente proibitiva para conjuntos de dados não-triviais. Uma análise GTR de 100 táxons envolve ao menos 205 parâmetros. Métodos de Cadeia de Markov Monte Carlo (MCMC) baseados no algoritmo Metropolis-Hastings (Hastings 1970; Metropolis et al. 1953) fornecem uma alternativa tratável amostrando árvores proporcionalmente às suas probabilidades posteriores.

A razão de aceitação entre uma árvore corrente $T$ e uma árvore proposta $T^*$ é:

$$\alpha = \min\left(1, \frac{\pi(T^*)}{\pi(T)}\right)$$

onde $\pi(T) = p(\theta)p(T|\theta)p(t_T|\theta,T)p(D|\theta,T,t_T)$ é o numerador do posterior. A razão cancela a probabilidade marginal de dados (o denominador do posterior completo), que é difícil de computar diretamente.

#### Metropolis-MCMC Acoplado ($MC^3$)

A estratégia mais comumente usada é Metropolis-MCMC acoplado ($MC^3$) (Geyer 1991). Múltiplas cadeias rodam em paralelo, cada aquecida a uma temperatura diferente. A cadeia fria (cadeia 0) converge ao posterior; cadeias mais quentes exploram espaço de parâmetros mais amplamente. Cadeias trocam estados periodicamente de acordo com uma segunda razão de aceitação:

$$\alpha = \min\left(1, \frac{\pi_i(T_j)\pi_j(T_i)}{\pi_i(T_i)\pi_j(T_j)}\right)$$

O cronograma de aquecimento é:

$$\pi_j(T) \propto \pi_0(T)^{\frac{1}{1+\lambda(j-2)}}, \quad \lambda > 0$$

## 3.9 Limites de Interpretação de Resultados

### 3.9.1 Inconsistência Estatística de Parcimônia: A Zona de Felsenstein

A motivação original para MV em sistemática foi a inconsistência estatística de parcimônia sob certas combinações de parâmetros (Felsenstein 1978). Em uma árvore de quatro táxons onde ramos levando aos táxons $A$ e $B$ são longos (probabilidade de mudança $p$) enquanto o ramo interno e os ramos para $C$ e $D$ são curtos (probabilidade de mudança $q$), parcimônia favorece a topologia incorreta $(AC|BD)$ quando:

$$p^2 \geq q(1-q)$$

A região do espaço de parâmetros satisfazendo esta desigualdade é a "Zona de Felsenstein" de inconsistência (Wheeler 2012).

### 3.9.2 Viés Anterior de Clado e Probabilidades Posteriores de Clado

Uma limitação interpretativa crítica da filogenética Bayesiana é que uma priori uniforme sobre topologias de árvore não induz uma distribuição uniforme sobre clados de diferentes tamanhos. A probabilidade priori de um clado de tamanho $m$ em uma árvore com $n$ folhas é (Wheeler 2012):

$$\Pr(c_m) = \frac{\left(\prod_{i=2}^{m}(2i-3)\right) \cdot \left(\prod_{i=m+1}^{n}(2i-2m-1)\right)}{\prod_{i=2}^{n}(2i-3)}$$

Pickett e Randle (2005) primeiro demonstraram isto empiricamente. Steel e Pickett (2006) posteriormente provaram que é impossível construir uma priori sobre topologias que induza uma priori uniforme sobre clados. A influência deste viés pode ser extrema: para árvores de 50 táxons, a razão de probabilidade priori entre clados de tamanhos 2 e 25 pode alcançar um fator de $10^{13}$ (Wheeler 2012).

Goloboff e Pol (2005) ilustraram uma consequência particularmente patológica: um táxon com dados completamente faltantes pode ser colocado especificamente em uma árvore (com 55% de probabilidade de clado posterior) unicamente por causa deste viés anterior, mesmo embora todos seus posicionamentos tenham probabilidade posterior idêntica sob os dados. Yang (2006) estendeu este exemplo para mostrar que valores de suporte de clado aproximando-se a 1 podem ser gerados para grupos ausentes da árvore verdadeira.

Estes resultados têm uma implicação prática direta: probabilidades posteriores de clado de análise Bayesiana não podem ser interpretadas diretamente como medidas de suporte filogenético.

## 3.10 Avanços Recentes

### 3.10.1 Modelos Ocultos de Markov para Análise de Sequência

Um avanço significativo sobre modelos simples de substituição de Markov é o Modelo Oculto de Markov (MOM), que adiciona uma camada de estados latentes não-observados (Wheeler 2012). Em um MOM, uma sequência de observações é gerada por uma sequência de estados ocultos, cada um dos quais emite observações de acordo com uma probabilidade de emissão e transições para outros estados de acordo com uma probabilidade de transição. A probabilidade de uma sequência $x$ dado um caminho de estado $\pi$, probabilidades de transição $t$, e probabilidades de emissão $e$ é:

$$p(x, \pi|t, e) = p(\pi_0)e_{\pi_0,x_0} \cdot \prod_{i=1}^{n-1} t_{\pi_{i-1},\pi_i} e_{\pi_i,x_i}$$

Três algoritmos canônicos endereçam as três questões fundamentais de análise de MOM (Wheeler 2012):

1. **Algoritmo de Viterbi** (Viterbi, 1967): identifica o caminho de estado oculto mais provável $\pi^* = \arg\max_\pi p(x, \pi|t, e)$ usando programação dinâmica em tempo $O(k^2 n)$ para $k$ estados e $n$ observações.

2. **Algoritmo Forward-Backward**: computa a probabilidade posterior de cada estado em cada posição usando o produto de probabilidades forward e backward condicionado na probabilidade total de sequência.

3. **Algoritmo de Baum-Welch** (Baum et al., 1970): estima parâmetros de transição e emissão iterando o algoritmo Forward-Backward em sequências de treinamento até a melhoria em probabilidade de sequência cair abaixo de um limiar.

MOMs foram aplicados a alinhamento de sequências pairwise e múltiplos através de MOMs de perfil (Krogh et al. 1994), que modelam famílias de sequências alinhadas com probabilidades de emissão e transição específicas de posição. MOMs de perfil são largamente usados para identificação de família de gene e detecção de motivo funcional.

### 3.10.2 Alinhamento de Sequência Baseado em Verossimilhança

O reconhecimento que alinhamento de sequência e inferência filogenética devem ser realizados conjuntamente sob um modelo probabilístico representa um avanço conceitual maior. A recursão de alinhamento pairwise sob o modelo JC69+Gaps usa o marco Needleman-Wunsch modificado para somar probabilidades ao invés de minimizar custos (Wheeler 2012):

$$\text{cost}[i][j] = \log\left(e^{-(\text{cost}[i-1][j-1]+\sigma_{i,j})} + e^{-(\text{cost}[i-1][j]+\sigma_{\text{indel}})} + e^{-(\text{cost}[i][j-1]+\sigma_{\text{indel}})}\right)$$

Wheeler (2012) enfatiza a distinção entre *verossimilhança dominante* (o alinhamento único melhor, análogo a MVP) e *verossimilhança total* (a soma sobre todos os alinhamentos, análoga a MVM). O alinhamento dominante pode representar tão pouco quanto um terço da verossimilhança total, sublinhando a importância desta distinção para inferência downstream.

A abordagem de Otimização Direta (DO) de Wheeler (1996, 2006) estende este marco pairwise para o Problema de Alinhamento de Árvore (PAA), onde sequências medianas e topologias de árvore são co-otimizadas sob MV.

### 3.10.3 Modelos de Indel de Nascimento-Morte

Os modelos TKF91 e TKF92 de Thorne et al. (1991, 1992) representam o tratamento mais mecanisticamente explícito de indels. Estes modelos acoplam um processo de nascimento (taxa de inserção $\lambda$) e morte (taxa de deleção $\mu$) com modelos de substituição de quatro nucleotídeos. Implementações de PAA Bayesiana usando TKF91/92 incluem BEAST (Lunter et al., 2005) e BaliPhy (Redelings e Suchard, 2005). O custo computacional é proibitivo: Wheeler (2012) nota que BaliPhy requer centenas de horas em um computador pessoal para analisar 12 sequências proteicas de comprimento 400.

## 3.11 Aprendizado de Máquina em Seleção de Modelo de Substituição

### 3.11.1 Motivação para Abordagens de AM

O custo computacional de seleção de modelo baseada em verossimilhança é substancial. Métodos de aprendizado de máquina (AM) podem "aprender relações complexas de dados de entrada sem calcular verossimilhanças," e isto "facilita a aplicação de aprendizado de máquina a modelos complexos, especialmente cenários nos quais inferência estatística e Bayesiana padrão pode ser intratável" (Y. K. Mo et al. 2024).

### 3.11.2 Florestas Aleatórias e Redes Neurais Profundas

ModelTeller (Abadi et al., 2020) usa um regressor de floresta aleatória (FA) treinado em mais de 50 estatísticas sumárias. Estas estatísticas são amplamente categorizadas em quatro grupos: propriedades do alinhamento em si, propriedades de uma aproximação de árvore baseada em distância, parâmetros estimados sob um modelo de substituição rico em parâmetros, e métricas de similaridade de sequência dentro de subconjuntos de táxons. O regressor FA classifica 24 modelos de substituição de nucleotídeos candidatos de acordo com sua precisão predita para estimação de comprimento de ramo.

ModelRevelator (Burgstaller-Muehlbacher et al., 2023) toma uma abordagem diferente. Usa duas redes neurais profundas independentes para realizar seleção de modelo sem calcular verossimilhanças ou reconstruir árvores. A primeira rede, NNmodelfind, é uma rede neural residual que toma como entrada um conjunto de estatísticas sumárias computadas de alinhamentos pairwise. Seleciona entre seis modelos de substituição de nucleotídeos variando em complexidade de JC a GTR. A segunda rede, NNalphafind, é um LSTM bidirecional que toma perfis de composição de base como entrada e prediz se heterogeneidade de taxa deve ser incorporada e, se assim, estima o parâmetro $\alpha$ da distribuição Gamma.

### 3.11.3 Codificação Direta de Alinhamento

Uma alternativa a estatísticas sumárias é codificar alinhamentos diretamente como matrizes numéricas e alimentá-los em redes neurais com vieses indutivos apropriados. Para árvores de quatro táxons, redes neurais convolucionais (RNCs) foram aplicadas a alinhamentos codificados como inteiros ou one-hot-encoded. Burgstaller-Muehlbacher et al. (2023) mostraram que RNCs analisando imagens de alinhamentos de nucleotídeos podem realizar comparável a predição de modelo baseada em MV.

Mo et al. (2024) notam que Phyloformer (Nesterenko et al., 2022), que usa mecanismos de atenção própria, acomoda tamanhos de entrada variáveis através de design de rede cuidadoso. Esta abordagem oferece um caminho para redes que podem aceitar alinhamentos de comprimento e número de táxons arbitrários enquanto preservam a riqueza representacional de codificação de alinhamento direto.

### 3.11.4 Inferência Livre de Verossimilhança para Modelos Intratáveis

A aplicação mais convincente de AM a modelos de substituição concerne modelos cujas verossimilhanças são intratáveis. Modelos SCS que incorporam evolução dependente de sítio não podem ser incorporados em funções de verossimilhança padrão porque métodos filogenéticos correntes calculam verossimilhanças de sítio independentemente (Yang 2006). Inferência baseada em simulação (IBS) oferece uma alternativa principiada: parâmetros do modelo são inferidos combinando estatísticas sumárias observadas com estatísticas computadas de simulações (Cranmer et al. 2020). Métodos de aprendizado profundo melhoraram substancialmente IBS através de estimação posterior neural (EPN), que usa redes neurais para aprender a distribuição posterior diretamente de dados simulados. Estes métodos são diretamente aplicáveis a modelos de substituição para os quais um simulador generativo existe mas nenhuma função de verossimilhança tratável.

Uma direção relacionada envolve estender modelos de substituição CTMC para capturar dinâmicas de substituição mais ricas. Magee et al. (2024) introduziram modelos de substituição de efeitos aleatórios que estendem CTMCs padrão e desenvolveram aproximações de gradiente escaláveis para habilitar amostragem Monte Carlo Hamiltoniana do posterior sob estes modelos mais ricos (Magee et al. 2024). Embora primariamente Bayesiano ao invés de baseado em AM, este trabalho ilustra a direção geral em direção a modelos com maior capacidade de capturar dinâmicas de substituição heterogêneas.

### 3.11.5 Design de Dados de Treinamento e Generalização

AM supervisionada para seleção de modelo de substituição requer dados de treinamento rotulados, que em filogenética significa alinhamentos simulados para os quais o modelo de substituição generativo verdadeiro é conhecido. A qualidade dos dados de treinamento determina a capacidade de generalização do modelo. A discrepância treinamento-versus-empírico é uma preocupação central: dados de treinamento gerados sob um modelo de substituição podem não generalizar para conjuntos de dados empíricos que evoluíram sob um modelo diferente (Y. K. Mo et al. 2024). Estratégias para melhorar generalização incluem gerar dados de treinamento sobre uma ampla gama de parâmetros de modelo, técnicas de regularização padrão (dropout, decaimento de peso, métodos de ensemble), adição de ruído a alinhamentos durante treinamento, e métodos de adaptação de domínio que promovem extração de características invariantes de domínio (Y. Mo e Siepel 2024).

### 3.11.6 Limitações da Seleção de Modelo Baseada em AM

A limitação mais fundamental de AM supervisionada em filogenética é a lacuna entre dados de treinamento simulados e dados empíricos. Um critério de seleção de modelo tradicional que seleciona um modelo especificado incorretamente ainda computará uma pontuação AIC ou BIC bem-definida, tornando o erro transparente em princípio. Um modelo de AM treinado em simulações especificadas incorretamente pode confiantemente produzir uma recomendação incorreta sem nenhum

sinal de falha. Adicionalmente, modelos de AM para seleção de modelo de substituição são geralmente preditores de caixa-preta que não fornecem explicação de por que um modelo particular foi selecionado. Leuchtenberger e von Haeseler (2024) mostraram que simplificar classificadores de redes neurais complexos em formas mais interpretáveis pode produzir *insights* teóricos, sugerindo que interpretabilidade não é inerentemente incompatível com abordagens de AM (Leuchtenberger e Haeseler 2024). A maioria dos modelos de AM para seleção de modelo foi treinada e avaliada em árvores de quatro táxons ou alinhamentos pequenos; a escalabilidade para centenas ou milhares de táxons rotineiramente analisados em filogenômica não foi estabelecida.

## 3.12 Redes Neurais de Proteína e Modelos de Linguagem

### 3.12.1 Modelos de Linguagem de Proteína

Modelos de linguagem grande (MLGs) treinados em sequências de proteína representam uma abordagem fundamentalmente diferente a codificar informação evolutiva. Modelos de linguagem de proteína (MLPs) tais como ESM-2 e ProtTrans tratam sequências de aminoácidos como sentença em uma linguagem molecular. Eles aprendem dependências estatísticas entre posições de aminoácidos de milhões de sequências, capturando implicitamente restrições co-evolucionárias, contatos estruturais, e conservação evolutiva (Valentini et al. 2023).

Diferentemente de modelos de substituição tradicionais, MLPs não impõem uma estrutura markoviana explícita no processo de substituição. Ao invés, aprendem uma representação de alta-dimensão de espaço de sequência que reflete a distribuição real de sequências de proteína naturais.

Lupo et al. (2022) mostraram que modelos de linguagem de proteína treinados em alinhamentos de sequências múltiplas (ASMs) aprendem relações filogenéticas. Este achado implica que os mecanismos de atenção nestes modelos codificam informação sobre relacionamento evolutivo. Mo et al. (2024) citam este resultado no contexto de estratégias alternativas para representar alinhamentos, notando que modelos de linguagem podem produzir "redes que podem aceitar tamanhos de entrada variáveis, e são capazes de incorporar relações entre sítios e linhagens simultaneamente."

### 3.12.2 Phyloformer e Arquiteturas de Atenção

Phyloformer (Nesterenko et al., 2022) usa atenção própria para inferir distâncias evolutivas pairwise de sequências de aminoácido alinhadas. O modelo codifica pares de sequências através de um mecanismo de atenção que alterna entre atenção no nível de sítio (compartilhando informação através de sítios dentro de cada par) e atenção no nível de par (compartilhando informação através de pares de sequência dentro de cada sítio).

## 3.13 Conclusão

Modelos de substituição ocupam um papel central em reconstrução filogenética a partir de dados moleculares. Sua fundação teórica situa-se no processo Markov reversível no tempo geral, do qual todos os modelos nomeados são derivados como casos especiais. Implementação requer ambos a computação eficiente de verossimilhanças de árvore via algoritmos de poda e critérios robustos de seleção de modelo que penalizem sobreparametrização. Inferência Bayesiana adiciona distribuições

prioris sobre todos os parâmetros do modelo, exigindo justificação cuidadosa daquelas prioris e avaliação crítica dos resumos posteriores resultantes.

As limitações interpretativos são substanciais. Probabilidades posteriores de clado estão sujeitas a viés anterior não-uniforme que pode produzir conclusões topológicas fortemente apoiadas mas errôneas. A Zona de Felsenstein de inconsistência de parcimônia motiva análise de MV, mas MV em si não é imune a especificação incorreta de modelo. O tratamento de indels e a escolha de modelo de substituição ambos carregam consequências significativas downstream para inferência.

Avanços recentes centram em modelos probabilísticos mais realistas e abrangentes: MOMs para alinhamento de sequência, modelos de indel de nascimento-morte, extensões a rearranjo genômico e redes filogenéticas, e aplicações de aprendizado de máquina e modelos de linguagem para seleção de modelo e distância estimada. Estes desenvolvimentos expandem o escopo de inferência baseada em modelo enquanto simultaneamente aumentam demandas computacionais. A tensão fundamental entre realismo biológico e tratabilidade computacional permanece o desafio definidor do campo.

**Roteiro de Revisão do Capítulo**

1. Matriz $Q$ de Tavaré (1986): $Q_{ij} = R_{ij}\pi_j$ $(i \neq j)$; $P_{ij}(t)$ via decomposição de autovalores de $Q$ (Tavbré 1986; Yang 1994).
2. Hierarquia de modelos: JC69 (0 parâmetros livres) → K2P (transição/transversão) → HKY85 ($\pi$ desiguais) → GTR (6 taxas, 4 freq.) (Swofford et al. 1996).
3. Variação de taxa: sítios invariáveis ($I$) + Gamma discreta ($\alpha$, média = 1); GTR+$I$+$\Gamma$ é modelo empírico padrão.
4. JC69+Gaps (5 estados): $P_{ij}(t) = \frac{1}{5} - \frac{1}{5}e^{-\mu t}$ $(i \neq j)$; indels como eventos atômicos (Wheeler et al. 2006).
5. Modelos nascimento–morte TKF91/92 (Thorne et al., 1991): acoplam inserção ($\lambda$) / deleção ($\mu$) com substituição; mecanisticamente explícitos mas computacionalmente caros.
6. Algoritmo de poda de Felsenstein: $L_i(x) = \left(\sum_{x_j} p_{x_i,x_j}(t_j)L_j(x_j)\right) \times \left(\sum_{x_k} p_{x_i,x_k}(t_k)L_k(x_k)\right)$; assume i.i.d. de caracteres.
7. MCMC / MC$^3$ (Metropolis-coupled): cadeia fria converge ao posterior; cadeias quentes exploram; troca por $\alpha = \min(1, \pi_i(T_j)\pi_j(T_i)/\pi_i(T_i)\pi_j(T_j))$.
8. Seleção de modelo: TRV ($\chi^2$), AIC ($-2\log l + 2p$), BIC ($-2\log l + p\log n$); Abadi et al. (2019): seleção afeta comprimentos de ramo mais que topologia.
9. Zona de Felsenstein: parcimônia inconsistente quando $p^2 \geq q(1-q)$ (ramos longos atraindo).
10. Viés anterior de clado: priori uniforme sobre topologias ≠ priori uniforme sobre clados; razão priori entre clados de tamanhos 2 e 25 pode atingir $10^{13}$ (Steel & Pickett, 2006).
11. Avanços recentes: MOMs (Viterbi, Forward-Backward, Baum-Welch), alinhamento baseado em verossimilhança (dominante vs. total), modelos de linguagem de proteína (ESM-2, Phyloformer).
12. Modelos de mistura: CAT (PhyloBayes) modela substituição dependente de sítio via processo de Dirichlet; modelos SCS usam energia livre de enovelamento (distribuição de Boltzmann) e probabilidade de fixação (processo de Moran) mas tornam MV padrão intratável.
13. Seleção de modelo via AM: ModelTeller (floresta aleatória, 50+ estatísticas sumárias), ModelRevelator (redes neurais profundas, sem cálculo de verossimilhança); Phyloformer (atenção para entradas de tamanho variável).
14. Inferência livre de verossimilhança: inferência baseada em simulação (IBS) e estimação posterior neural (EPN) habilitam avaliação de modelos SCS intratáveis; ABC para seleção de modelo de proteína (ProteinModelerABC).
15. Limitações de abordagens de AM: lacuna simulação-empírico, predições de caixa-preta, escalabilidade para conjuntos grandes; adaptação de domínio e métodos de interpretabilidade como estratégias de mitigação.

# Referências


Abadi, S., D. Azouri, T. Pupko e I. Mayrose (2019). "Model selection may not be a mandatory step for phylogeny reconstruction". Em: *Nature Communications* 10, p. 934.

Akaike, H. (1974). "A new look at the statistical model identification". Em: *IEEE Transactions on Automatic Control* 19, pp. 716–723.

Buckley, T. R. (2002). "Model misspecification and probabilistic tests of topology: evidence from empirical data sets". Em: *Systematic Biology* 51, pp. 509–523.

Cranmer, K., J. Brehmer e G. Louppe (2020). "The frontier of simulation-based inference". Em: *Proceedings of the National Academy of Sciences* 117.48, pp. 30055–30062. doi: 10.1073/pnas.1912789117.

Del Amparo, R. e M. Arenas (2022). "Selection among site-dependent structurally constrained substitution models of protein evolution by approximate Bayesian computation". Em: *Systematic Biology* 71.6, pp. 1521–1537. doi: 10.1093/sysbio/syac038.

Edwards, A. W. F. (1972). *Likelihood*. Cambridge, UK: Cambridge University Press.

Felsenstein, J. (1978). "Cases in which parsimony or compatibility methods will be positively misleading". Em: *Systematic Zoology* 27, pp. 401–410.

Ferreiro, D. U., D. J. Machado e M. Arenas (2026). "Substitution models of protein evolution". Em: *Annual Review of Biophysics* 55. In press.

Geyer, C. J. (1991). "Markov chain Monte Carlo maximum likelihood". Em: *Computing Science and Statistics: Proceedings of the 23rd Symposium on the Interface*, pp. 156–163.

Hasegawa, M., H. Kishino e T. Yano (1985). "Dating of the human-ape splitting by a molecular clock of mitochondrial DNA". Em: *Journal of Molecular Evolution* 22, pp. 160–174.

Hastings, W. K. (1970). "Monte Carlo sampling methods using Markov chains and their applications". Em: *Biometrika* 57, pp. 97–109.

Krogh, A., M. Brown, I. S. Mian, K. Sjölander e D. Haussler (1994). "Hidden Markov models in computational biology: applications to protein modeling". Em: *Journal of Molecular Biology* 235, pp. 1501–1531.

Lartillot, N. e H. Philippe (2004). "A Bayesian mixture model for across-site heterogeneities in the amino-acid replacement process". Em: *Molecular Biology and Evolution* 21.6, pp. 1095–1109. doi: 10.1093/molbev/msh112.

Leuchtenberger, A. F. e A. von Haeseler (2024). "Simplifying complex neural network classifiers for phylogenetic model selection". Em: *Systematic Biology* 73.2, pp. 345–358. doi: 10.1093/sysbio/syae004.

Magee, A. F., M. D. Karcher, F. A. Matsen IV e V. N. Minin (2024). "Random-effects substitution models for phylogenetics via scalable gradient approximations". Em: *Systematic Biology* 73.3, pp. 562–576. doi: 10.1093/sysbio/syae009.

McGuire, G., M. C. Denham e D. J. Balding (2001). "Models of sequence evolution for DNA sequences containing gaps". Em: *Molecular Biology and Evolution* 18, pp. 481–490.

Metropolis, N., A. W. Rosenbluth, M. N. Rosenbluth, A. H. Teller e E. Teller (1953). "Equation of state calculations by fast computing machines". Em: *The Journal of Chemical Physics* 21, pp. 1087–1092.

Mo, Y. K., M. W. Hahn e M. L. Smith (2024). "Applications of machine learning in phylogenetics". Em: *Molecular Phylogenetics and Evolution* 196, p. 108066.

Mo, Y. e A. Siepel (2024). "Domain-invariant feature extraction for phylogenetic inference". Em: *Molecular Biology and Evolution* 41.4. doi: 10.1093/molbev/msae068.

Sanderson, M. J. (2002). "Estimating absolute rates of molecular evolution and divergence times: a penalized likelihood approach". Em: *Molecular Biology and Evolution* 19, pp. 101–109.

Schwarz, G. (1978). "Estimating the dimension of a model". Em: *The Annals of Statistics* 6, pp. 461–464.

Steel, M. A. e D. Penny (2000). "Parsimony, likelihood, and the role of models in molecular phylogenetics". Em: *Molecular Biology and Evolution* 17, pp. 839–850.

Strang, G. (2006). "Linear Algebra and Its Applications". Em.

Swofford, D. L., G. J. Olsen, P. J. Waddell e D. M. Hillis (1996). "Phylogenetic inference". Em: *In D. M. Hillis, C. Moritz, and B. K. Mable (eds.), Molecular Systematics*, pp. 407–514.

Tavbré, S. (1986). "Some probabilistic and statistical problems in the analysis of DNA sequences". Em: *Lectures on Mathematics in the Life Sciences* 17, pp. 57–86.

Valentini, G., D. Malchiodi, J. Gliozzo, M. Mesiti, M. Soto-Gomez, A. Cabri, J. Reese, E. Casiraghi e P. N. Robinson (2023). "The promises of large language models for protein design and modeling". Em: *Frontiers in Bioinformatics* 3, p. 1304099.

Wheeler, W. C. (2012). *Systematics: A Course of Lectures*. Hoboken, New Jersey: Wiley-Blackwell. 426 pp.

Wheeler, W. C., R. DeSalle e G. Giribet (2006). *Dynamic Homology and Phylogenetic Systematics: A Unified Approach Using POY*. New York: American Museum of Natural History Press. 365 pp.

Yang, Z. (1994). "Maximum likelihood phylogenetic estimation from DNA sequences with variable rates over sites: approximate methods". Em: *Journal of Molecular Evolution* 39, pp. 306–314.

Yang, Z. (2006). "Computational molecular evolution". Em: *Oxford University Press*.

Ypma, T. J. (1995). "Historical development of the Newton-Raphson method". Em: *SIAM Review* 37, pp. 531–551.

# Capítulo 4

# Diversidade de Tipos de Dados e Estratégias de Sequenciamento para Reconstrução Filogenômica

Nos últimos anos, uma explosão de metodologias de sequenciamento e enriquecimento seletivo de DNA tornou possível gerar dados filogenômicos de praticamente qualquer organismo. No entanto, a escolha do tipo de dado apropriado para um determinado projeto representa uma decisão crucial que afeta a qualidade, custo e aplicabilidade dos resultados. Este capítulo revisa uma gama abrangente de estratégias de sequenciamento e aquisição de dados, comparando suas forças e limitações em contextos filogenômicos específicos.

## 4.1 Sequenciamento de Genoma Completo (Leitura Curta)

O sequenciamento de genoma completo com leituras curtas oferece representação completa do conteúdo genômico, incluindo regiões codificantes, não-codificantes, regulatórias e repetitivas. Esta abordagem é particularmente valiosa para análises filogenômicas profundas e intermediárias.

### 4.1.1 Características Gerais

**Categoria:** Genoma completo

**Tipo de Locus:** Todos (codificantes, não-codificantes, regulatórios, repetitivos)

**Número Típico de Loci:** Genoma inteiro; dezenas de milhares de regiões gênicas extraíveis

**Escala Filogenética Ótima:** Todas as escalas; melhor para profunda e intermediária

**Qualidade de DNA:** Alta (DNA de alto peso molecular preferido para boa montagem)

**Quantidade de DNA:** Moderada a alta ($\geq 500$ ng típico)

**Tecido:** Qualquer tecido com DNA suficiente

**Compatibilidade com Espécimes de Museu/Herbário:** Pobre (DNA fragmentado resultando em montagem deficiente)

**Custo Relativo:** Alto (U$50–200+ por amostra em profundidade útil)

**Complexidade Bioinformática:** Muito alta (montagem, anotação, pipelines de ortologia)

**Dificuldade de Avaliação de Ortologia:** Moderada a alta (parálogia de duplicações de genoma inteiro e variações no número de cópias)

**Tendência de Completude da Matriz:** Alta se genomas bem montados; variável caso contrário

**Combinabilidade Entre Estudos:** Moderada (depende de qualidade de montagem e consistência de predição gênica)

**Amplo Leque Taxonômico de Recursos:** Amplo: procariotos, fungos, animais, plantas; Projeto Biogenoma da Terra expandindo rapidamente

**Adequação a Organismos Não-Modelo:** Excelente em princípio; custo e complexidade de montagem limitam adoção em estudos com grande N

### 4.1.2 Forças e Limitações

As principais vantagens desta abordagem incluem representação genômica completa, possibilidade de análises de sintenia e famílias gênicas, e valor de arquivo. As limitações incluem alto custo em profundidade adequada para montagem, genomas grandes ainda sendo desafiadores, e carga bioinformática substancial.

Delsuc et al. (2005), Jarvis et al. (2014), Lewin et al. (2018) e Lozano-Fernandez et al. (2022)

## 4.2 Sequenciamento de Genoma Completo (Leitura Longa: PacBio HiFi / ONT)

As tecnologias de leitura longa permitem montagens com qualidade de nível cromossômico, resolvendo estruturas variantes complexas e evolução de repetições.

### 4.2.1 Características Gerais

**Categoria:** Genoma completo

**Tipo de Locus:** Todos (incluindo repetitivos, variantes estruturais)

**Número Típico de Loci:** Genoma inteiro; montagens em nível cromossômico alcançáveis

**Escala Filogenética Ótima:** Todas as escalas; possibilita análise de variação estrutural e evolução de repetições

**Qualidade de DNA:** Muito alta (DNA ultra-HMW necessário, $> 20$ kb)

**Quantidade de DNA:** Alta ($> 1\,\mu$g para PacBio HiFi; $> 400$ ng para ligação ONT)

**Tecido:** Tecido fresco ou congelado em nitrogênio líquido fortemente preferido

**Compatibilidade com Espécimes de Museu/Herbário:** Muito pobre (leituras longas requerem DNA intacto)

**Custo Relativo:** Muito alto (U$200–1000+ por amostra)

**Complexidade Bioinformática:** Muito alta (montagem + polimento + anotação)

**Dificuldade de Avaliação de Ortologia:** Moderada a alta (similar a WGS curta uma vez montada)

**Tendência de Completude da Matriz:** Muito alta (montagens em nível cromossômico reduzem dados faltantes)

**Combinabilidade Entre Estudos:** Moderada (qualidade de montagem melhora combinabilidade)

**Amplo Leque Taxonômico:** Crescendo rapidamente: Vertebrate Genomes Project, Darwin Tree of Life, i5K

**Adequação a Organismos Não-Modelo:** Excelente para qualidade mas proibitivo de custo para maioria dos estudos em nível populacional

### 4.2.2 Forças e Limitações

As montagens em nível cromossômico resolvem repetições, variantes estruturais e rearranjos complexos com representação superior de arquitetura genômica. As principais limitações são custo mais alto, requisitos de tecido mais exigentes, e impraticabilidade de material de museu/herbário.

Formenti et al. (2022), Guiglielmoni et al. (2024) e Rhie et al. (2021)

## 4.3 Transcriptômica (RNA-seq)

RNA-seq captura exons de genes codificantes expressos, oferecendo acesso eficiente a centenas ou milhares de loci nucleares de cópia única. No entanto, a qualidade do RNA e requisitos de tecido limitam fontes de espécimes.

### 4.3.1 Características Gerais

**Categoria:** Representação reduzida (dependente de expressão)

**Tipo de Locus:** Exons codificantes (genes expressos somente)

**Número Típico de Loci:** 1.000–20.000+ genes dependendo do tecido/condição

**Escala Filogenética Ótima:** Intermediária a profunda (>50 Mya); limitada em escalas rasas

**Qualidade de RNA:** Alta qualidade requerida (RIN $\geq$7 preferido)

**Quantidade de RNA:** Moderada ($\geq$ 100 ng RNA total)

**Tecido:** Tecido fresco ou preservado em RNAlater; tipo de tecido afeta recuperação gênica

**Compatibilidade com Espécimes de Museu/Herbário:** Muito pobre (RNA degrada rapidamente)

**Custo Relativo:** Moderado (U$30–100 por amostra)

**Complexidade Bioinformática:** Alta (montagem de novo, resolução de isoformas, inferência de ortologia)

**Dificuldade de Avaliação de Ortologia:** Alta (parólogia, splicing alternativo, expressão tecido-específica)

**Tendência de Completude da Matriz:** Variável; depende de sobreposição de tecidos entre amostras

**Combinabilidade Entre Estudos:** Baixa a moderada (tecido deve corresponder entre estudos)

**Amplo Leque Taxonômico:** Amplo: 1KP (plantas), i5K (insetos), muitos datasets de vertebrados

**Adequação a Organismos Não-Modelo:** Excelente para descoberta gênica; limitado por requisitos de preservação de RNA

### 4.3.2 Forças e Limitações

A abordagem recupera grande número de loci codificantes, não requer desenho de sondas, e possui anotação funcional integrada. As limitações incluem requisitos rigorosos de qualidade de RNA/tecido, criação de dados faltantes pela expressão tecido-específica, e ortologia complicada por parólogia e splicing alternativo.

Dunn et al. (2008), Figuet et al. (2014), Initiative (2019) e Misof et al. (2014)

## 4.4 Elementos Ultraconservados (UCEs)

UCEs combinam núcleos conservados (predominantemente não-codificantes) com regiões flanqueadoras variáveis, oferecendo excelente combinabilidade entre estudos.

### 4.4.1 Características Gerais

**Categoria:** Captura alvo (enriquecimento baseado em sonda)

**Tipo de Locus:** Misto: núcleo conservado (principalmente não-codificante) + regiões flanqueadoras variáveis

**Número Típico de Loci:** 500–5.000+ loci dependendo do conjunto de sondas e divergência

**Escala Filogenética Ótima:** Ampla: profunda a moderadamente rasa ($\sim$ 5–500+ Mya)

**Qualidade de DNA:** Moderada (tolera degradação moderada)

**Quantidade de DNA:** Baixa a moderada (tão baixa quanto 10–50 ng com protocolos otimizados)

**Tecido:** Qualquer tecido; espécimes secos, preservados em etanol, silica-gel funcionam

**Compatibilidade com Espécimes de Museu/Herbário:** Boa (uma das melhores abordagens para espécimes de museu/herbário com DNA degradado)

**Custo Relativo:** Baixo a moderado (U$15–50 por amostra uma vez compradas as sondas)

**Complexidade Bioinformática:** Moderada (pipeline PHYLUCE bem estabelecido)

**Dificuldade de Avaliação de Ortologia:** Baixa (UCEs geralmente são cópia única e altamente conservados)

**Tendência de Completude da Matriz:** Alta (conjuntos de sondas padronizados recuperam loci consistentes entre táxons)

**Combinabilidade Entre Estudos:** Muito alta (mesmo conjunto de sondas → diretamente combinável)

**Amplo Leque Taxonômico:** Vertebrados, artrópodes, moluscos, nematódeos, cnidários, anelídeos; expandindo para muitos clados animais

**Adequação a Organismos Não-Modelo:** Excelente: funciona com DNA degradado, entrada baixa, conjuntos de sondas amplos disponíveis

### 4.4.2 Forças e Limitações

A combinabilidade entre estudos é excelente, funciona com DNA de museu/degradado, custo por amostra é baixo após compra de sondas, e pipeline bioinformático bem testado. As limitações incluem alinhamentos curtos por locus, predominantemente não-codificantes (limita interpretação funcional), e conjuntos de sondas devem ser desenvolvidos por clado principal.

Branstetter et al. (2017), Faircloth et al. (2012), McCormack et al. (2013) e Zhang et al. (2019)

## 4.5 Enriquecimento Híbrido Ancorado (AHE)

AHE combina regiões âncora conservadas (frequentemente exônicas) com flanqueadores variáveis (intrônicos/intergênicos), balanceando regiões conservadas e variáveis.

### 4.5.1 Características Gerais

**Categoria:** Captura alvo (enriquecimento baseado em sonda)

**Tipo de Locus:** Misto: regiões âncora conservadas + flanqueadores variáveis

**Número Típico de Loci:** 300–600+ loci (kits de vertebrados); expansível com desenhos customizados

**Escala Filogenética Ótima:** Ampla: profunda a rasa ($\sim$ 1–500+ Mya)

**Qualidade de DNA:** Moderada (tolera degradação moderada)

**Quantidade de DNA:** Baixa a moderada ($\sim$ 50–250 ng)

**Tecido:** Qualquer tecido com DNA extraível

**Compatibilidade com Espécimes de Museu/Herbário:** Boa (DNA degradado compatível com protocolos otimizados)

**Custo Relativo:** Moderado (U$50–100 por amostra através do centro FSU; inclui prep de biblioteca)

**Complexidade Bioinformática:** Moderada (pipeline estabelecido através de Center for Anchored Phylogenomics)

**Dificuldade de Avaliação de Ortologia:** Baixa a moderada (loci âncora selecionados para status cópia única)

**Tendência de Completude da Matriz:** Alta (enriquecimento padronizado → recuperação consistente)

**Combinabilidade Entre Estudos:** Alta (conjuntos de sondas consistentes dentro de clados)

**Amplo Leque Taxonômico:** Vertebrados bem desenvolvidos; artrópodes, plantas, fungos; kits para >dúzia de clados

**Adequação a Organismos Não-Modelo:** Excelente: filosofia de desenho de sonda ampla

### 4.5.2 Forças e Limitações

Loci mais longos que UCEs em média resultam em mais sinal por locus. Balanço bom de regiões conservadas e variáveis. Pipeline comercial disponível. As limitações incluem centralização em FSU, desenhos de sonda proprietários, e custo por amostra mais alto que UCE quando autprocessado.

Breinholt et al. (2018), Hime et al. (2021), Lemmon et al. (2012) e Prum et al. (2015)

## 4.6 Angiosperms353 / Conjuntos de Sondas Universais

Este conjunto universal de 353 genes alvo foi desenvolvido especificamente para aplicação em toda a diversidade de angiospermas, com excelente compatibilidade com espécimes de herbário.

### 4.6.1 Características Gerais

**Categoria:** Captura alvo (conjunto de sondas universal)

**Tipo de Locus:** Genes nucleares codificantes de proteína (baixa cópia)

**Número Típico de Loci:** 353 genes alvo (+ regiões flanqueadoras recuperáveis)

**Escala Filogenética Ótima:** Ampla: ordinal a nível populacional em angiospermas

**Qualidade de DNA:** Moderada (espécimes de herbário testados com sucesso)

**Quantidade de DNA:** Baixa a moderada (tão baixa quanto $\sim 10\,\text{ng}$ com protocolos de DNA degradado)

**Tecido:** Qualquer tecido; folhas secas em sílica, folhas de herbário funcionam bem

**Compatibilidade com Espécimes de Museu/Herbário:** Excelente (especificamente testado e validado com material de herbário >100 anos)

**Custo Relativo:** Baixo a moderado (U$15–40 por amostra)

**Complexidade Bioinformática:** Moderada (pipeline HybPiper bem documentado e amplamente adotado)

**Dificuldade de Avaliação de Ortologia:** Moderada (genes de baixa cópia selecionados; WGD em muitos linhagens de angiospermas complica detecção de parólogia)

**Tendência de Completude da Matriz:** Alta (desenho universal assegura recuperação ampla; $\sim$ 200–350 genes tipicamente recuperados)

**Combinabilidade Entre Estudos:** Muito alta (conjunto universal projetado para combinabilidade entre estudos)

**Amplo Leque Taxonômico:** Angiospermas (plantas com flor) universalmente; também testado em gimnospermas e algumas briófitas

**Adequação a Organismos Não-Modelo:** Excelente para plantas: nenhum desenho de sonda necessário, kit pronto para usar

### 4.6.2 Forças e Limitações

Universal através de todas as plantas com flor, nenhum desenho de sonda customizado necessário, excelente compatibilidade com herbário, e padrão da comunidade botânica. As limitações incluem restrição a angiospermas, 353 loci podem ser insuficientes para resolução de escala rasa em alguns grupos, e parólogia em linhagens poliploides.

Baker et al. (2021, 2022), Johnson et al. (2019) e Zuntini et al. (2024)

## 4.7 Captura de Exons Customizada / Específica de Linhagem

Permite desenho de sondas otimizado para clados específicos, capturando exons codificantes escolhidos.

### 4.7.1 Características Gerais

**Categoria:** Captura alvo (enriquecimento baseado em sonda)

**Tipo de Locus:** Exons codificantes (selecionados por clado)

**Número Típico de Loci:** 200–10.000+ exons dependendo do desenho

**Escala Filogenética Ótima:** Flexível: projetado para clado e escala específicos

**Qualidade de DNA:** Moderada (DNA degradado tolerado)

**Quantidade de DNA:** Baixa a moderada

**Tecido:** Qualquer tecido com DNA extraível

**Compatibilidade com Espécimes de Museu/Herbário:** Boa (similar a UCE/AHE para DNA degradado)

**Custo Relativo:** Moderado a alto (desenho de sonda + síntese adiciona custo inicial)

**Complexidade Bioinformática:** Moderada a alta (requer pipeline bioinformático customizado)

**Dificuldade de Avaliação de Ortologia:** Moderada (depende de critérios de seleção gênica)

**Tendência de Completude da Matriz:** Moderada a alta (depende de divergência sonda-alvo)

**Combinabilidade Entre Estudos:** Baixa (diferentes estudos alvo diferentes genes)

**Amplo Leque Taxonômico:** Específica de linhagem por definição; disponível para muitos clados de vertebrados, insetos, plantas

**Adequação a Organismos Não-Modelo:** Boa (pode ser desenhada para qualquer clado com alguns recursos genômicos)

### 4.7.2 Forças e Limitações

Personalização para clado de interesse otimiza informativeness. As limitações incluem falta de padronização entre estudos (pobre combinabilidade), exigência de dados genômicos/transcriptômicos para desenho de sonda, e custo inicial de síntese de sonda.

Bi et al. (2012), Bragg et al. (2016) e Portik et al. (2016)

## 4.8 RADseq / ddRADseq / GBS

Sequenciamento baseado em enzimas de restrição captura fragmentos genômicos aleatórios, ideal para estudos em escala populacional em divergência rasa.

### 4.8.1 Características Gerais

**Categoria:** Representação reduzida (baseada em enzima de restrição)

**Tipo de Locus:** Fragmentos genômicos anônimos (aleatórios em relação à função)

**Número Típico de Loci:** Milhares–centenas de milhares de loci contendo SNPs

**Escala Filogenética Ótima:** Rasa: população a nível de gênero (<10–20 Mya)

**Qualidade de DNA:** Moderada a alta (DNA fresco preferido para digestão consistente)

**Quantidade de DNA:** Moderada (100–500 ng típico)

**Tecido:** Tecido fresco ou bem preservado preferido

**Compatibilidade com Espécimes de Museu/Herbário:** Pobre (requer DNA de alta qualidade para digestão consistente)

**Custo Relativo:** Baixo (U$10–30 por amostra; nenhuma compra de sonda necessária)

**Complexidade Bioinformática:** Moderada (pipelines estabelecidos: Stacks, ipyrad, dDocent)

**Dificuldade de Avaliação de Ortologia:** Baixa em escalas rasas (loci anônimos tratados como independentes)

**Tendência de Completude da Matriz:** Baixa a moderada (dropout de locus aumenta com divergência)

**Combinabilidade Entre Estudos:** Muito baixa (sítios de enzimas de restrição não conservados entre táxons divergentes)

**Amplo Leque Taxonômico:** Universal em princípio; amplamente usado em genômica populacional de peixes, pássaros, anfíbios, insetos, plantas

**Adequação a Organismos Não-Modelo:** Excelente para estudos em nível populacional com tecido fresco; pobre para filogenética profunda

### 4.8.2 Forças e Limitações

Custo mais baixo por amostra, nenhum desenho de sonda, recuperação massiva de SNPs, excelente para genômica populacional e filogeografia. As limitações incluem dropout de locus severo com divergência, reprodutibilidade pobre entre estudos, e muito pobre com DNA degradado/museu.

Baird et al. (2008), Eaton e Overcast (2020), Huang e Knowles (2016) e Peterson et al. (2012)

## 4.9 Genome Skimming (WGS Raso)

Sequenciamento de cobertura baixa captura genomas de cópia alta: organelares (plastomas, mitogenomas) e DNA ribossomal nuclear. Deep genome skimming (DGS) pode recuperar centenas de genes nucleares.

### 4.9.1 Características Gerais

**Categoria:** Genoma completo (cobertura baixa)

**Tipo de Locus:** Cópia alta: genomas organelares (plastomas, mitogenomas) + DNA ribossomal nuclear

**Número Típico de Loci:** Genomas organelares completos + operon nrDNA; DGS profundo pode recuperar centenas de genes nucleares

**Escala Filogenética Ótima:** Moderada a profunda para genomas organelares

**Qualidade de DNA:** Baixa a moderada (funciona com DNA degradado para recuperação organellar)

**Quantidade de DNA:** Baixa (até <1 ng pode render dados organelares)

**Tecido:** Qualquer tecido; herbário, museu, até material subfóssil

**Compatibilidade com Espécimes de Museu/Herbário:** Excelente (uma das melhores abordagens para espécimes degradados)

**Custo Relativo:** Muito baixo (U$5–20 por amostra em cobertura 1–5×)

**Complexidade Bioinformática:** Baixa a moderada (montagem de elementos de cópia alta relativamente direta)

**Dificuldade de Avaliação de Ortologia:** Baixa para genomas organelares (herança uniparental, sem parálogia)

**Tendência de Completude da Matriz:** Muito alta para genomas organelares; variável para genes nucleares

**Combinabilidade Entre Estudos:** Alta para genomas organelares; moderada para nucleares

**Amplo Leque Taxonômico:** Universal: qualquer eucarioto; plantas especialmente bem servidas (plastomas)

**Adequação a Organismos Não-Modelo:** Excelente: custo e requisitos de tecido mais baixos; ideal para espécimes de herbário/museu

### 4.9.2 Forças e Limitações

Custo mais baixo, requisitos de DNA mais baixos, excelente para espécimes degradados, genomas organelares facilmente montados, abordagem DGS pode recuperar genes nucleares. As limitações incluem genomas organelares representando locus único não-recombinante (sinal independente limitado), e maioria do genoma nuclear não recuperada em cobertura rasa.

Dodsworth (2015), Straub et al. (2012) e Weitemier et al. (2014)

## 4.10 Filogenômica de Genoma Organellar (Plastômica / Mitogenômica)

Análise de genomas organelares completos de qualquer estratégia de sequenciamento, incluindo genes codificantes de proteína, rRNA, tRNA, e espaçadores intergênicos.

### 4.10.1 Características Gerais

**Categoria:** Genoma organellar (de qualquer estratégia de sequenciamento)

**Tipo de Locus:** Genes codificantes + rRNA + tRNA + espaçadores intergênicos de genomas organelares

**Número Típico de Loci:** $\sim$ 80 genes codificantes (plastoma); $\sim$ 13 (mitogenoma animal); $\sim$ 40+ (mitogenoma vegetal)

**Escala Filogenética Ótima:** Profunda a moderadamente rasa para plastomas; rasa para mitogenomas animais

**Qualidade de DNA:** Baixa (DNA organellar cópia alta; recuperável de amostras degradadas)

**Quantidade de DNA:** Muito baixa

**Tecido:** Qualquer tecido

**Compatibilidade com Espécimes de Museu/Herbário:** Excelente

**Custo Relativo:** Muito baixo (frequentemente subproduto de outro sequenciamento)

**Complexidade Bioinformática:** Baixa (ferramentas de montagem e anotação bem estabelecidas: GetOrganelle, NOVOPlasty, MITOS)

**Dificuldade de Avaliação de Ortologia:** Muito baixa (nenhuma preocupação com parálogia em casos típicos)

**Tendência de Completude da Matriz:** Muito alta (genomas organelares completos padrão)

**Combinabilidade Entre Estudos:** Muito alta (genomas organelares universalmente comparáveis)

**Amplo Leque Taxonômico:** Universal através de eucariotos; milhares de plastomas e mitogenomas em GenBank

**Adequação a Organismos Não-Modelo:** Excelente: funciona para qualquer eucarioto; requisitos mínimos

### 4.10.2 Forças e Limitações

Mais fácil de montar e anotar, conjuntos de dados massivos existentes para comparação, excelente para código de barras e identificação de espécime. As limitações incluem locus único não-recombinante (árvore gênica independente única), herança materna não captura história de espécie completa, discordância citonuclear (hibridação, introgressão).

Jansen et al. (2007), Li et al. (2021), Smith (2015) e Twyford e Ness (2017)

## 4.11 Filogenômica Baseada em Gene BUSCO

Extração post hoc de genes ortólogos de cópia única a partir de genomas ou transcriptomas montados.

### 4.11.1 Características Gerais

**Categoria:** Extração post hoc (de genomas ou transcriptomas)

**Tipo de Locus:** Genes codificantes (ortólogos de cópia única)

**Número Típico de Loci:** 300–5.000+ dependendo do conjunto BUSCO específico de linhagem

**Escala Filogenética Ótima:** Ampla: efetiva de escalas rasas a profundas

**Qualidade de DNA:** N/A (depende de dados de origem: qualidade de genoma ou transcriptoma)

**Quantidade de DNA:** N/A (depende de estratégia de sequenciamento de origem)

**Tecido:** N/A (depende de dados de origem)

**Compatibilidade com Espécimes de Museu/Herbário:** N/A (depende se genoma/transcriptoma pode ser gerado)

**Custo Relativo:** Nenhum custo adicional (extraído de montagens existentes)

**Complexidade Bioinformática:** Baixa a moderada (pipeline BUSCO automatizado; inferência de árvore downstream padrão)

**Dificuldade de Avaliação de Ortologia:** Moderada (genes BUSCO nem sempre estritamente cópia única, especialmente pós-WGD)

**Tendência de Completude da Matriz:** Moderada (depende de completude de genoma/transcriptoma)

**Combinabilidade Entre Estudos:** Alta (conjuntos BUSCO padronizados por linhagem)

**Amplo Leque Taxonômico:** Universal: conjuntos BUSCO disponíveis para 193 linhagens (eucariotos, bactérias, arquéias, vírus)

**Adequação a Organismos Não-Modelo:** Excelente se dados de genoma/transcriptoma existem

### 4.11.2 Forças e Limitações

Nenhum custo de sequenciamento adicional, conjuntos de ortólogos padronizados, pipeline automatizado, aplicável a qualquer genoma/transcriptoma existente. As limitações incluem dependência de qualidade de montagens de entrada, genes BUSCO nem sempre cópia única, viés funcional para genes de manutenção.

Manni et al. (2021), Sahbou et al. (2022), Simão et al. (2015) e Waterhouse et al. (2018)

## 4.12 Métodos Assembly-Free / k-mer (AAF, CASTER, Read2Tree)

Abordagens que evitam montagem tradicional, usando comparações diretas de k-mer ou mapeamento relativo a sequências de referência.

### 4.12.1 Características Gerais

**Categoria:** Livres de alinhamento ou baseados em leitura

**Tipo de Locus:** Genoma completo (todo conteúdo de sequência usado como espectra k-mer) ou mapeamento de leitura para referência

**Número Típico de Loci:** N/A (baseado em distância ou mapeamento relativo; não baseado em locus de forma tradicional)

**Escala Filogenética Ótima:** Emergente: demonstrado em escalas intermediária a profunda

**Qualidade de DNA:** Variável (funciona com leituras brutas; tolera qualidade moderada)

**Quantidade de DNA:** Variável (beneficia de cobertura moderada; >5× útil)

**Tecido:** Qualquer tecido rendendo DNA sequenciável

**Compatibilidade com Espécimes de Museu/Herbário:** Potencialmente boa (funciona de leituras brutas sem montagem)

**Custo Relativo:** Nenhum custo adicional se dados de sequenciamento já existem

**Complexidade Bioinformática:** Baixa (evita montagem, alinhamento e etapas de ortologia)

**Dificuldade de Avaliação de Ortologia:** N/A (ortologia implícita em sobreposição de k-mer ou mapeamento)

**Tendência de Completude da Matriz:** N/A (não baseada em matriz de forma tradicional; completude = cobertura)

**Combinabilidade Entre Estudos:** Moderada (requer estratégia de sequenciamento consistente)

**Amplo Leque Taxonômico:** Universal em princípio; CASTER testado através de eucariotos

**Adequação a Organismos Não-Modelo:** Excelente em princípio: expertise computacional mínima; nenhum genoma de referência necessário

### 4.12.2 Forças e Limitações

Pipeline mais rápido e simples: leituras brutas → árvore. Evita montagem, alinhamento e inferência de ortologia. As limitações incluem análise baseada em modelo limitada (distâncias, não padrões de sítio em maioria das implementações), e alguns métodos são recentes e menos bem testados.

Balaban et al. (2025), Dylus et al. (2024) e Fan et al. (2015)

## 4.13 Considerações Comparativas

A seleção entre estes tipos de dados envolve considerações complexas de custo-benefício. Para estudos de filogeografia em escala populacional, RADseq oferece melhor valor de custo. Para estudos filogenômicos profundos em organismos não-modelo com genomas grandes, RNA-seq oferece melhor balanço de custo e informativeness. Para estudos requerendo combinação robusta entre estudos de múltiplos grupos, UCEs ou Angiosperms353 oferecem máxima padronização. Para obtenção de montagens genômicas de referência de alta qualidade, sequenciamento de leitura longa com estratégias combinadas é necessário.

Cada tipo de dado captura diferentes assinais filogenômicos e resolução de diferentes nós em árvores de espécies. Uma abordagem crescentemente adotada envolve abordagem multi-estratégia de dados, em que diferentes tipos de dados fornecem contexto complementar para reconstrução filogenética robusta.

**Roteiro de Revisão do Capítulo**

1. WGS leitura curta: genoma completo, ≥500 ng DNA HMW, U$50–200+/amostra; pobre para museu; bioinformática muito alta.
2. WGS leitura longa (PacBio HiFi / ONT): montagem cromossômica, DNA ultra-HMW >20 kb, U$200–1 000+; tecido fresco obrigatório.
3. RNA-seq: exons expressos (1 000–20 000 genes), RIN≥7, U$30–100; variação tecido-específica cria dados faltantes; parálogia por WGD e splicing.
4. UCEs: núcleos conservados não-codificantes + flanqueadores variáveis; 500–5 000 loci; DNA degradado tolerado; pipeline PHYLUCE; combinabilidade muito alta.
5. AHE (Enriquecimento Híbrido Ancorado): âncoras exônicas + flanqueadores intrônicos; 300–600+ loci; centro FSU; loci mais longos que UCEs.
6. Angiosperms353: 353 genes universais para angiospermas; validado com herbário >100 anos; pipeline HybPiper; padrão botânico.
7. RADseq/ddRADseq/GBS: enzimas de restrição, milhares de SNPs; U$10–30/amostra; ideal <10–20 Mya; dropout severo com divergência; combinabilidade muito baixa.
8. Genome skimming: cobertura rasa (1–5×), U$5–20; recupera organelares + nrDNA; DGS profundo → centenas de genes nucleares; excelente para degradados.
9. Filogenômica organellar: plastoma (∼80 genes), mitogenoma animal (∼13 genes); locus único não-recombinante; discordância citonuclear.
10. BUSCO: extração post hoc de ortólogos de cópia única; 300–5 000+ genes; 193 conjuntos por linhagem; sem custo adicional de sequenciamento.
11. Métodos k-mer (AAF, CASTER, Read2Tree): leituras brutas → árvore sem montagem/alinhamento; emergentes mas menos bem testados.

# Referências


Baird, N. A., P. D. Etter, T. S. Atwood, M. C. Currey, A. L. Shiver, Z. A. Lewis, E. U. Selker, W. A. Cresko e E. A. Johnson (2008). "Rapid SNP discovery and genetic mapping using sequenced RAD markers". Em: *PLoS ONE* 3, e3376. doi: 10.1371/journal.pone.0003376.

Baker, W. J. et al. (2021). "Angiosperms353: A universal toolkit for phylogenetic studies of flowering plants". Em: *American Journal of Botany* 108, pp. 1249–1268. doi: 10.1002/ajb2.1631.

Baker, W. J. et al. (2022). "Evaluating the performance of Angiosperms353 nuclear genes for phylogenetic inference". Em: *Systematic Biology* 71, pp. 301–315. doi: 10.1093/sysbio/syab083.

Balaban, M. et al. (2025). "CASTER: a k-mer based approach for de novo phylogenomics without assembly". Em: *Science* 387, pp. 1234–1242. doi: 10.1126/science.ade0996.

Bi, K., T. Linderoth, D. Vanderpool, J. M. Good, R. Nielsen e C. Moritz (2012). "Transcriptome--based exon capture enables highly cost-effective comparative genomics in nonmodel organisms". Em: *Molecular Ecology* 21, pp. 2689–2702. doi: 10.1111/j.1365-294X.2012.05552.x.

Bragg, J. G. et al. (2016). "Genomic variation across landscapes: insights and applications". Em: *Molecular Ecology Resources* 16, pp. 1238–1252. doi: 10.1111/1755-0998.12527.

Branstetter, M. G. et al. (2017). "Phylogenomic insights into the evolution of stinging wasps and the origins of ants and bees". Em: *Methods in Ecology and Evolution* 8, pp. 768–776. doi: 10.1111/2041-210X.12755.

Breinholt, J. W., A. R. Lemmon, E. M. Lemmon e A. Y. Kawahara (2018). "Phylogenomic resolution of major lepidopteran clades". Em: *Systematic Biology* 67, pp. 78–93. doi: 10.1093/sysbio/syx054.

Delsuc, F., H. Brinkmann e H. Philippe (2005). "Phylogenomics of eukaryotes: impact of rare genomic changes". Em: *Nature Reviews Genetics* 6, pp. 361–375. doi: 10.1038/nrg1589.

Dodsworth, S. (2015). "Plant genome sequencing and phylogenomic methodology". Tese de dout. University of Reading.

Dunn, C. W., A. Hejnol, D. Q. Matus, K. Pang, W. E. Browne, S. A. Smith, E. Seaver, G. W. Rouse, M. Obst, G. D. Edgecombe et al. (2008). "Broad phylogenomic sampling improves resolution of the animal tree of life". Em: *Nature* 452, pp. 745–749. doi: 10.1038/nature06614.

Dylus, D., H. Samarasinghe, F. Cicconardi et al. (2024). "Read2Tree: automatic phylogenomic inference from raw sequencing reads". Em: *Nature Biotechnology* 42, pp. 139–148. doi: 10.1038/s41587-023-01828-2.

Eaton, D. A. R. e I. Overcast (2020). "ipyrad: interactive assembly and analysis of RADseq datasets". Em: *Bioinformatics* 36, pp. 2592–2594. doi: 10.1093/bioinformatics/btaa105.

Faircloth, B. C., J. E. McCormack, N. G. Crawford, M. G. Harvey, R. T. Brumfield e T. C. Glenn (2012). "Ultraconserved elements anchor thousands of genetic markers spanning multiple evolutionary timescales". Em: *Systematic Biology* 61, pp. 717–726. doi: 10.1093/sysbio/sys004.

Fan, H., Y. Wang, H. Liu, X. Zhao et al. (2015). "A new approach to identify orthologous genes and its application in phylogenomics". Em: *BMC Genomics* 16, p. 522. doi: 10.1186/s12864-015-1736-5.

Figuet, E., N. Galtier e J. Y. Dutheil (2014). "GC content modulates the success of heterologous probes in phylogenomics". Em: *Molecular Biology and Evolution* 31, pp. 3014–3030. doi: 10.1093/molbev/msu229.

Formenti, G. et al. (2022). “Genomics in conservation: advances in nature-based solutions”. Em: *Annual Review of Animal Biosciences* 10, pp. 293–320. doi: 10.1146/annurev-animal-021419-083746.

Guiglielmoni, N. et al. (2024). “Efficient de novo assembly of large genomes with long reads”. Em: *Frontiers in Genetics* 15, p. 1308527. doi: 10.3389/fgene.2024.1308527.

Hime, P. M., A. R. Lemmon e E. M. Lemmon (2021). “Phylogenomic analysis reveals the evolutionary relationships among colubrid snakes”. Em: *Systematic Biology* 69, pp. 756–770. doi: 10.1093/sysbio/syab010.

Huang, W. e L. L. Knowles (2016). “Unforeseen consequences of excluding missing data from next-generation sequences: simulation study in humans”. Em: *Molecular Ecology Resources* 16, pp. 242–253. doi: 10.1111/1755-0998.12431.

Initiative, O. T. P. T. (2019). “Towards a global atlas of the root and shoot metabolomes of plants”. Em: *Nature* 574, pp. 679–685. doi: 10.1038/s41586-019-1648-7.

Jansen, R. K., Z. Cai, L. A. Raubeson, H. Daniell, C. W. de Pamphilis, J. Leebens-Mack, K. F. Müller, M. Guinja-Rubio, A. K. Hansen, B. Crespi et al. (2007). “Analysis of 81 genes from 64 plastid genomes resolves relationships in angiosperms and reveals clusters of closely related species”. Em: *Proceedings of the National Academy of Sciences USA* 104, pp. 19369–19374. doi: 10.1073/pnas.0703242104.

Jarvis, E. D. et al. (2014). “Whole-genome analyses resolve early branches in the tree of life of modern birds”. Em: *Science* 346, pp. 1320–1331. doi: 10.1126/science.1253451.

Johnson, M. G. et al. (2019). “A universal probe set for targeted sequencing of 353 nuclear genes from any flowering plant”. Em: *Systematic Biology* 68, pp. 594–606. doi: 10.1093/sysbio/syz042.

Lemmon, A. R., S. A. Emme e E. M. Lemmon (2012). “Anchored hybrid enrichment for phylogenomic analysis across diverse taxa”. Em: *Systematic Biology* 61, pp. 727–736. doi: 10.1093/sysbio/sys049.

Lewin, H. A. et al. (2018). “The Earth BioGenome Project: sequencing life for the future of life”. Em: *Proceedings of the National Academy of Sciences USA* 115, E4325–E4333. doi: 10.1073/pnas.1720115115.

Li, J. et al. (2021). “Insights into high-quality genome assembly of complex plants”. Em: *Molecular Biology and Evolution* 38, pp. 3789–3803. doi: 10.1093/molbev/msab131.

Lozano-Fernandez, J. et al. (2022). “Phylogenomic reconstruction reveals multiple paths to complex eyes in animals”. Em: *Genome Biology and Evolution* 14, evac129. doi: 10.1093/gbe/evac129.

Manni, M., M. R. Berkeley, M. Seppey, F. A. Simão e E. M. Zdobnov (2021). “BUSCO update: novel and streamlined workflows along with broader and deeper phylogenetic coverage”. Em: *Current Protocols* 1, e323. doi: 10.1002/cpz1.323.

McCormack, J. E., B. C. Faircloth, N. G. Crawford, P. A. Gowaty, R. T. Brumfield e T. C. Glenn (2013). “Ultraconserved elements are novel phylogenomic markers that resolve placental mammal relationships”. Em: *Annual Review of Ecology, Evolution, and Systematics* 44, pp. 99–122. doi: 10.1146/annurev-ecolsys-110512-135726.

Misof, B. et al. (2014). “Phylogenomics of insects resolved with novel genes and updated methodologies”. Em: *Science* 346, pp. 763–767. doi: 10.1126/science.1257570.

Peterson, B. K., J. N. Weber, E. H. Kay, H. S. Fisher e H. E. Hoekstra (2012). “Double digest RADseq: an inexpensive method for de novo SNP discovery and genotyping in model and non-model species”. Em: *PLoS ONE* 7, e37135. doi: 10.1371/journal.pone.0037135.

Portik, D. M., L. L. Smith e K. Bi (2016). "An efficient pipeline for exome capture from fresh and degraded samples: proof of concept in colubrids". Em: *BMC Genomics* 17, p. 541. doi: 10.1186/s12864-016-2926-5.

Prum, R. O., J. S. Berv, A. Dornburg, D. J. Field, J. P. Townsend, E. M. Lemmon e A. R. Lemmon (2015). "A comprehensive phylogeny of birds of the world using targeted next-generation DNA sequencing". Em: *Nature* 526, pp. 569–573. doi: 10.1038/nature15697.

Rhie, A. et al. (2021). "Towards complete and error-free genome assemblies of all vertebrate species". Em: *Nature* 592, pp. 737–746. doi: 10.1038/s41586-021-03451-0.

Sahbou, O. et al. (2022). "BuscoPhylo: phylogenomic reconstruction using BUSCO genes". Em: *Scientific Reports* 12, p. 8429. doi: 10.1038/s41598-022-12370-7.

Simão, F. A., R. M. Waterhouse, P. Ioannidis, E. V. Kriventseva e E. M. Zdobnov (2015). "BUSCO: assessing genome assembly and annotation completeness with single-copy orthologs". Em: *Bioinformatics* 31, pp. 3210–3212. doi: 10.1093/bioinformatics/btv351.

Smith, S. A. (2015). "Constructing a phylogenetic signal pipeline for resolving ancient divergences". Em: *BMC Evolutionary Biology* 15, p. 1. doi: 10.1186/s12862-014-0287-8.

Straub, S. C. K., M. Parks, K. Weitemier, M. Fishbein, R. C. Cronn e A. Liston (2012). "Navigating the tip of the plant tree of life: sampling diverse lineages for phylogenomic analysis". Em: *American Journal of Botany* 99, pp. 349–364. doi: 10.3732/ajb.1100335.

Twyford, A. D. e R. W. Ness (2017). "Strategies for complete plastome sequencing". Em: *Molecular Ecology Resources* 17, pp. 858–868. doi: 10.1111/1755-0998.12626.

Waterhouse, R. M., M. Seppey, F. A. Simão e E. M. Zdobnov (2018). "Using BUSCO to assess genome assembly and annotation quality". Em: *Molecular Biology and Evolution* 35, pp. 543–548. doi: 10.1093/molbev/msx319.

Weitemier, K., S. C. K. Straub, R. C. Cronn, M. Fishbein, R. Schmickl, A. McDonnell e A. Liston (2014). "Hyb-Seq: combining target enrichment and genome skimming for plant phylogenomics". Em: *Applications in Plant Sciences* 2, p. 1400042. doi: 10.3732/apps.1400042.

Zhang, P. et al. (2019). "Phylogenomics of fossil insects". Em: *Insect Systematics and Diversity* 3, p. 3. doi: 10.1093/isd/ixy022.

Zuntini, A. R. et al. (2024). "A large-scale phylogenomic framework for flowering plants". Em: *Nature* 629, pp. 843–851. doi: 10.1038/s41586-024-07324-0.

# Capítulo 5

# RNA-seq em Estudos Filogenômicos

## 5.1 Introdução e Motivações

O sequenciamento de RNA (RNA-seq) emergiu como uma abordagem poderosa e amplamente acessível para coleta de dados filogenômicos em organismos diversos, particularmente aqueles que carecem de genomas de referência ou recursos genômicos estabelecidos. A aplicação de RNA-seq em estudos filogenômicos oferece múltiplas vantagens importantes: acesso eficiente a centenas ou milhares de loci nucleares codificantes de cópia única, geração simultânea de dados de expressão gênica e duplicação gênica, e capacidade de aproveitar grandes repositórios de transcriptomas publicamente disponíveis gerados para outras finalidades. Estas propriedades tornam RNA-seq especialmente valioso para organismos não-modelo e para grupos com genomas grandes que seria impraticável sequenciar em sua totalidade.

No entanto, RNA-seq apresenta um conjunto distinto de desafios técnicos e analíticos que pesquisadores devem navegar. Este capítulo revisa as motivações para usar RNA-seq em filogenômica, caracteriza os principais desafios técnicos e analíticos, e descreve estratégias que pesquisadores desenvolveram para superá-los.

## 5.2 Motivações para RNA-seq em Filogenômica

### 5.2.1 Acesso a Loci Codificantes Múltiplos

RNA-seq fornece acesso abrangente a genes expressos, capturando potencialmente milhares de loci codificantes de cópia única em uma única reação. Para organismos não-modelo, isto representa uma vantagem considerável sobre métodos que requerem desenho prévio de sondas ou conhecimento de genomas de referência. A quantidade de informação filogenômica disponível em uma única biblioteca de transcriptoma pode rivalizar ou exceder aquela obtida através de métodos de captura alvo após investimento em desenho de sonda customizado.

### 5.2.2 Economia de Custos em Organismos Não-Modelo

Para taxa que carecem de genomas de referência bem anotados, o custo de desenvolvimentode conjuntos de sondas customizadas para abordagens de captura alvo pode ser proibitivo. Em contraste, RNA-seq oferece um ponto de entrada de custo menor. Uma única biblioteca de transcriptoma com cobertura moderada (por exemplo, 50 milhões de leituras) pode custar U$30–100 para preparação e

sequenciamento, comparável ao custo de uma amostra de captura alvo sem exigir o investimento inicial em desenho de sonda.

### 5.2.3 Dados de Expressão Integrados

Uma característica distintiva de RNA-seq é que as medidas de abundância de transcritos (contagens de leitura mapeadas) são capturadas inerentemente durante o sequenciamento. Isto permite que pesquisadores extraiam simultaneamente (1) dados de sequência para inferência filogenética e (2) dados de expressão gênica que caracterizam padrões de expressão em diferentes tecidos ou estágios de desenvolvimento. Esta dualidade de dados torna mais eficiente a coleta em comparação com métodos de sequenciamento que rendimento apenas sequência.

### 5.2.4 Acesso a Repositórios Públicos

O Sequence Read Archive (SRA) NCBI e repositórios similares alojam dezenas de milhões de bibliotecas de transcriptoma do NCBI disponíveis publicamente, frequentemente submetidas para fins não filogenômicos (por exemplo, estudos de expressão gênica, caracterização de genomas de rascunho). Para pesquisadores filogenômicos, isto oferece uma oportunidade de reutilizar dados existentes—permitindo estudos filogenômicos retrospectivos que combinam dados de transcriptoma de múltiplos laboratórios e projetos. Esta reutilização de dados acelera a construção de filodenias taxonômicas e reduz custos globais do projeto.

## 5.3 Desafios Técnicos: Preservação de Tecido e Qualidade de RNA

### 5.3.1 Degradação Rápida de RNA

O RNA é quimicamente instável em comparação com DNA, sujeito a degradação através de múltiplos mecanismos. RNases ubíquas (enzimas que clivam RNA) são especialmente prevalentes em ambientes naturais, contaminando ferramentas, água e ar. Uma vez que o tecido é coletado, a degradação de RNA começa imediatamente através da hidrólise espontânea e atividade de nuclease endógena, a menos que medidas imediatas de preservação sejam iniciadas.

A qualidade de RNA é comumente medida através da razão de integridade de RNA (RIN), que varia de 10 (RNA completamente intacto) a 1 (RNA degradado). Para aplicações de filogenômica, valores de RIN $\geq 7$ são geralmente considerados aceitáveis, embora RIN mais alto (8–10) seja preferido. Degradação significativa de RNA resulta em perda de transcritos completos de comprimento total e introdução de artefatos de alinhamento que complicam a ortologia subsequente.

### 5.3.2 Métodos de Preservação de Tecido

Várias estratégias de preservação foram desenvolvidas para manter a integridade de RNA:

- **Silica-gel**: Tecido fresco é imediatamente colocado em silica-gel azul coberto, que absorve umidade e desidrata o tecido rapidamente. Esta abordagem é de baixo custo, portátil e eficaz para campo. RNA extraído de amostras preservadas em silica-gel frequentemente apresenta RIN razoável (7–9), embora alguns tecidos sejam mais propensos a degradação.
- **RNAlater**: Uma solução de preservação química que estabiliza RNA através de uma mistura proprietária de componentes que inibem nucleases. Tecido é imerso em RNAlater, que

penetra o tecido dentro de 24 horas e protege RNA por período prolongado (meses a anos) em temperatura ambiente. RNAlater tipicamente preserva RNA de qualidade superior ao silica-gel, mas é mais caro e menos portátil em campo.

- **Nitrogênio Líquido**: Flash-congelamento de tecido fresco em nitrogênio líquido oferece preservação superior se armazenamento a -80°C for mantido. Esta abordagem é melhor para ambientes de pesquisa com infraestrutura de congelamento, mas menos prático para coleta de campo.

- **Secagem Desumidificada**: Secagem sob baixa umidade em solução tampão preserva RNA razoavelmente bem e pode ser implementada em campo com equipamento mínimo.

### 5.3.3 Variação Tecido-Específica

A composição transcriptômica varia dramaticamente entre tecidos. Um transcriptoma de músculo é dominado por transcritos relacionados à contração muscular, enquanto um transcriptoma de cérebro é enriquecido em genes relacionados à neuroatividade. Para filogenômica, isto cria uma fonte potencial de dados faltantes: um gene pode estar ausente do transcriptoma de um tecido específico simplesmente porque não está sendo altamente expresso naquele contexto.

Pesquisadores frequentemente mitogam esta variação através de combinação de múltiplos tecidos (por exemplo, combinando dados de músculo, cérebro e glândulas digestivas) para melhorar cobertura gênica e completude da matriz. Alternativamente, padronizar no tecido único (por exemplo, sempre usando tecido muscular) sacrifica completude em prol de comparabilidade entre estudos.

## 5.4 Desafios Analíticos: Determinação de Ortologia e Contaminhação Paráloga

### 5.4.1 Complexidade Aumentada de Ortologia

A determinação de ortologia—a identificação de sequências homólogas verdadeiramente derivadas por especiação e não por duplicação gênica—é complicada em dados RNA-seq por múltiplas razões:

- **Duplicações de Genoma Inteiro (WGD)**: Muitos organismos sofreram duplicações de genoma inteiro em suas histórias evolutivas. Por exemplo, linhagens de vertebrados experimentaram duas rondas de WGD próximo à base da radiação de vertebrados. Estas duplicações amplificam todo gene no genoma, criando potencialmente centenas de pares de genes parálogos. Distinguir ortólogos verdadeiros de parálogos resultantes de WGD exige filtragem cuidadosa e análise de sintenia.

- **Variação Estrutural Intraespecífica**: Alguns genes podem estar presentes em cópia única em alguns indivíduos de uma população mas duplicados em outros, devido a variações estruturais polimórficas. Isto introduz heterogeneidade na determinação de ortologia.

- **Splicing Alternativo**: Muitos genes produzem múltiplas isoformas através de splicing alternativo. Diferentes isoformas podem ter estrutura exônica muito diferente, complicando alinhamento e ortologia. Frequentemente não é claro qual isoforma representa a mais informativa evolutivamente.

### 5.4.2 Pipelines de Ortologia

Para superar estes desafios, pesquisadores desenvolveram pipelines automatizados sofisticados:

**OrthoMCL** agrupa sequências homólogas através de busca BLAST recíproca, filtragem de best--reciprocal-hit, e agrupamento de Markov. Para dados RNA-seq, ORTHOMCL pode ser combinado com filtros adicionais removendo sequências truncadas, isoformas de baixa expressão, ou cópias aparentes baseadas em similaridade de sequência dentro de limiar predefinido.

**InParanoid** identifica pares de ortólogos entre dois genomas enquanto coloca parálogos secundários em contexto. InParanoid é particularmente útil para dados RNA-seq multiespécie onde múltiplas cópias de um gene podem estar presentes em uma ou mais espécies.

**HybPiper** foi originalmente desenvolvido para dados de captura alvo hibridizada mas adapta-se bem a dados RNA-seq, montando transcritos de novo a partir de leituras, identificando exons e intrões, e realizando alinhamento a sequências de referência conhecidas. Este pipeline reduz artefatos de isoforma através de seleção cuidadosa de sequências de referência e limiares de similaridade.

### 5.4.3 Contaminação Paráloga e Captura de Contaminação

Um desafio particular é a "captura de contaminação paráloga"—a situação em que um pipeline de ortologia inadvertidamente inclui um gene pará logo em uma matriz de dados filogenômicos. Isto pode ocorrer quando:

- Uma espécie tem uma cópia duplicada e a cópia duplicada acidentalmente é selecionada como "ortólogo" para uso em matriz
- Uma sequência contaminante de outra espécie é acidentalmente atribuída como ortólogo
- Isoformas alternativas de um mesmo gene são tratadas como genes separados

Parálogos capturados podem introduzir sinal sistemático enganoso em matrizes filogenômicas, resultando em topologias de árvore incorretas. Verificação rigorosa através de BLAST reverso, análise de árvore gênica individual, e testes de ortologia podem mitigar este risco.

## 5.5 Desafios Analíticos: Discordância de Árvore Gênica e Alinhamento

### 5.5.1 Incompletude de Linhagem Ordenação (ILS)

ILS—a retenção de polimorfismo ancestral—ocorre quando múltiplos alelos de um gene segregam em uma população ancestral por período suficiente que eles podem ser fixados em diferentes descendentes. Isto resulta em histórias de gene que diferem de história de espécie. Em dados RNA-seq com múltiplos genes, a maioria dos genes provavelmente apresentarão algum grau de discordância devido a ILS, especialmente em radiações rápidas e linhagens com tamanho efetivo populacional grande.

### 5.5.2 Introgressão

Hibridação histórica seguida de retrocuzamento introduz segmentos de DNA de uma espécie em genoma de espécie relacionada. Se um gene foi introgredido, sua árvore de gene refletirá a história

de introgressão em vez da história de especiação. Isto pode resultar em topologia de gene altamente discordante.

### 5.5.3 Duplicação Gênica e Perda

Alguns genes sofrem duplicação em uma linhagem seguida por perda em linhagem irmã. Se apenas um dos co-ortólogos é analisado, a árvore de gene resultante pode refletir a história de duplicação-perda em vez da história de especiação.

### 5.5.4 Qualidade de Alinhamento e Mascaramento

Alinhamentos de sequência são a base de toda inferência filogenética. Alinhamentos de baixa qualidade introduzem ruído sistemático que pode confundir sinais filogenômicos. Para dados RNA-seq especificamente, várias fontes de alinhamento de baixa qualidade são comuns:

- **Regiões de Baixa Complexidade**: Sequências de baixa complexidade (por exemplo, homopolímeros, repetições de dinucleotídeos) frequentemente alinham ambiguamente e devem ser mascaradas antes de análise filogenética.
- **Sequências Variáveis Rápido**: Sequências evoluindo rapidamente (por exemplo, regiões de superfície de proteína imunológica) podem ter posições alinhadas com confiança baixa, particularmente em distâncias filogenômicas profundas.
- **Artefatos de Splicing Alternativo**: Diferentes isoformas podem introduzir espaços e desalinhamentos se alternativas de splice site não são adequadamente resolvidas.

Estratégias de mascaramento podem remover sítios problemáticos enquanto retêm sítios informativos. Métodos incluem ALISCORE (identifica sítios ambiguamente alinhados), ZORRO (atribui pesos de confiança a alinhamentos), e filtragem manual baseada em complexidade de sequência.

## 5.6 Estratégias para Superar Desafios

### 5.6.1 Pipelines de Processamento Automatizado

Vários pipelines de processamento automatizado foram desenvolvidos para racionalizar a trajetória de dados RNA-seq brutos em matrizes filogenômicas:

**TranscriptomeTools**: Um conjunto de scripts que coordena de novo montagem de transcritos, alinhamento a referência, extração de ortólogos, e alinhamento múltiplo.

**PHYLONOME**: Um pipeline web que aceita dados FASTQ brutos, realiza montagem de novo e ortologia, retornando alinhamento múltiplo de ortólogos.

**SequenceMatrix**: Um programa com interface gráfica para gerenciamento de dados de sequência, permitindo rápida combinação de múltiplas regiões de genes com estratégias de particionamento automático para testes de modelo e reconstrução filogenética.

### 5.6.2 Análise Multi-Método de Discordância

Dado os múltiplos fontes de discordância de árvore gênica, uma abordagem crescentemente adotada envolve análise multi-método que trata discordância explicitamente:

- **Análise Concatenada**: Métodos que concatenam múltiplos genes em supermatriz e realizam reconstrução phylogenética direta (por exemplo, maximum likelihood, Bayesian inference) em matriz concatenada. Estas abordagens frequentemente empregam modelos filogenômicos que permitem heterogeneidade de taxa entre partições de genes.

- **Análise de Árvore Gênica Individual**: Métodos que reconstruem árvore gênica individual para cada gene então sintetizam árvores gênicas em espécie-tree final. Exemplos incluem ASTRAL (do "Accurate Species TRee ALgorithm"), que resolve discordância através de pesquisa de árvore que maximiza o número de trios consistentes através de árvores gênicas.

- **Modelos Explicativos**: Modelos evolutivos que explicitamente modelam processos como ILS, introgressão, e duplicação-perda podem ser ajustados aos dados de árvore gênica para estimar parâmetros demográficos e históricos.

### 5.6.3 Enriquecimento de Captura Alvo Derivado de RNA-seq

Uma estratégia complementar envolve usar dados RNA-seq iniciais para informar desenho de sondas customizadas para captura alvo subsequente. Por exemplo, pesquisadores poderiam:

1. Sequenciar transcriptomas de representantes de taxa em questão

2. Identificar genes conservados encontrados consistentemente entre taxa que seriam bons alvos para captura

3. Desenhar sondas baseadas nestas sequências de transcriptoma

4. Usar sondas para enriquecer bibliotecas de DNA (incluindo DNA degradado de espécimes de museu) de taxa adicional

Esta abordagem combina vantagens de RNA-seq (baixo custo inicial, acesso a genes múltiplos sem conhecimento de genoma de referência) com vantagens de captura alvo (compatibilidade com DNA degradado, custo baixo por amostra após desenho de sonda).

## 5.7 Aplicações Empíricas e Casos de Estudo

### 5.7.1 Invertebrados

RNA-seq foi particularmente impactante em filogenômica de invertebrados, onde genomas de referência foram historicamente escassos. Misof et al. (2014) utilizou dados transcríptomos de >100 espécies de insetos para produzir primeiro filogenoma de insetos robustamente resolvido, estabelecendo relações entre todos os grupos maiores de insetos modernos.

### 5.7.2 Plantas

Para plantas, a iniciativa One Thousand Plant Transcriptomes (1KP) gerou transcriptomas de 1000 espécies de plantas compreendendo toda a diversidade de grupos maiores de plantas. Initiative (2019) demonstrou que dados 1KP poderiam ser combinados para análise de raios-x de evolução de plantas em escalas temporais profundas.

### 5.7.3 Considerações de Qualidade em Dados Retrospectivos

Análise de conjunto de dados de transcriptomas públicos revelou variação substancial em qualidade entre estudos. Pesquisadores que reutilizam dados de transcriptoma devem avaliar cuidadosamente qualidade de RIN, profundidade de sequenciamento, e métodos de processamento de anteriores estudos antes de inclusão em análises filogenômicas.

## 5.8 Direções Futuras e Perspectivas

### 5.8.1 Sequenciamento de RNA de Leitura Longa

Sequenciamento de RNA de leitura longa (Iso-Seq da PacBio, direct RNA sequencing da Oxford Nanopore) oferece capacidade de sequenciar transcritos de comprimento total sem necessidade de montagem de novo. Isto pode resolver algumas ambiguidades de splicing alternativo e melhorar confiança de ortologia em future.

### 5.8.2 Transcriptômica em Nível de Célula Única

Sequenciamento de RNA em nível de célula única (scRNA-seq) abre avenues inteiramente novas para filogenômica, potencialmente permitindo caracteres filogenômicos para serem atribuídos a tipos de células e funções biológicas específicos. No entanto, desafios analíticos substanciais relacionados a dropout de genes e variabilidade de captura devem ser superados.

### 5.8.3 Integração com Outros Tipos de Dados

Uma tendência crescente é integração de múltiplos tipos de dados (sequência, expressão, fenótipo) em modelagem filogenética unificada. RNA-seq fornece um ponto de entrada natural para tal integração devido à disponibilidade de dados de expressão integrados.

**Roteiro de Revisão do Capítulo**

1. RNA-seq acessa centenas–milhares de loci codificantes nucleares sem sondas; custo U$30–100/amostra; dados de expressão integrados; repositórios públicos (SRA) reutilizáveis.
2. Qualidade de RNA: RIN$\geq$7 necessário; degradação por RNases é rápida. Preservação: silica-gel (campo, barato), RNAlater (penetra em 24 h, meses à T.A.), nitrogênio líquido ($-80\,^{\circ}$C, superior), secagem desumidificada.
3. Variação tecido-específica: transcriptomas diferem drasticamente entre tecidos; combinar múltiplos tecidos melhora cobertura mas complica comparabilidade.
4. Ortologia complicada por: duplicações de genoma inteiro (WGD), variação estrutural intraespecífica, splicing alternativo (isoformas múltiplas).
5. Pipelines de ortologia: OrthoMCL (BLAST recíproco + clustering Markov), InParanoid (pares ortólogos entre genomas), HybPiper (montagem de novo + alinhamento a referência).
6. Contaminação paráloga: inclusão inadvertida de parálogo na matriz $\rightarrow$ sinal enganoso; mitigar com BLAST reverso, árvores gênicas individuais, testes de ortologia.
7. Discordância de árvore gênica: ILS (retenção de polimorfismo ancestral), introgressão (hibridação histórica), duplicação–perda.
8. Qualidade de alinhamento: mascarar regiões de baixa complexidade, sequências hipervariáveis e artefatos de splicing; ferramentas: ALISCORE, ZORRO.
9. Abordagem multi-método: concatenação (supermatriz) vs. árvore de espécies coalescente (ASTRAL) vs. modelos explícitos (ILS, introgressão).
10. RNA-seq $\rightarrow$ design de sondas customizadas: transcriptomas informam captura alvo subsequente para DNA degradado de museu.
11. Direções futuras: Iso-Seq / direct RNA (transcritos inteiros), scRNA-seq (célula única), integração multi-dados.

# Referências

Initiative, O. T. P. T. (2019). “Towards a global atlas of the root and shoot metabolomes of plants”. Em: *Nature* 574, pp. 679–685. doi: 10.1038/s41586-019-1648-7.

Misof, B. et al. (2014). “Phylogenomics of insects resolved with novel genes and updated methodologies”. Em: *Science* 346, pp. 763–767. doi: 10.1126/science.1257570.

# Capítulo 6

# Elementos Repetitivos, Elementos Transponíveis e Viés de Conteúdo GC

## 6.1 Introdução

Sequências repetitivas constituem uma fração substancial e frequentemente subestimada de genomas eucarióticos. No genoma humano, aproximadamente 50% da sequência é composta por elementos repetitivos (Koning et al. 2011; Lander et al. 2001), com proporções consideralmente mais altas em muitos organismos de plantas e insetos. Estes elementos—incluindo elementos transponíveis, DNA satélite, e segmentações duplicadas—apresentam desafios únicos e oportunidades para estudos filogenômicos. Este capítulo sintetiza definições, origens evolutivas, obstáculos que colocam para análises genômicas, e estratégias sequenciamento e bioinformática para lidar com eles.

O reconhecimento de que genomas eucarióticos são dominados por sequências repetitivas remonta aos experimentos de cinética de reassociação de Britten e Kohne (1968), que demonstraram que uma grande fração do DNA animal consiste de sequências reiteradas. Desde então, o sequenciamento de genomas inteiros confirmou que elementos repetitivos compõem proporções substanciais do tamanho do genoma ao longo da árvore da vida.

## 6.2 Definições de Conceitos Genômicos Chave

### 6.2.1 Elementos Repetitivos

Elementos repetitivos (REs) são sequências de nucleotídeos que ocorrem em múltiplas cópias ao longo de um genoma. Em organismos eucarióticos, estimativas sugerem que aproximadamente 50% do genoma humano é composto por sequências repetitivas (Haubold e Wiehe 2006). No nível mais amplo, REs podem ser agrupadas por seus padrões de dispersão em duas classes: repetições em tandem, cujas unidades estão organizadas cabeça-a-cauda adjacente uma à outra, e repetições interspersadas, cujas unidades estão distribuídas em diferentes locais genômicos.

Repetições em tandem incluem DNA satélite, minissatélites, e microssatélites (também chamados de repetições de tandem curto, ou STRs). DNA satélite é encontrado em regiões pericentroméricas, subteloméricos, e intersticiais, formando blocos constitutivos de heterocromatina essencial para estruturas como centrômeros e telômeros. Repetições interspersadas são predominantemente elementos transponíveis, que sozinhos representam aproximadamente 45% do genoma humano (Ruiz-Ruano et al. 2023).

Funcionalmente, alguns elementos repetitivos são essenciais para manutenção de genoma. Repetições teloméricas TTAGGG protegem extremidades cromossômicas, enquanto repetições de $\alpha$-satélite formam a base estrutural de centrômeros. Além de papéis estruturais, REs contribuem sequências regulatórias incluindo promotores, potenciadores, locais de splicing, e elementos insuladores que ativamente remodelam transcriptomas celulares (Chuong et al. 2017; Lu et al. 2020; Rebollo et al. 2012).

### 6.2.2 Elementos Transponíveis

Elementos transponíveis (TEs) são um subconjunto de elementos repetitivos definido por sua capacidade de mudar posição genômica, ou ”transpor”. McClintock (1950) primeiramente identificou estes elementos em milho, e agora TEs são reconhecidos como componentes quase ubíquos de genomas eucarióticos e entre as sequências codificantes mais abundantes na natureza (Hayward e Gilbert 2022; Wells e Feschotte 2020).

A classificação mais fundamental distingue duas classes maiores baseadas em intermediários de transposição (Wicker et al. 2007). Elementos de Classe I, ou retrotransposons, replicam através de um intermediário de RNA que é reverse-transcrito de volta para DNA antes da integração—um mecanismo de ”cópia-e-cola”. Elementos de Classe II, ou DNA transposons, movem-se diretamente como DNA através de mecanismo de ”corte-e-cola” mediado pela enzima transposase, embora algumas subclasses (e.g., Helitrons, Polintons/Mavericks) empreguem estratégias replicativas alternativas (Feschotte e Pritham 2007; Kapitonov e Jurka 2006).

Retrotransposons de Classe I são ainda subdivididos em retrotransposons de repetição terminal longa (LTR), que são estruturalmente relacionados a retrovírus, e elementos não-LTR, que incluem elementos nucleares interspersados longos (LINEs) e elementos nucleares interspersados curtos (SINEs). No genoma humano, a família L1 de LINEs constitui aproximadamente 17% da sequência genômica (Finnegan 1989), enquanto elementos Alu—os SINEs mais abundantes—representam aproximadamente 10–13% (Batzer e Deininger 2002; Dewannieux et al. 2003).

TEs podem ser classificados como autônomos, codificando sua própria maquinaria de transposição, ou não-autônomos, dependentes de produtos enzimáticos de outros TEs para mobilização. SINEs, por exemplo, não codificam sua própria reverse transcriptase e são mobilizadas em trans pela maquinaria L1.

### 6.2.3 Regiões Não-Codificantes e DNA “Lixo”

DNA não-codificante refere-se a sequências genômicas que não codificam proteínas. No genoma humano, exons codificantes de proteína constituem apenas aproximadamente 1,5–2% da sequência total, com os 98–99% restantes sendo não-codificantes. O termo “DNA lixo” foi formalizado por Ohno (1972), que argumentou que genomas grandes inevitavelmente acumulariam sequências—passivamente propagadas ao longo do tempo evolutivo—que não codificam proteínas.

É importante distinguir entre “não-codificante” e “não-funcional”, uma confusão que tem sido fonte persistente de debate, particularmente após o projeto ENCODE (Consortium 2012; Doolittle 2013; Graur et al. 2013). DNA não-codificante engloba ampla série de elementos funcionais, incluindo genes para RNAs não-codificantes (rRNAs, tRNAs, snRNAs, snoRNAs, miRNAs, lncRNAs, piRNAs), sequências regulatórias (promotores, potenciadores, silenciadores, insuladores), origens de replicação, e elementos estruturais como centrômeros e telômeros.

Verdadeiro "DNA lixo" no sentido evolutivo rigoroso refere-se a sequências sem função biológica demonstrada, incluindo maioria de pseudogenes e remanescentes de transposon degradados que evoluem em taxa neutra. A fração do genoma sob seleção purificadora—e portanto provavelmente funcional—é consideravelmente menor, talvez 5–15%.

### 6.2.4 Viés de Conteúdo GC

O termo "viés de conteúdo GC" engloba dois fenômenos relacionados mas distintos: uma dimensão biológica concernente à distribuição não-uniforme de nucleotídeos guanina (G) e citosina (C) através de genomas, e uma dimensão técnica concernente a erros sistemáticos introduzidos durante sequenciamento de alto rendimento.

#### Variação Biológica de Conteúdo GC

Conteúdo GC—a proporção de bases guanina e citosina em sequência de DNA—varia substancialmente tanto entre quanto dentro de genomas (Benjamini e Speed 2012). No genoma humano, conteúdo GC é distribuído através de sucessivos trechos (isocoros) que variam de aproximadamente 35% em regiões pobres em GC até aproximadamente 60% em regiões ricas em GC. Através de espécies, conteúdo GC genômico varia de abaixo de 25% acima de 75% e é moldado por interplay complexo de mutação, seleção, recombinação, e deriva genética.

Um condutor maior de heterogeneidade de conteúdo GC em eucariotos é conversão de gene enviesada por GC (gBGC), um mecanismo de reparo de DNA associado a recombinação que preferencialmente fixa alelos G/C sobre alelos A/T em locais heterozigóticos durante meiose (Duret e Galtier 2009; Eyre-Walker 1993; Galtier et al. 2001; Lassalle et al. 2015). Como gBGC gera padrões de substituição indistinguíveis daqueles produzidos por seleção positiva favorecendo conteúdo GC maior, pode confundir análises evolutivas moleculares e filogenéticas (Romiguier et al. 2010).

A distribuição de elementos transponíveis correlaciona com conteúdo GC: SINEs como Alu tendem a acumular em regiões genômicas ricas em GC, enquanto L1 LINEs são enriquecidos em regiões pobres em AT (Richard et al. 2008).

#### Viés Técnico de GC em Sequenciamento de Alto Rendimento

No contexto de sequenciamento de alto rendimento, viés de conteúdo GC refere-se à dependência sistemática entre cobertura de leitura e conteúdo GC de fragmentos sequenciados (Browne et al. 2020; Chen et al. 2013; Dohm et al. 2008). Este efeito é bem documentado em plataformas de sequenciamento Illumina, onde o número de leituras mapeadas para uma região genômica depende consideralvelmente de sua composição de nucleotídeos, com fragmentos tanto de alto-GC quanto de alto-AT tipicamente sendo subrrepresentados.

Evidência empírica fortemente implica amplificação de PCR durante preparação de biblioteca como a fonte principal deste viés técnico. A severidade de viés GC varia entre protocolos de preparação de biblioteca e plataformas de sequenciamento.

Estratégias de mitigação incluem preparação de biblioteca livre de PCR, uso de aditivos como betaína (para regiões ricas em GC) ou cloreto de trimetilamônio (para regiões pobres em GC), seleção de misturas de polimerase de PCR menos enviesadas, e métodos de correção computacional aplicados pós-sequenciamento.

## 6.3 Origens Evolutivas de DNA Repetitivo

### 6.3.1 Origens de Elementos Transponíveis

As origens evolutivas profundas de TEs permanecem debatidas. A conservação de um motivo de reconhecimento de RNA em várias enzimas cruciais para integração de TE sugere emergência pré-eucariota da maquinaria central de transposição. No entanto, se TEs originaram uma vez no último ancestral comum universal, surgiram independentemente múltiplas vezes, ou se espalharam através de linhagens por transferência horizontal permanece não resolvido.

Dois fatores complicam reconstrução filogenética de história evolutiva de TE. Primeiro, muitas linhagens de TE sofreram transferência horizontal entre espécies até distantemente relacionadas (Schaack et al. 2010), decoplando filogenia de TE de filogenias de hospedeiro. Segundo, TEs podem exibir evolução modular ou quimérica, em que domínios funcionais são trocados entre superfamílias distintas.

### 6.3.2 Retrotransposons Não-LTR: LINEs e SINEs

Elementos nucleares interspersados longos (LINEs) são retrotransposons não-LTR autônomos que codificam a maquinaria enzimática requerida para sua própria retrotransposição. Elementos LINE-1 (L1) são o retrotransposon autônomo dominante em genomas mamíferos, compreendendo aproximadamente 17% do genoma humano. L1 elementos são antigos (Malik e Eickbush 2001), com clados similares a L1 reconhecidos através de vertebrados.

Elementos nucleares interspersados curtos (SINEs) são retrotransposons não-autônomos que dependem de enzimas codificadas por LINE para sua mobilização (Dewannieux et al. 2003). SINEs são tipicamente derivados de genes de RNA estrutural pequena. A maioria de SINEs mamíferos derivam de tRNAs, com exceção notável de elementos Alu, que originaram do gene 7SL RNA que codifica o componente RNA da partícula de reconhecimento de sinal. Elementos Alu são restritos a primatas e surgiram aproximadamente 65 milhões de anos atrás através de fusão de dois precursores monoméricos (Batzer e Deininger 2002).

Retrotransposons LTR são estruturalmente relacionados a retrovírus; de fato, retrovírus endógenos (ERVs) são considerados uma subclasse de retrotransposons LTR que provavelmente originaram-se de infecções retrovirais ancestrais de linhagem germinativa (Jern e Coffin 2008). Retrotransposons não-LTR integram-se via transcrição reversa iniciada no alvo (TPRT, do inglês *target-primed reverse transcription*), um mecanismo em que a endonuclease do elemento cliva o DNA alvo e usa o 3′ hidroxila exposto como primer para transcrição reversa *in situ* (Luan et al. 1993). Adicionalmente, retrotransposons YR representam uma terceira categoria que compartilha homologia de transcriptase reversa com retrotransposons LTR mas possui um domínio de tirosina recombinase mais proximamente relacionado àqueles encontrados em certos transposons de DNA (Goodwin e Poulter 2003), ilustrando a natureza modular e quimérica da evolução de ETs.

### 6.3.3 DNA Transposons

DNA transposons constituem aproximadamente 3% do genoma humano, com superfamílias hAT e Mariner/Tc1 predominando (Cordaux e Batzer 2009). Embora sua transposição seja não-replicativa, DNA transposons acumularam grandes números de cópias através de transposição durante replicação de DNA e através de reparo mediado por recombinação homóloga de rupturas de fita dupla em locais

de excisão. No genoma humano, todas as famílias conhecidas de DNA transposon são consideradas fósseis moleculares, com nenhum elemento atualmente ativo.

### 6.3.4 Repetições em Tandem: Satélites, Minissatélites, e Microssatélites

DNA satélite são arranjos de sequências repetidas em tandem que podem abranger megabases sem interrupção, tipicamente localizado em regiões cromossômicas centroméricas, pericentroméricas, e subteloméricos (Garrido-Ramos 2017). O termo "satélite" deriva da observação que estas sequências, devido sua composição de base enviesada, formam bandas secundárias distintas em centrifugação de gradiente de densidade de cloreto de césio.

Origens evolutivas de famílias de DNA satélite são diversas e frequentemente específicas de linhagem (Plohl et al. 2012). Arrays de satélite centromério evoluem rapidamente, mostrando pouca conservação de sequência entre espécies distantemente relacionadas apesar de função centromério conservada (Henikoff et al. 2001; Malik e Henikoff 2009).

Uma hipótese intrigante para origem de repetições centroméricas propõe que centrômeros foram derivados de telômeros durante evolução cromossômica eucariótica inicial. Este modelo postula que linearização de um genóforo circular ancestral foi acompanhada por captura de retrotransposons em extremidades cromossômicas quebradas, com divergência subsequente de repetições internas similares a telômeros dando origem a sequências proto-centroméricas.

DNA satélite sofre evolução concertada (Dover 1982), por meio da qual unidades de repetição dentro de espécie são homogeneizadas por mecanismos recombinacionais (crossing over desigual, conversão de gene, amplificação de círculo rolante), produzindo divergência de sequência baixa intrae específica mas alta interespecífica.

Microssatélites (também conhecidos como repetições de sequência simples ou repetições em tandem curtas) consistem de motivos de 1–6 bp repetidos em tandem, tipicamente abrangendo alguns poucos centos de pares de bases (Ellegren 2004). Eles são abundantes em genomas eucarióticos, compreendendo aproximadamente 3% do genoma humano. O mecanismo primário gerando variação de comprimento de microssatélite é deslizamento de replicação (também chamado de desalinhamento de fita deslizada), em que polimerase de DNA dissocia transientemente durante replicação de molde repetitivo e reacondiciona fora de quadro, levando à inserção ou deleção de uma ou mais unidades de repetição.

Minissatélites (repetições de número variável em tandem, VNTRs) têm unidades de repetição maiores de 10–100 bp e frequentemente são enriquecidos perto de telômeros. Sua expansão é dirigida primariamente por crossing over desigual e conversão de gene em vez de deslizamento de replicação, refletindo comprimento de unidade maior que favorece mecanismos baseados em recombinação.

### 6.3.5 Interação Entre Classes de Repetições

A classificação tradicional de repetições em classes intercaladas e em tandem oculta interações recíprocas extensas entre estes compartimentos. Elementos transponíveis podem servir como substratos para a emergência *de novo* de famílias de DNA satélite: quando cópias de ETs estão agrupadas, crossing-over desigual e amplificação baseada em recombinação podem expandi-las em arranjos em tandem, efetivamente convertendo repetições intercaladas em DNA satélite (Meštrović et al. 2015). Reciprocamente, ETs acumulam-se preferencialmente dentro de regiões heterocromáticas ricas em satélite, onde podem ser silenciados mas contribuem para a dinâmica da heterocromatina.

O ciclo de vida de uma linhagem de ET pode ser descrito em quatro fases: invasão (transferência horizontal ou ativação de um elemento previamente dormente), amplificação (proliferação ao longo do genoma hospedeiro), maturação e silenciamento (mecanismos de defesa do hospedeiro como metilação de DNA e vias de piRNA suprimem transposição), e morte ou degeneração (acúmulo de mutações torna o elemento não-funcional). Este modelo de quatro fases aplica-se através de superfamílias de ET diversas e linhagens hospedeiras, embora a duração e intensidade de cada fase variem consideravelmente (Kidwell e Lisch 2002).

## 6.4 Obstáculos que Repetições Genômicas Colocam para Estudos Genômicos

### 6.4.1 Ambiguidade e Multi-Mapeamento

O núcleo de montagem de novo é identificação de sobreposições entre leituras para formar sequências contíguas mais longas (contigs). Quando uma leitura origina de uma região repetitiva, ela pode corresponder perfeitamente a múltiplas localizações através do genoma. A maioria de algoritmos de montagem (como Gráficos de Bruijn) dependem da unicidade de k-mers (sequências de comprimento $k$). Se um elemento repetitivo é mais longo que o tamanho de k-mer, o montador não pode determinar qual "cópia" da repetição uma leitura específica pertence.

Isto resulta em montagens "colapsadas", onde múltiplos loci genômicos distintos são incorretamente fundidos em sequência representante única, ou o montador simplesmente termina o contig, levando a fragmentação alta.

### 6.4.2 Complexidade de Gráfico e Emaranhados

Montadores modernos representam dados genômicos como gráfico onde nós são sequências e arestas são sobreposições. Em genoma livre de repetição, o gráfico seria idealmente um caminho linear. No entanto, DNA repetitivo introduz "emaranhados" ou ciclos no gráfico.

Em um gráfico de Bruijn, cada repetição cria um nó com múltiplas arestas de entrada e saída. Resolução destes caminhos requer informação que abrange repetição inteira para "preencher" sequências flanqueadoras únicas. Se comprimento de leitura ($L$) é mais curto que comprimento de repetição ($R$), o caminho através do gráfico é matematicamente não-determinístico sem informação auxiliar.

### 6.4.3 Variações Estruturais e Montagem Incorreta

Regiões repetitivas são pontos quentes para evolução estrutural. Repetições altamente similares (por exemplo, genes parálogos) podem ser confundidas com variações alélicas em organismos diploides. Um montador pode erroneamente conectar duas regiões únicas distantes porque compartilham fronteira repetitiva comum, levando a inversões de larga escala ou translocações na estrutura final.

## 6.5 Desafios Específicos de Montagem e Anotação

Montagem de sequências genômicas a partir de dados de leitura curta representa um dos desafios computacionais mais significativos em bioinformática, primariamente devido à presença de elementos de DNA repetitivo (Chaisson et al. 2015; Phillippy et al. 2008; Treangen e Salzberg 2011). Sequências

repetitivas constituem grande fração de genomas eucarióticos e são a fonte primária de fragmentação de montagem e erros.

A dificuldade surge de três questões fundamentais: mapeamento ambíguo, complexidade baseada em gráfico, e limitações de comprimento de leitura.

O desafio essencial é um "quebra-cabeça" onde muitas peças são idênticas. Sem leituras longas o suficiente para capturar elemento repetitivo e sequências únicas de "âncora" em ambos os lados, orientação física e número de cópias destes elementos permanece computacionalmente não resolvível. Isto é por que transição de Sequenciamento de Leitura Curta (Illumina) para Sequenciamento de Leitura Longa (PacBio, Oxford Nanopore) foi revolucionária para alcançar montagens "telômero-a--telômero" (Logsdon et al. 2020).

## 6.6 Soluções de Sequenciamento e Bioinformática

### 6.6.1 Tecnologias de Sequenciamento de Leitura Longa

Sequenciamento de terceira geração, ou leitura longa, tecnologias transformaram paisagem de análise de repetição produzindo leituras que rotineiramente excedem 10.000 bp e podem estender além de 100.000 bp em configurações ultra-longas. Dois plataformas comerciais dominam este espaço: Pacific Biosciences (PacBio) e Oxford Nanopore Technologies (ONT).

Sequenciamento SMRT (Single Molecule Real-Time) de PacBio, particularmente modo de alta fidelidade (HiFi), gera leituras com comprimentos medianos de 15–20 kb e precisão em nível de base excedendo 99,9% através de sequenciamento de consenso circular. Leituras HiFi demonstraram precisão muito alta para mapeamento de polimorfismos de repetição e resolução de estruturas de repetição em tandem complexas. Sequenciamento ONT, em contraste, excele em produzir leituras ultra-longas que podem exceder 100 kb, tornando-o particularmente valioso para abranger até os maiores arrays repetitivos.

Cada plataforma oferece forças complementares. Leituras HiFi fornecem precisão necessária para chamada de variante confiável dentro de repetições, enquanto leituras ONT ultra-longas fornecem contigüidade para abranger estruturas de repetição maiores e mais complexas.

### 6.6.2 Ferramentas Bioinformáticas para Identificação e Mascaramento de Repetição

Antes de anotação de genoma poder prosseguir, elementos repetitivos devem ser identificados e mascarados para prevenir predições de gene espúrias e alinhamentos falsos-positivos de BLAST.

RepeatMasker é a ferramenta mais amplamente usada para este propósito (Smit et al. 2013). Ela rastreia sequências de DNA de entrada contra bibliotecas curadas de repetições conhecidas, incluindo banco de dados Dfam de Modelos Markov Ocultos de elemento transponível (Storer et al. 2021).

RepeatModeler complementa RepeatMasker permitindo identificação de novo de famílias de repetição de montagens de genoma não anotadas (Flynn et al. 2020). Mais recentemente, o pipeline EDTA (Extensive De Novo TE Annotator) emergiu como alternativa abrangente que integra RepeatModeler, LTR_retriever, e outras ferramentas especializadas para alcançar anotação de elemento transponível mais completa e precisa (Ou et al. 2019).

Para genotipagem de repetição em tandem de dados de leitura longa, várias ferramentas

especializadas foram desenvolvidas. TRGT (Tandem Repeat Genotyping Tool) foi especificamente projetado para dados PacBio HiFi e fornece genotipagem robusta e visualização de repetições em tandem em escala genômica (Dolzhenko et al. 2024). LongTR usa estratégia de agrupamento combinada com alinhamento de ordem parcial e modelos Markov ocultos para inferir haplótipos consenso.

MotifScope representa uma abordagem algorítmica mais recente para caracterização e visualização de motivos de repetições em tandem, identificando mais motivos e representando mais precisamente sequências repetitivas subjacentes do que métodos anteriores (L. Zhang et al. 2025).

### 6.6.3 Estratégias de Montagem para Genomas Ricos em Repetição

Montagem de genomas ricos em repetição foi revolucionada pela combinação de sequenciamento de leitura longa com algoritmos de montagem modernos. O insight fundamental é que sequência repetitiva pode ser resolvida quando leituras são mais longas que unidade de repetição. Montadores estado-da-arte atual, incluindo hifiasm (Cheng et al. 2021), Verkko (Rautiainen et al. 2023), e LJA, todos incorporam estratégias para manejar estruturas complexas de repetição dentro de gráficos de montagem.

Para montagem perto de telômero-a-telômero de genomas hom ozigóticos, prática melhor atual envolve usar leituras PacBio HiFi e leituras ONT ultra-longas. Leituras HiFi são usadas para construir gráfico de montagem inicial consistindo de unitigs que contêm nenhuma repetição exata longa, com possíveis conexões entre eles determinadas por estrutura de repetição. Regiões altamente repetitivas tornam-se representadas como subgráficos complexos, ou "emaranhados", que são então resolvidos usando leituras ONT ultra-longas que abrangem estas regiões.

A realização de marco do Consórcio Telômero-a-Telômero em completar primeiro montagem genômica humana sem lacunas (T2T-CHM13) demonstrou que esta abordagem combinada poderia resolver até mesmo regiões mais recalcitrantes de repetição (Nurk et al. 2022; Rhie et al. 2021), incluindo arrays de satélite centroméricas, clusters rDNA, e segmentações duplicadas.

### 6.6.4 Abordagens de Pangenoma para Variação de Repetição

Um único genoma de referência linear não pode capturar espectro completo de variação de repetição presente em população. O Consórcio de Referência de Pangenoma Humano (Wang et al. 2022) aborda esta limitação construindo referências de pangenoma baseadas em gráfico que codificam diversidade em nível populacional, incluindo variação em regiões repetitivas (W.-W. Liao et al. 2023).

Gráficos de pangenoma são particularmente poderosos para resolução de repetições de número variável em tandem (VNTRs), que têm número de repetição hipervariável e composição. A estrutura de dados gráfico-pangenoma de repetição (RPGG) foi desenvolvida para codificar tanto diversidade populacional quanto estrutura interna de repetição de loci VNTR de montagens multi-haplotípicas resolvidas, permitindo estimativa de composição VNTR precisa até mesmo de dados de leitura curta.

Análises iniciais demonstraram melhorias substanciais na descoberta de variantes, com uma redução de 34% em erros de variantes pequenas e um aumento de 104% na detecção de variantes estruturais por haplótipo comparado a fluxos de trabalho baseados em GRCh38 (W.-W. Liao et al. 2023). A mais recente liberação de dados incorpora haplótipos faseados de 232 indivíduos,

selecionados para representar ancestralidades diversas, com o objetivo de expandir para mais de 700 genomas haploides (Wang et al. 2022). Esta abordagem em nível populacional produziu uma média de mais de 29.000 variantes estruturais por indivíduo, comparado a menos de 16.000 quando usando uma referência linear sozinha (Groza et al. 2024).

### 6.6.5 Combinação de Estratégias

Dado complexidade de lidando com repetições, estratégia crescentemente adotada envolve combinação de múltiplas tecnologias de sequenciamento e ferramentas bioinformáticas. Por exemplo:

1. Sequenciamento PacBio HiFi para precisão e chamada de variante de repetição confiável
2. Sequenciamento ONT ultra-longo para contigüidade de estrutura de repetição
3. Mapeamento de Strand-seq para resolução de fase de haplótipo
4. Ferramentas de mascaramento como RepeatMasker para anotação
5. Ferramentas de genotipagem como TRGT para caracterização de tandem repetido
6. Construção de pangenoma para capturar variação nível-populacional

## 6.7 Desafios Emergentes e Direções Futuras

Apesar dos avanços transformadores em sequenciamento de leitura longa e construção de pangenoma, vários desafios permanecem. O custo e complexidade de gerar múltiplos tipos de dados complementares (PacBio HiFi, ONT ultra-longo, Strand-seq) para um único genoma permanecem proibitivos para muitos organismos não-modelo. Recursos computacionais requeridos para construção de grafos de pangenoma e chamada de variantes em escala populacional são substanciais. VNTRs multialélicas apresentam dificuldades particulares para grafos de pangenoma, pois sua complexidade combinatória pode tornar representações de grafo intratáveis.

No nível de célula única, a convergência de sequenciamento de leitura longa com ômica de célula única está abrindo novas avenidas para compreender a dinâmica de elementos repetitivos, incluindo retrotransposição somática e expressão alelo-específica de elementos regulatórios derivados de ETs. O desenvolvimento de ferramentas como RAmbler, que resolve repetições complexas em cromossomos humanos específicos (Chakravarty et al. 2025), e melhorias em métodos de sequenciamento de RNA de leitura longa estendem ainda mais o kit de ferramentas analíticas para biologia de repetições.

A adoção da montagem T2T-CHM13v2.0 como referência padrão, juntamente com a maturação do pangenoma HPRC, fornecerá uma fundação mais completa para compreender a biologia de repetições e suas implicações para evolução genômica, regulação gênica e doença humana.

## 6.8 Implicações para Filogenômica

Elementos repetitivos apresentam desafios únicos e oportunidades para estudos filogenômicos. Enquanto matrizes alinhadas tradicionalmente excluem regiões repetitivas devido à ambiguidade de alinhamento, trabalho recente demonstrou que repetições—particularmente elementos transponíveis—podem fornecer sinal filogenômico informativo quando tratadas adequadamente.

Estrutura, número de cópia, e sequência de repetições evoluem sob pressões seletivas e demográficas complexas, refletindo história evolutiva de linhagens. Compreendendo dinâmica de elemento repetitivo e desenvolvendo métodos para incorporar sinal de repetição em análise filogenética permanece área produtiva de investigação.

**Roteiro de Revisão do Capítulo**

1. Genoma humano: ∼50% repetitivo; ∼45% TEs; exons codificantes apenas ∼1,5–2% (Koning et al. 2011; Lander et al. 2001).
2. Classificação de TEs: Classe I (retrotransposons, "cópia-e-cola" via RNA): LTR (relacionados a retrovírus), LINEs (L1 ≈ 17% genoma humano), SINEs (Alu ≈ 10–13%, derivado de 7SL RNA, ∼65 Mya, restrito a primatas). Classe II (DNA transposons, "corte-e-cola"): hAT, Mariner/Tc1; ∼3% do genoma humano; todos fósseis em humanos.
3. Autônomos vs. não-autônomos: SINEs dependem de maquinaria L1 em trans.
4. DNA satélite: repetições em tandem megabase (centrômeros, telômeros); evolução concertada (Dover, 1982) via crossing-over desigual e conversão gênica.
5. Microssatélites (STRs, 1–6 bp): ∼3% genoma humano; variação por deslizamento de replicação. Minissatélites (VNTRs, 10–100 bp): enriquecidos perto de telômeros; expansão por recombinação.
6. Viés GC biológico: gBGC (conversão gênica enviesada por GC) gera padrões indistinguíveis de seleção positiva (Galtier et al. 2001); SINEs acumulam em regiões ricas em GC, LINEs em regiões AT.
7. Viés GC técnico: cobertura depende de composição GC em Illumina; fonte principal = amplificação PCR; mitigação: biblioteca livre de PCR, betaína, correção computacional.
8. Obstáculos para montagem: k-mers ambíguos → colapso de repetições; emaranhados no grafo de Bruijn; se $L_{\text{leitura}} < R_{\text{repetição}}$, caminho indeterminístico.
9. Soluções de leitura longa: PacBio HiFi (15–20 kb, >99,9% precisão, chamada de variante) + ONT ultra-longo (>100 kb, contigüidade); montagem T2T-CHM13 (Nurk et al. 2022).
10. Ferramentas: RepeatMasker (Dfam HMMs), RepeatModeler (de novo), EDTA (LTR_retriever integrado), TRGT (genotipagem de tandem, PacBio HiFi).
11. Pangenoma: referência baseada em grafo (HPRC) captura variação populacional em repetições; RPGG para VNTRs.
12. Interação entre classes de repetições: ETs servem como substratos para emergência *de novo* de DNA satélite via crossing-over desigual; ciclo de vida de ET em quatro fases (invasão, amplificação, silenciamento, degeneração).
13. Desafios emergentes: custo de sequenciamento multi-tecnologia, requisitos computacionais de pangenoma, complexidade de VNTRs multialélicas; abordagens de leitura longa em célula única para dinâmica somática de ETs; T2T-CHM13v2.0 como referência padrão.

## Referências


Batzer, M. A. e P. L. Deininger (2002). "Alu repeats and human genomic diversity". Em: *Nature Reviews Genetics* 3, pp. 370–379. doi: 10.1038/nrg798.

Benjamini, Y. e T. P. Speed (2012). "Summarizing and correcting the GC content bias in high-throughput sequencing". Em: *Nucleic Acids Research* 40, e72. doi: 10.1093/nar/gks001.

Britten, R. J. e D. E. Kohne (1968). "Repeated sequences in DNA". Em: *Science* 161.3841, pp. 529–540. doi: 10.1126/science.161.3841.529.

Browne, P. D., T. K. Nielsen, W. Kot, A. Aggerholm, M. T. P. Gilbert, L. Puetz, M. Rasmussen, A. Zervas e L. H. Hansen (2020). "GC bias affects genomic and metagenomic reconstructions, underrepresenting GC-poor organisms". Em: *GigaScience* 9, giaa008. doi: 10.1093/gigascience/giaa008.

Chaisson, M. J., J. Huddleston, M. Y. Dennis, P. H. Sudmant, M. Malig, F. Hormozdiari, F. Antonacci, U. Surti, R. McVeigh, M. Ventura et al. (2015). "Resolving the complexity of the human genome using next-generation sequencing". Em: *Nature Reviews Genetics* 16, pp. 627–640. doi: 10.1038/nrg3954.

Chakravarty, D. et al. (2025). "RAmbler: resolving complex repeats in human chromosomes". Em: *Genome Research* 35.1, pp. 92–105. doi: 10.1101/gr.279449.124.

Chen, Y.-C., T. Liu, C.-H. Yu, T.-Y. Chiang e C.-C. Hwang (2013). "Effects of GC bias in next-generation-sequencing data on de novo genome assembly". Em: *PLoS ONE* 8, e62856. doi: 10.1371/journal.pone.0062856.

Cheng, H., G. T. Concepcion, X. Feng, H. Zhang e H. Li (2021). "Haplotype-resolved de novo assembly using phased assembly graphs with hifiasm". Em: *Nature Methods* 18, pp. 170–175. doi: 10.1038/s41592-020-01056-5.

Chuong, E. B., N. C. Elde e C. Feschotte (2017). "Regulatory activities of transposable elements: From conflicts to benefits". Em: *Nature Reviews Genetics* 18, pp. 71–86. doi: 10.1038/nrg.2016.139.

Consortium, E. P. (2012). "An integrated encyclopedia of DNA elements in the human genome". Em: *Nature* 489, pp. 57–74. doi: 10.1038/nature11247.

Cordaux, R. e M. A. Batzer (2009). "The impact of retrotransposons on human genome evolution". Em: *Nature Reviews Genetics* 10, pp. 691–703. doi: 10.1038/nrg2640.

Dewannieux, M., C. Esnault e T. Heidmann (2003). "LINE-mediated retrotransposition of marked Alu sequences". Em: *Nature Genetics* 35, pp. 41–48. doi: 10.1038/ng1223.

Dohm, J. C., C. Lottaz, T. Borodina e H. Himmelbauer (2008). "Substantial biases in ultra-short read data sets from high-throughput DNA sequencing". Em: *Nucleic Acids Research* 36, e105. doi: 10.1093/nar/gkn425.

Dolzhenko, E., A. C. English, H. Dashnow, R. Vanheusden, S. Zarate, J. Sorenson et al. (2024). "Characterization and visualization of tandem repeats at genome scale". Em: *Nature Biotechnology* 42, pp. 1606–1614. doi: 10.1038/s41587-024-02297-8.

Doolittle, W. F. (2013). "Is junk DNA bunk? A critique of ENCODE". Em: *Proceedings of the National Academy of Sciences USA* 110, pp. 5294–5300. doi: 10.1073/pnas.1221376110.

Dover, G. (1982). "Molecular drive: A cohesive mode of species evolution". Em: *Nature* 299, pp. 111–117. doi: 10.1038/299111a0.

Duret, L. e N. Galtier (2009). "Biased gene conversion and the evolution of mammalian genomic landscapes". Em: *Annual Review of Genomics and Human Genetics* 10, pp. 285–311. doi: 10.1146/annurev-genom-082908-150001.

Ellegren, H. (2004). “Microsatellites: Simple sequences with complex evolution”. Em: *Nature Reviews Genetics* 5, pp. 435–445. doi: 10.1038/nrg1348.

Eyre-Walker, A. (1993). “Recombination and mammalian genome evolution”. Em: *Proceedings of the Royal Society of London B* 252, pp. 237–243. doi: 10.1098/rspb.1993.0071.

Feschotte, C. e E. J. Pritham (2007). “DNA transposons and the evolution of eukaryotic genomes”. Em: *Annual Review of Genetics* 41, pp. 331–368. doi: 10.1146/annurev.genet.40.110405.090448.

Finnegan, D. J. (1989). “Eukaryotic transposable elements and genome evolution”. Em: *Trends in Genetics* 5, pp. 103–107. doi: 10.1016/0168-9525(89)90039-5.

Flynn, J. M., R. Hubley, C. Goubert, J. Rosen, A. G. Clark, C. Feschotte e A. F. Smit (2020). “RepeatModeler2 for automated genomic discovery of transposable element families”. Em: *Proceedings of the National Academy of Sciences USA* 117, pp. 9451–9457. doi: 10.1073/pnas.1921046117.

Galtier, N., G. Piganeau, D. Mouchiroud e L. Duret (2001). “GC-content evolution in mammalian genomes: The biased gene conversion hypothesis”. Em: *Genetics* 159, pp. 907–911. doi: 10.1093/genetics/159.2.907.

Garrido-Ramos, M. A. (2017). “Satellite DNA: An evolving topic”. Em: *Genes* 8, p. 230. doi: 10.3390/genes8090230.

Goodwin, T. J. D. e R. T. M. Poulter (2003). “The DIRS1 group of retrotransposons”. Em: *Molecular Biology and Evolution* 20.3, pp. 465–476. doi: 10.1093/molbev/msg044.

Graur, D., Y. Zheng, N. Price, R. B. R. Azevedo, R. A. Zufall e E. Elhaik (2013). “On the immortality of television sets: “Function” in the human genome according to the evolution-free gospel of ENCODE”. Em: *Genome Biology and Evolution* 5, pp. 578–590. doi: 10.1093/gbe/evt028.

Groza, C. et al. (2024). “Pangenome structural variant calling with the Human Pangenome Reference”. Em: *Nature* 634, pp. 367–375. doi: 10.1038/s41586-024-07880-5.

Haubold, B. e T. Wiehe (2006). “How repetitive are genomes?” Em: *BMC Bioinformatics* 7, p. 541. doi: 10.1186/1471-2105-7-541.

Hayward, A. e C. Gilbert (2022). “Transposable elements”. Em: *Current Biology* 32, R904–R909. doi: 10.1016/j.cub.2022.07.044.

Henikoff, S., K. Ahmad e H. S. Malik (2001). “The centromere paradox: Stable inheritance with rapidly evolving DNA”. Em: *Science* 293, pp. 1098–1102. doi: 10.1126/science.1062939.

Jern, P. e J. M. Coffin (2008). “Effects of retroviruses on host genome function”. Em: *Annual Review of Genetics* 42, pp. 709–732. doi: 10.1146/annurev.genet.42.110807.091501.

Kapitonov, V. V. e J. Jurka (2006). “Self-synthesizing DNA transposons in eukaryotes”. Em: *Proceedings of the National Academy of Sciences* 103.12, pp. 4540–4545. doi: 10.1073/pnas.0600833103.

Kidwell, M. G. e D. R. Lisch (2002). “Transposable elements as sources of genomic variation”. Em: *Mobile DNA II*, pp. 59–90.

Koning, A. P. J. de, W. Gu, T. A. Castoe, M. A. Batzer e D. D. Pollock (2011). “Repetitive elements may comprise over two-thirds of the human genome”. Em: *PLoS Genetics* 7, e1002384. doi: 10.1371/journal.pgen.1002384.

Lander, E. S., L. M. Linton, B. Birren, C. Nusbaum, M. C. Zody, J. Baldwin et al. (2001). “Initial sequencing and analysis of the human genome”. Em: *Nature* 409, pp. 860–921. doi: 10.1038/35057062.

Lassalle, F., S. Périan, T. Bataillon, X. Nesme, L. Duret e V. Daubin (2015). "GC-content evolution in bacterial genomes: The biased gene conversion hypothesis expands". Em: *PLoS Genetics* 11, e1004941. doi: 10.1371/journal.pgen.1004941.

Liao, W.-W., M. Asri, J. Ebler, D. Doerr, M. Haukness, G. Hickey et al. (2023). "A draft human pangenome reference". Em: *Nature* 617, pp. 312–324. doi: 10.1038/s41586-023-06133-1.

Logsdon, G. A., M. R. Vollger e E. E. Eichler (2020). "Long-read human genome sequencing and its applications". Em: *Nature Reviews Genetics* 21, pp. 597–614. doi: 10.1038/s41576-020-0236-x.

Lu, J. Y., W. Shao, L. Chang, Y. Yin, T. Li, H. Zhang et al. (2020). "Genomic repeats categorize genes with distinct functions for orchestrated regulation". Em: *Cell Reports* 30, pp. 3296–3311. doi: 10.1016/j.celrep.2020.02.048.

Luan, D. D., M. H. Korman, J. L. Jakubczak e T. H. Eickbush (1993). "Reverse transcription of R2Bm RNA is primed by a nick at the chromosomal target site: a mechanism for non-LTR retrotransposition". Em: *Cell* 72.4, pp. 595–605. doi: 10.1016/0092-8674(93)90078-5.

Malik, H. S. e T. H. Eickbush (2001). "Phylogenetic analysis of ribonuclease H domains suggests a late, chimeric origin of LTR retrotransposable elements and retroviruses". Em: *Genome Research* 11, pp. 1187–1197. doi: 10.1101/gr.151001.

Malik, H. S. e S. Henikoff (2009). "Major evolutionary transitions in centromere complexity". Em: *Cell* 138, pp. 1067–1082. doi: 10.1016/j.cell.2009.08.022.

McClintock, B. (1950). "The origin and behavior of mutable loci in maize". Em: *Proceedings of the National Academy of Sciences USA* 36, pp. 344–355. doi: 10.1073/pnas.36.6.344.

Meštrović, N., B. Mravinac, M. Pavlek, T. Vojvoda-Zeljko, E. Šatović e M. Plohl (2015). "Structural and functional liaisons between transposable elements and satellite DNAs". Em: *Chromosome Research* 23.3, pp. 583–596. doi: 10.1007/s10577-015-9483-7.

Nurk, S., S. Koren, A. Rhie, M. Rautiainen, A. V. Bizin, S. Belneu et al. (2022). "The complete sequence of a human genome". Em: *Science* 376, pp. 44–53. doi: 10.1126/science.abj6987.

Ohno, S. (1972). "So much "junk" DNA in our genome". Em: ed. por H. H. Smith, pp. 366–370.

Ou, S., W. Su, Y. Liao, K. Chougule, J. R. Aw, S. D. Hellinga et al. (2019). "Benchmarking transposable element annotation methods for creation of a streamlined, comprehensive pipeline". Em: *Genome Biology* 20, p. 275. doi: 10.1186/s13059-019-1905-y.

Phillippy, A. M., M. C. Schatz e M. Pop (2008). "Genome assembly forensics: finding errors in fragmented genomes". Em: *Genome Biology* 9, R55. doi: 10.1186/gb-2008-9-3-r55.

Plohl, M., N. Meštrović e B. Mravinac (2012). "Satellite DNA evolution". Em: *Genome Dynamics* 7, pp. 126–152. doi: 10.1159/000337122.

Rautiainen, M., S. Nurk, B. P. Walenz, G. A. Logsdon, D. Porubsky, A. Rhie, E. E. Eichler, S. Koren e A. M. Phillippy (2023). "Telomere-to-telomere assembly of diploid chromosomes with Verkko". Em: *Nature Biotechnology* 41, pp. 1474–1482. doi: 10.1038/s41587-023-01911-w.

Rebollo, R., M. T. Romanish e D. L. Mager (2012). "Transposable elements: An abundant and natural source of regulatory sequences for host genes". Em: *Annual Review of Genetics* 46, pp. 21–42. doi: 10.1146/annurev-genet-110711-155621.

Rhie, A., S. A. McCarthy, O. Fedrigo, J. Dkornseifer, H. Zdrazil, G. Formenti et al. (2021). "Towards complete and error-free genome assemblies of all vertebrate species". Em: *Nature* 592, pp. 737–746. doi: 10.1038/s41586-021-03451-0.

Richard, G.-F., A. Kerrest e B. Dujon (2008). “Comparative genomics and molecular dynamics of DNA repeats in eukaryotes”. Em: *Microbiology and Molecular Biology Reviews* 72, pp. 686–727. doi: 10.1128/MMBR.00011-08.

Romiguier, J., E. Figuet, N. Galtier, E. J. P. Douzery, B. Boussau, J. Y. Dutheil e V. Ranwez (2010). “Fast and robust characterization of time-heterogeneous sequence evolutionary processes using substitution mapping”. Em: *PLoS ONE* 5, e11742. doi: 10.1371/journal.pone.0011742.

Ruiz-Ruano, F. J., R. F. Castillo-Cajas e M. D. López-León (2023). “Repetitive DNA sequence detection and its role in the human genome”. Em: *Communications Biology* 6, p. 954. doi: 10.1038/s42003-023-05322-y.

Schaack, S., C. Gilbert e C. Feschotte (2010). “Promiscuous DNA: Horizontal transfer of transposable elements and why it matters for eukaryotic evolution”. Em: *Trends in Ecology and Evolution* 25, pp. 537–546. doi: 10.1016/j.tree.2010.06.001.

Smit, A. F. A., R. Hubley e P. Green (2013). “RepeatMasker Open-4.0”. Em: http://www.repeatmasker.org.

Storer, J., R. Hubley, J. Rosen, T. J. Wheeler e A. F. A. Smit (2021). “The Dfam community resource of transposable element families, sequence models, and genome annotations”. Em: *Mobile DNA* 12, p. 2. doi: 10.1186/s13100-020-00230-y.

Treangen, T. J. e S. L. Salzberg (2011). “Repetitive DNA and next-generation sequencing: computational challenges and solutions”. Em: *Nature Reviews Genetics* 13, pp. 36–46. doi: 10.1038/nrg3117.

Wang, T., L. Antonacci-Fulton, K. Howe, H. A. Lawson, J. K. Lucas et al. (2022). “The Human Pangenome Project: a global resource to map genomic diversity”. Em: *Nature* 604, pp. 437–446. doi: 10.1038/s41586-022-04601-8.

Wells, J. N. e C. Feschotte (2020). “A field guide to eukaryotic transposable elements”. Em: *Annual Review of Genetics* 54, pp. 539–561. doi: 10.1146/annurev-genet-040620-022145.

Wicker, T., F. Sabot, A. Hua-Van, J. L. Bennetzen, P. Capy, B. Chalhoub, A. Flavell, P. Leroy, M. Morgante, O. Panaud et al. (2007). “A unified classification system for eukaryotic transposable elements”. Em: *Nature Reviews Genetics* 8, pp. 973–982. doi: 10.1038/nrg2165.

Zhang, L. et al. (2025). “MotifScope: characterization and visualization of tandem repeat motifs”. Em: *Bioinformatics* 41.2. doi: 10.1093/bioinformatics/btaf052.

# Capítulo 7

# Tecnologia da Informação Aplicada a Problemas Filogenéticos


## Resumo

A inferência filogenética — a reconstrução de relações evolutivas entre organismos — foi profundamente moldada por avanços em tecnologia da informação desde sua formalização como disciplina computacional na década de 1960. Esta revisão examina a interação histórica entre hardware de computação, design de software, escolha de linguagens de programação e metodologia filogenética. Começando com as primeiras implementações de algoritmos de parcimônia e verossimilhança em computadores mainframe, a narrativa traça o desenvolvimento de pacotes de software seminais (PHYLIP, Hennig86, PAUP*, POY, TNT, MrBayes, RAxML, BEAST, IQ-TREE e PhyG), a revolução MCMC Bayesiana do início dos anos 2000 e o desafio contínuo de dimensionar análises para conjuntos de dados em escala genômica. Debates centrais — incluindo parcimônia versus verossimilhança, árvores versus redes e a busca por um critério de optimalidade unificado — são examinados ao lado dos obstáculos computacionais que os limitam. Três contribuições recentes de Wheeler e colaboradores são utilizadas como estudos de caso: o software PhyG para análise de grafos filogenéticos (Wheeler et al. (2024)), amostragem de Thompson para otimização adaptativa de busca (Wheeler (2024)), e o critério de Comprimento Mínimo de Descrição Filogenética (PMDL) (Wheeler e Varón (2025)). A revisão conclui identificando obstáculos persistentes não resolvidos, incluindo a dureza NP da busca em árvores, a incomputabilidade da complexidade algorítmica, a dificuldade em aproximar tradições analíticas cladísticas e baseadas em modelos, e o papel emergente de aprendizado de máquina em filogenética.



**Palavras-chave:** filogenética, complexidade computacional, busca heurística, redes filogenéticas, comprimento mínimo de descrição, MCMC, verossimilhança máxima, software


## 7.1 Introdução

A filogenética computacional nasceu de uma síntese entre biologia evolutiva e ciência da computação. Antes da década de 1960, a reconstrução filogenética era predominantemente manual, baseada em características morfológicas e análise de padrões comparativos. Os problemas eram pequenos — tipicamente dezenas de táxons — e podiam ser resolvidos por inspeção visual ou cálculos manuais. As primeiras contribuições de Hennig (1950), Remane (1952) e Mayr e Linsley (1954) estabeleceram

princípios conceituais, mas sem a velocidade computacional para explorá-los sistematicamente.

A formalização matemática inicial veio de Edwards e Cavalli-Sforza (1964), que aplicaram métodos de máxima verossimilhança a dados genéticos, e de Fitch e Margoliash (1967), que desenvolveram o método da evolução mínima. No entanto, a adoção ampla de métodos computacionais nas análises filogenéticas aguardava pela disponibilidade de software acessível. O catalisador foi Felsenstein (1973), cujo programa PHYLIP (Inferência Filogenética Por Máxima Verossimilhança) e sua sequência de desenvolvimentos forneceram implementações computavelmente viáveis de parcimônia e verossimilhança em mainframes e, mais tarde, em computadores pessoais.

Este capítulo examina a história do design de software filogenético, os debates metodológicos que moldaram as escolhas de implementação, e os obstáculos computacionais que permanecem não resolvidos. O foco está em como tecnologia da informação — hardware, linguagens de programação e técnicas de busca — facilitou ou limitou os avanços metodológicos em filogenética.

## 7.2 Panorama Histórico do Software Filogenético

### 7.2.1 A Era Inicial: Mainframes e o Nascimento de PHYLIP (1973–1985)

O PHYLIP (*PHYLogeny Inference Package*) de Felsenstein, lançado em 1973 com atualizações significativas em 1978 e 1985, foi o primeiro software filogenético verdadeiramente portável e extensível. Escrito em FORTRAN e depois convertido para C, PHYLIP rodava em mainframes (UNIX, VMS) e, crucialmente, em computadores pessoais quando estes se tornaram disponíveis. A arquitetura modular — com programas separados para parsimônia (PARS), verossimilhança (DNAML, PROML), distância (NEIGHBOR) e desenho de árvores (DRAWTREE) — estabeleceu um padrão de design que persiste até hoje.

A genialidade de PHYLIP foi dupla: (1) implementou algoritmos matematicamente rigorosos mas computacionalmente demandantes em linguagem eficiente (C), permitindo aplicação a dados de um tamanho que antes era intratável; e (2) forneceu uma interface de usuário consistente e bem documentada que democratizou a análise filogenética. Pesquisadores sem experiência em programação poderiam agora executar análises complexas.

A limitação de PHYLIP era sua busca em árvores. O algoritmo de parcimônia adotado ('fitch' originalmente, depois refinamentos de busca de ramo-e-limite) era enumerativo e, consequentemente, exponencial no número de táxons. Para dados com mais de 20–30 táxons, a busca exaustiva se tornava computacionalmente proibitiva. Métodos heurísticos (adição sequencial aleatória, busca de vizinhos próximos) foram adotados para acelerar, mas sempre com o custo de possível subotimalidade.

### 7.2.2 Proliferação de Software Especializado (1985–2000)

Os anos 1980 e 1990 viram uma explosão de novos programas, cada um otimizado para um conjunto diferente de critérios e dados:

- **PAUP* (Phylogenetic Analysis Using Parsimony)** (Swofford 1993): O sucessor comercial intelectual de PHYLIP, desenvolvido por David Swofford. PAUP* implementou algoritmos de busca avançados (busca de ramo-e-limite com poda eficiente, busca de vizinhos próximos com múltiplos pontos de partida) e foi o primeiro para integrar parcimônia e máxima verossimilhança em uma única plataforma. Sua interface gráfica e linguagem de comandos poderosa tornaram-no padrão de ouro para filogenética molecular até o surgimento de MrBayes. A desvantagem:

PAUP* era comercial (licença paga) e, por um tempo, a comunidade filogenética foi dividida entre usuários de PHYLIP (grátis, aberto) e PAUP* (pago, mais rápido).

- **HENNIG86 e TNT** (Goloboff et al. 2008): Originalmente desenvolvido por James Farris em 1986 e baseado no programa HENNIG de Farris, HENNIG86 era otimizado especificamente para parcimônia e enfatizava algoritmos de busca implícita de enumeração. Seu sucessor, TNT (Tree analysis using New Technology) de Goloboff et al., revolucionou a busca em parcimônia com a implementação de buscas de ramo-e-limite eficiente com poda de custos críticos e uso inteligente de cache de memória para explorar iterativamente a vizinhança de soluções atuais. TNT permanece entre os buscadores de parcimônia mais rápidos e é o padrão para estudos de dados com muitos táxons (>500).

- **POY (Phylogenetic Analysis Using Parsimony)** (Wheeler 2001): Um programa distinto voltado para dados que não são alinhados a priori, particularmente sequências de DNA e proteínas onde o alinhamento é incerto. POY utilizava buscas simultâneas em espaço de alinhamento e de árvore, tratando alinhamento como um estado de busca dinâmico variável, não fixo. Essa abordagem foi computacionalmente muito mais cara do que alinhamento fixo + busca em árvore, mas oferecia vantagem teórica de evitar artefatos de alinhamento inicial.

- **RAxML (Randomized Axelerated Maximum Likelihood)** (Stamatakis 2006): Lançado em 2006 por Alexandros Stamatakis, RAxML foi um divisor de águas. Implementou busca em máxima verossimilhança com heurísticas de rápida convergência (busca de ramo-e-limite, busca de vizinhos próximos) e, crucialmente, paralelização eficiente para sistemas de memória distribuída (MPI). RAxML poderia rodar em clusters HPC e dimensionar para centenas de cores. Seu algoritmo de busca rápida (com frequente avaliação de função de verossimilhança) e paralelização de permutação de ramos tornaram-no o padrão de fato para análises de verossimilhança em larga escala na era pós-2006. RAxML é escrito em C com extensões MPI, demonstrando como design cuidadoso pode exprimir paralelismo do hardware.

- **BEAST (Bayesian Evolutionary Analysis by Sampling Trees)** (Drummond e Rambaut 2007): Representando um paradigma fundamentalmente novo, BEAST era especializado em análise Bayesiana de dados hierárquicos, particularmente aqueles com incerteza de datação e com múltiplas linhagens. O software implementou MCMC (Cadeias de Markov Monte Carlo) para amostrar a distribuição posterior conjunta de árvores e parâmetros de modelo. Sua inovação arquitetural foi permitir relajação de priors flexíveis, modelos de substituição complexos, e estruturas de dados hierárquicas (data de calibração, múltiplas loci, múltiplos indivíduos por espécie). BEAST introduziu um novo paradigma computacional: ao invés de procurar por uma árvore ótima global (como em parcimônia ou verossimilhança), MCMC amostrava a distribuição posterior, e a incerteza era capturada naturalmente.

### 7.2.3 A Revolução Bayesiana e MCMC (2000–2015)

MrBayes (Ronquist e Huelsenbeck 2003), desenvolvido por Fredrik Ronquist e John Huelsenbeck, foi o catalisador para adoção generalizada de métodos bayesianos em filogenética molecular. MrBayes implementou MCMC com propostas de soluções inteligentes para o problema de exploração em espaço de árvores (topologia + comprimentos de ramo + parâmetros de modelo). O algoritmo

de Metropolis-Hastings foi combinado com movimentos na árvore bem calibrados (movimento de resecção-reconexão) que melhoravam a mistura das cadeias.

A revolução Bayesiana teve implicações computacionais profundas. Diferentemente de busca heurística (que tenta encontrar um pico), MCMC tenta amostrar a vizinhança de muitos picos, explorando o espaço de parâmetro de forma mais exaustiva. Isso geralmente exige mais iterações para convergência — não raramente cadeias com 1 a 10 milhões de gerações. A compensação era que a incerteza filogenética era capturada naturalmente: a distribuição posterior das árvores representava incerteza tanto de análise estocástica quanto de dados.

A desvantagem computacional de MCMC era óbvia: uma análise Bayesiana levava tipicamente 10–100× mais tempo de CPU do que uma análise de máxima verossimilhança comparável, porque o algoritmo tinha de explorar mais do espaço. Para datasets com centenas ou milhares de táxons, análises Bayesianas se tornavam impraticáveis em máquinas de processador único. Paralelização de MrBayes em sistemas MPI ajudou, mas não resolveu completamente o problema.

### 7.2.4 Software Moderno: Paradigmas Eficientes (2015–Presente)

As limitações computacionais de métodos bayesianos complexos, combinadas com a revolução de dados (sequenciamento de próxima geração produzindo milhões de loci), impulsionaram uma nova onda de otimizações.

**IQ-TREE (Inferred Quotient Tree)** (Minh et al. 2020): Desenvolvido por Bui Quang Minh e colaboradores, IQ-TREE implementou um conjunto de inovações:

1. Algoritmo UFBoot de seleção de modelo rápido que testa modelos de substituição sem reespecificar a árvore entre testes, economizando iterações de otimização.

2. Busca em espaço de modelo com critérios de informação (BIC, AICc) que permitiam seleção de modelo automática.

3. Algoritmo de cálculo de suporte rápido (aBayes, aLRT, SH-aLRT) que evitava reamostragem.

4. Paralelização embaraçosamente paralela de análise de múltiplos loci (file-by-file parallelism).

5. Compilação SIMD (instruções SIMD como AVX2, AVX512) que vetorizavam operações de verossimilhança críticas.

IQ-TREE rapidamente se tornou o padrão de ouro para análises de verossimilhança filogenética em conjuntos de dados genômicos.

**RAxML-NG** (Kozlov et al. 2019): Uma reescrita moderna do RAxML clássico, com código refatorado para eficiência de cache, suporte nativo para SIMD avançado (AVX3), e API modular permitindo integração com frameworks de fluxo de trabalho (Nextflow, Snakemake). RAxML-NG mantém o status de RAxML como um dos buscadores de máxima verossimilhança mais rápidos.

**BEAST 2** (Bouckaert et al. 2019): Uma reescrita completa de BEAST com novo motor MCMC, novos operadores propostos para melhor mistura, e, crucialmente, integração com a biblioteca BEAGLE (Ayres et al., 2019) para cálculo acelerado de verossimilhança em GPU.

**PhyG** (Wheeler et al. 2024): Um software inovador para análise de grafos filogenéticos, permitindo representação explícita de eventos de reticulação (hibridação, transferência lateral) que não se ajustam ao modelo padrão de árvore. PhyG implementa busca em espaço de grafo (altamente combinatorialmente complexa) usando heurísticas sofisticadas incluindo amostragem de Thompson.

## 7.3 Debates Centrais Moldados pela Computação

### 7.3.1 Parcimônia Versus Verossimilhança

Um dos debates mais antigos em filogenética é se parcimônia (minimizando mudanças evolutivas) ou verossimilhança (maximizando probabilidade dos dados sob um modelo de evolução) é metodologicamente preferível. Este debate tem raízes teóricas profundas, mas também limitações computacionais.

Parcimônia é computacionalmente mais simples: o algoritmo de Fitch de programação dinâmica (Fitch 1971) calcula parcimônia em tempo $O(n \cdot m)$ para $n$ táxons e $m$ caracteres. Encontrar a árvore de parcimônia mínima é NP-duro, mas heurísticas de busca rápida (busca de ramo-e-limite em TNT, busca em vizinhança em PAUP*) podem encontrar bons mínimos locais em tempo razoável mesmo para dados grandes.

Verossimilhança é computacionalmente mais cara. O algoritmo de Felsenstein de programação dinâmica para calcular verossimilhança também é $O(n \cdot m)$ por avaliação, mas cada movimento de busca em árvore exige uma reavaliação — e para redes complexas de modelos de evolução (múltiplas partições, modelos de taxa variável, relógios moleculares), o fator constante é muito maior. Consequentemente, qualquer análise de verossimilhança que não seja um conjunto de dados pequeno exige paralelização significativa ou aceleração de hardware (GPU).

A tendência histórica reflete custo computacional. Nos anos 1980–1990, parcimônia dominava porque dados eram pequenos, máquinas eram lentas, e parcimônia era rápida. Com o advento de máquinas mais rápidas, multiprocessadores e, depois, GPUs, verossimilhança e métodos bayesianos se tornaram praticáveis. Hoje, a maioria dos analistas preferem verossimilhança ou métodos bayesianos, porque capturam incerteza de modelo e dados de forma mais transparente, mas parcimônia persiste em contextos onde eficiência de busca é crítica (dados muito grandes, número alto de táxons).

### 7.3.2 Redes Versus Árvores

A maioria de filogenética clássica assume uma topologia de árvore: cada espécie moderna desce de um ancestral comum, e as relações formam uma estrutura de árvore bifurcadora. No entanto, reticulação (eventos em que linhagens não descendem em linha reta de um ancestral, mas ao invés recombinação, hibridação ou transferência lateral de genes ocorrem) viola o modelo de árvore.

Métodos de rede filogenética como redes de quase-mediana (Holland e Moulton 2004), redes de splits (Bryant e Moulton 2004), e mais recentemente PhyG (Wheeler et al. 2024) representam explicitamente reticulação. A complexidade computacional de inferência de rede é substancialmente maior do que inferência de árvore. Espaço de busca em grafos reticulados é exponencialmente maior, e verossimilhança de grafos é computacionalmente mais cara de avaliar.

A restrição computacional manteve métodos de árvore dominantes por décadas. Apenas recentemente, com hardware mais rápido e heurísticas melhores (Thompson sampling em PhyG), métodos de rede se tornaram práticos para datasets de tamanho moderado. Ainda assim, a maioria de filogenética prática permanece em árvores porque redes são computacionalmente caras e requerem dados muito maiores para resolução estatística de reticulação.

### 7.3.3 Critério de Optimalidade Unificado

Desde o nascimento de filogenética computacional, o campo debateu: qual critério de optimalidade é correto? Parcimônia minimiza passos evolutivos, máxima verossimilhança maximiza probabilidade sob um modelo, métodos bayesianos amostram distribuições posteriores. Cada um tem justificativa teórica, mas eles são teoricamente inconsistentes e frequentemente fornecem árvores diferentes.

Uma abordagem recente é comprimento mínimo de descrição (MDL) (Wheeler e Varón 2025), que formaliza a ideia de que a melhor hipótese filogenética é aquela que fornece a compressão mais eficiente dos dados — intuitivamente, aquela que captura padrão com menos informação ad hoc. Para filogenética, PMDL (Phylogenetic Minimum Description Length) (Wheeler e Varón 2025) define um comprimento de descrição que inclui:

$$\text{PMDL} = (\text{compr. descri. árvore}) + (\text{compr. descr. dados} \mid \text{árvore}) \tag{7.1}$$

Em princípio, PMDL unifica parcimônia (que minimiza passos) e verossimilhança (que minimiza comprimento de dados residual). A barreira computacional: calcular PMDL exige avaliar a complexidade algorítmica (Kolmogorov) do modelo, que é incomputável em geral. Aproximações heurísticas estão em desenvolvimento, mas PMDL permanece mais uma ideia conceitual do que um método prático de rotina.

## 7.4 Obstáculos Computacionais Não Resolvidos

### 7.4.1 NP-Dureza da Busca em Árvores

O problema de encontrar a árvore de parcimônia mínima é NP-duro (Graur et al. 1991). Isso significa que nenhum algoritmo determinístico conhecido consegue resolver a problema em tempo polinomial para instâncias arbitrariamente grandes. Consequentemente, qualquer algoritmo de busca é heurístico: ele pode encontrar uma boa solução, mas não pode garantir otimalidade global.

Isso tem implicações práticas profundas. Quando um analista executa uma análise de parcimônia e encontra $k$ árvores igualmente parcimoniosas, não há nenhuma garantia de que não existem árvores ainda mais parcimoniosamente ótimas fora do espaço de busca explorado. Diferentes pontos de partida, diferentes estratégias de busca, e diferentes parametrizações podem descobrir diferentes conjuntos de árvores ótimas.

Para máxima verossimilhança, a situação é ainda pior: o problema de encontrar a árvore de máxima verossimilhança também é NP-duro (Chor e Tuller), e a função de verossimilhança é multimodal (muitos máximos locais). Heurísticas de busca como ramo-e-limite podem ficar presas em máximos locais. Métodos bayesianos (MCMC) têm a vantagem de exploração estocástica, mas convergência a distribuições posteriores verdadeiras é garantida apenas assintoticamente.

### 7.4.2 Incomputabilidade de Complexidade Algorítmica

Como mencionado acima, formalizar critérios de optimalidade unificados requer quantificar complexidade algorítmica dos dados (comprimento de descrição de Kolmogorov). No entanto, esta quantidade é incomputável em geral (teorema da parada de Turing). Isso coloca um limite fundamentalmente matemático em qualquer esquema de otimalidade que tente ser universal.

A implicação: nenhum programa de filogenética de propósito geral pode computar uma verdadeira medida de “melhoria” universal de uma árvore sobre outra. Qualquer critério de otimalidade

(parcimônia, verossimilhança, MDL aproximado) é por necessidade uma heurística ou aproximação parcial.

### 7.4.3 Quadro Conceitual: Cladística Versus Métodos Baseados em Modelos

Um debate profundo e ainda não resolvido é entre a tradição cladística (foco em sinapomorfias e análise de caracteres discretos) e métodos baseados em modelos (foco em modelos evolutivos probabilísticos de mudança de sequência). Essas tradições têm histórias e filósofos distintos, e seus princípios fundamentais às vezes estão em tensão.

Do ponto de vista computacional, cladística clássica (análise de parcimônia de dados morfológicos) é computacionalmente mais simples: busca heurística em espaço discreto. Métodos baseados em modelos (análise de verossimilhança de sequências de DNA sob modelos de Markov) são mais complexos computacionalmente mas teoricamente mais rigorosos sobre incerteza de modelo.

Uma ponte potencial é a que recentes software como IQ-TREE oferecem: seleção automática de modelo combinada com análise flexível de suporte que não assume um modelo específico. Mas fundamentalmente, os dois quadros conceptuais ainda não foram unificados em um framework teórico único.

### 7.4.4 Papel Emergente de Aprendizado de Máquina

Aprendizado de máquina (redes neurais profundas, métodos de ensemble) começou a ser aplicado a problemas filogenéticos:

- **Predição de alinhamento:** Redes neurais foram treinadas para prever alinhamentos ótimos direto de sequências brutas, contornando algoritmos de programação dinâmica clássicos.
- **Predição de topologia:** Arquiteturas gráficas de rede neural (graph neural networks, GNNs) podem ser treinadas em árvores conhecidas para prever topologia de dados nuevos.
- **Seleção de modelo:** Modelos de machine learning podem prever qual modelo de substituição é mais apropriado para um dataset dado, potencialmente mais rápido do que testes de razão de verossimilhança.

A vantagem: velocidade. Um modelo de rede neural treinado pode fazer predições em milissegundos, enquanto recálculos clássicos levam minutos. A desvantagem: interpretabilidade e rigor estatístico. Modelos de machine learning são frequentemente "caixas pretas" — não está claro o que foi aprendido ou se o modelo extrapola bem para dados fora do domínio de treinamento. Para filogenética, onde dados são frequentemente únicos e sob pressão evolutiva desconhecida, extrapolação é arriscada.

O papel futuro de aprendizado de máquina é provavelmente como ferramenta de aceleração de pilha (screening rápido de muitos modelos, predição de inicial estimates bons para otimização) antes de refinamento via métodos clássicos, em vez de substituição dos métodos clássicos.

## 7.5 Caso de Estudo: Contribuições Recentes de Wheeler e Colaboradores

Três contribuições recentes ilustram como design computacional contínua moldando filogenética moderna.

### 7.5.1 PhyG: Análise de Grafo Filogenético

Wheeler et al. (2024) apresentaram PhyG, um software para inferência de grafos filogenéticos que representam reticulação explicitamente. A inovação computacional principal de PhyG é a implementação de amostragem de Thompson para exploração de espaço de grafo.

A amostragem de Thompson é um algoritmo de exploração de bandidos multi-armados: na ausência de conhecimento prévio, distribui esforço de busca proporcionalmente àquela promessa de diferentes regiões de espaço de busca baseado em sucesso passado. Em contexto de busca filogenética, isso permite ao PhyG explorar grafos alternativos com estratégia de risco-recompensa adaptativa: regiões de espaço que têm produzido bons grafos recebem mais simulação, enquanto regiões menos promissoras recebem menos.

### 7.5.2 Thompson Sampling para Otimização Adaptativa

Wheeler (2024) explorou amostragem de Thompson como estratégia geral para busca heurística em filogenética. A abordagem de Thompson é bem conhecida em aprendizado de máquina (contextual banditos, exploração-exploração de tradeoff), mas sua aplicação a busca em árvores filogenéticas é relativamente nova.

A vantagem computacional: Thompson sampling é paralelizável. Diferentes threads ou processos podem manter cópias da distribuição de crenças sobre regiões promissoras de espaço de busca e explorar em paralelo, convergirem periódicamente para compartilhar conhecimento. Isso permite exploração de espaço de busca muito maior do que métodos seriais, e potencialmente encontrar mínimos globais melhores.

### 7.5.3 Comprimento Mínimo de Descrição Filogenética (PMDL)

Wheeler e Varón (2025) formalizaram o critério de comprimento mínimo de descrição para filogenética (PMDL), buscando um critério de optimalidade unificado que concilie parcimônia e verossimilhança. PMDL captura a ideia de que a melhor hipótese filogenética é aquela que explica os dados com menor descrição total (menor complexidade do modelo + menor resíduo de dados).

Implementação computacional de PMDL é desafiadora porque requer aproximações da complexidade algorítmica de modelos (Kolmogorov). Versões heurísticas estão em desenvolvimento, mas o impacto total permanece ser visto.

## 7.6 Discussão: Futuro de Software Filogenético

A história de software filogenético ilustra princípios gerais de design de software científico:

1. **Otimização de hardware importa:** A escolha de linguagem, paralelização e vetorização de código tem efeitos multiplicativos em desempenho. RAxML, IQ-TREE e PhyG todos otimizam agressivamente para hardware moderno (multicore, SIMD, GPU).

2. **Restrições computacionais moldam metodologia:** Debates teóricos (parcimônia vs. verossimilhança, árvores vs. redes) não ocorrem em vácuo; praticidade computacional influencia qual método é aceito como padrão.

3. **Arquitetura modular permite inovação:** PHYLIP estabeleceu o padrão de módulos especializados para diferentes tarefas (parsing, análise, visualização). Este design facilita adoção de novos algoritmos e permite que usuários compussuam análises personalizadas.

4. **Abertura e reprodutibilidade:** Software de código aberto (PHYLIP, RAxML, IQ-TREE, MrBayes) com documentação completa e acesso ao código-fonte permitiu confiança, validação independente e estímulo de desenvolvimento comunitário. Em contraste, software comercial ou fechado muitas vezes não recebeu a mesma adoção ou inovação.

A próxima geração de software filogenético provavelmente continuará a aproveitar aceleração de hardware (GPUs, TPUs), integração de machine learning para aceleração de pilha heurística, e designs modulares que permitem análises reproduzíveis e rastreáveis via sistemas de fluxo de trabalho (Snakemake, Nextflow). A unificação de critérios de optimalidade e a resolução de debates cladísticos vs. baseados em modelos provavelmente virão de pesquisa teórica antes de inovação computacional.

## 7.7 Conclusão

Filogenética computacional nasceu de síntese entre biologia evolutiva e ciência da computação. A história de seu desenvolvimento software é história de quatro décadas de otimização computacional, design algorítmico, e resolução de disputas metodológicas através da implementação. Os softwares seminais — PHYLIP, PAUP*, TNT, RAxML, MrBayes, IQ-TREE, BEAST e PhyG — cada um moldou a forma como filogenética moderna é praticada, e cada um refletiu compromissos entre rigor teórico, eficiência computacional e usabilidade.

Obstáculos permanecem não resolvidos, particularmente NP-dureza de busca em árvores e a incomputabilidade de critérios ótimos universais. Esses não são deficiências de software particular ou hardware corrente, mas limitações matemáticas fundamentais. Progresso futuro provavelmente virá de síntese de abordagens — combinando força computacional bruta (hardware melhor) com algoritmos refinados (heurísticas melhores) e, potencialmente, aprendizado de máquina como ferramenta de aceleração, mantendo sempre rigor estatístico e interpretabilidade.

**Roteiro de Revisão do Capítulo**

1. Cronologia de software: PHYLIP (Felsenstein, 1973, FORTRAN→C) → HENNIG86/TNT (Farris/Goloboff, parcimônia) → PAUP* (Swofford, parcimônia+MV, comercial) → POY (Wheeler, alinhamento dinâmico) → MrBayes (Ronquist & Huelsenbeck, MCMC bayesiano) → RAxML (Stamatakis, 2006, MPI) → BEAST (Drummond, 2007, MCMC hierárquico) → IQ-TREE (Minh, UFBoot, SIMD) → RAxML-NG → BEAST 2 (BEAGLE/GPU) → PhyG (Wheeler, grafos).
2. Parcimônia: algoritmo de Fitch $O(n \cdot m)$; busca NP-dura; TNT = buscador mais rápido (>500 táxons).
3. MV: algoritmo de Felsenstein $O(n \cdot m)$ por avaliação; fator constante muito maior que parcimônia; requer paralelização/GPU.
4. Revolução Bayesiana (2000–2015): MrBayes implementou Metropolis-Hastings + movimentos de resecção-reconexão; 10–100× mais CPU que MV; $MC^3$ com cadeias quentes.
5. IQ-TREE: UFBoot, seleção de modelo automática (BIC/AICc), suporte rápido (aBayes, SH-aLRT), SIMD (AVX2/AVX-512), paralelismo por arquivo.
6. BEAGLE 3: biblioteca para cálculo de verossimilhança em GPU; speedup até 100×; restrição = memória de GPU.
7. Redes filogenéticas: redes de quase-mediana (Holland e Moulton 2004), Neighbor-Net (Bryant e Moulton 2004), PhyG (Wheeler et al. 2024); espaço de busca exponencialmente maior que árvores.
8. Thompson sampling (Wheeler, 2024): exploração adaptativa de espaço de busca (bandidos multi-armados); paralelizável; usado em PhyG.
9. PMDL (Wheeler & Varón, 2025): critério de comprimento mínimo de descrição filogenética; unifica parcimônia e verossimilhança; barreira = incomputabilidade da complexidade de Kolmogorov.
10. Obstáculos não resolvidos: NP-dureza (nenhuma garantia de ótimo global), incomputabilidade de complexidade algorítmica, tensão cladística vs. baseada em modelos.
11. ML emergente: RNCs para predição de alinhamento/topologia/modelo; rápido mas "caixa preta"; papel futuro = aceleração de pilha heurística.

# Referências


Bouckaert, R., T. G. Vaughan, J. Barido-Sottani et al. (2019). “BEAST 2.5: An advanced software platform for Bayesian evolutionary analysis”. Em: *PLOS Computational Biology* 15, e1006650.

Bryant, D. e V. Moulton (2004). “Neighbor-net: An agglomerative method for the construction of phylogenetic networks”. Em: *Molecular Biology and Evolution* 21, pp. 255–265.

Drummond, A. J. e A. Rambaut (2007). “BEAST: Bayesian evolutionary analysis by sampling trees”. Em: *BMC Evolutionary Biology* 7, p. 214.

Fitch, W. M. (1971). “Toward defining the course of evolution: minimum change for a specified tree topology”. Em: *Systematic Zoology* 20, pp. 406–416. doi: 10.2307/2412116.

Goloboff, P. A., J. S. Farris e K. C. Nixon (2008). “TNT, a free program for phylogenetic analysis”. Em: *Cladistics* 24, pp. 774–786. doi: 10.1111/j.1096-0031.2008.00217.x.

Graur, D., W. A. Hide e W. H. Li (1991). “Is the guinea-pig a rodent?” Em: *Nature* 351, pp. 649–652.

Holland, B. R. e V. Moulton (2004). “Consensus networks: A method for visualizing incompatible evolutionary trees”. Em: *Molecular Biology and Evolution* 21, pp. 254–267.

Kozlov, A. M., D. Darriba, T. Flouri et al. (2019). “RAxML-NG: A fast, scalable and user-friendly tool for maximum likelihood phylogenetic inference”. Em: *Bioinformatics* 35, pp. 4453–4455.

Minh, B. Q., H. A. Schmidt, O. Chernomor, D. Schrempf, M. D. Woodhams, A. von Haeseler e R. Lanfear (2020). “IQ-TREE 2: New models and efficient methods for phylogenetic inference in the genomic era”. Em: *Molecular Biology and Evolution* 37, pp. 1530–1534.

Ronquist, F. e J. P. Huelsenbeck (2003). “MrBayes 3: Bayesian phylogenetic inference under mixed models”. Em: *Bioinformatics* 19, pp. 1572–1574.

Stamatakis, A. (2006). “RAxML-VI-HPC: maximum likelihood-based phylogenetic analyses with thousands of taxa and mixed models”. Em: *Bioinformatics* 22, pp. 2688–2690. doi: 10.1093/bioinformatics/btl446.

Swofford, D. L. (1993). *PAUP*: Phylogenetic analysis using parsimony (*and other methods)*. 3.1. Sinauer Associates.

Wheeler, W. C. (2001). “Homology and the optimization of DNA sequence data”. Em: *Cladistics* 17, pp. 3–11.

Wheeler, W. C. et al. (2024). “PhyG: Software for phylogenetic graph analysis”. Em: *Journal of Phylogenetics* 1, pp. 1–20.

Wheeler, W. C. (2024). “Thompson sampling for adaptive search optimization in phylogenetics”. Em: *Journal of Computational Biology* 31, pp. 123–145.

Wheeler, W. C. e A. Varón (2025). “Phylogenetic minimum description length: A unified optimality criterion”. Em: *Systematic Biology* 74, pp. 1–25.

# Capítulo 8

# Projeto de Sistemas Computacionais de Alto Desempenho para Filogenômica


## Resumo

Análises filogenômicas modernas envolvem centenas a milhares de loci extraídos de dados em escala genômica. Cada locus deve ser individualmente alinhado, aparado e submetido a estimação de árvore de genes antes de inferência de árvore de espécies downstream. Esta expansão de escala, impulsionada por sequenciamento de captura de alvo, transcriptômica e abordagens de genoma inteiro, tornou computação em escala de desktop inadequada para a maioria dos grupos de pesquisa. Este capítulo examina design e implementação de sistemas computacionais de alto desempenho (HPC) especificamente otimizados para filogenômica, cobrindo desde auditoria de perfil de workload através otimização financeira, estratégia de alocação de recursos, e gerenciamento multi-usuário. Apresentamos uma proposta de cluster específica para departamento de bioinformática universitário e discutimos princípios gerais aplicáveis a laboratórios variando em escala de simple workstations até clusters regionais.


## 8.1 Introdução

Uma análise única de IQ-TREE em um alinhamento particionado de várias centenas de loci pode consumir dezenas de milhares de horas de CPU. Análises Bayesianas com BEAST ou MrBayes adicionam ordens de magnitude adicionais quando convergência MCMC requer comprimentos de cadeia estendidos. Além disso, questões sobre se métricas padrão de suporte de clado (bootstrap, SH-aLRT, aBayes) são calibradas com respeito a sensibilidade de alinhamento — uma questão ativamente sendo investigada — demandam replicação em larga escala através de alinhamentos alternativos e configurações de parâmetros. Tais estudos são computacionalmente inviáveis sem recursos HPC dedicados.

Clusters de pesquisa gerais da universidade, enquanto valiosos, frequentemente têm políticas de agendamento otimizadas para justiça em escala de campus e não para as características específicas de workloads filogenômicos. Um cluster departamental dedicado permite otimização de heterogeneidade de hardware, topologia de armazenamento, e políticas de agendamento especificamente para

filogenômica.

## 8.2 Perfil Computacional de Workflows Filogenômicos

O design de um sistema HPC para filogenômica deve ser informado por análise cuidadosa dos gargalos computacionais em cada estágio do pipeline. Workflows filogenômicos são heterogêneos: alguns estágios são limitados em memória, outros limitados em CPU ou I/O, e alguns são cada vez mais adequados para GPU.

### 8.2.1 Fase 1: Controle de Qualidade e Pré-processamento de Leituras

Ferramentas como *fastp* (Chen et al. 2018) e Trimmomatic (Bolger et al. 2014) realizam remoção de adaptador, aparagem de qualidade e filtragem de leitura. Essas tarefas são predominantemente limitadas por I/O, com requisitos de CPU modestos. *fastp* é notável por seu tratamento multi-threaded de I/O e tipicamente se saturação em 4–8 threads. O gargalo chave é throughput de armazenamento: uma única lane Illumina HiSeq/NovaSeq pode produzir 100–400 GB de dados FASTQ comprimidos, e operações de QC envolvem ler e reescrever esses arquivos em sua totalidade.

**Perfil de Recurso:** limitado por I/O; 4–8 núcleos de CPU por job; 4–16 GB de RAM; armazenamento de scratch de alto throughput crítico.

### 8.2.2 Fase 2: Montagem, Mapeamento e Extração de Locus

Dependendo do design do estudo, leituras podem ser montadas *de novo* (*e.g.*, SPAdes, Trinity) ou mapeadas para uma referência (*e.g.*, BWA-MEM2, HybPiper para dados de captura de alvo). Montagem *de novo*, particularmente com Trinity para dados de transcriptômica, é ambos CPU-intensiva e memory-hungry, com pico de uso de RAM frequentemente excedendo 100 GB para datasets de tamanho moderado. Abordagens baseadas em referência são mais modestas mas ainda se beneficiam de armazenamento rápido para I/O de arquivo BAM.

**Perfil de Recurso:** CPU- e memory-intensivo; 16–32 núcleos; 64–256 GB de RAM; armazenamento de scratch rápido.

### 8.2.3 Fase 3: Inferência de Ortologia

Ferramentas como OrthoFinder (Emms e Kelly 2019) realizam buscas DIAMOND/BLAST all-vs-all seguidas por clustering MCL. A fase de busca DIAMOND é embaraçosamente paralela e se beneficia de contagem de núcleos alta, enquanto a fase de clustering MCL é memory-intensiva para conjuntos de proteomas grandes (>50 espécies).

**Perfil de Recurso:** CPU-intensivo (paralelizável); 16–64 núcleos; 32–128 GB de RAM.

### 8.2.4 Fase 4: Alinhamento Múltiplo de Sequências

MAFFT (Katoh e Standley 2013), MUSCLE e outras ferramentas de alinhamento são CPU-bound, com a maioria das implementações threading eficientemente para 4–16 núcleos. No entanto, porque um dataset filogenômico típico envolve centenas a milhares de loci individuais, a estratégia de paralelismo dominante é executar muitos jobs de alinhamento independentes concorrentemente em vez de alocar muitos núcleos para um único alinhamento. Isso torna alinhamento uma carga de trabalho ideal para arrays de job SLURM.

**Perfil de Recurso:** CPU-bound; 4–16 núcleos por alinhamento individual; 2–8 GB de RAM por alinhamento; alto throughput de job via arrays.

### 8.2.5 Fase 5: Aparagem e Filtragem de Alinhamento

Ferramentas como trimAl (Capella-Gutiérrez et al. 2009) e BMGE (Criscuolo e Gribaldo 2010) são leves, tipicamente completando em segundos por locus. A consideração primária é latência de I/O em vez de poder de computação.

**Perfil de Recurso:** CPU/RAM mínimos; I/O-latency-sensível.

### 8.2.6 Fase 6: Estimação de Árvore de Gene (Máxima Verossimilhança)

Inferência de árvore de máxima verossimilhança com IQ-TREE (Minh et al. 2020) ou RAxML-NG (Kozlov et al. 2019) é a fase mais CPU-intensiva do pipeline para abordagens baseadas em ML. Ambas ferramentas implementam avaliação de verossimilhança multi-threaded eficiente usando kernels vetorizados SIMD (AVX2/AVX-512). IQ-TREE 2 demonstra eficiência de paralelismo alta, atingindo scaling quase-linear para 4 núcleos e speedups úteis para 8–16 núcleos para análises individuais. Para estudos filogenômicos, a estratégia ótima é frequentemente inferir árvores de gene em paralelo (uma por locus), com cada busca em árvore alocada 4–8 núcleos.

**Perfil de Recurso:** CPU-bound; beneficia de velocidade de clock alta e AVX-512; 4–16 núcleos por árvore de gene; 2–16 GB de RAM; alto throughput de job via arrays SLURM.

### 8.2.7 Fase 7: Estimação de Árvore de Gene (Bayesiana)

Inferência Bayesiana com MrBayes (Ronquist et al. 2012) ou BEAST/BEAST2 (Bouckaert et al. 2019) é substancialmente mais cara do que inferência ML devido a requisitos de amostragem MCMC. A biblioteca BEAGLE (Ayres et al. 2019) fornece computação de verossimilhança acelerada por GPU, atingindo speedups de até 100× para datasets grandes em GPUs NVIDIA. BEAGLE 3 inclui implementações OpenCL e CPU-threaded, mas a implementação baseada em CUDA em hardware NVIDIA moderno permanece como líder de desempenho. Memória de GPU é a restrição primária: análises nucleotídicas de dupla-precisão com quatro categorias de taxa requerem aproximadamente 2 GB de memória de GPU por 1.000 OTUs e 10.000 padrões de sites únicos.

**Perfil de Recurso:** GPU-acelerado via BEAGLE/CUDA; 24–48 GB de memória de GPU recomendada; CPU moderado para caminhos de código não-BEAGLE.

### 8.2.8 Fase 8: Inferência de Árvore de Espécies e Análise de Concordância

Métodos coalescentes sumários como ASTRAL-III (Zhang et al. 2018) são rápidos e memory-eficientes, tipicamente completando em minutos mesmo para datasets com centenas de loci e espécies. Abordagens baseadas em concatenação (supermatriz) usando IQ-TREE ou RAxML-NG no alinhamento particionado completo são mais demandantes e representam um segundo gargalo computacional major. Análise de fator de concordância (gCF, sCF) em IQ-TREE requer re-avaliação de todas as árvores de gene contra a árvore de espécies e é moderadamente CPU-intensiva.

**Perfil de Recurso:** Variável; ASTRAL é leve; ML concatenado é CPU-intensivo (similar a Fase 6 mas em dados maiores); análise de concordância é moderada.

## 8.3 Arquitetura de Hardware Proposta

### 8.3.1 Filosofia de Design

O cluster segue uma filosofia de design heterogêneo: em vez de comprar nós uniformes, propomos três tipos de nó distintos otimizados para os diferentes perfis computacionais. Esta abordagem maximiza eficácia de custo evitando over-provisioning de recursos caros (GPU, RAM grande) em nós onde não são necessários.

### 8.3.2 Componentes Recomendados

Tabela 8.1: Componentes Recomendados de Hardware para Cluster Filogenômico

| Componente | Qtd | CPU | RAM | Armazenamento | GPU |
|---|---|---|---|---|---|
| Nó Computacional (Tipo A) | 4 | 2× EPYC 9554 (64C) | 512 GB DDR5 | 2× 2TB NVMe | — |
| Nó High-Memory (Tipo B) | 1 | 2× EPYC 9554 (64C) | 1.5 TB DDR5 | 4× 4TB NVMe | — |
| Nó GPU (Tipo C) | 1 | 1× EPYC 9454 (48C) | 256 GB DDR5 | 2× 2TB NVMe | 2× RTX A6000 (48GB) |
| Nó Management/Login | 1 | 1× EPYC 9124 (16C) | 64 GB DDR5 | 2× 1TB NVMe (RAID 1) | — |
| Servidor NAS | 1 | 1× Xeon entry | 64 GB ECC | 12× 18TB HDD (RAID6) + 2× 4TB NVMe | — |
| Networking (Switch 25GbE) | 1 | — | — | — | — |
| UPS + Rack + Cabagem | 1 | — | — | — | — |
| **Custo Total Estimado: $163.000–$185.000** | | | | | |

### 8.3.3 Rationale de Seleção de CPU

O AMD EPYC 9554 (64 núcleos, 3.75 GHz boost, 256 MB cache L3) fornece excelente balanço de contagem de núcleos, velocidade de clock, e tamanho de cache para workloads filogenômicos. Ambas IQ-TREE e RAxML-NG usam kernels de verossimilhança vetorizados AVX2/AVX-512, e a arquitetura Zen 4 na série EPYC 9004 fornece suporte nativo AVX-512. O cache L3 grande é particularmente benéfico para operações de busca em árvore, que exibem padrões de acesso à memória irregulares quando atravessando arrays de verossimilhança através de nós internos de árvore. A configuração dual-socket rende 128 núcleos por nó Tipo A (512 total através de quatro nós), permitindo execução simultânea de 32–64 jobs de árvore de gene por nó em 4–8 núcleos cada.

### 8.3.4 Rationale de Seleção de GPU

O NVIDIA RTX A6000 fornece 48 GB de memória GDDR6 por card, o que é crítico para análises Bayesianas aceleradas por BEAGLE. Memória de GPU é a restrição vinculante para BEAGLE: uma análise nucleotídica com 500 OTUs e 50.000 padrões de sites únicos em dupla precisão requer aproximadamente 10 GB de memória de GPU. Dois cards RTX A6000 permitem análise simultânea de múltiplas partições ou cadeias MCMC independentes, e BEAST pode particionar datasets através de múltiplas instâncias de BEAGLE, uma por GPU.

### 8.3.5 Arquitetura de Armazenamento

A arquitetura de armazenamento proposta segue um design de três tiers:

1. **Tier 1 — NVMe SSD (fast scratch):** Use para diretórios de análise ativa. Raw read processing, montagem e alinhamento são I/O-intensivos. Unidades NVMe (idealmente em RAID-0 ou ZFS stripe para throughput) previnem armazenamento de se tornar gargalo. Apunte para pelo menos 4–8 TB de scratch rápido por nó.

2. **Tier 2 — SATA SSD ou HDD RAID (warm storage):** Resultados intermediários, alinhamentos completados, e arquivos de árvore que precisam ser acessíveis mas não estão sob computação ativa. 20–50 TB é um ponto de partida razoável.

3. **Tier 3 — Cold/archival (tape, cloud cold-tier):** Leituras sequenciadas brutas (FASTQ) após QC e montagem. Estes são grandes mas raramente re-acessados. Armazenamento comprimido aqui é eficaz em custo.

### 8.3.6 Fabric de Rede

Para um cluster multi-nó, se seu workflow paraleliza *através* de nós (*e.g.*, análises MPI baseadas como ExaBayes; Aberer et al. (2014)), você necessita interconnect de baixa latência. InfiniBand (HDR, 200 Gb/s) é o padrão ouro. Se jobs MPI cross-nó são raros, 25 GbE ou mesmo 10 GbE é suficiente e muito mais barato.

Para a maioria de labs filogenômicos, InfiniBand pode ser completamente evitado. O padrão paralelo dominante é "muitos jobs independentes através de loci," o qual requer um agendador de job — não MPI.

### 8.3.7 Otimização Financeira: Custo Total de Propriedade

Preço de compra de hardware é apenas 40–60% do custo total de 5 anos de propriedade. O restante é eletricidade, resfriamento, manutenção, e tempo de staff.

#### Eletricidade e Resfriamento

Um servidor dual-socket com CPUs high-end consome 800–1500 W sob carga. Em uma taxa institucional norte-americana média de $0.10/kWh, um único nó executando 1 kW continuamente custa $876/ano em eletricidade sozinho — antes de sobrecarga de resfriamento. Resfriamento tipicamente adiciona 30–60% ao custo de eletricidade (expresso como Eficácia de Uso de Energia, PUE). Uma sala de servidor bem-desenhada alcança PUE 1.3–1.5; um closet de escritório repurposado pode atingir 2.0+.

#### Buy vs. Cloud

Para workloads sustentados e previsíveis (runs de pipeline diárias, recurso compartilhado sempre-ativo), hardware possuído quase sempre vence computação em nuvem em custo por hora-compute após ano 1–2. Para workloads bursty (montagem grande ocasional, crise de prazo de concessão anual), instâncias em nuvem (AWS, Google Cloud, Azure) evitam custos de hardware ocioso. AWS Spot / GCP Preemptible instances são 60–90% mais baratos do que on-demand e toleráveis para jobs embaraçosamente paralelos filogenômicos que checkpoint bem.

Uma abordagem híbrida é cada vez mais a estratégia recomendada para labs de genômica acadêmica: possuir um sistema base modesto para trabalho diário, burst para nuvem durante picos.

Tabela 8.2: Projeção de Custo Total de Propriedade (5 Anos)

| **Categoria** | **Ano 1** | **Anos 2–5 (anual)** |
|---|---|---|
| Aquisição de hardware | $163.000–$185.000 | — |
| Eletricidade ( 8 kW sustentado) | $7.000 | $7.000 |
| Resfriamento (suplementar, est.) | $2.000 | $2.000 |
| Administração de sistema (0.25 FTE) | $20.000 | $20.000 |
| Fundo de warranty/replacement | — | $5.000 |
| Burst em nuvem (contingência) | $3.000 | $3.000 |
| **TOTAL** | **$195.000–$217.000** | **$37.000/yr** |
| **Custo Total 5 Anos: $343.000–$365.000** | | |
| **Custo por usuário por ano (15–25 usuários): $2.700–$4.900** | | |

**Projeção de Custo Total de 5 Anos**

## 8.4 Software Stack e Gerenciamento de Ambiente

### 8.4.1 Sistema Operacional e Agendamento de Job

Todos os nós executarão Rocky Linux 9 (compatível com RHEL), que fornece estabilidade de longo prazo e compatibilidade ampla com software de bioinformática. O gerenciador de workload SLURM (Team 2023) manipulará agendamento de job, alocação de recurso, e accounting.

SLURM é o agendador dominante em HPC acadêmico e fornece suporte nativo para agendamento consciente de GPU (GRES), arrays de job (essenciais para processamento em batch filogenômico), agendamento fair-share através de grupos de usuário, e accounting detalhado para relatório de uso de recurso.

### 8.4.2 Containerização e Reproducibilidade

Ambientes de software serão manipulados via containers Apptainer (anteriormente Singularity) e o sistema Lmod de environment modules. Containers Apptainer permitem usuários empacotar pilhas de software completas (incluindo versões específicas de IQ-TREE, RAxML-NG, BEAST, MAFFT, etc.) em imagens portáveis e reproduzíveis que podem ser compartilhadas e arquivadas ao lado de publicações.

Diferentemente de Docker, Apptainer executa sem privilégio e integra nativamente com SLURM, tornando-o adequado para ambientes HPC compartilhados. Imagens de container pré-construídas para workflows filogenômicos comuns serão mantidas pelo time de administração de sistema.

### 8.4.3 Orquestração de Pipeline

Usuários serão encorajados a implementar workflows reproduzíveis usando Snakemake (Mölder et al. 2021) ou Nextflow, ambos integrando com SLURM para automaticamente decompor pipelines filogenômicos em steps de job paralelizáveis. Um template de Snakemake departamental para workflows padrão filogenômicos (QC → montagem → ortologia → alinhamento → aparagem → árvores de gene → árvore de espécies) será fornecido como ponto de partida.

## 8.5 Estratégia de Alocação de Recursos

### 8.5.1 Design de Partição SLURM

O cluster será dividido em partições SLURM que mapeiam para topologia de hardware e perfis computacionais identificados acima:

Tabela 8.3: Partições SLURM Recomendadas

| Partição | Nós | Max Walltime | Caso de Uso |
|---|---|---|---|
| standard | Tipo A (4 nós) | 7 dias | Busca em árvore ML, alinhamento |
| highmem | Tipo B (1 nó) | 14 dias | Montagem *de novo*, análises concatenadas grandes |
| gpu | Tipo C (1 nó) | 14 dias | BEAST/MrBayes com BEAGLE |
| quick | Todos Tipo A | 4 horas | QC, aparagem, ASTRAL, testes |

### 8.5.2 Agendamento Fair-Share

O algoritmo de agendamento fair-share de SLURM será configurado com contas hierárquicas correspondendo a grupos de pesquisa. Cada PI receberá uma alocação base (*e.g.*, 40% de capacidade de cluster para grupo de filogenômica primária, com restante dividido entre grupos colaboradores). Fair-share decay garantirá que grupos que consumiram recentemente recursos desproporcionais são desprioritizados na fila, prevenindo qualquer projeto único de monopolizar o cluster.

### 8.5.3 Limites de Recurso e Accountability

Limites de CPU e memória por-usuário serão impostos via agendamento fair-share de SLURM. Sem estes, um único usuário executando 10.000 jobs de IQ-TREE desfalecerá todos os demais. Limites de wall-time máximo por partição prevenirão jobs zumbis de entesourar recursos. Accounting de SLURM (`sacct`) será usado para monitorar uso, justificar compras de hardware em relatórios de concessão, e identificar gargalos.

## 8.6 Requisitos de Recurso Recomendados por Tipo de Análise

Tabela 8.4: Requisições de Recurso Recomendadas por Tipo de Análise

| Tarefa | Núcleos | RAM | Partição | Notas |
|---|---|---|---|---|
| fastp (por amostra) | 4–8 | 8 GB | quick | Array job; ~5 min/amostra |
| MAFFT L-INS-i (por locus) | 4 | 4 GB | quick | Array job; seg–min/locus |
| IQ-TREE árvore de gene | 4–8 | 4 GB | standard | Array job; 10 min–hrs/locus |
| IQ-TREE concat. (particionado) | 32–64 | 64–128 GB | standard | Job único grande; hrs–days |
| RAxML-NG (particionado) | 32–64 | 64–128 GB | standard | Considere MPI para >64 núcleos |
| Trinity assembly | 32 | 256–1024 GB | highmem | Requer nó Tipo B |
| BEAST + BEAGLE (por cadeia) | 4–8 + 1 GPU | 32 GB + 48GB VRAM | gpu | Use `--gres=gpu:1` |
| ASTRAL-III | 1–4 | 16 GB | quick | Usualmente $< 30$ minutos |

## 8.7 Gerenciamento Multi-Usuário

### 8.7.1 Estrutura de Conta

Contas de usuário serão manipuladas através de LDAP, integrado com sistema existente de gerenciamento de identidade da universidade. Contas de SLURM seguirão uma estrutura hierárquica: uma

conta “filogenômica” de nível superior com sub-contas para cada grupo de PI. Estudantes e postdocs serão adicionados à sub-conta de seu PI, herdando alocações de fair-share e acesso de partição.

### 8.7.2 Quotas de Armazenamento

Cada usuário receberá diretório home de 50 GB (backed up cada noite) e alocação de scratch de 2 TB no NAS. Diretórios compartilhados de nível de grupo serão provisionados em 10–20 TB por PI, dependendo de necessidades ativas de projeto. Dados de scratch com mais de 60 dias sem acesso serão marcados para arquivamento. Um relatório mensal automatizado notificará usuários de consumo de armazenamento e limites de quota próximos.

### 8.7.3 Segurança e Controle de Acesso

Autenticação baseada em chave SSH será requerida para todo acesso. Autenticação de dois-fatores será imposta para operações administrativas. Dados de usuário serão separados por permissões de grupo Unix, e datasets sensíveis podem ser colocados em diretórios restritos acessíveis apenas a usuários autorizados. Todos os nós estarão atrás de firewall departamental, com acesso apenas via VPN ou rede de campus.

### 8.7.4 Treinamento e Documentação

Uma wiki departamental fornecerá documentação cobrindo submissão de job de SLURM, uso de container, scripts SLURM exemplo para tarefas filogenômicas comuns, e melhores práticas para alocação de recurso. Workshops bi-anuais serão oferecidos para estudantes graduados novos. Usuários power serão designados como “cluster champions” para fornecer suporte de nível peer e contribuir à documentação.

## 8.8 Monitoramento e Alertas

Você não pode otimizar o que não mede.

- **Monitoramento de Recurso:** Implante stack leve tal qual Prometheus + Grafana ou simplesmente use accounting incorporado de SLURM mais summários de `squeue`/`sacct`. Rastreie utilização de CPU, marcas de água alta de memória, throughput de I/O de disco, e utilização de GPU ao longo do tempo.

- **Saúde Térmica e de Hardware:** Use IPMI/iDRAC/iLO (disponível em todo hardware de servidor-grade) para monitorar temperaturas, velocidades de ventilador, e saúde de disco. Configure email alerts para avisos de disco SMART e thermal throttling.

- **Auditorias de Eficiência de Job:** Periodicamente revise jobs completados. Usuários que requisitam 500 GB de RAM mas usam 30 GB, ou requisitam 64 núcleos mas executam single--threaded, desperdiçam recursos de agendador. Forneça feedback — a maioria de usuários simplesmente copiam-colam scripts de job sem ajustar parâmetros.

## 8.9 Roadmap de Escalabilidade: Pense em Fases

A maioria de labs não pode (e não deve) construir um cluster completo no dia um. Uma progressão sensata:

1. **Fase 1 — Single high-spec workstation** (dual-socket, 256–512 GB RAM, 64–128 núcleos, scratch NVMe, 1 GPU). Instale SLURM mesmo aqui. Isso manipula a maioria de workflows filogenômicos para lab de 3–5 usuários.
2. **Fase 2 — Adicione segundo nó** quando contenção de CPU se torna crônica. Conecte via 10/25 GbE, compartilhe dados via NFS.
3. **Fase 3 — Servidor de armazenamento dedicado** quando volumes de dados ultrapassa discos locais. Centralize warm e cold storage.
4. **Fase 4 — Cluster heterogêneo** com nós especializados (high-memory, GPU, high-clock) conforme grants e workloads justificam.
5. **Contínuo — Cloud bursting** para pico de demanda transiente em vez de over-provisioning de hardware permanente.

## 8.10 Conclusão

Sistemas HPC bem-designados para filogenômica amplificam capacidade analítica de grupos de pesquisa por órdãos de magnitude. O investimento — capital inicial, eletricidade, staff — é significante, mas retornam-se rapidamente em forma de mais análises por pesquisador, mais estudantes habilitados, e publicações de maior qualidade. Para laboratórios operando em instituições com suporte de HPC central limitado, um cluster departamental dedicado é frequentemente o caminho mais pragmático para produtividade analítica sustentada.

**Roteiro de Revisão do Capítulo**

1. 8 fases do workflow: (1) QC/pré-proc. (I/O, fastp 4–8 cores), (2) montagem/mapeamento (CPU+RAM, Trinity >100 GB), (3) ortologia (OrthoFinder, DIAMOND paralelo), (4) alinhamento (MAFFT, arrays SLURM), (5) aparagem (trimAl/BMGE, leve), (6) árvore de gene ML (IQ-TREE/RAxML-NG, AVX-512, 4–8 cores/locus), (7) árvore de gene Bayesiana (BEAST+BEAGLE/GPU, 24–48 GB VRAM), (8) árvore de espécies (ASTRAL leve; concatenação pesada).
2. Design heterogêneo: 3 tipos de nó. Tipo A (4 nós): 2×EPYC 9554 (128 cores), 512 GB DDR5. Tipo B (1 nó): 1,5 TB RAM (montagem). Tipo C (1 nó): 2×RTX A6000 (48 GB VRAM cada).
3. CPU: EPYC 9554 — 64 cores, 3,75 GHz boost, 256 MB L3, AVX-512 nativo (Zen 4).
4. GPU: RTX A6000 para BEAGLE/CUDA; ∼10 GB VRAM para 500 OTUs × 50 000 padrões em dupla precisão.
5. Armazenamento 3 tiers: Tier 1 NVMe (scratch rápido), Tier 2 SATA/HDD RAID (warm), Tier 3 cold/archival (tape/nuvem).
6. Rede: 25 GbE suficiente se jobs são independentes por locus; InfiniBand (HDR 200 Gb/s) apenas para MPI cross-nó (ExaBayes).
7. SLURM: partições `standard` (Tipo A, 7d), `highmem` (Tipo B, 14d), `gpu` (Tipo C, 14d), `quick` (4h); fair-share hierárquico por PI.
8. TCO 5 anos: hardware $163–185k + eletricidade $7k/ano + resfriamento $2k/ano + sysadmin 0,25 FTE $20k/ano + contingência = **$343–365k total**; $2.700–4.900/usuário/ano.
9. Software: Rocky Linux 9, Apptainer (Singularity) para containers, Snakemake/Nextflow para pipelines, Lmod para módulos.
10. Roadmap de escalabilidade: Fase 1 (workstation única + SLURM) → Fase 2 (2º nó, NFS) → Fase 3 (NAS dedicado) → Fase 4 (cluster heterogêneo) → cloud bursting contínuo.

# Referências

Aberer, A. J., K. Kobert e A. Stamatakis (2014). "ExaBayes: Massively parallel Bayesian tree inference for the whole-genome era". Em: *Molecular Biology and Evolution* 31, pp. 2553–2556.

Ayres, D. L., A. Darling, G. Baele et al. (2019). "BEAGLE 3: Improved performance, scaling, and usability for a high-performance computing library for statistical phylogenetics". Em: *Systematic Biology* 68, pp. 1052–1061.

Bolger, A. M., M. Lohse e B. Usadel (2014). "Trimmomatic: A flexible trimmer for Illumina sequence data". Em: *Bioinformatics* 30, pp. 2114–2120.

Bouckaert, R., T. G. Vaughan, J. Barido-Sottani et al. (2019). "BEAST 2.5: An advanced software platform for Bayesian evolutionary analysis". Em: *PLOS Computational Biology* 15, e1006650.

Capella-Gutiérrez, S., J. M. Silla-Martínez e T. Gabaldón (2009). "trimAl: A tool for automated alignment trimming in large-scale phylogenetic analyses". Em: *Bioinformatics* 25, pp. 1972–1973.

Chen, S., Y. Zhou, Y. Chen e J. Gu (2018). "fastp: An ultra-fast all-in-one FASTQ preprocessor". Em: *Bioinformatics* 34, pp. i884–i890.

Criscuolo, A. e S. Gribaldo (2010). "BMGE (Block Mapping and Gathering with Entropy): A new software for selection of phylogenetic informative regions from multiple sequence alignments". Em: *BMC Evolutionary Biology* 10, p. 210.

Emms, D. M. e S. Kelly (2019). "OrthoFinder: Phylogenetic orthology inference for comparative genomics". Em: *Genome Biology* 20, p. 238.

Katoh, K. e D. M. Standley (2013). "MAFFT multiple sequence alignment software version 7: Improvements in performance and usability". Em: *Molecular Biology and Evolution* 30, pp. 772–780.

Kozlov, A. M., D. Darriba, T. Flouri et al. (2019). "RAxML-NG: A fast, scalable and user-friendly tool for maximum likelihood phylogenetic inference". Em: *Bioinformatics* 35, pp. 4453–4455.

Minh, B. Q., H. A. Schmidt, O. Chernomor, D. Schrempf, M. D. Woodhams, A. von Haeseler e R. Lanfear (2020). "IQ-TREE 2: New models and efficient methods for phylogenetic inference in the genomic era". Em: *Molecular Biology and Evolution* 37, pp. 1530–1534.

Mölder, F., K. P. Jablonski, B. Letcher et al. (2021). "Sustainable data analysis with Snakemake". Em: *F1000Research* 10, p. 33.

Ronquist, F., M. Teslenko, P. van der Mark et al. (2012). "MrBayes 3.2: Efficient Bayesian phylogenetic inference and model choice across a large model space". Em: *Systematic Biology* 61, pp. 539–542.

Team, S. (2023). "SLURM workload manager documentation". Em.

Zhang, C., M. Rabiee, E. Sayyari e S. Mirarab (2018). "ASTRAL-III: Polynomial time species tree reconstruction from partially resolved gene trees". Em: *BMC Bioinformatics* 19, p. 153.

# Capítulo 9

# Gestão de Dados Ômicos


## Resumo

Análises computacionais são agora centrais em virtualmente toda pesquisa ômicas, mas o componente computacional é frequentemente o link mais fraco em reproducibilidade científica. Este capítulo examina fundações teóricas de reproducibilidade, os princípios FAIR (Encontrável, Acessível, Interoperável, Reutilizável) para gestão de dados e software de pesquisa, e implementação prática desses princípios em contexto de filogenômica e multi-ômicas. Especial atenção é dada às limitações técnicas de computação — comportamento dependente de hardware, restrições de memória e armazenamento, o paradoxo de computação em nuvem — que afetam reproducibilidade mesmo quando melhores práticas são seguidas. Fornecemos um checklist prático para fazer projetos filogenômicos FAIR e discutimos conexões entre design de sistema HPC e conformidade FAIR.


## 9.1 Introdução: O Problema de Reproducibilidade em Biologia Computacional

Análises computacionais são agora centrais em virtualmente toda pesquisa ômicas, porém o componente computacional é frequentemente o link mais fraco em reproducibilidade científica. O problema tem múltiplas dimensões interagindo.

### 9.1.1 Opacidade e Fragilidade de Software

Muitas ferramentas de bioinformática são pobremente documentadas, sensíveis a versão, e distribuídas sem ambientes containerizados, significando que instalar a mesma ferramenta seis meses depois em um sistema operacional diferente pode produzir resultados diferentes — ou falhar inteiramente. Martín del Pico et al. (2024) avaliaram FAIRness através de software de pesquisa em ciências da vida e encontraram que reproducibilidade e verificabilidade de componentes computacionais permanecem sistemicamente deficientes. Zafeiropoulos et al. (2021) documentaram isto do lado de facility: seu sistema HPC acumulou sobre 200 pacotes de software com versionamento frequente e não-periódico e cadeias de dependência quebradas, motivando sua transição para pipelines containerizados.

### 9.1.2 Sensibilidade de Parâmetro e Configuração

Powers et al. (2022) demonstraram que algo aparentemente rotineiro quanto alocação de thread por tarefa ou a escolha de nível de compressão em GATK pode alteravelmente mudar runtime e, no caso

de configurações scatter-gather, potencialmente introduzir artefatos. Essas decisões de configuração são raramente relatadas em seções de métodos.

### 9.1.3 Negligência em Gestão de Dados

Dados sequenciados bruços, arquivos intermediários, e resultados finais são frequentemente armazenados em estruturas de diretório ad hoc sem metadados, sem versionamento, e sem política de ciclo de vida de dados. Quando um estudante se gradua, seu histórico de análise pode ser efetivamente perdido.

### 9.1.4 Escala do Problema

Kim et al. (2018) realizaram estudo de caso em reproducibilidade em bioinformática e encontraram que mesmo análises bem-documentadas não podiam ser confiávelmente replicadas devido a diferenças de ambiente e dependência. Isto não é preocupação marginal — afeta confiabilidade fundamental de resultados publicados.

## 9.2 Os Princípios FAIR: Um Framework para Intendência de Dados

### 9.2.1 Origem e Escopo

Os Princípios Orientadores FAIR foram formalizados por Wilkinson et al. (2016) como um conjunto de diretrizes para melhorar Encontrabilidade, Acessibilidade, Interoperabilidade, e Reutilizabilidade de ativos digitais — incluindo dados, metadados, e infraestrutura que os suporta. Uma ênfase chave do paper original é *acionabilidade por máquina*: a capacidade de sistemas computacionais encontrarem, acessarem, interoperarem com, e reutilizarem dados com intervenção mínima ou nenhuma de humano, motivada pelo volume acelerador e complexidade de dados de pesquisa.

### 9.2.2 Os Quinze Sub-Princípios

#### Encontrável (F)

Dados devem ser descobertos por ambos humanos e máquinas.

- F1: (Meta)dados são designados identificadores globalmente únicos e persistentes (*e.g.*, DOIs, números de acesso).
- F2: Dados são descritos com metadados ricos.
- F3: Metadados explicitamente incluem identificador dos dados que descrevem.
- F4: (Meta)dados são registrados ou indexados em recurso pesquisável (*e.g.*, NCBI, ENA, Zenodo).

#### Acessível (A)

Uma vez encontrados, dados devem ser recuperáveis sob condições claras.

- A1: (Meta)dados são recuperáveis pelo seu identificador usando protocolo de comunicação padronizado (*e.g.*, HTTP, FTP).

- A1.1: O protocolo é aberto, grátis, e implementável universalmente.
- A1.2: O protocolo permite para autenticação e autorização onde necessário.
- A2: Metadados permanecem acessíveis mesmo quando os dados mesmos não estão mais disponíveis. Isto é crítico para manutenção científica de longo-prazo.

**Interoperável (I)**

Dados devem ser integráveis com outros dados e compatíveis com aplicações e workflows.

- I1: (Meta)dados usam linguagem formal, acessível, compartilhada, e broadly aplicável para representação de conhecimento (*e.g.*, RDF, OWL, ontologias padronizadas).
- I2: (Meta)dados usam vocabulários que eles mesmos seguem os princípios FAIR.
- I3: (Meta)dados incluem referências qualificadas para outros (meta)dados, habilitando construção de grafos de conhecimento.

**Reutilizável (R)**

Dados devem ser bem-descritos assim que possam ser replicados e combinados em diferentes contextos.

- R1: (Meta)dados são ricamente descritos com pluralidade de atributos acurados e relevantes.
- R1.1: (Meta)dados são lançados com licença de uso de dados clara e acessível (*e.g.*, CC-BY, CC0).
- R1.2: (Meta)dados são associados com proveniência detalhada (quem gerou dados, como, quando, com que parâmetros).
- R1.3: (Meta)dados encontram padrões comunitários relevantes de domínio (*e.g.*, MIGS/MIMS para genômica, ISA-Tab para multi-ômicas).

### 9.2.3 FAIR Aplica-se a Três Entidades

Os princípios endereçam três tipos distintos de entidades: **dados** (ou qualquer objeto digital), **metadados** (informação sobre objeto digital), e **infraestrutura** (sistemas que hospedam, indexam, e servem estes objetos). Por exemplo, princípio F4 requer que ambos metadados e dados sejam registrados em recurso pesquisável — o componente de infraestrutura. Este escopo de três-vias é importante porque muitos pesquisadores tratam FAIR como apenas exercício de etiquetação de dados, quando de fato demanda investimentos correspondentes em infraestrutura e serviços de metadados.

## 9.3 FAIR Além de Dados: Princípios para Software de Pesquisa

Os princípios FAIR originais alvo dados e metadados. Reconhecendo que software de pesquisa é igualmente crítico e igualmente frágil, Barker et al. (2022) propuseram FAIR4RS — uma adaptação de princípios FAIR para software de pesquisa. As adaptações chave incluem:

- Software deveria ter identificadores persistentes (como DOIs via Zenodo ou Software Heritage).
- Software deveria ser descrito com metadados ricos incluindo dependências, ambiente de runtime, e histórico de versão.
- Software deveria usar formatos e padrões aceitos por comunidade, interoperar com outras ferramentas, e ser lançado sob licenças claras.

Martín del Pico et al. (2024) operacionalizaram isto com FAIRsoft, fornecendo framework de avaliação prático que avalia software de pesquisa através destas dimensões. Avaliações periódicas de ferramentas de bioinformática revelaram gaps persistentes em documentação, licensing, e disponibilidade de código-fonte.

Para pesquisa ômicas, a implicação é direta: um pipeline filogenômico é apenas tão reproducível quanto seu componente menos FAIR. Se IQ-TREE é bem-versionado e depositado em Bioconda mas seu script de filtragem customizado vive sem versão em um desktop de lab, a análise geral não é reproducível.

## 9.4 Implementando FAIR em Gestão de Dados Ômicos

### 9.4.1 Repositórios de Dados e Identificadores

Em genômica e filogenômica, repositórios primários já impõem porções dos princípios FAIR:

- **NCBI SRA / ENA / DDBJ** para leituras sequenciadas bruças — números de acesso servem como identificadores persistentes (F1); campos de metadados capturam organismo, plataforma de sequenciamento, e design de estudo (F2, R1); e a Colaboração Internacional de Banco de Dados de Nucleotídeos garante indexação global (F4).
- **TreeBASE / Dryad / Zenodo** para árvores filogenéticas, alinhamentos, e dados suplementares — DOIs fornecem persistência (F1), e integração de Zenodo com GitHub habilita arquivo de software versionado.
- **NCBI GenBank / UniProt / Ensembl** para sequências montadas e anotações.

A lacuna é tipicamente não no nível de repositório mas no nível de lab: pesquisadores frequentemente falham depositar produtos de análise intermediária (alinhamentos filtrados, esquemas de partição, outputs de seleção de modelo, árvores bootstrap) que seriam necessários para verdadeiramente reproduzir estudo filogenômico.

### 9.4.2 Metadados: O Ponto Fraco Perene

Metadados ricos são o elo crítico de FAIR, ainda assim permanece aspecto mais negligenciado em prática. Para filogenômica, metadados essenciais que frequentemente está faltando incluem:

- Versões exatas de software e parâmetros de linha de comando para cada passo de pipeline.
- Critérios de mascaramento de alinhamento ou filtragem (*e.g.*, configurações de Gblocks, limites de trimAl).

- Resultados de seleção de modelo (qual modelo de substituição foi escolhido por locus, e por qual critério).

- Descrição de ambiente computacional (sistema operacional, versões de biblioteca, hash de imagem de container).

- Vínculo de proveniência entre dados brutos, produtos intermediários, e resultados finais.

Niehues et al. (2024) demonstraram abordagem prática a este problema embrulhando workflow de análise multi-ômicas como Objeto Digital FAIR, embutindo metadados, dados, e workflow computacional junto em pacote único reutilizável. Eles usaram RO-Crate como formato de empacotamento, Snakemake como motor de workflow, e Git para controle de versão — fornecendo modelo concreto para como labs filogenômicos poderiam estruturar suas próprias análises.

### 9.4.3 Gerenciadores de Workflow como Habilitadores FAIR

Gerenciadores de workflow servem propósito dual: eles impõem reprodutibilidade codificando steps de análise, e geram metadados de proveniência legível por máquina como efeito colateral de execução. As duas ferramentas dominantes em bioinformática são:

- **Snakemake** (Mölder et al. 2021): Baseado em Python, integra com Conda e Singularity/Apptainer, gera DAGs de execução e logs.

- **Nextflow** (Di Tommaso et al. 2017): Baseado em Groovy, designado para portabilidade através HPC, nuvem, e ambientes locais; comunidade nf-core (Ewels et al. 2020) fornece pipelines de bioinformática curados e revisados por pares.

Ambos produzem registros do que foi executado, com que parâmetros, em que ordem, e em que dados — diretamente endereçando princípios FAIR R1.2 (proveniência) e R1.3 (padrões comunitários).

### 9.4.4 Containers como Infraestrutura de Reprodutibilidade

Containers congelam ambiente de software em imagem portável. Em contexto de FAIR:

- **Singularity/Apptainer** é preferido para HPC porque executa sem privilégio root e integra com SLURM. Zafeiropoulos et al. (2021) adotaram Singularity como seu formato de container padrão por sua compatibilidade com imagens Docker e adequação para ambientes HPC multi-usuário.

- **Docker** é mais comum em contextos de nuvem e desenvolvimento; pipelines nf-core enviam como imagens Docker.

- Hashes de imagem de container (digestos SHA256) servem como identificadores persistentes para exato ambiente computacional, satisfazendo F1 para ambientes de software.

## 9.5 Limitações Técnicas de Computação e Seu Impacto em Reproducibilidade

### 9.5.1 Comportamento Dependente de Hardware

Resultados computacionais em bioinformática não são sempre idênticos bit-a-bit através diferentes hardware, mesmo com software idêntico. Fontes de não-determinismo incluem:

- **Aritmética de ponto flutuante:** Diferentes arquiteturas de CPU (Intel vs. AMD, diferentes conjuntos de instruções SIMD como AVX2 vs. AVX-512) podem produzir resultados de ponto flutuante ligeiramente diferentes, que podem propagar através cálculos de verossimilhança em inferência filogenética. Powers et al. (2022) demonstraram que Genomics Kernel Library (GKL) em GATK usa instruções AVX-512 para kernels de PairHMM e Smith-Waterman, reduzindo runtime de HaplotypeCaller de 35 horas para menos de 1 hora — mas esta aceleração é dependente de arquitetura.
- **Não-determinismo de ordem de thread:** Programas multi-threaded que reduzem resultados através threads (*e.g.*, somando log-verossimilhanças) podem acumular valores de ponto flutuante em ordens diferentes dependendo de agendamento de thread, produzindo somas ligeiramente diferentes. IQ-TREE, RAxML-NG, e BEAST todos exibem este comportamento em graus variados.
- **Sensibilidade de seed aleatória:** Algoritmos de busca em árvore heurísticos dependem de árvores iniciais geradas de seeds aleatórias. Relatando e fixando a seed aleatória é essencial para reproducibilidade.

### 9.5.2 Restrições de Memória e Armazenamento

Como documentado por Zafeiropoulos et al. (2021), armazenamento é a restrição mais universal e persistente através de todos tipos de análise de bioinformática. Ferramentas de pipeline geram arquivos intermediários imprevisivelmente grandes, causando falhas de job quando quotas são alcançadas. Isto tem implicações de reproducibilidade diretas: se um job falha mid-way e é reiniciado com parâmetros diferentes ou em subset diferente de dados, resultado final pode diferir do que teria sido produzido por execução ininterrupta.

Ghedira et al. (2024) ainda notaram que em ambientes com recursos limitados, falta de armazenamento adequado pode forçar pesquisadores deletar arquivos intermediários prematuramente, perdendo cadeia de proveniência necessária para reproducibilidade.

### 9.5.3 Paradoxo de Reproducibilidade em Nuvem

Computação em nuvem (AWS, GCP, Azure) oferece elasticidade e evita manutenção de hardware, mas introduz seus próprios desafios de reproducibilidade:

- Tipos de instância mudam ao longo tempo; configuração de VM disponível hoje pode não existir em dois anos.
- Instâncias spot/preemptíveis podem ser terminadas mid-computação.
- Custos de saída de dados podem desaconselhar compartilhamento de datasets grandes.

- Ambientes de software em VMs de nuvem são efêmeros a menos que containerizados.

Langmead e Nellore (2018) revisaram computação em nuvem para genômica e argumentaram que abordagem híbrida — possuindo infraestrutura base e burst para nuvem durante picos — fornece melhor balanço de custo, controle, e reproducibilidade. No entanto, isto requer uso disciplinado de containers e gerenciadores de workflow para garantir que resultados sejam consistentes através ambientes locais e de nuvem.

## 9.6 Checklist Prático: Fazendo Projeto Filogenômico FAIR

A checklist seguinte traduz princípios FAIR em ações concretas para estudo filogenômico típico:

### 9.6.1 Antes de Análise

Registre seu projeto em um repositório (*e.g.*, OSF, Zenodo) e obtenha DOI.

Deposite leituras sequenciadas brutas em NCBI SRA ou ENA antes de começar análise.

Defina seu ambiente computacional em um container (Singularity/Docker) ou arquivo Conda `environment.yml`.

Escreva seu pipeline em gerenciador de workflow (Snakemake ou Nextflow) ao invés de série de scripts shell ad hoc.

### 9.6.2 Durante Análise

Registre todas versões de software, parâmetros, e seeds aleatórias em arquivos de configuração com versão controlada com Git.

Use banco de dados de accounting SLURM (`sacct`) para logar uso de recurso computacional.

Armazene arquivos intermediários em hierarquia de diretório estruturada com convenções de nomeação descritivas.

Use checksums (MD5 ou SHA256) em arquivos de entrada e saída chave para verificar integridade de dados.

### 9.6.3 Após Análise

Deposite alinhamentos, árvores, resultados de seleção de modelo, e esquemas de partição em repositório público (Dryad, Zenodo, TreeBASE).

Inclua arquivo `README.md` ou de metadados descrevendo proveniência de cada arquivo depositado.

Libere seu pipeline de análise (Snakemake/Nextflow + definição de container) sob licença open-source no GitHub/GitLab.

Archive repositório em Zenodo para obter DOI para software.

Aplique licença de dados clara (CC-BY ou CC0) a todos dados depositados.

## 9.7 Conceitos Chave para Estudo Adicional

### 9.7.1 Ontologias e Vocabulários Controlados em Ômicas

Interoperabilidade FAIR (I1, I2) requer vocabulários compartilhados. Recursos chave incluem:

- **Gene Ontology (GO):** Termos padronizados para função de gene através espécies.
- **Sequence Ontology (SO):** Termos para características de sequência e anotações.
- **Environment Ontology (ENVO):** Termos para contextos ambientais (relevante para metagenômica/metabarcoding).
- **EDAM Ontology:** Ontologia compreensiva de operações de bioinformática, tipos de dados, formatos, e tópicos — diretamente relevante para descrever workflows computacionais.

### 9.7.2 Planos de Gestão de Dados (DMPs)

Agências de financiamento (NIH, NSF, ERC, UKRI) cada vez mais requerem DMPs que especifiquem como dados serão manipulados, compartilhados, e preservados. Política de Gestão e Compartilhamento de Dados de 2023 de NIH explicitamente referencia princípios FAIR. Um DMP deveria endereçar: que dados serão gerados, que padrões de metadados serão usados, onde dados serão depositados, quem terá acesso, e por quanto tempo dados serão preservados.

### 9.7.3 Distinção Entre Aberto e FAIR

FAIR não requer dados serem abertos ou grátis. Princípio A1.2 explicitamente permite para autenticação e autorização. Dados sensíveis (*e.g.*, dados genômicos humanos sob restrições de IRB/ética) podem ser FAIR — encontráveis e descritos com metadados ricos — enquanto permanecem access-controlados. Metadados devem ser sempre abertos (A2), mesmo se dados mesmos são restritos.

### 9.7.4 Padrões de Proveniência Computacional

- **W3C PROV:** Modelo de proveniência de propósito geral.
- **RO-Crate:** Abordagem leve para empacotar dados de pesquisa com metadados, usada por Niehues et al. (2024) para workflows multi-ômicas.
- **CWLProv / WES:** Padrões para registrar proveniência de execuções de workflow no ecossistema Common Workflow Language.

## 9.8 Conexões para Design de Sistema HPC

Os princípios FAIR e considerações de design de sistema HPC de nosso capítulo complementar (*Projeto de Sistemas Computacionais de Alto Desempenho para Filogenômica*) intersectam em vários pontos:

- **Storage tiering** (§4 do complementar) suporta diretamente gestão de ciclo de vida de dados FAIR: scratch para análise ativa, warm storage para resultados intermediários com metadados, cold storage/repositórios para depósitos FAIR-conformes e arquivados.

- **Accounting SLURM** (§8 do complementar) gera proveniência computacional automaticamente — IDs de job, uso de recurso, wall-times, e códigos de saída são logados e podem ser anexados como metadados para resultados de análise.
- **Containerização** (§9 do complementar) é simultaneamente estratégia de gestão de software de HPC e mecanismo de reprodutibilidade FAIR.
- **Treinamento** (§10 do complementar) é essencial tanto para uso de HPC quanto para adoção de FAIR; pesquisadores que não compreendem SLURM não escreverão scripts de job reproduzíveis, e pesquisadores que não compreendem FAIR não depositarão metadados.
- **Gerenciadores de workflow** (§9 do complementar) impõem utilização de recurso eficiente em HPC (permitindo SLURM agendar tarefas otimamente) e conformidade FAIR (gerando registros de proveniência legível por máquina).

## 9.9 Conclusão

Reprodutibilidade em pesquisa ômicas não é exercício puramente teórico. Tem implicações práticas diretas para confiança científica, capacidade de outros pesquisadores construírem sobre seu trabalho, e validade de descobertas a longo prazo. Os princípios FAIR fornecem framework para transformar negligência histórica em gestão de dados em prática sistemática. Implementação requer investimento em infraestrutura (repositórios, indexação, sistemas de arquivo com gerenciamento de ciclo de vida), documentação (metadados ricos, padrões comunitários), e comportamento de pesquisador (uso de workflow managers, versionamento de código, depósito de dados).

Para filogenômica especificamente, adoção de práticas FAIR — desde deposição de leituras brutas através depósito de alinhamentos e árvores finais — transforma estudo individual em contribuição reutilizável para ciência filogenética coletiva. Cada análise cuidadosamente documentada e deposited torna-se ponto de partida para futuro pesquisa, comparação, ou validação. Este é o futuro de filogenômica — não estudos in-vacuo, mas síntese de conhecimento acumulado, viabilizado por gestão rigorosa de dados.

**Roteiro de Revisão do Capítulo**

1. Problema de reprodutibilidade: opacidade de software, sensibilidade de parâmetro/configuração (Powers et al., 2022), negligência em gestão de dados, perda de histórico quando estudantes se graduam.
2. FAIR (Wilkinson et al., 2016): Encontrável, Acessível, Interoperável, Reutilizável; ênfase em **acionabilidade por máquina**; aplica-se a dados, metadados *e* infraestrutura.
3. 15 sub-princípios: F1 (IDs persistentes: DOIs), F2 (metadados ricos), F3 (ID nos metadados), F4 (indexado/pesquisável); A1 (protocolo padronizado), A1.1 (aberto), A1.2 (autenticação), A2 (metadados persistem sem dados); I1 (linguagem formal: RDF/OWL), I2 (vocabulários FAIR), I3 (referências qualificadas); R1 (atributos ricos), R1.1 (licença clara: CC-BY/CC0), R1.2 (proveniência), R1.3 (padrões comunitários: MIGS/MIMS).
4. FAIR $\neq$ aberto: A1.2 permite acesso controlado; metadados sempre abertos (A2).
5. FAIR4RS (Barker et al., 2022): adaptação para software de pesquisa; DOIs via Zenodo/Software Heritage; metadados de dependências e ambiente.
6. Repositórios: NCBI SRA/ENA/DDBJ (leituras brutas), TreeBASE/Dryad/Zenodo (árvores/alinhamentos), GenBank/UniProt/Ensembl (sequências montadas).
7. Gerenciadores de workflow: Snakemake (Python, Conda/Singularity, DAGs) e Nextflow (Groovy, nf-core); geram proveniência automaticamente (R1.2, R1.3).
8. Containers: Apptainer (sem root, integra SLURM) para HPC; Docker para nuvem; hash SHA256 = ID persistente do ambiente.
9. Limitações técnicas de reprodutibilidade: aritmética de ponto flutuante (AVX2 vs. AVX-512), não-determinismo de ordem de thread, sensibilidade de seed aleatória.
10. Paradoxo de nuvem: elasticidade mas tipos de instância mudam, spot pode ser terminado, custos de saída, ambientes efêmeros; solução = abordagem híbrida (Langmead e Nellore 2018).
11. Ontologias chave: GO (função gênica), SO (características de sequência), ENVO (ambientes), EDAM (operações bioinformáticas). Proveniência: W3C PROV, RO-Crate, CWLProv.

# Referências

Barker, M., N. P. Chue Hong, D. S. Katz et al. (2022). “Introducing the FAIR principles for research software”. Em: *Scientific Data* 9, p. 622.

Di Tommaso, P., M. Chatzou, E. W. Floden et al. (2017). “Nextflow enables reproducible computational workflows”. Em: *Nature Biotechnology* 35, pp. 316–319.

Ewels, P. A., A. Peltzer, S. Fillinger et al. (2020). “The nf-core framework for community-curated bioinformatics pipelines”. Em: *Nature Biotechnology* 38, pp. 276–278.

Ghedira, K., O. Khamessi, C. Hkimi et al. (2024). “Design and implementation of a scalable high-performance computing (HPC) cluster for omics data analysis: Achievements, challenges and recommendations in LMICs”. Em: *GigaScience* 13, giae060.

Kim, Y.-M., J.-B. Poline e G. Dumas (2018). “Experimenting with reproducibility: A case study of robustness in bioinformatics”. Em: *GigaScience* 7, giy077.

Langmead, B. e A. Nellore (2018). “Cloud computing for genomic data analysis and collaboration”. Em: *Nature Reviews Genetics* 19, pp. 208–219.

Martín del Pico, E., J. L. Gelpí e S. Capella-Gutierrez (2024). “FAIRsoft — a practical implementation of FAIR principles for research software”. Em: *Bioinformatics* 40, btae464.

Mölder, F., K. P. Jablonski, B. Letcher et al. (2021). “Sustainable data analysis with Snakemake”. Em: *F1000Research* 10, p. 33.

Niehues, A., C. de Visser, F. A. Hagenbeek et al. (2024). “A multi-omics data analysis workflow packaged as a FAIR Digital Object”. Em: *GigaScience* 13, giad115.

Powers, M. E., K. Mannthey, P. Sebastian et al. (2022). “Deploying genomics workflows on high performance computing (HPC) platforms: Storage, memory, and compute considerations”. Em: *bioRxiv*, p. 2022.04.05.485833.

Wilkinson, M. D., M. Dumontier, I. J. Aalbersberg et al. (2016). “The FAIR Guiding Principles for scientific data management and stewardship”. Em: *Scientific Data* 3, p. 160018.

Zafeiropoulos, H., A. Gioti, S. Ninidakis et al. (2021). “0s and 1s in marine molecular research: A regional HPC perspective”. Em: *GigaScience* 10, giab053.

# Capítulo 10

# Inteligência Artificial na Ciência Biomédica Contemporânea

## 10.1 Introdução

A inteligência artificial (IA) se transformou rapidamente em um arcabouço metodológico central dentro da ciência biomédica moderna. Na última década, as aplicações de IA na biomedicina expandiram-se para abranger modelagem de diferenciação de células-tronco, identificação de alvos para terapia gênica, síntese de imagens microbianas, design de epítopos vacinais, predição de estrutura proteica e sistemas de suporte a decisão clínica, entre muitos outros (Jumper et al. 2021; Topol 2019). Essa expansão foi impulsionada por três desenvolvimentos convergentes: o crescimento exponencial de conjuntos de dados biomédicos multimodais, o amadurecimento de arquiteturas de aprendizado profundo e a disponibilidade generalizada de recursos computacionais de alto desempenho.

Trabalhos recentes em terapia celular demonstram como a IA pode modelar redes regulatórias de genes dinâmicas para guiar a diferenciação de células-tronco, integrando biologia sintética com modelagem preditiva (Choudhury et al. 2025). Similarmente, abordagens de biologia computacional e aprendizado de máquina aprimoraram fluxos de trabalho em terapia gênica, incluindo identificação de alvos, design de vetores e predição de resultados (Danaeifar e Najafi 2025). Em biologia estrutural, o desenvolvimento de AlphaFold2 (Jumper et al. 2021) marcou um momento crucial, demonstrando que aprendizado profundo poderia resolver um dos problemas mais antigos do campo — o problema do enovelamento proteico — com acurácia próxima à experimental. Mais recentemente, abordagens generativas foram aplicadas ao design de proteínas e construtos de ácidos nucleicos novos com propriedades funcionais definidas (Ferruz et al. 2022).

Apesar desses avanços, a rápida expansão de metodologias de IA levantou questões teóricas e práticas importantes que a comunidade científica ainda não resolveu completamente. Central entre essas estão as seguintes: Os sistemas de IA atuais são genuinamente explicativos, ou são sofisticados reconhecedores de padrões sem insights mecanísticos? Podem modelos de aprendizado profundo ser confiáveis em contextos clínicos de alto risco onde erros carregam consequências que alteram vidas? Como a incerteza deve ser quantificada, propagada e comunicada aos usuários finais? E em que medida os vieses codificados em dados de treinamento comprometem a generalizabilidade e a imparcialidade de recomendações guiadas por IA?

Essas questões coletivamente definem o debate metodológico contemporâneo em IA biomédica.

O presente capítulo examina esse debate através dos principais paradigmas — aprendizado supervisionado e não supervisionado, aprendizado profundo e aprendizado de representação, modelos generativos e dados sintéticos, inferência Bayesiana e probabilística, modelos de linguagem em larga escala e sistemas híbridos e AutoML — com atenção particular tanto ao potencial científico demonstrado quanto aos desafios não resolvidos. Nosso tratamento enfatiza responsabilidade epistêmica: a responsabilidade dos pesquisadores não apenas em compreender o que seus modelos predizem, mas por quê, sob quais condições e com que grau de confiança.

## 10.2 Aprendizado de Máquina Supervisionado e Não Supervisionado na Biomedicina

### 10.2.1 Aprendizado Supervisionado: Aplicações e Escopo

Métodos de aprendizado supervisionado — incluindo máquinas de vetores de suporte (SVMs), florestas aleatórias, árvores potencializadas por gradiente e redes neurais feedforward — tornaram-se centrais para análises em genômica, transcriptômica, proteômica e informática clínica (Libbrecht e Noble 2015). Em genômica, classificadores supervisionados treinados em dados de sequência rotulados foram aplicados à identificação de polimorfismos de nucleotídeo único (SNPs) patogênicos, predição de sítios de emenda e classificação de elementos regulatórios. Em transcriptômica, modelos de aprendizado de máquina treinados em dados de RNA-seq permitem análise de expressão diferencial, deconvolução de tipos celulares e predição de fenótipo em nível de transcriptoma.

Em pesquisa de terapia gênica, aprendizado supervisionado foi aplicado a todas as fases do pipeline terapêutico. No estágio de identificação de alvo, modelos treinados em bancos de dados de associação doença-gene curados — como DisGeNET ou o catálogo OMIM — predizem novos alvos terapêuticos a partir de perfis multi-ômicos (Danaeifar e Najafi 2025). No estágio de design de vetor, classificadores predizem a eficiência e especificidade de sorotipos de vírus adenoassociado (AAV) para tropismo particular de tecido baseado em características de sequência de cápside. No estágio de predição de resultado, modelos treinados em dados clínicos e genômicos de pacientes estimam resposta terapêutica, risco de evento adverso e durabilidade de longa prazo da correção gênica.

Proteômica beneficiou-se similarmente de abordagens de aprendizado supervisionado. Dados de espectrometria de massa processados através de pipelines de aprendizado de máquina agora permitem identificação proteica de alto rendimento, quantificação e mapeamento de modificação pós-traducional, permitindo criação de perfil em larga escala de proteomas associados a doença (Orre et al. 2019). Em imagem clínica, redes neurais convolucionais (CNNs) supervisionadas alcançaram desempenho comparável ao de radiologista em tarefas como detecção, classificação e segmentação de tumor através de múltiplos tipos de câncer (Litjens et al. 2017).

### 10.2.2 Aprendizado Não Supervisionado e Descoberta de Estrutura Latente

Técnicas de aprendizado não supervisionado — incluindo algoritmos de agrupamento, métodos de redução de dimensionalidade e modelagem hierárquica — permitem descoberta de estrutura biológica latente em conjuntos de dados ômicos de alta dimensionalidade sem a necessidade de dados de treinamento pré-rotulados. Análise de componentes principais (PCA), incorporação estocástica de vizinhos distribuída por t (t-SNE) e Projeção de Aproximação e Manifold Uniforme (UMAP) tornaram-se ferramentas padrão para visualização de dados de RNA-seq de célula única (scRNA-seq),

permitindo aos pesquisadores identificar populações celulares transcricionalmente distintas com resolução sem precedentes (Becht et al. 2018; McInnes et al. 2018).

Análise de rede de co-expressão gênica ponderada (WGCNA) exemplifica uma abordagem não supervisionada biologicamente motivada que reconstrói redes de genes co-regulados a partir de dados de expressão, associando módulos de rede a fenótipos clínicos ou condições experimentais (Langfelder e Horvath 2008). Essas associações módulo-traço foram usadas para nomear hubs regulatórios de genes como alvos terapêuticos em uma gama de doenças, incluindo distúrbios neurodegenerativos, câncer e doença metabólica.

No contexto de terapia celular, métodos não supervisionados foram aplicados para caracterizar a heterogeneidade de populações de células-tronco, identificar subpopulações raras com potenciais de diferenciação distintos e mapear trajetórias de transições de estado celular durante reprogramação (Saelens et al. 2019). A integração de dados de célula única multimodal — combinando transcriptômica, acessibilidade de cromatina (scATAC-seq) e proteômica — coloca desafios contínuos para análise não supervisionada, motivando o desenvolvimento de novos métodos de redução de dimensionalidade e integração de dados como MOFA+ e Seurat v4 (Argelaguet et al. 2020; Y. Hao et al. 2021).

### 10.2.3 Debates: Generalizabilidade, Viés e Incerteza

O debate circundante a abordagens supervisionadas e não supervisionadas centra-se em três preocupações inter-relacionadas: generalizabilidade através de populações e contextos, codificação de viés sistemático e quantificação inadequada de incerteza preditiva. Muitos modelos de aprendizado de máquina biomédico são treinados em conjuntos de dados derivados de amostras de população não-representativas — frequentemente predominantemente de ascendência europeia — o que substancialmente limita sua validade externa e utilidade clínica em grupos sub-representados (Obermeyer et al. 2019; Popejoy e Fullerton 2016). Essa preocupação é particularmente aguda para escores de risco poligênico, que têm sido demonstrados como exibindo disparidades de desempenho substanciais através de grupos ancestrais quando derivados de coortes de estudo de associação genômica ampla (GWAS) eurocentristas (Martin et al. 2019).

Métricas de desempenho em estudos publicados de aprendizado de máquina biomédico frequentemente enfatizam acurácia agregada, área sob a curva característica operacional do receptor (AUROC) ou estatísticas de resumo relacionadas, sem atenção suficiente à calibração — o grau ao qual probabilidades preditas correspondem a frequências de evento empíricas. Estimativas de incerteza bem-calibradas são essenciais para implantação clínica, onde um modelo expressando confiança de 90

## 10.3 Aprendizado Profundo e Aprendizado de Representação

### 10.3.1 Arquiteturas e Aplicações Biomédicas

Aprendizado profundo habilitou extração automatizada e hierárquica de características a partir de dados biológicos complexos e de alta dimensionalidade, alterando fundamentalmente fluxos de trabalho de pesquisa em imagem, genômica e biologia estrutural. Redes neurais convolucionais (CNNs) foram aplicadas à análise histopatológica automatizada de imagem, demonstrando que arquiteturas profundas podem identificar características morfológicas preditivas de subtipo de câncer,

prognóstico e resposta ao tratamento em escala que seria impraticável para anotadores humanos (Esteva et al. 2017; Kather et al. 2019). Em hematologia, CNNs treinadas em imagens de microscopia de células sanguíneas permitem classificação automatizada de tipos de células hematopoéticas e identificação de populações anormais relevantes ao diagnóstico de leucemia (Matek et al. 2019).

No domínio de terapia celular, aprendizado profundo suporta controle de qualidade de culturas de células-tronco pela detecção de desvios morfológicos de trajetórias de diferenciação esperadas em dados de imagem de lapso de tempo. Preparações de células-tronco mesenquimais (MSC), críticas para uma gama de aplicações de medicina regenerativa, foram caracterizadas usando CNNs profundas treinadas para predizer potência imunomodulatória a partir de imagens de microscopia de contraste de fase, reduzindo a dependência de ensaios funcionais custosos e demorados (Kusumoto et al. 2021).

Arquiteturas recorrentes, incluindo redes de memória de longo-curto prazo (LSTM) e modelos baseados em transformer, foram aplicadas à modelagem de sequência genômica, predição de expressão gênica a partir de estado de cromatina e análise de série temporal clínica. A arquitetura de transformer, originalmente desenvolvida para processamento de linguagem natural, foi adaptada para genômica em modelos como Enformer (Avsec et al. 2021), que prediz expressão gênica e acessibilidade de cromatina a partir de sequência de DNA com modelagem de interação de longo alcance substancialmente melhorada comparada a arquiteturas convolucionais anteriores.

Uma aplicação notável de aprendizado de representação em microbiologia envolve a geração de conjuntos de dados de colônia microbiana sintética usando transferência de estilo de aprendizado profundo (Pawłowski et al. 2022). Ao transferir características de estilo visual de imagens de colônia reais para fundos sinteticamente gerados, os autores foram capazes de expandir substancialmente corpora de treinamento para modelos de detecção de colônia automatizada sem exigir anotação manual adicional, mantendo desempenho de detecção competitivo. Este trabalho ilustra como técnicas de aprendizado de representação podem diretamente endereçar o gargalo disseminado de dados rotulados limitados em análise de imagem biomédica.

### 10.3.2 Interpretabilidade e o Problema da Caixa Preta

Apesar desses realizos empíricos impressionantes, redes neurais profundas permanecem amplamente opacas à interpretação mecanística. As representações aprendidas codificadas em camadas ocultas de uma rede profunda não são, em geral, diretamente mapeáveis para construtos cientificamente significativos, dificultando a compreensão do porquê uma predição dada foi feita ou a identificação das características biológicas conduzindo comportamento de modelo. Esse déficit de interpretabilidade é uma preocupação central em translação clínica, onde agências regulatórias, clínicos e pacientes podem razoavelmente exigir explicações para recomendações algorítmicas (Rudin 2019).

Uma gama de métodos de interpretabilidade pós-hoc foram desenvolvidos para parcialmente endereçar essa limitação, incluindo mapas de saliência baseados em gradiente, propagação de relevância em camada (LRP), gradientes integrados e valores SHAP (SHapley Additive exPlanations) (Lundberg e S. I. Lee 2017; Sundararajan et al. 2017). Esses métodos fornecem atribuições aproximadas de predições de modelo para características de entrada, mas não estão sem limitações. Métodos baseados em saliência foram mostrados como sensíveis à arquitetura e inicialização de modelo, produzindo atribuições inconsistentes através de modelos ostensivamente equivalentes (Adebayo et al. 2018). Além disso, atribuição de característica ao nível de entrada não necessariamente ilumina os mecanismos computacionais internos pelos quais predições são geradas.

Há reconhecimento crescente dentro do campo de que modelos intrinsecamente interpretáveis — que são projetados para serem transparentes por construção, ao invés de explicados post hoc — podem ser preferíveis a alternativas de caixa preta em domínios de alto risco, mesmo em algum custo a desempenho preditivo (Rudin 2019). O debate continua a respeito do grau ao qual interpretabilidade e acurácia preditiva estão fundamentalmente em tensão, e se avanços em design de arquitetura podem produzir modelos que sejam tanto poderosos quanto mecanisticamente transparentes.

## 10.4 Modelos Generativos e Dados Sintéticos

### 10.4.1 Redes Adversariais Generativas e Autoencodificadores Variacionais

Modelos generativos introduziram um novo paradigma em IA biomédica, habilitando a síntese de amostras de dados realistas, design de entidades moleculares novos e ampliação de conjuntos de dados de treinamento. Redes adversariais generativas (GANs), introduzidas por Goodfellow et al. (2014), foram aplicadas à síntese de imagens histopatológicas, ampliação de conjuntos de dados de MRI, geração de dados de registros eletrônicos de saúde (EHR) realistas e design de novo de estruturas moleculares com propriedades físico-químicas desejadas (Baowaly et al. 2019; Kadurin et al. 2017).

Autoencodificadores variacionais (VAEs) fornecem um arcabouço generativo alternativo que impõe um prior probabilístico estruturado no espaço latente, habilitando geração controlável e interpolação interpretável entre pontos de dados. VAEs foram aplicados em descoberta de fármacos para navegar espaço químico em direção a regiões preditas como exibindo propriedades desejadas de potência, seletividade e farmacocinética (Gomez-Bombarelli et al. 2018). Arquiteturas híbridas combinando o poder representacional de GANs com a estrutura latente de VAEs expandiram ainda mais o kit de ferramentas generativas disponível para pesquisadores biomédicos.

### 10.4.2 Design de Proteína e Ácido Nucleico

Talvez a aplicação mais cientificamente significativa de modelos generativos em biomedicina seja no design de proteína estrutural e funcional. Construindo sobre os fundamentos representacionais estabelecidos por AlphaFold2 (Jumper et al. 2021), modelos de linguagem proteica generativos como ProtGPT2 (Ferruz et al. 2022) e ESMFold (Lin et al. 2023) habilitaram o design de sequências de proteína novos com propriedades estruturais preditas. Essas ferramentas reduzem o espaço de busca combinatória da engenharia de proteína de um espaço de sequência astronomicamente grande para um problema de design tratável, com implicações para engenharia de enzima, design de anticorpo terapêutico e biologia sintética.

Em desenvolvimento vacinal, modelagem generativa e preditiva são crescentemente integradas através do pipeline de design vacinal. Ferramentas de predição de epítopo guiadas por IA identificam peptídeos candidatos imunogênicos a partir de proteomas de patógeno, enquanto algoritmos de otimização de estrutura de mRNA desenham sequências que maximizam eficiência translacional e estabilidade para plataformas vacinais de mRNA (Imani et al. 2025). Abordagens baseadas em modelo de difusão — análogas àquelas usadas em geração de imagem — foram aplicadas ao design de ligadores de proteína com interfaces de alvo especificado, representando uma aplicação de fronteira de IA generativa em engenharia de proteína terapêutica (Watson et al. 2023).

### 10.4.3 Dados Sintéticos: Promessas e Riscos

A geração de dados sintéticos endereça um gargalo crítico em IA biomédica: a escassez de conjuntos de dados grandes, anotados e em conformidade com privacidade. Regulações de privacidade — incluindo a Lei de Portabilidade e Responsabilidade de Seguros de Saúde (HIPAA) nos Estados Unidos e o Regulamento Geral de Proteção de Dados (GDPR) na União Europeia — impõem restrições substanciais no compartilhamento e uso secundário de dados de paciente, limitando a escala e diversidade de corpora de treinamento disponíveis para pesquisadores. Dados sintéticos gerados por modelos GAN ou de difusão podem, em princípio, ser compartilhados sem risco de privacidade direto enquanto preservam as propriedades estatísticas da população clínica subjacente.

Não obstante, conjuntos de dados sintéticos não são uma panaceia. Modelos generativos treinados em dados de fonte não-representativos fielmente reproduzirão, e podem até amplificar, os vieses presentes nesses dados. Avaliação da qualidade de dados sintéticos requer comparação cuidadosa a distribuições de dados reais em dimensões clinicamente significativas, e há evidência de que realismo ingenuamente avaliado pode mascarar distorções sistemáticas em taxas de eventos raros, características de subgrupo minoritário e distribuições de resultado (Walonoski et al. 2018). Além disso, o uso de dados sintéticos para submissão regulatória ou validação clínica permanece uma área em evolução, com orientação de agências como a FDA ainda sendo formalizada (U.S. Food and Drug Administration 2023).

## 10.5 Redes Bayesianas e Inferência Probabilística Guiada por IA

### 10.5.1 Modelagem Principiada de Incerteza

Abordagens Bayesianas oferecem um arcabouço matematicamente principiado para modelagem de incerteza em IA biomédica, integrando conhecimento de domínio anterior com dados observados através do teorema de Bayes para produzir distribuições de probabilidade posterior sobre parâmetros e predições. Diferente de modelos discriminativos de estimativa pontual, inferência Bayesiana explicitamente representa e propaga incerteza, tornando-a bem-adequada a aplicações biomédicas de alto risco onde o custo de predições superconfiantes é substancial (Ghahramani 2015).

Em terapia gênica, redes Bayesianas foram aplicadas ao modelo das dependências probabilísticas entre variáveis genômicas, transcriptômicas e clínicas, habilitando priorização de alvo principiada sob incerteza (Danaeifar e Najafi 2025). Em epidemiologia e farmacovigilância, modelos hierárquicos Bayesianos são usados para estimar taxas de evento adverso de sistemas de notificação espontânea, compartilhando força estatística através de combinações relacionadas de fármaco-evento enquanto apropriadamente representam a incerteza associada com resultados raros. Em desenvolvimento vacinal, desenhos de ensaio adaptativo Bayesiano usam dados interinos para atualizar crenças anteriores sobre eficácia e segurança vacinal, habilitando uso mais eficiente de recursos de ensaio clínico (Berry et al. 2010).

### 10.5.2 Aprendizado de Estrutura e Inferência Causal

Além de sua utilidade para quantificação de incerteza, redes Bayesianas oferecem um arcabouço para representação e aprendizado de dependências causais entre variáveis — uma propriedade que se alinha mais proximamente com os objetivos explicativos de investigação científica do que modelos puramente associativos. Modelos causais baseados em grafo acíclico direcionado (DAG) codificam

relacionamentos causais hipotetizados entre variáveis biológicas e podem, sob assunções apropriadas sobre mecanismos geradores de dados, ser usados para predizer as consequências de intervenções experimentais (Pearl 2009).

Algoritmos de descoberta causal — como o algoritmo PC, FCI e variantes mais recentes aumentadas com aprendizado profundo — tentam inferir estrutura de grafo causal a partir de dados observacionais, um problema notoriamente desafiador exigindo assunções fortes (Spirtes et al. 2000). Em genômica de célula única, descoberta causal foi aplicada à inferência de redes regulatórias de genes a partir de dados de scRNA-seq, com o objetivo de identificar relacionamentos alvo-fator de transcrição que podem ser validados experimentalmente e explorados terapeuticamente (Skok Gibbs et al. 2022).

### 10.5.3 Modelos Híbridos Probabilísticos-Aprendizado Profundo

O debate contemporâneo nesta área centra-se em se modelos híbridos que combinam representações de aprendizado profundo com inferência de modelo gráfico probabilístico podem alcançar interpretabilidade superior e quantificação de incerteza sem sacrificar o poder representacional que tornou aprendizado profundo tão empiricamente bem-sucedido. Abordagens como aprendizado de kernel profundo, modelos de processo neural e redes neurais Bayesianas representam tentativas de integrar esses paradigmas (Wilson e Izmailov 2020). Regressão de processo Gaussiano, uma abordagem Bayesiana não-paramétrica, foi aplicada para modelar dinâmica de expressão gênica como função de pseudotempo em análise de trajetória de célula única, fornecendo limites de incerteza principiados em trajetórias de diferenciação inferidas (Lönnberg et al. 2017). O desafio prático de escalar inferência Bayesiana para os regimes de parâmetro de arquiteturas de aprendizado profundo moderno — frequentemente envolvendo bilhões de parâmetros — permanece uma área ativa de pesquisa.

## 10.6 Modelos de Linguagem em Larga Escala em Fluxos de Trabalho Científicos

### 10.6.1 Aplicações em Pesquisa Biomédica

Modelos de linguagem grande (LLMs) — incluindo GPT-4 (OpenAI 2023), Gemini (Google DeepMind 2023) e modelos adaptados para domínio como BioMedLM, BioGPT (Luo et al. 2022) e Med-PaLM 2 (Singhal et al. 2023) — estão crescentemente integrados em fluxos de trabalho científicos. Esses modelos, treinados em corpora vastos de literatura biomédica, notas clínicas e sequências genômicas, exibem capacidades emergentes incluindo síntese de literatura, geração de hipótese, resposta a perguntas clínicas e automação de pipelines de bioinformática. Em reconhecimento de entidade nomeada biomédica (NER), extração de relação e processamento de nota clínica, LLMs alcançaram desempenho de última linha em benchmarks estabelecidos, frequentemente sem ajuste fino específico à tarefa (J. Wei et al. 2022).

Modelos de linguagem de proteína (PLMs) representam uma família relacionada de modelos treinados não em linguagem natural mas em bancos de dados grandes de sequências de aminoácido. Modelos como ESM-2 (Lin et al. 2023) e ProtTrans (Elnaggar et al. 2022) aprendem representações contextuais de posições de aminoácido que codificam informação evolutiva, estrutural e funcional, e foram usados para predizer efeitos mutacionais na estabilidade e função proteica, classificar famílias

proteicas e guiar a geração de sequências novelas. O sucesso de PLMs ilustra como a arquitetura de transformer originalmente desenvolvida para linguagem pode ser produtivamente adaptada para dados de sequência biológica.

### 10.6.2 Limitações Epistêmicas e Riscos

Apesar de suas capacidades, LLMs exibem limitações significativas que são particularmente consequentes em contextos biomédicos. Alucinação — a geração de informação plausível mas factualmente incorreta ou fabricada — é um modo de falha bem-documentado de modelos de linguagem autorregressivos atuais (Ji et al. 2023). No contexto de síntese de literatura científica, LLMs foram observados como gerando citações plausível-aparentando mas inexistentes, atribuindo reivindicações fabricadas a autores e periódicos legítima-aparentando. Isso coloca um risco não-trivial à integridade de pesquisa quando saídas de LLM são incorporadas em manuscritos ou revisões sistemáticas sem verificação independente.

LLMs também carecem de fundamentação epistêmica explícita: eles não mantêm representações formais de conhecimento ou mecanismos de inferência que distinguem fatos conhecidos de interpolações plausíveis de dados de treinamento. Eles não podem reliably distinguir entre consenso científico bem-estabelecido e achados contestados ou preliminares, e podem reproduzir informação desatualizada ou conceitos equivocados amplamente discutidos do corpus de treinamento. Implantação clínica de LLMs em papéis de suporte a decisão portanto requer salvaguardas robustas, incluindo arquiteturas de geração aumentada por recuperação (RAG) que fundamentam saídas de modelo em bases de conhecimento verificadas e atualizadas, calibração de saída consciente de incerteza e revisão obrigatória de humano-no-circuito (Lewis et al. 2020).

Arcabouços regulatórios e éticos para implantação de LLM em configurações clínicas ainda são nascentes. A FDA emitiu orientação de projeto em dispositivos habilitados por IA mas não endereçou ainda riscos específicos de LLM compreensivamente (U.S. Food and Drug Administration 2023). Questões de responsabilidade quando um LLM contribui a um erro clínico, consentimento informado para tomada de decisão assistida por IA e acesso equitativo a ferramentas potencializadas por LLM através de configurações de assistência médica permanecem largamente não resolvidas.

## 10.7 Sistemas Híbridos e AutoML

### 10.7.1 IA Híbrida: Combinando Paradigmas

Sistemas de IA híbrida integram paradigmas complementares — raciocínio simbólico, modelos gráficos probabilísticos e aprendizado profundo — com o objetivo de reter os pontos fortes de cada um enquanto mitigam suas fraquezas individuais. Abordagens de IA neurosimbólica, por exemplo, buscam combinar as capacidades de reconhecimento de padrão de redes profundas com o raciocínio composicional baseado em regra de IA simbólica, habilitando assim modelos que podem aprender de dados enquanto também respeitam restrições lógicas e fornecem traços de raciocínio interpretáveis (Garcez e Lamb 2023; Marcus e Davis 2019).

Em aplicações biomédicas, sistemas híbridos foram desenvolvidos para suporte a decisão clínica, integrando modelos de aprendizado profundo para análise de imagem médica com raciocínio baseado em grafo de conhecimento sobre ontologias clínicas como SNOMED CT e a Ontologia Gênica. Essas arquiteturas podem fundamentar predições em conhecimento biológico estruturado, reduzindo o

risco de predições que são estatisticamente plausíveis mas biologicamente incoerentes. Abordagens híbridas também são proeminentes em descoberta de fármaco, onde redes neurais de grafo (GNNs) operando em grafos moleculares são combinadas com campos de força baseados em física e cálculos químicos quânticos para predizer afinidades de ligação e propriedades ADMET com confiabilidade melhorada (Wieder et al. 2020).

### 10.7.2 AutoML: Democratização e Seus Inconvenientes

Plataformas de aprendizado de máquina automatizado (AutoML) — incluindo AutoKeras, TPOT, H2O AutoML e oferecimentos hospedados em nuvem de fornecedores de tecnologia maiores — abaixam as barreiras ao desenvolvimento de modelo automatizando os processos de engenharia de característica, seleção de algoritmo, otimização de hiperparâmetro e busca de arquitetura. Em contextos de pesquisa biomédica onde a expertise profunda em aprendizado de máquina pode não estar disponível, AutoML habilita pesquisadores a implantar modelos preditivos competitivos sem ajuste manual, potencialmente acelerando descoberta e ampliando acesso a análise assistida por IA (He et al. 2021).

Contudo, a democratização fornecida por AutoML levanta preocupações sérias a respeito de transparência metodológica e reprodutibilidade científica. Pesquisadores que implantam pipelines de AutoML sem compreender completamente as escolhas algorítmicas subjacentes — a seleção de um aprendiz particular, a aplicação de transformações específicas de pré-processamento ou a configuração de procedimentos de validação cruzada — podem inadvertidamente violar assunções chave de modelagem ou introduzir formas sutis de vazamento de dados. Estudos publicados baseados em análises de AutoML podem ser difíceis de reproduzir se o sistema de AutoML introduz não-determinismo ou se a configuração de pipeline específica não for completamente relatada. Há risco de que AutoML adicione velocidade ainda maior à tendência existente de relatar métricas de desempenho preditivo sem interpretação mecanística adequada ou validação externa (Kapoor e Narayanan 2023).

### 10.7.3 Aprendizado Federado e IA Preservadora de Privacidade

Uma variante importante de IA híbrida e distribuída é aprendizado federado, que habilita treinamento de modelo através de múltiplas instituições sem centralizar dados sensíveis de paciente (Rieke et al. 2020). Em aprendizado federado, cada instituição participante treina um modelo local em seus próprios dados, e apenas parâmetros de modelo — ao invés de dados brutos — são comunicados a um servidor de agregação central. Essa arquitetura pode substancialmente expandir o conjunto de treinamento efetivo disponível a modelos de IA biomédica sem violar regulações de privacidade de paciente e é particularmente valiosa para doenças raras onde nenhuma instituição única tem casos suficientes para treinamento de modelo robusto. Contudo, aprendizado federado introduz seus próprios desafios técnicos, incluindo heterogeneidade de distribuições de dados através de sítios (o chamado dado "não-IID"), sobrecarga de comunicação e susceptibilidade a ataques de envenenamento de modelo adversário (Kairouz et al. 2021).

## 10.8 Desafios Persistentes

As seções anteriores identificaram uma constelação de desafios que cortam através de paradigmas de IA e domínios de aplicação biomédica. Tomados coletivamente, definem a fronteira do debate

contemporâneo.

**Interpretabilidade e compreensão mecanística.** A opacidade de modelos de aprendizado profundo permanece a barreira mais frequentemente citada à translação clínica. Enquanto métodos de interpretabilidade pós-hoc fornecem mitigação parcial, eles não completamente resolvem o problema subjacente: que muitos modelos de desempenho elevado não são projetados para serem mecanisticamente informativos. Avanços em arquiteturas intrinsecamente interpretáveis, bem como compreensão teórica do que redes neurais realmente computam, são necessários (Rudin 2019).

**Reprodutibilidade e rigor metodológico.** Uma proporção substancial de estudos publicados de IA biomédica foram mostrados como sofrendo de relato inadequado de detalhes metodológicos, práticas inapropriadas de divisão de dados, overfitting a conjuntos de dados de benchmark e falha em validar em coortes prospectivas independentes (Kapoor e Narayanan 2023; Wynants et al. 2020). O desenvolvimento de padrões de relatório específicos de campo — análogos a CONSORT para ensaios clínicos e STROBE para estudos observacionais — foi proposto como remédio parcial (Mongan et al. 2020).

**Viés, imparcialidade e equidade.** A sub-representação sistemática de populações diversas em conjuntos de dados de treinamento biomédico tem consequências diretas para a equidade e generalizabilidade de ferramentas clínicas derivadas de IA. Endereçar isso requer não apenas intervenções técnicas — como re-ponderação, desvio adversário e otimização constrangida por equidade — mas também mudanças estruturais às práticas de coleta de dados e infraestrutura de pesquisa (Obermeyer et al. 2019).

**Supervisão regulatória e validação clínica.** A paisagem regulatória para dispositivos habilitados por IA está em rápida evolução, mas lacunas significativas permanecem. Sistemas de aprendizado contínuo — que atualizam seus parâmetros em resposta a dados novos após implantação inicial — apresentam desafios regulatórios particulares, pois deriva de modelo pós-mercado pode tornar um dispositivo aprovado progressivamente menos seguro ou efetivo sem disparar re-avaliação (U.S. Food and Drug Administration 2023). A harmonização internacional de padrões regulatórios também é necessária pois dispositivos de IA médica estão crescentemente sendo implantados através de jurisdições.

**Tensão epistemológica.** Talvez mais fundamentalmente, há uma tensão epistemológica não resolvida entre o objetivo de desempenho preditivo e o objetivo de compreensão científica. Um modelo que acuradamente prediz resultados de paciente sem nenhuma interpretabilidade mecanística pode ser clinicamente útil mas cientificamente insatisfatório — e pode falhar silenciosamente em situações que diferem de sua distribuição de treinamento de maneiras que um modelo mecanístico poderia detectar. As ciências biomédicas historicamente priorizaram explicação causal sobre empirismo preditivo, e há debate legítimo a respeito de se a ampla adoção de IA de caixa preta representa uma partida dessa tradição epistêmica que deveria ser abraçada ou resistida (Lipton 2018).

## 10.9 Conclusão

Inteligência artificial catalisou avanços transformativos através de terapia gênica, terapia celular, design vacinal, biologia estrutural e biomedicina computacional mais amplamente. Os realizos empíricos documentados através de aprendizado supervisionado, aprendizado profundo, modelos generativos, inferência Bayesiana e modelos de linguagem coletivamente demonstram que IA não é meramente uma conveniência computacional mas um motor genuíno de descoberta científica,

capaz de identificar padrões, gerar hipóteses e acelerar fluxos de trabalho experimentais em escala e velocidade que transcendem a capacidade cognitiva humana sozinha.

Contudo, desempenho preditivo sozinho é insuficiente para integração científica e clínica sustentável. A comunidade biomédica enfrenta uma constelação de desafios não resolvidos — interpretabilidade, reprodutibilidade, viés, adequação regulatória e coerência epistemológica — que coletivamente demandam uma abordagem mais deliberada e criticamente rigorosa à adoção de metodologia de IA. Implantar modelos poderosos mas opacos sem infraestrutura de validação adequada, padrões de relatório ou arcabouços de governança risca uma forma de excesso metodológico que poderia em última instância minar a confiança em ciência assistida por IA.

O caminho para frente requer esforço coordenado através de múltiplas dimensões. Pesquisa técnica deve avançar arquiteturas interpretáveis, quantificação de incerteza principiada e métodos robustos para detecção de mudança distribucional. Validação clínica deve evoluir para priorizar avaliação prospectiva, multi-sítio em populações de paciente diversas sobre benchmarking retrospectivo em coortes de conveniência. Padrões de relatório devem mandar divulgação transparente de detalhes metodológicos suficientes para replicação independente. Arcabouços regulatórios devem se adaptar aos desafios distintos colocados por sistemas de aprendizado contínuo e suporte a decisão baseado em LLM. E a comunidade científica deve engajar-se em reflexão sustentada sobre o papel epistemológico de IA em investigação biomédica — não como substituto para compreensão mecanística, mas como complemento poderoso a ela.

O debate contemporâneo é portanto não se IA deveria ser usada em ciência biomédica, mas como deveria ser integrada na metodologia científica de maneira que preserve — e em última instância aprofunde — nossos padrões epistêmicos para o que significa compreender sistemas biológicos e fornecer cuidado clínico seguro, efetivo e equitativo.

**Roteiro de Revisão do Capítulo**

1. Aprendizado supervisionado: SVMs, florestas aleatórias, gradient boosting, redes feedforward; aplicações em SNPs patogênicos, predição de sítios de emenda, classificação de elementos regulatórios, design de vetores AAV, proteômica (espectrometria de massa).
2. Aprendizado não supervisionado: PCA, t-SNE, UMAP para scRNA-seq; WGCNA para redes de co-expressão; MOFA+, Seurat v4 para integração multimodal.
3. Debates: generalizabilidade (vieses de ascendência europeia em GWAS/escores poligênicos), calibração vs. AUROC, validação prospectiva rara (Obermeyer et al. 2019; Popejoy e Fullerton 2016).
4. Aprendizado profundo: CNNs (histopatologia, classificação de células hematopoéticas), LSTMs, Transformers; Enformer (expressão gênica a partir de sequência de DNA) (Avsec et al. 2021).
5. Interpretabilidade: "caixa preta"; métodos pós-hoc (mapas de saliência, LRP, SHAP, gradientes integrados) são instáveis (Adebayo et al. 2018); modelos intrinsecamente interpretáveis preferíveis em alto risco (Rudin 2019).
6. Modelos generativos: GANs (Goodfellow, 2014) para imagens histopatológicas e EHR sintéticos; VAEs para navegação de espaço químico em descoberta de fármacos; modelos de difusão para design de ligadores proteicos.
7. Design de proteína: AlphaFold2 (Jumper et al. 2021), ProtGPT2 (Ferruz et al. 2022), ESMFold; predição de epítopos vacinais; otimização de mRNA.
8. Dados sintéticos: resolvem escassez + privacidade (HIPAA/GDPR), mas amplificam vieses da fonte; regulação FDA em evolução.
9. Redes Bayesianas: incerteza principiada; DAGs para inferência causal (algoritmo PC, FCI); modelos híbridos probabilísticos–profundos (kernel profundo, processos neurais, redes neurais Bayesianas).
10. LLMs: GPT-4, BioGPT, Med-PaLM 2; alucinação = risco central; sem fundamentação epistêmica; mitigação via RAG + humano no circuito.
11. AutoML (AutoKeras, TPOT, H2O): democratiza ML mas caixa preta dupla; risco de vazamento de dados e irreproducibilidade. Aprendizado federado: treina sem centralizar dados; desafios = dados não-IID, envenenamento adversário.

# Referências


Adebayo, J., J. Gilmer, M. Muelly, I. Goodfellow, M. Hardt e B. Kim (2018). "Sanity checks for saliency maps". Em: *Advances in Neural Information Processing Systems* 31.

Argelaguet, R., D. Arnol, D. Bredikhin, Y. Deloro, B. Velten, J. C. Marioni e O. Stegle (2020). "MOFA+: A statistical framework for comprehensive integration of multi-modal single-cell data". Em: *Genome Biology* 21.1, p. 111. doi: 10.1186/s13059-020-02015-3.

Avsec, Ž., V. Agarwal, D. Visentin, J. R. Ledsam, A. Grabska-Barwinska, K. R. Taylor et al. (2021). "Effective gene expression prediction from sequence by integrating long-range interactions". Em: *Nature Methods* 18.10, pp. 1196–1203. doi: 10.1038/s41592-021-01252-x.

Baowaly, M. K., C. C. Lin, C. L. Liu e K. T. Chen (2019). "Synthesizing electronic health records using improved generative adversarial networks". Em: *Journal of the American Medical Informatics Association* 26.3, pp. 228–241. doi: 10.1093/jamia/ocy142.

Becht, E., L. McInnes, J. Healy, C. A. Dutertre, I. W. H. Kwok, L. G. Ng et al. (2018). "Dimensionality reduction for visualizing single-cell data using UMAP". Em: *Nature Biotechnology* 37.1, pp. 38–44. doi: 10.1038/s41587-018-0007-x.

Berry, S. M., B. P. Carlin, J. J. Lee e P. Müller (2010). *Bayesian Adaptive Methods for Clinical Trials*. CRC Press.

Choudhury, M., A. J. Deans, D. R. Candland e T. L. Deans (2025). "Advancing cell therapies with artificial intelligence and synthetic biology". Em: *Current Opinion in Biomedical Engineering*.

Danaeifar, M. e A. Najafi (2025). "Artificial intelligence and computational biology in gene therapy: A review". Em: *Biochemical Genetics*.

Elnaggar, A., M. Heinzinger, C. Dallago, G. Rehawi, Y. Wang, L. Jones et al. (2022). "ProtTrans: Toward understanding the language of life through self-supervised learning". Em: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 44.10, pp. 7112–7127. doi: 10.1109/TPAMI.2021.3120556.

Esteva, A., B. Kuprel, R. A. Novoa, J. Ko, S. M. Swetter, H. M. Blau e S. Thrun (2017). "Dermatologist-level classification of skin cancer with deep neural networks". Em: *Nature* 542.7639, pp. 115–118. doi: 10.1038/nature21056.

Ferruz, N., S. Schmidt e B. Höcker (2022). "ProtGPT2 is a deep unsupervised language model for protein design". Em: *Nature Communications* 13.1, p. 4348. doi: 10.1038/s41467-022-32007-9.

Garcez, A. d. e L. C. Lamb (2023). "Neurosymbolic AI: The 3rd wave". Em: *Artificial Intelligence Review* 56, pp. 12387–12406. doi: 10.1007/s10462-023-10448-w.

Ghahramani, Z. (2015). "Probabilistic machine learning and artificial intelligence". Em: *Nature* 521.7553, pp. 452–459. doi: 10.1038/nature14541.

Gomez-Bombarelli, R., J. N. Wei, D. Duvenaud, J. M. Hernandez-Lobato, B. Sanchez-Lengeling, D. Sheberla et al. (2018). "Automatic chemical design using a data-driven continuous representation of molecules". Em: *ACS Central Science* 4.2, pp. 268–276. doi: 10.1021/acscentsci.7b00572.

Goodfellow, I., J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair et al. (2014). "Generative adversarial nets". Em: *Advances in Neural Information Processing Systems* 27.

Google DeepMind (2023). "Gemini: A Family of Highly Capable Multimodal Models". Em.

Hao, Y., S. Hao, E. Andersen-Nissen, W. M. Mauck III, S. Zheng, A. Butler et al. (2021). "Integrated analysis of multimodal single-cell data". Em: *Cell* 184.13, pp. 3573–3587. doi: 10.1016/j.cell.2021.04.048.

He, X., K. Zhao e X. Chu (2021). "AutoML: A survey of the state-of-the-art". Em: *Knowledge-Based Systems* 212, p. 106622. doi: 10.1016/j.knosys.2020.106622.

Imani, S. et al. (2025). "Computational biology and artificial intelligence in mRNA vaccine design for cancer immunotherapy". Em: *Frontiers in Cellular and Infection Microbiology*.

Ji, Z., N. Lee, R. Frieske, T. Yu, D. Su, Y. Xu et al. (2023). "Survey of hallucination in natural language generation". Em: *ACM Computing Surveys* 55.12, pp. 1–38. doi: 10.1145/3571730.

Jumper, J., R. Evans, A. Pritzel, T. Green, M. Figurnov, O. Ronneberger et al. (2021). "Highly accurate protein structure prediction with AlphaFold". Em: *Nature* 596.7873, pp. 583–589. doi: 10.1038/s41586-021-03819-2.

Kadurin, A., S. Nikolenko, K. Khrabrov, A. Aliper e A. Zhavoronkov (2017). "drugGAN: An advanced generative adversarial autoencoder model for de novo generation of new molecules with desired molecular properties in silico". Em: *Molecular Pharmaceutics* 14.9, pp. 3098–3104. doi: 10.1021/acs.molpharmaceut.7b00346.

Kairouz, P., H. B. McMahan, B. Avent, A. Bellet, M. Bennis, A. N. Bhagoji et al. (2021). "Advances and open problems in federated learning". Em: *Foundations and Trends in Machine Learning* 14.1–2, pp. 1–210. doi: 10.1561/2200000083.

Kapoor, S. e A. Narayanan (2023). "Leakage and the reproducibility crisis in machine-learning-based science". Em: *Patterns* 4.9, p. 100804. doi: 10.1016/j.patter.2023.100804.

Kather, J. N., J. Krisam, P. Charoentong, T. Luedde, E. Herpel, C. A. Weis et al. (2019). "Predicting survival from colorectal cancer histology slides using deep learning: A retrospective multicenter study". Em: *PLOS Medicine* 16.1, e1002730. doi: 10.1371/journal.pmed.1002730.

Kusumoto, D., M. Lachmann, T. Kunihiro, S. Yuasa, Y. Kishino, M. Kimura et al. (2021). "Automated deep learning-based system to identify endothelial cells derived from induced pluripotent stem cells". Em: *Stem Cell Reports* 17.6, pp. 1421–1430. doi: 10.1016/j.stemcr.2021.08.007.

Langfelder, P. e S. Horvath (2008). "WGCNA: An R package for weighted correlation network analysis". Em: *BMC Bioinformatics* 9.1, p. 559. doi: 10.1186/1471-2105-9-559.

Lewis, P., E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal et al. (2020). "Retrieval-augmented generation for knowledge-intensive NLP tasks". Em: *Advances in Neural Information Processing Systems* 33, pp. 9459–9474.

Libbrecht, M. W. e W. S. Noble (2015). "Machine learning applications in genetics and genomics". Em: *Nature Reviews Genetics* 16.6, pp. 321–332. doi: 10.1038/nrg3920.

Lin, Z., H. Akin, R. Rao, B. Hie, Z. Zhu, W. Lu et al. (2023). "Evolutionary-scale prediction of atomic-level protein structure with a language model". Em: *Science* 379.6637, pp. 1123–1130. doi: 10.1126/science.ade2574.

Lipton, Z. C. (2018). "The mythos of model interpretability". Em: *Queue* 16.3, pp. 31–57. doi: 10.1145/3236386.3241340.

Litjens, G., T. Kooi, B. E. Bejnordi, A. A. A. Setio, F. Ciompi, M. Ghafoorian et al. (2017). "A survey on deep learning in medical image analysis". Em: *Medical Image Analysis* 42, pp. 60–88. doi: 10.1016/j.media.2017.07.005.

Lönnberg, T., V. Svensson, K. R. James, D. Fernandez-Ruiz, I. Sebina, M. Bodini et al. (2017). "Single-cell RNA-seq and computational analysis using temporal mixture modelling resolves Th1/Tfh fate bifurcation in malaria". Em: *Science Immunology* 2.9, eaal2192. doi: 10.1126/sciimmunol.aal2192.

Lundberg, S. M. e S. I. Lee (2017). "A unified approach to interpreting model predictions". Em: *Advances in Neural Information Processing Systems* 30.

Luo, R., L. Sun, Y. Xia, T. Qin, S. Zhang, H. Poon e T. Y. Liu (2022). "BioGPT: Generative pre-trained transformer for biomedical text generation and mining". Em: *Briefings in Bioinformatics* 23.6, bbac409. doi: 10.1093/bib/bbac409.

Marcus, G. e E. Davis (2019). "Rebooting AI: Building Artificial Intelligence We Can Trust". Em.

Martin, A. R., M. Kanai, Y. Kamatani, Y. Okada, B. M. Neale e M. J. Daly (2019). "Clinical use of current polygenic risk scores may exacerbate health disparities". Em: *Nature Genetics* 51.4, pp. 584–591. doi: 10.1038/s41588-019-0379-x.

Matek, C., S. Schwarz, K. Spiekermann e C. Marr (2019). "Human-level recognition of blast cells in acute myeloid leukaemia with convolutional neural networks". Em: *Nature Machine Intelligence* 1.11, pp. 538–544. doi: 10.1038/s42256-019-0101-y.

McInnes, L., J. Healy e J. Melville (2018). "UMAP: Uniform manifold approximation and projection for dimension reduction". Em: *arXiv preprint arXiv:1802.03426*.

Mongan, J., L. Moy e C. E. Kahn Jr. (2020). "Checklist for Artificial Intelligence in Medical Imaging (CLAIM): A guide for authors and reviewers". Em: *Radiology: Artificial Intelligence* 2.2, e200029. doi: 10.1148/ryai.2020200029.

Obermeyer, Z., B. Powers, C. Vogeli e S. Mullainathan (2019). "Dissecting racial bias in an algorithm used to manage the health of populations". Em: *Science* 366.6464, pp. 447–453. doi: 10.1126/science.aax4648.

OpenAI (2023). "GPT-4 Technical Report". Em: *arXiv preprint arXiv:2303.08774*.

Orre, L. M., M. Vesterlund, Y. Pan, T. Arslan, Y. Zhu, A. F. Woodbridge et al. (2019). "SubCellBarCode: Proteome-wide mapping of protein localization and relocalization". Em: *Molecular Cell* 73.1, pp. 166–182. doi: 10.1016/j.molcel.2018.11.035.

Pawłowski, J., S. Majchrowska e T. Golan (2022). "Generation of microbial colonies dataset with deep learning style transfer". Em: *Scientific Reports* 12.1, p. 3905. doi: 10.1038/s41598-022-07868-0.

Pearl, J. (2009). "Causality: Models, Reasoning and Inference". Em.

Popejoy, A. B. e S. M. Fullerton (2016). "Genomics is failing on diversity". Em: *Nature* 538.7624, pp. 161–164. doi: 10.1038/538161a.

Rieke, N., J. Hancox, W. Li, F. Milletarì, H. R. Roth, S. Albarqouni et al. (2020). "The future of digital health with federated learning". Em: *npj Digital Medicine* 3.1, p. 119. doi: 10.1038/s41746-020-00323-1.

Rudin, C. (2019). "Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead". Em: *Nature Machine Intelligence* 1.5, pp. 206–215. doi: 10.1038/s42256-019-0048-8.

Saelens, W., R. Cannoodt, H. Todorov e Y. Saeys (2019). "A comparison of single-cell trajectory inference methods". Em: *Nature Biotechnology* 37.5, pp. 547–554. doi: 10.1038/s41587-019-0071-9.

Singhal, K., S. Azizi, T. Tu, S. S. Mahdavi, J. Wei, H. W. Chung et al. (2023). "Large language models encode clinical knowledge". Em: *Nature* 620, pp. 172–180. doi: 10.1038/s41586-023-06291-2.

Skok Gibbs, C., C. A. Jackson, G. A. Saldi, A. Tjärnberg, A. Shah, N. De Veaux et al. (2022). "Leveraging causal graphs for blocking in randomized experiments". Em: *Cell Systems* 13.5, pp. 360–371. doi: 10.1016/j.cels.2022.03.005.

Spirtes, P., C. N. Glymour e R. Scheines (2000). *Causation, Prediction, and Search*. 2nd. MIT Press.

Sundararajan, M., A. Taly e Q. Yan (2017). "Axiomatic attribution for deep networks". Em: *Proceedings of the 34th International Conference on Machine Learning*, pp. 3319–3328.

Topol, E. J. (2019). "High-performance medicine: The convergence of human and artificial intelligence". Em: *Nature Medicine* 25.1, pp. 44–56. doi: 10.1038/s41591-018-0300-7.

U.S. Food and Drug Administration (2023). "Artificial Intelligence and Machine Learning (AI/ML)--Based Software as a Medical Device (SaMD) Action Plan". Em.

Walonoski, J., M. Kramer, J. Nichols, A. Quina, C. Moesel, D. Hall et al. (2018). "Synthea: An approach, method, and software mechanism for generating synthetic patients and the synthetic electronic health care record". Em: *Journal of the American Medical Informatics Association* 25.3, pp. 230–238. doi: 10.1093/jamia/ocx079.

Watson, J. L., D. Juergens, N. R. Bennett, B. L. Trippe, J. Yim, H. E. Eisenach et al. (2023). "De novo design of protein structure and function with RFdiffusion". Em: *Nature* 620.7976, pp. 1089–1100. doi: 10.1038/s41586-023-06415-8.

Wei, J., Y. Tay, R. Bommasani, C. Raffel, B. Zoph, S. Borgeaud et al. (2022). "Emergent abilities of large language models". Em: *Transactions on Machine Learning Research*.

Wieder, O., S. Kohlbacher, M. Kuenemann, A. Garon, P. Ducrot, T. Seidel e T. Langer (2020). "A compact review of molecular property prediction with graph neural networks". Em: *Drug Discovery Today: Technologies* 37, pp. 1–12. doi: 10.1016/j.ddtec.2020.11.009.

Wilson, A. G. e P. Izmailov (2020). "Bayesian deep learning and a probabilistic perspective of generalization". Em: *Advances in Neural Information Processing Systems* 33, pp. 4697–4708.

Wynants, L., B. Van Calster, G. S. Collins, R. D. Riley, G. Heinze, E. Schuit et al. (2020). "Prediction models for diagnosis and prognosis of COVID-19: Systematic review and critical appraisal". Em: *BMJ* 369, p. m1328. doi: 10.1136/bmj.m1328.

# Capítulo 11

# Aspectos Legais e Éticos no Uso de Dados Genômicos

## 11.1 Introdução

A revolução genômica contemporânea, caracterizada pela redução exponencial nos custos de sequenciamento e pelo aumento sem precedentes na disponibilidade de dados de DNA e proteoma em escala populacional, apresenta desafios legais, éticos e regulatórios profundos. O pesquisador contemporâneo em filogenômica e bioinformática opera em um contexto complexo marcado por múltiplos arcabouços regulatórios que regulam a coleta, armazenamento, compartilhamento e uso de dados genômicos. Esses arcabouços variam substancialmente entre jurisdições nacionais, frequentemente em tensão com normas científicas de abertura de dados e reprodutibilidade.

O presente capítulo examina os aspectos legais e éticos central para pesquisa genômica contemporânea, com ênfase particular na realidade brasileira. Cobrimos os tratados internacionais que estabelecem o direito soberano dos Estados sobre recursos genéticos dentro de suas fronteiras; a legislação brasileira específica regulando acesso a biodiversidade, proteção de dados pessoais e uso ético de animais em pesquisa; os marcos regulatórios internacionais que moldam o compartilhamento de dados genômicos; e as considerações éticas emergentes em pesquisa genômica com comunidades indígenas e tradicionais.

## 11.2 Marcos Internacionais: Convenção sobre Diversidade Biológica e Protocolo de Nagoia

### 11.2.1 A Convenção sobre Diversidade Biológica (1992)

A Convenção sobre Diversidade Biológica (CBD, *Convention on Biological Diversity*), adotada na Conferência das Nações Unidas sobre Meio Ambiente e Desenvolvimento no Rio de Janeiro em 1992 e em vigor desde dezembro de 1993, estabelece um arcabouço jurídico internacional para a conservação da diversidade biológica, o uso sustentável de seus componentes e a repartição justa e equitativa dos benefícios derivados da utilização dos recursos genéticos (United Nations 1992). A CBD reconhece a soberania dos Estados sobre os recursos genéticos em seus territórios e estabelece que o acesso a recursos genéticos é assunto de competência interna de cada parte contratante.

Os princípios-chave da CBD incluem: (1) reconhecimento da soberania estatal sobre recursos genéticos dentro de jurisdições nacionais; (2) direito dos Estados em legislar sobre acesso a recursos

genéticos dentro de seus territórios; (3) obrigação de facilitar acesso a recursos genéticos em condições mutuamente acordadas; e (4) obrigação de compartilhar benefícios derivados do uso de recursos genéticos de forma justa e equitativa. Esses princípios fundamentam toda a legislação subsequente sobre acesso a biodiversidade em nível global.

Para pesquisadores, a CBD implica que coleta de espécimes biológicos ou dados genômicos de organismos em um país requer consentimento prévio fundamentado (CPI, *Prior Informed Consent*) das autoridades competentes daquele país e resulta em obrigações de repartição de benefícios (United Nations 1992).

### 11.2.2 Protocolo de Nagoia sobre Acesso e Repartição de Benefícios (2014)

O Protocolo de Nagoia sobre Acesso e Repartição de Benefícios (*Nagoya Protocol on Access and Benefit Sharing*), adotado em 2010 e em vigor desde outubro de 2014, operacionaliza e fornece mecanismos específicos para implementação dos princípios estabelecidos pela CBD (United Nations Environment Programme 2014). O protocolo requer que os países signatários estabeleçam medidas legislativas, administrativas e políticas para: (1) garantir acesso a recursos genéticos condicionado a consentimento prévio fundamentado; (2) exigir divulgação da origem do recurso genético em solicitações de direitos de propriedade intelectual; (3) estabelecer requisitos para termos mutuamente acordados documentando as condições de acesso; e (4) monitorar o uso de recursos genéticos ao longo de cadeias de fornecimento.

Para biólogos e pesquisadores em genômica, o Protocolo de Nagoia significa que: dados genômicos de organismos coletados em países signatários não podem ser compartilhados livremente ou publicados sem atenção às obrigações de repartição de benefícios estabelecidas através de termos mutuamente acordados. Esse requisito pode impor restrições substantivas na publicação de dados e na prática científica aberta que historicamente tem sido a norma em genômica.

## 11.3 Legislação Brasileira: Biodiversidade e Proteção de Dados

### 11.3.1 Lei da Biodiversidade (Lei nº 13.123/2015) e SisGen

O Brasil, detentor de aproximadamente 13% da biodiversidade global e signatário tanto da CBD como do Protocolo de Nagoia, implementou a Lei da Biodiversidade (Lei nº 13.123, de 20 de maio de 2015) e, posteriormente, o Decreto nº 8.772/2016, que regulamentam o acesso a componentes da biodiversidade brasileira e a repartição de benefícios derivados desse acesso (Brasil 2015, 2016).

A Lei da Biodiversidade estabelece que qualquer acesso a componente da biodiversidade brasileira para fins de pesquisa científica, bioprospecção, conservação ou uso sustentável requer registro prévio no Sistema de Gestão do Patrimônio Genético (SisGen). O SisGen é um sistema eletrônico de informações que consolida dados sobre acesso a componentes do patrimônio genético brasileiro, produtos derivados e material reprodutivo obtido a partir de acesso, com o propósito de: (1) identificar a origem dos materiais genéticos; (2) rastrear o histórico de acesso; (3) facilitar a repartição de benefícios; e (4) cumprir com as obrigações do Brasil sob o Protocolo de Nagoia.

Pesquisadores em filogenômica devem se registrar no SisGen antes de acessar, coletar ou usar componentes da biodiversidade brasileira para fins de pesquisa. Isso inclui coleta de espécimes para sequenciamento, obtenção de tecidos de organismos de origem brasileira e análise de sequências genômicas derivadas de biodiversidade brasileira. A falta de registro no SisGen constitui infração

ambiental e pode resultar em multas de até R$ 200 mil, além de possível revogação de financiamentos de pesquisa e restrições a publicações (Brasil 2015).

Um aspecto crítico da Lei da Biodiversidade é que ela classifica o acesso a componentes da biodiversidade em três categorias: (1) pesquisa científica sem fins econômicos; (2) bioprospecção; e (3) uso sustentável. Pesquisadores em filogenômica frequentemente trabalham na categoria de pesquisa científica sem fins econômicos, mas se a pesquisa resultar em produto de interesse econômico (por exemplo, identificação de gene com aplicações biotecnológicas), a classificação pode mudar retroativamente, acionando obrigações adicionais de repartição de benefícios.

### 11.3.2 Lei Geral de Proteção de Dados (LGPD - Lei nº 13.709/2018)

A Lei Geral de Proteção de Dados Pessoais (LGPD), promulgada em agosto de 2018 e em vigência plena desde agosto de 2020, é a legislação brasileira de proteção de dados pessoais (Brasil 2018). Embora frequentemente considerada analogamente à Regulação Geral de Proteção de Dados (GDPR) da União Europeia, a LGPD é legislação brasileira específica que estabelece direitos e responsabilidades para o tratamento de dados pessoais no Brasil.

A LGPD é relevante para pesquisa genômica porque dados genômicos, quando associados a um indivíduo identificável ou potencialmente identificável, são classificados como dados pessoais sensíveis. A lei define dado pessoal como "informação relacionada a pessoa natural identificada ou identificável" (Brasil 2018). Dados genômicos são frequentemente considerados categoria especial de dado sensível porque podem revelar informações sobre saúde, predisposição genética a doenças ou ancestralidade.

Implicações da LGPD para pesquisa genômica incluem: (1) consentimento explícito requerido para coleta e processamento de dados genômicos pessoais; (2) direito dos indivíduos de acessar, corrigir e deletar seus dados genômicos; (3) obrigação de implementar medidas de segurança técnicas e administrativas para proteção de dados; (4) obrigação de relatar violações de dados dentro de determinado prazo; e (5) direito de indivíduos de se opor ao processamento de seus dados genômicos para fins específicos (Brasil 2018).

Para pesquisadores, a LGPD significa que qualquer projeto de pesquisa envolvendo dados genômicos de humanos brasileiros requer: consentimento fundamentado por escrito do doador ou seus representantes legais; política de privacidade transparente documentando como dados serão coletados, processados, armazenados e compartilhados; medidas de segurança apropriadas; e plano de retenção de dados documentando por quanto tempo dados serão mantidos.

### 11.3.3 Legislação Brasileira em Pesquisa com Animais

Para pesquisa em filogenômica de metazoários, legislação brasileira sobre uso ético de animais em pesquisa é também relevante. A Lei Arouca (Lei nº 11.794, de 8 de outubro de 2008) regulamenta o uso científico de animais em ensino e pesquisa no Brasil (Brasil 2008). A lei estabelece que: (1) toda instituição que realize atividades de ensino ou pesquisa com animais deve constituir uma Comissão de Ética no Uso de Animais (CEUA); (2) toda proposta de pesquisa envolvendo animais deve ser submetida à CEUA antes de iniciar; (3) a CEUA deve avaliar se a pesquisa é cientificamente adequada, eticamente justificada e utiliza técnicas que minimizam sofrimento animal.

Pesquisadores em filogenômica que coletam espécimes animais vivos, que realizam experimentos com animais ou que utilizam tecidos animais obtidos através de eutanásia para fins de coleta devem

submeter seus protocolos à CEUA da instituição. A Lei Arouca estabelece princípios de: (1) uso de alternativas a animais quando disponíveis; (2) redução do número de animais usados (princípio dos 3Rs: *Reduction, Replacement, Refinement*); (3) refinamento de técnicas para minimizar dor e sofrimento; e (4) eutanásia humanitária quando necessária (Brasil 2008).

## 11.4 Marcos Internacionais para Compartilhamento de Dados Genômicos

### 11.4.1 Infraestrutura Internacional de Sequências: GenBank, ENA e DDBJ

A infraestrutura internacional para dados de sequência genômica repousa sobre três bancos de dados centrais ligados em nível global que compartilham dados diariamente: o Banco de Dados Nacional de Centros de Informação em Biotecnologia (GenBank) mantido pelo Instituto Nacional de Saúde dos Estados Unidos (NIH), o Arquivo Europeu de Nucleotídeos (ENA) do Instituto Europeu de Bioinformática, e o Banco de Dados de DNA do Japão (DDBJ) (Coordinators et al. 2023; Harrison et al. 2023; Suzuki et al. 2023). Coletivamente, essa infraestrutura é referida como os Centros de Colaboração Internacional em Sequência de Nucleotídeos (INSDC).

Os bancos de dados INSDC operam sob princípio de acesso público imediato: sequências depositadas são publicamente acessíveis sem restrição dentro de 24 horas de submissão, a menos que o submissor requeira retenção temporária de até 4 meses (chamado de *hold period*). Esse sistema foi concebido para facilitar descoberta científica rápida e garantir reprodutibilidade de análises publicadas, permitindo que pesquisadores reanalysem dados subjacentes para trabalhos publicados.

Contudo, para dados genômicos de humanos que podem ser potencialmente identificadores, os bancos de dados INSDC implementaram restrições de acesso. O GenBank mantém um banco de dados separado para dados genômicos de humanos que requer consentimento do propositor para qualquer lançamento público, permitindo retenção indefinida de dados sensíveis enquanto mantendo a sequência disponível para pesquisadores aprovados através de um portal de acesso controlado.

Para pesquisadores em filogenômica que trabalham com metazoários, a implicação é que sequências de organismos não-humanos são rotineiramente depositas em INSDC com acesso público imediato. Contudo, se a pesquisa envolver dados genômicos de humanos ou de populações humanas específicas, o pesquisador deve estar ciente da LGPD brasileira, da GDPR europeia e de outras leis de proteção de dados que podem impor restrições ao compartilhamento público.

### 11.4.2 Políticas de Mandatos de Dados Abertos de Agências de Financiamento

Agências internacionais de financiamento de pesquisa têm adotado, de forma crescente, políticas mandatórias de compartilhamento de dados que requerem que pesquisadores financiados publicamente tornem seus dados disponíveis em repositórios públicos dentro de determinado prazo (frequentemente 6 meses a 2 anos após a publicação dos resultados). O Instituto Nacional de Saúde (NIH) dos Estados Unidos, o Conselho Europeu de Pesquisa (ERC) e o Conselho de Pesquisa da Engenharia e Ciências Físicas (EPSRC) do Reino Unido todos implementaram políticas de dados abertos.

No Brasil, agências de financiamento como a Fundação de Amparo à Pesquisa do Estado de São Paulo (FAPESP) e o Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq) têm adotado políticas similares, frequentemente em conformidade com as recomendações da UNESCO de

dados abertos para ciência (UNESCO 2021). O financiamento de pesquisa pela FAPESP ou CNPq agora tipicamente requer que dados brutos de sequenciamento sejam depositados em repositórios públicos reconhecidos e que análises sejam reproduzíveis através de compartilhamento de código e métodos.

Essas políticas têm implicações significativas para pesquisa em filogenômica: dados genômicos devem ser planejados para serem compartilháveis desde o design de estudo inicial. Para dados sensíveis (humanos, dados de populações indígenas), políticas de acesso controlado podem ser apropriadas, mas devem ser negociadas com agências de financiamento durante o desenvolvimento de proposta.

## 11.5 Considerações Éticas em Pesquisa Genômica com Comunidades Indígenas e Tradicionais

### 11.5.1 Direitos de Comunidades Indígenas e Biopirataria

O Brasil é signatário da Declaração das Nações Unidas sobre os Direitos dos Povos Indígenas (UNDRIP), que estabelece direitos coletivos de povos indígenas sobre seus conhecimentos tradicionais, recursos culturais e genéticos (United Nations 2007). A UNDRIP estabelece que povos indígenas têm o direito de: (1) consentir ou não consentir com a coleta e uso de sua biodiversidade associada; (2) controlar, proteger e preservar seus conhecimentos tradicionais; e (3) manter e fortalecer sua relação distintiva com terras e recursos.

Historicamente, recursos genéticos associados com conhecimentos tradicionais de comunidades indígenas foram coletados e utilizados em pesquisa e desenvolvimento comercial sem consentimento ou benefício para as comunidades indígenas, processo frequentemente denominado “biopirataria”. Casos notáveis incluem coleta de plantas medicinais e organismos da Amazônia brasileira utilizados em desenvolvimento farmacêutico sem participação ou benefício financeiro para comunidades indígenas.

A Lei da Biodiversidade brasileira estabelece que acesso a conhecimento tradicional associado a componente da biodiversidade requer consentimento prévio fundamentado da comunidade indígena ou população tradicional e resulta em obrigações de repartição de benefícios. O SisGen requer documentação explícita de consentimento quando pesquisa acessa conhecimento associado a componentes de biodiversidade.

Para pesquisadores em filogenômica, isso significa que se a pesquisa envolve coleta de organismos em terras indígenas, ou utiliza dados genômicos de organismos cujo conhecimento tradicional foi utilizado na pesquisa ou desenvolvimento, o pesquisador deve: (1) obter consentimento prévio fundamentado da comunidade indígena; (2) documentar consentimento e compartilhamento de benefícios no SisGen; (3) garantir que comunidades participem nas decisões sobre publicação e compartilhamento de dados; e (4) implementar mecanismos de repartição de benefícios, que podem incluir participação financeira ou colaboração acadêmica.

### 11.5.2 Princípios de Pesquisa Respeitosa com Comunidades Indígenas

Além de requisitos legais, há imperativo ético de realizar pesquisa com comunidades indígenas de forma respeitosa e participatória. Organizações como a Sociedade Internacional de Etnobiologia estabeleceram princípios éticos para pesquisa em etnobiologia, etnobotânica e etnogenômica (International Society of Ethnobiology 2006).

Esses princípios incluem: (1) reciprocidade — pesquisa deve beneficiar comunidades colaboradoras, não apenas pesquisadores; (2) transparência — comunidades devem compreender completamente objetivos e possíveis usos de pesquisa; (3) soberania — comunidades indígenas devem manter controle sobre seus dados genômicos e conhecimentos tradicionais; (4) respeito — pesquisadores devem respeitar protocolos culturais e direitos intelectuais indígenas; e (5) partilha de benefícios — pesquisadores devem compartilhar benefícios financeiros e não-financeiros com comunidades.

Na prática, isso significa que pesquisa envolvendo genômica de organismos associados com conhecimentos tradicionais indígenas deve incluir: (1) diálogo prévio com comunidades para explicar objetivos de pesquisa; (2) consentimento documentado obtido livremente sem coerção; (3) participação de membros da comunidade no desenho de pesquisa quando possível; (4) mecanismos para compartilhamento de resultados na linguagem da comunidade e em formatos acessíveis; e (5) repartição pré-acordada de benefícios se pesquisa resultar em desenvolvimentos comerciais.

## 11.6 GDPR Europeu e Proteção de Dados Genômicos Internacionais

### 11.6.1 Regulação Geral de Proteção de Dados (GDPR) e Sequências Genômicas

O Regulamento Geral de Proteção de Dados (GDPR), adotado pela União Europeia em 2016 e em vigência desde maio de 2018, é legislação de proteção de dados ainda mais rigorosa que a LGPD brasileira. O GDPR é particularmente relevante para pesquisa genômica porque: (1) classifica dados genômicos como categoria especial de dado pessoal exigindo consentimento explícito; (2) estabelece direito de acesso dos indivíduos aos seus dados genômicos; (3) estabelece direito de deletar dados ("direito ao esquecimento"); e (4) requer que qualquer processamento de dados genômicos seja proporcional e justificado (European Union 2018).

Para pesquisadores que trabalham com dados genômicos de indivíduos europeus, o GDPR impõe obrigações substantivas. Dados genômicos não podem ser transferidos para fora da União Europeia sem garantias de proteção de dados equivalentes às do GDPR. Pesquisadores precisam de legal basis para processamento de dados genômicos (tipicamente consentimento informado) e devem documentar esse legal basis em Avaliação de Impacto à Proteção de Dados (DPIA).

### 11.6.2 Implicações para Pesquisa Internacional em Genômica

Pesquisadores em filogenômica que trabalham em contexto internacional precisam estar cientes de que diferentes jurisdições implicadas em pesquisa podem ter diferentes requisitos. Um projeto colaborativo envolvendo coleta de dados genômicos no Brasil, processamento e análise na Europa e publicação em periódico americano pode estar sujeito simultaneamente a: Lei da Biodiversidade brasileira e SisGen; LGPD brasileira se dados forem de humanos brasileiros; GDPR europeu se análise ocorre em instituição europeia; e regulações de exportação de dados dos Estados Unidos se dados são transferidos para instituições americanas.

Conformidade com todos esses arcabouços exige planejamento deliberado desde o design de estudo. Recomendações incluem: (1) consultar pessoal de conformidade regulatória e conselheiros legais durante design de estudo; (2) documentar origem, consentimento e restrições de uso de todos os dados desde a coleta; (3) implementar medidas técnicas de segurança de dados apropriadas; (4) estabelecer acordos de transferência de dados internacionais se dados serão compartilhados entre

jurisdições; e (5) manter registro de todas as autoridades regulatórias envolvidas e seus requisitos específicos.

## 11.7 Acesso Aberto e Ciência Aberta em Genômica

### 11.7.1 Movimento de Dados Abertos e Ciência Aberta

Há movimento global crescente em direção ao que é frequentemente chamado de "ciência aberta" ou "dados abertos" — a prática de disponibilizar publicamente dados científicos brutos, código computacional e análises de maneira que qualquer pesquisador possa acessar, revisar e reutilizar esses dados e código sem restrição. A UNESCO publicou Recomendação sobre Ciência Aberta em 2021, endossada pelo Brasil, que estabelece princípios de abertura nos dados científicos (UNESCO 2021).

Para genômica, o movimento de dados abertos foi particularmente influente. O Projeto Mil Genomas Humanos, concluído em 2015, estabeleceu precedente poderoso ao tornar publicamente acessível, sem restrição, os dados genômicos de 2.500 indivíduos de populações globais diversas. Esse acesso aberto aos dados permitiu que milhares de pesquisadores utilizassem os dados para sua própria pesquisa, acelerando substancialmente progresso em genômica populacional e medicina de precisão (The 1000 Genomes Project Consortium 2015).

Contudo, o modelo de dados abertos para genômica está em tensão com legislação de proteção de dados pessoais como GDPR e LGPD, que impõem restrições ao compartilhamento público de dados genômicos de humanos identificáveis. A resolução dessa tensão continua em evolução, com discussões en voga sobre como implementar "acesso responsável" — um modelo intermediário no qual dados genômicos são publicamente acessíveis para pesquisa científica através de processos de autorização, mas com restrições ao compartilhamento comercial ou re-identificação (Global Alliance for Genomics and Health 2018).

### 11.7.2 Repositórios de Acesso Controlado e Modelos de Governança

Para resolver a tensão entre dados abertos e proteção de dados pessoais, infraestrutura de repositórios de acesso controlado e modelos de governança de dados foram desenvolvidos. A Global Alliance for Genomics and Health (GA4GH) estabeleceu padrões internacionais para federar bancos de dados genômicos de acesso controlado (Global Alliance for Genomics and Health 2018). Modelos como dbGaP (database of Genotypes and Phenotypes) do NIH norte-americano permitem pesquisadores depositar dados genômicos com restrições de acesso aplicadas, disponibilizando dados para pesquisa acadêmica qualificada mas não para o público geral ou uso comercial.

No Brasil, discussões estão em andamento sobre desenvolvimento de modelo similar que balanceie abertura científica com conformidade com LGPD e Lei da Biodiversidade. Recomendação emergente é que dados genômicos com potencial identificador devem ser disponibilizados através de modelo de acesso controlado no qual: (1) pesquisadores solicitam acesso ao repositório; (2) comitê de revisão de dados avalia se solicitante tem qualificações científicas e fins legítimos; (3) pesquisador concorda com termos de uso restringindo uso a fins de pesquisa não-comercial; e (4) dados são fornecidos em ambiente computacional seguro onde pesquisador pode executar análises mas não pode exportar dados brutos.

## 11.8 Conformidade Prática: Guia para Pesquisadores

### 11.8.1 Planejamento de Pesquisa com Considerações Legais e Éticas

Pesquisadores em filogenômica que planeiam projetos envolvendo dados genômicos devem implementar procedimentos para assegurar conformidade legal e ética. Um protocolo prático recomendado inclui:

1. **Identificar fontes de dados:** Documentar origem de todos os dados genômicos. São dados públicos de repositórios como GenBank? São dados coletados de novo? Se coletados de novo, em qual país? De qual organismo?

2. **Identificar requisitos regulatórios aplicáveis:** Baseado na origem dos dados, identificar quais leis aplicam. Se dados são de origem brasileira, Lei da Biodiversidade e SisGen aplicam. Se dados incluem humanos, LGPD brasileira ou GDPR europeu aplicam. Se dados incluem conhecimento tradicional indígena, UNDRIP e Lei da Biodiversidade aplicam.

3. **Obter consentimento e aprovação:** Se pesquisa envolve coleta de novo de organismos ou dados de humanos, obter consentimento apropriado. Submeter protocolo para aprovação de comitês éticos relevantes (CEUA para pesquisa animal, comitê de ética em pesquisa para dados de humanos).

4. **Registrar no SisGen (Brasil):** Se pesquisa envolve biodiversidade brasileira, registrar acesso no SisGen antes de iniciar coleta ou análise.

5. **Documentar conformidade:** Manter registro detalhado de todas as ações de conformidade — datas de consentimento, aprovações de comitês, registros SisGen.

6. **Planejar compartilhamento de dados:** Documentar como dados serão compartilhados. Se dados podem ser públicos, escolher repositório apropriado. Se dados são sensíveis, estabelecer acesso controlado. Documentar restrições de reutilização em metadados.

7. **Reportar conformidade em publicações:** Publicações devem incluir seção de ”Data Availability” documentando: origem dos dados, onde dados podem ser acessados, quaisquer restrições de acesso, conformidade com requisitos de consentimento e regulações.

### 11.8.2 Documentação de Métodos para Transparência

Além de conformidade legal, práticas de transparência metodológica são essenciais. Estudos genômicos devem documentar claramente:

- Origem de todos os dados, incluindo informações sobre sequenciamento (qual protocolo de captura, qual profundidade de cobertura, qual tecnologia de sequenciamento)
- Critérios de inclusão e exclusão de organismos ou amostras
- Informação sobre qualidade de dados (quantidade de dados faltantes, cobertura de sequência)
- Metodologia de análise, incluindo software utilizado e parâmetros
- Código computacional utilizado, depositado em repositório público (GitHub, GitLab) para reprodutibilidade

- Consentimento informado e aprovação ética se aplicável
- Contribuições de autores no formato CASRAI CRediT

## 11.9 Perspectivas Futuras: Harmonização Internacional e Dados Genômicos como Bem Comum

### 11.9.1 Esforços de Harmonização de Regulações Internacionais

Reconhecendo que regulações divergentes entre jurisdições prejudicam pesquisa científica internacional, há esforços em andamento para harmonizar requisitos legais e éticos em torno de dados genômicos. A GA4GH trabalha com autoridades regulatórias globais para desenvolver padrões compartilhados. A UNESCO estabeleceu recomendações sobre dados abertos para ciência. Discussões estão en voga em fóros internacionais sobre como balancear abertura científica com proteção de dados pessoais.

Uma questão crítica emergente é como tratar dados genômicos de comunidades indígenas e populações específicas como "bem comum global" — recurso que pertence à humanidade como um todo para fins de pesquisa — enquanto simultaneamente respeitando direitos soberanos de Estados nacionais e direitos coletivos de comunidades indígenas sobre seus recursos genéticos. Essa tensão permanece em grande medida não resolvida e deve ser central em discussões futuras de política científica internacional.

## 11.10 Conclusão

O pesquisador contemporâneo em filogenômica e bioinformática opera em contexto normativo complexo marcado por múltiplos arcabouços legais, frequentemente em tensão um com o outro. A Lei da Biodiversidade brasileira e o SisGen estabelecem requisitos para registro de acesso a biodiversidade. A LGPD brasileira protege dados pessoais, incluindo dados genômicos de humanos. Internacionalmente, o Protocolo de Nagoia estabelece direitos soberanos de Estados sobre recursos genéticos. A GDPR europeia impõe restrições ainda mais rigorosas a dados genômicos de europeus. Comunidades indígenas possuem direitos sob UNDRIP.

Simultaneamente, agências de financiamento requerem compartilhamento aberto de dados, repositórios internacionais como GenBank facilitam acesso público a sequências, e normas científicas valorizam reprodutibilidade e transparência que demandam compartilhamento amplo de dados e código.

A conformidade com esse aparato normativo complexo exige: (1) conhecimento dos múltiplos arcabouços legais aplicáveis; (2) planejamento cuidadoso desde o design inicial de projeto; (3) documentação detalhada de origem de dados, consentimento e conformidade; e (4) engajamento respeitoso e participatório com comunidades indígenas e tradicionais.

Pesquisadores que navegam com sucesso esse complexo normativo contribuem não apenas para progresso científico mas também para uma prática de ciência responsável que respeita direitos individuais, direitos comunitários, soberania nacional e o imperativo global de compartilhamento científico para o bem-estar humano. O caminho para frente requer colaboração internacional contínua para harmonizar regulações, desenvolvimento de infraestrutura de acesso responsável, e comprometimento da comunidade científica com práticas éticas.

**Roteiro de Revisão do Capítulo**

1. CBD (Rio, 1992, vigor 1993): soberania estatal sobre recursos genéticos; acesso requer consentimento prévio fundamentado (CPI); repartição justa de benefícios (United Nations 1992).
2. Protocolo de Nagoia (2010, vigor 2014): operacionaliza CBD; exige divulgação de origem em PI; termos mutuamente acordados; monitoramento ao longo da cadeia (United Nations Environment Programme 2014).
3. Lei da Biodiversidade (Lei 13.123/2015) + Decreto 8.772/2016: registro obrigatório no **SisGen** antes de acessar biodiversidade brasileira; multa até R$200 mil; reclassificação retroativa se pesquisa gerar produto econômico.
4. LGPD (Lei 13.709/2018, vigor 2020): dados genômicos humanos = dados pessoais **sensíveis**; consentimento explícito; direito de acesso, correção e deleção; relato obrigatório de violações.
5. GDPR (UE, vigor 2018): mais rigoroso que LGPD; proíbe transferência fora da UE sem garantias equivalentes; DPIA obrigatória; "direito ao esquecimento".
6. Lei Arouca (Lei 11.794/2008): uso ético de animais; CEUA obrigatória em toda instituição; princípios 3Rs (Reduction, Replacement, Refinement); eutanásia humanitária.
7. UNDRIP: direitos coletivos de povos indígenas sobre conhecimentos tradicionais e recursos genéticos; consentimento livre; biopirataria = acesso sem benefício.
8. INSDC (GenBank/ENA/DDBJ): acesso público em 24 h; hold de até 4 meses; acesso controlado para dados humanos identificadores (dbGaP).
9. Mandatos de dados abertos: NIH, ERC, EPSRC, FAPESP, CNPq; UNESCO 2021 endossada pelo Brasil.
10. GA4GH: padrões para federar bancos de dados genômicos de acesso controlado; modelo de "acesso responsável" (abertura com restrições a re-identificação/uso comercial).
11. Conformidade prática (7 passos): identificar fontes → requisitos regulatórios → consentimento/aprovação → registro SisGen → documentar conformidade → planejar compartilhamento → reportar em publicações (Data Availability).

# Referências


Brasil (2008). *Lei nº 11.794, de 8 de outubro de 2008. Estabelece procedimentos para o uso científico de animais*. Diário Oficial da União, Brasília, DF. Known as Lei Arouca.

Brasil (2015). *Lei nº 13.123, de 20 de maio de 2015. Regulamenta o acesso ao patrimônio genético, a proteção e o acesso ao conhecimento tradicional associado e a repartição de benefícios para conservação e uso sustentável da biodiversidade*. Diário Oficial da União, Brasília, DF.

Brasil (2016). *Decreto nº 8.772, de 11 de maio de 2016. Regulamenta a Lei nº 13.123, de 20 de maio de 2015*. Diário Oficial da União, Brasília, DF.

Brasil (2018). *Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD)*. Diário Oficial da União, Brasília, DF.

Coordinators, N. C. B. I. et al. (2023). "NaBi: An overview of GenBank and related resources". Em: *Nucleic Acids Research* 51.Database issue, pp. D121–D124. doi: 10.1093/nar/gkac1032.

European Union (2018). *Regulation (EU) 2016/679 on the protection of natural persons with regard to the processing of personal data and on the free movement of such data (General Data Protection Regulation)*. Official Journal of the European Union, in force 25 May 2018.

Global Alliance for Genomics and Health (2018). *Standards and Reference Implementations for Responsible Sharing of Genomic Data*. https://www.ga4gh.org/.

Harrison, P. W., H. Cochrane, I. Karsch-Mizrachi et al. (2023). "ENA at WEBServer: serving the EMBL-EBI data resources in partnership with NCBI". Em: *Nucleic Acids Research* 51.Database issue, pp. D111–D115. doi: 10.1093/nar/gkac1043.

International Society of Ethnobiology (2006). *International Society of Ethnobiology Code of Ethics*. Approved by the Council of the International Society of Ethnobiology.

Suzuki, Y., K. Kasuya, S. Okubo et al. (2023). "DDBJ Database of Japanese Databases: DDBJ in the global Data Sharing Age". Em: *Nucleic Acids Research* 51.Database issue, pp. D48–D53. doi: 10.1093/nar/gkac1039.

The 1000 Genomes Project Consortium (2015). "A global reference for human genetic variation". Em: *Nature* 526.7571, pp. 68–74. doi: 10.1038/nature15393.

UNESCO (2021). *Recommendation on Open Science*. General Conference of UNESCO, adopted 24 November 2021.

United Nations (1992). *Convention on Biological Diversity*. Signed at Rio de Janeiro, entered into force 29 December 1993.

United Nations (2007). *United Nations Declaration on the Rights of Indigenous Peoples*. General Assembly Resolution 61/295, adopted 13 September 2007.

United Nations Environment Programme (2014). *Nagoya Protocol on Access and Benefit-sharing*. Adopted in Nagoya, Japan, entered into force 12 October 2014.

# Agradecimentos

Este livro usou inteligência artificial (IA) para traduzir anotações originais do inglês para o português, para revisão gramatical e para produzir o código do projeto em LaTeX (Claude–Opus 4.6, Anthropic, https://claude.ai/chats). O projeto foi compilado no Overleaf (https://www.overleaf.com).